

Business Intelligence und Business Analytics (WDS224 · NOU)

Quelle: WDS224 - Business Intelligence (NOU).zip Foliensatz „Business Analytics und Business Intelligence – 2026 Q2 – Gesamt“ (190 Folien), Foliensatz „Monte Carlo Simulation“ (26 Folien), „Anleitungen Gesamt“ (SPSS-Schritt-für-Schritt-Anleitungen), 6 Excel-Datensätze. **Dozent:** Prof. Dr. Uwe Nölte, MBA **Durchgehender Datensatz:** *Airline Passengers* — monatliche Flugbuchungen Januar 1949 – Dezember 1960; Aufgabe: Prognose für 1961.

0. Prüfungsleistung (kein Klausur-, sondern Paper-Format!)

Sie sollen eine **selbstgewählte Fragestellung** anhand von Daten und unter Anwendung mathematisch-statistischer Methoden lösen.

Anforderungen:

- Passenden **Datensatz**, geeignete **Datenquelle** und geeignete **Fragestellung** suchen.
 - Daten aus beliebigen Bereichen (Umsatz-, Kosten-, Cashflow-Daten, Temperatur, Sozialprodukt, Zuschauerzahlen ...)
 - Quellen: firmenintern, extern, Statista, Bundesanzeiger, Forschungsinstitute, Kaggle, GitHub, Lehrbücher
- Eine oder mehrere **gelernte Methoden** anwenden: Regressionsanalyse · Zeitreihenanalyse · Monte-Carlo-Simulation · Logistische Regression · Clusteranalyse
- Daten passend **visualisieren**

Bewertungskriterien:

1. Originalität und Relevanz der Problemstellung
2. Originalität des Datensatzes und Erhebungsaufwand
3. **Methodenkomplexität und -vielfalt** (mehrere passend angewandte Methoden werden positiv bewertet)
4. Klarheit der Problemstellung und Darstellung des Nutzens

Formales: Abgabe **27. Juni 2026, 23:59 Uhr** in Moodle · **10–15 Seiten** · Regeln wie bei Projektarbeiten (PDF) · Datensätze als Excel hochladen · Bei firmeninternen Daten gilt ein Sperrvermerk (alternativ anonymisieren/transformieren, aber in sich schlüssig).

Software: SPSS (DHBW-Lizenz) · MS Excel (stets notwendig) · alternativ Python oder R.

Literatur: Camm et al., *Business Analytics*, 4th ed. (2021) · Seiter, M., *Business Analytics*, 3. Aufl. (2020) · Backhaus et al., *Fortgeschrittene Multivariate Analysemethoden*, 3. Aufl. (2015)

1. Grundbegriffe

1.1 Definitionen

Business Analytics ist „der **wissenschaftliche Prozess der Transformation von Daten in Wissen** zur Bestimmung von besseren betriebswirtschaftlichen Entscheidungen" (*Institute of Operations Research and Management Sciences*).

Business Intelligence bezeichnet **Technologien, Anwendungen, Prozesse und Praktiken**, die Unternehmen dabei unterstützen, Daten zu sammeln, zu analysieren, zu präsentieren und in wertvolle Informationen umzuwandeln. Hauptziel: Entscheidungsträgern helfen, **fundierte, datengestützte Entscheidungen** zu treffen und Geschäftsprozesse zu optimieren.

1.2 ★ BI vs. BA — der Unterschied

Business Intelligence (BI)	Business Analytics (BA)
Sammlung und Präsentation historischer Daten	fortgeschrittene Analyse von Daten
Einblicke in vergangene und aktuelle Leistungen	tieferer Einblicke, Muster, Zusammenhänge
Berichte, Dashboards, visuelle Darstellungen	statistische und quantitative Methoden, Prognosen
Nützlich zum Überwachen , Trends erkennen, Performance verfolgen	beantwortet spezifische Fragen , löst Geschäftsprobleme, identifiziert Chancen

1.3 ★ Die drei Analytics-Stufen

Strukturierung nach **Komplexität und zeitlicher Abfolge**. In der Praxis wandern Unternehmen häufig von einfachen zu komplexeren Anwendungen, sobald der Nutzen klar wird.

Descriptive Analytics → Predictive Analytics → Prescriptive Analytics
 Was ist passiert? Was wird passieren? Was sollen wir tun?

Descriptive Analytics — beschreibt die Vergangenheit

Methode	Erklärung	Beispiel
Data Queries (Datenabfragen)	Abrufen von Daten aus einer Datenbank	Abfrage der Kunden der letzten 12 Monate mit geordneten Produkten und Preisen, dargestellt mit Durchschnitt
Data Mining	systematisches Analysieren von Daten, um Muster zu erkennen	Analyse von Kundendaten: Gibt es Kundengruppen, die ähnliche Produkte ordern? → Clustering
Dashboards	Ansammlungen von Graphiken und Tabellen auf einer Seite , für schnelle Übersicht	Produktmanager lässt sich Kaufwahrscheinlichkeiten der Kundengruppen anzeigen und prüft Produktverfügbarkeit → Visualisation

Predictive Analytics — sagt die Zukunft voraus

Methode	Erklärung	Beispiel
Predictive Modeling	Entwicklung statistischer Modelle, um Entscheidungen vorherzusagen	Betrugserkennung; Wahrscheinlichkeit von Produktkäufen im Kundenmanagement → Classification
Forecasting	Vorhersage zukünftiger Ergebnisse , meist über Zeitreihen	Preisentwicklung eines Produkts anhand von Vergangenheitswerten → Forecasting
Simulation	Abbildung der Unsicherheit , die in Forecasts enthalten ist	Monte-Carlo-Simulation zur Abschätzung der Gewinnwahrscheinlichkeit für die Börsenkommunikation → Simulation

Prescriptive Analytics — empfiehlt Handlungen

Method e	Erklärung	Beispiel
Optimization	Generierung von Vorschlägen, die unter bestimmten Nebenbedingungen die besten Entscheidungen hervorbringen	Renditeprognose für Aktien/Anleihen → Anlagevorschläge unter Berücksichtigung der Risikopräferenzen
Rule-Based Models	Modelle, die nach bestimmten Regeln Entscheidungsvorschläge entwickeln	Bei 30 % Zahlungsausfallwahrscheinlichkeit: Entscheidungsmodell legt die Grenze für die Kreditvergabe unter oder über 30 %, um den Gesamtgewinn zu optimieren

1.4 Anwendungsfelder (Praxisbeispiele aus dem Kurs)

Feld	Beispiel	Methode
Financial Analytics	Banken nutzen Alter und Einkommensdaten, um Kundengruppen zu bilden	→ Clustering
Marketing Analytics	Wettanbieter bwin analysiert anhand von Charakteristika, wie hoch die Wechselwahrscheinlichkeit (Churn Rate) von Kunden ist	→ Classification
Health Care Analytics	Diskriminanzanalyse, Decision Trees und Random Forest helfen in der Medizin, die richtige Medikation zu finden	
Accounting Analytics	Bayer AG nutzt Predictive Analytics, um die Kosten von Kostenstellen vorherzusagen — Ziel: schnellere und präzisere Prognosen als die langwierigen aktuellen Verfahren	→ Forecasting
HR Analytics	Die Zieglerschen (Pflegeheim) nutzen Predictive Analytics, um Kündigungen von Mitarbeitern vorherzusagen	
Sports Analytics	„ Moneyball “ — Buch und Film: Das Baseballteam der Oakland Athletics bestimmt anhand von Regressionsanalysen das Potential neuer Spieler und deren Nutzen für das Team	

1.5 ★ Das Leitbeispiel: Bayer AG — Prognose von Kostenstellen

Betriebswirtschaftliches Problem: Die Erstellung von Kosten- und Umsatz-Forecasts dauert lang, ist zu unpräzise und zu teuer.

- Fehlende Präzision:** Die Kostenstellen verfehlten in der Budgetplanung regelmäßig die tatsächlichen IST-Werte.
- Langwierige, teure Prozesse:** Prognosen für über **3.400 Kostenstellen** in Deutschland verbrauchen viel Zeit und Aufwand.

Business-Analytics-Ansatz: Lange Zeitreihen zu Umsätzen und Kosten erheben, bereinigen und sortieren → mit Methoden der Zeitreihenanalyse neue Forecasts erstellen → Präzision mit den bestehenden Forecasts vergleichen.

Ergebnis (Modeling und Evaluation):

1. Die **Planwerte lagen 13 % über den IST-Werten** (z.B. durch Pufferbildung). Die Verfahren der Predictive Analytics lagen im Schnitt **nur 3 % über den IST-Werten**.
2. **Je nach Art der Kostenstelle waren unterschiedliche Predictive-Analytics-Verfahren vorteilhaft** — d.h. je nach Kostenstelle sollte ein anderes Verfahren verwendet werden.

TEIL A — FORECASTING

2. Zeitreihenanalyse: Grundlagen

Zeitreihe = zeitabhängige Folge von Datenpunkten. Wirtschaftliche Beispiele: Börsenkurse, Verkaufsmengen, Warenbestände. **Zeitreihenanalyse** = Disziplin, die sich mit der Analyse von Zeitreihen und der Vorhersage (Trends) ihrer künftigen Entwicklung beschäftigt. Sie ist eine **Spezialform der Regressionsanalyse**.

Typische Fragestellungen

Problemstellung	Fragestellung
Prognose	Können die Passagierzahlen einer Airline vorhergesagt werden?
Budgetierung	Wie können Kosten und Umsätze in der nächsten Periode besser prognostiziert werden?
Analyse der Vorratsbestände	Wie kann die Lagerhaltung optimiert werden, wenn nur die notwendigen Produkte bevorratet werden?

★ Die 5-Schritte-Vorgehensweise

1. Datenerhebung und Visualisierung
2. Modellformulierung
3. Schätzung des Modells
4. Erstellung von Prognosen
5. Prüfung der Prognosegüte

★ Die vier Zeitreihenkomponenten

Komponente	Symbol	Bedeutung
Basiskomponente / stationäre Komponente	α	Ausgangswert der Zeitreihe, das Level , von dem begonnen wird (Y-Achsenabschnitt)
Trendkomponente	β	langfristige Entwicklung der Größe Y; kann positiv oder negativ sein (Steigung)
Saisonale Komponente	γ	zyklische Schwankung , die im Zeitraum eines Jahres (Saison) wiederkehrt
Zufällige Komponente / Error Term	e	Fehler der Schätzung im Vergleich zum tatsächlichen Wert — soll minimiert werden

Die **Visualisierung** einer Zeitreihe dient insbesondere dazu, die Komponenten zu identifizieren, um dann das passende Modell zu schätzen — und der Hypothesenentwicklung für die Höhe von Basis-, Trend- und Saisonkomponente.

★ Additives vs. multiplikatives Modell

	Formel	Annahme
Additives Modell	$\hat{Y} = \alpha + \beta + \gamma + e$	Trend und Saisonkomponente bleiben konstant . Die Störgröße ist normalverteilt, im Zeitablauf konstant.
Multiplikatives Modell	$\hat{Y} = \alpha \times \beta \times \gamma \times e$	Trend und Saisonkomponente werden im Zeitablauf größer . Auch die Störgröße steigt.

(Eine Kombination von additiv und multiplikativ ist ebenfalls denkbar.)

Praxisanwendung am Airline-Datensatz: Steigender Trend erkennbar · steigende Varianz · Saisoneffekte in jedem Jahr ⇒ **multiplikatives Modell** bietet sich an.

★ Schätzperiode vs. Validierungsperiode vs. Testset

Set	Zweck
Trainingsset / Schätzperiode	Daten, anhand derer das Modell gebaut wird. Sollte mehrere Perioden umfassen, um möglichst viele Beobachtungen für Saisonalitäten abzudecken. ⚠ Ein mit dem Trainingsset erzeugtes Modell wird an denselben Daten evaluiert und ist damit immer besser , als wenn es mit neuen Daten getestet wird.
Validierungsset / Validierungsperiode	Die letzte Periode der Zeitreihe, für die noch Daten verfügbar sind und die einen kompletten Zyklus abdeckt. Unabhängiger Vergleichsmaßstab. ⚠ Wird das Validierungsset auch zum Vergleich mehrerer Modelle verwendet, ist das Ergebnis wieder gebiased .
Testset / Holdout-Set	Daten, die weder zum Training noch zur Selektion des besten Modells verwendet wurden. Ergebnis dient zur Abschätzung der zukünftigen Performance des besten Modells.

Backtesting: Die Schätzperiode wird so verkürzt, dass sie **nicht** den gesamten Zeitraum mit tatsächlichen Ergebnissen abdeckt. So können tatsächliche mit prognostizierten Ergebnissen verglichen werden. **Das Modell mit den geringsten Fehlermaßen im Backtesting ist das beste Modell.**

3. ★ Gütemaße der Prognose

Maß	Formel	Beschreibung
MAD / MAE (Mean Absolute Deviation / Error)	$\text{MAD} = (1/K) \cdot \sum$	$e_{\{T+k\}}$
MAPE (Mean Absolute Percentage Error)	$\text{MAPE} = (1/K) \cdot \sum$	$e_{\{T+k\}} / Y_{\{T+k\}}$
MSE (Mean Squared Error)	$\text{MSE} = (1/K) \cdot \sum e^2$	Mittlerer quadrierter Fehler — bestraft große Fehler stärker
RMSE (Root Mean Squared Error)	$\text{RMSE} = \sqrt{(1/K) \cdot \sum e^2}$	Wurzel des MSE — wieder in der Einheit der Zielgröße

Legende: e_t = Prognoseabweichung ($e_t = \hat{y}_t - y_t$) · T = Ende der Periode mit historischen Daten · K = Prognosehorizont (Anzahl prognostizierter Perioden) · $Y_{\{T+k\}}$ = tatsächlicher Wert der Periode

Bestimmtheitsmaß R^2

Definition: Gibt an, **wieviel Variation in den Daten durch ein Regressionsmodell erklärt werden kann.**

Gesamtstreuung (SST) = Erklärte Streuung (SSE) + Nicht erklärte Streuung (SSR)

$R^2 = \text{Erklärte Streuung} / \text{Gesamtstreuung}$

- **SST** = Summe der quadrierten Differenzen zwischen $\bar{y}$ (Mittelwert aller Beobachtungen) und der jeweiligen Beobachtung y_k
- **SSE** = Summe der quadrierten Differenzen zwischen geschätztem Wert $\hat{y}$ und Mittelwert $\bar{y}$

Interpretation: R^2 liegt stets **zwischen 0 und 1**. Je näher bei 1, umso kleiner der Schätzfehler und umso besser erklärt das Modell die tatsächlichen Werte.

Analyse der Residuen

Ein Zeitreihenmodell wird geschätzt, um **möglichst viele Informationen** aus den Zeitdaten zu generieren. Die Residuenanalyse prüft, ob in den Residuen **noch Informationen** enthalten sind. **Liegt in den Residuen noch Autokorrelation vor, ist das ein Hinweis auf eine suboptimale Modellspezifikation.**

Beispiel aus dem Kurs: Ein ARIMA(1,1,0)(1,1,0)-Modell zeigt im ACF der Residuen **keine** signifikanten Korrelationen → alle Informationen erfasst. Ein ARIMA(1,1,0)-Modell ohne Saisonmodellierung zeigt **starke Korrelationen bei Lag 2, 4, 6, 8 ...** → **fehlspezifiziert**.

4. Methode 1: Lineare Zeitregression

4.1 Grundprinzip

Deterministisches Modell: $Y = f(X) \rightarrow Y = b_0 + b_1 \cdot X$ **Stochastisches Modell:** $Y = f(X) + e \rightarrow Y = b_0 + b_1 \cdot X + e$

Ziel: Eine Regressionsgerade finden, die sich der empirischen Punkteverteilung möglichst gut anpasst. Dazu werden die **quadratierten Abweichungen (error terms)** zwischen den tatsächlich gemessenen und den geschätzten Werten **minimiert** (Methode der kleinsten Quadrate).

4.2 Die drei Modellstufen

Modell 1 — ohne Saisonkomponente

$$\hat{Y}_t = \alpha + \beta_1 \cdot t + e$$

- **Basiskomponente α** durch den Achsenabschnitt berücksichtigt ✓
- **Trendkomponente** durch den Steigungskoeffizienten β_1 berücksichtigt ✓
- **Saisonkomponente** ✗ **nicht** berücksichtigt

Modell 2 — mit Saisonkomponente (Dummy-Variablen)

$$\hat{Y} = \alpha + \beta_1 \cdot t + \gamma_1 \cdot q_1 + \gamma_2 \cdot q_2 + \gamma_3 \cdot q_3 + \dots + u$$

Dummy-Variablen nehmen den Wert **1** an, wenn eine Bedingung erfüllt ist, sonst **0**. $q_1 = 1$ für Monat 1, sonst 0 · $q_2 = 1$ für Monat 2, sonst 0 · ... · $q_{11} = 1$ für Monat 11, sonst 0 (Für 12 Monate werden 11 Dummies verwendet — eine Kategorie ist die Referenz.)

Bedeutung: Der Schätzwert $\hat{Y}$ wird um den Wert des jeweiligen Saisonkoeffizienten erhöht, sollte diese Saison vorliegen.

Modell 3 — mit Saisonkomponente und Kausalvariablen

$$\hat{Y} = \alpha + \beta_1 \cdot t + \gamma_1 \cdot q_1 + \gamma_2 \cdot q_2 + \dots + \beta_2 \cdot x_1 + \beta_3 \cdot x_2 + \dots + u$$

Kausalvariablen sind unabhängige Variablen (x), von denen man einen **logischen Einfluss** auf die untersuchte abhängige Variable erwartet. Sie werden per **Addition** integriert. *Beispiele:* x_1 = durchschnittliches Monatsgehalt · x_2 = durchschnittlicher Kerosinpreis

4.3 ★ Lag-Variablen

Eine **Lag-Variable** ist eine um eine oder mehrere Perioden **verzögerte** Variable. Sie wird genutzt, wenn sich der Einfluss der unabhängigen auf die abhängige Variable **nur mit Verzögerung** niederschlägt.

Kursbeispiel: Ein Bauunternehmen will den Einfluss der **Bauanträge** auf die **Aufträge pro Quartal** bestimmen. Die Anträge müssen erst bearbeitet werden → sie wirken sich erst z.B. einen Monat später auf den Auftragseingang aus.

$$\text{Auftragseingang}_t = \alpha + \beta_1 \cdot \text{Bauanträge}_{\{t-1\}}$$

⚠ **Ob es sinnvoll ist, eine Variable zu „laggen“, muss selbständig beurteilt werden.**

4.4 ★ Ergebnisübersicht der Zeitregression (Airline-Beispiel)

Modell	MAPE	MAD	R ²	Adj. R ²
Lineare Regression (ohne Dummies)	11,4 %	58,66	0,8518	0,8508
Lineare Regression mit Saisoneffekten	7,1 %	37,22	0,9559	0,9518
Lineare Regression mit Saisoneffekten und Kausalvariablen	6,7 %	34,99	0,9644	0,9608

Interpretation: Die Bestimmtheitsmaße sind beim Modell mit Dummies deutlich besser, nahezu perfekt. In beiden Modellen sind Zeiteffekte signifikant; im Modell mit Dummies werden auch die **Saisoneffekte signifikant**. Das Modell mit Saison-Dummyvariablen kann den Zeitverlauf fast perfekt nachbilden. Mit Kausalvariablen wird es noch etwas besser.

Koeffizienten-Interpretation: Schnittpunkt $87,03 \cdot \beta_1 = 2,664 \Rightarrow$ **mit jedem abgelaufenen Monat steigt die Anzahl der Passagiere um 2,664 Einheiten** (bzw. 2,564 im Basismodell).

4.5 Prognoseerstellung

Kernziel ist neben der Schätzung des Zusammenhangs die **Erstellung von Prognosen für spätere Perioden**. Dazu müssen lediglich die Werte für die Zeit, die Dummy-Variablen und evtl. die Kausalvariablen in das geschätzte Modell **eingesetzt** werden.

5. Methode 2: Smoothing Methods (Glättungsverfahren)

5.1 Naive Forecast

	Inhalt
Idee	Die naive Prognose ist einfach der letzte verfügbare Wert der Zeitreihe.
Formel	$\hat{y}_{t+1} = y_t$
Probleme	Keine Berücksichtigung von Trends · keine Berücksichtigung von Saisoneffekten · für lange Perioden ungeeignet, da immer nur der letzte tatsächliche Wert verwendet wird
Beste Nutzung	stabile Zeitreihen mit wenig Schwankungen · als Vergleichswert (Benchmark) für andere Prognoseverfahren

Beispiel: $t=1: y=6 \cdot t=2: y=8$, Forecast=6 · $t=3: y=12$, Forecast=8 · $t=4: y=17$, Forecast=12

5.2 Simple Average (Einfacher Durchschnitt)

	Inhalt
Idee	Verwendet alle verfügbaren Vergangenheitsdaten zur Schätzung der nächsten Periode
Formel	$\hat{y}_{t+1} = (y_t + y_{t-1} + \dots + y_{t-n}) / t$
Vorteil	Einfachheit · Daten verfügbar
Nachteil	Trends werden nur langsam berücksichtigt · keine Saisoneffekte · weiter entfernte Prognosen nicht möglich (bzw. nur unter Verwendung vorheriger Prognosen → langsame Glättung)

Beispiel: $t=1: y=6 \cdot t=2: y=8$, Forecast=7 · $t=3: y=12$, Forecast=8,66 · $t=4: y=17$, Forecast=10,75

5.3 Moving Averages (Gleitende Durchschnitte)

Variante	Idee	Formel (Beispiel)
Trailing Moving Average (TMA)	Prognosewert = Durchschnitt eines Zeitfensters w , das direkt vor dem Prognosewert liegt. Werte gleich gewichtet .	$MA_t = (y_{t-1} + y_{t-2} + y_{t-3} + y_{t-4}) / 4 \quad (w = 4)$
Weighted Moving Average (WMA)	Werte im Zeitfenster werden unterschiedlich stark gewichtet — verwendet, wenn aktuellere Werte relevanter sind. Summe der Gewichte muss 1 ergeben .	$\hat{y}_{t+1} = 0,6 \cdot y_t + 0,3 \cdot y_{t-1} + 0,1 \cdot y_{t-2} \quad (w = 3)$

Nutzung: Moving Averages werden zur Prognose verwendet, **wenn kein Trend und keine Saisonalität vorliegen**, da beides im Modell nicht berücksichtigt wird.

5.4 ★ Simple Exponential Smoothing (SES)

Idee: Der Prognosewert ergibt sich aus **allen** Werten der Vergangenheit, deren Gewicht jedoch **exponentiell abnimmt**. Werte aus der näheren Vergangenheit erhalten mehr Bedeutung. Dieser Wert wird als **Level L_t** bezeichnet.

$$\hat{y}_{t+1} = \alpha \cdot y_t + \alpha(1-\alpha) \cdot y_{t-1} + \alpha(1-\alpha)^2 \cdot y_{t-2} + \dots$$

Der Smoothing-Parameter α :

- bestimmt die Gewichtung — **je höher α , desto mehr Gewicht erhalten die jüngeren Werte**
- α sollte zwischen **0 und 1** liegen
- ⚠ **Bei $\alpha = 1$ entspricht dies wieder der naiven Prognose**, da dann nur der letzte Wert die Basis bildet

Die drei Probleme des SES:

Problem	Erklärung	Lösung
1. Nur ein Prognosewert	Ab der zweiten Schätzperiode wird derselbe Wert verwendet → die Prognosewerte bilden eine Gerade	Methode eignet sich nur für Zeitreihen ohne Trend und Saisoneffekte
2. Wahl des Startwerts	Für die erste Periode existiert kein Prognosewert → ein Startwert Level 0 (I_0) muss vorgegeben werden	Regelmäßig wird der erste tatsächliche Wert genommen
3. Wahl des Smoothing-Parameters	Der optimale α ist der Wert, der die Schätzfehler minimiert	Trial-and-Error oder Optimierungsfunktion (in Excel verfügbar): I_0 und α werden so optimiert, dass die SSE (Sum of Squared Errors) minimiert werden

5.5 ★ Double Exponential Smoothing (Holt's Linear Method)

Idee: Es soll insbesondere ein **existierender Trend** in die Prognose aufgenommen werden. Sowohl die **Level-Komponente L_t** als auch eine **Trend-Komponente T_t** werden geglättet. Der Prognosewert ergibt sich **additiv** aus beiden.

Allgemeine Formel: $\hat{y}_{t+k} = L_t + k \cdot T_t$

Levelkomponente: $L_t = \alpha \cdot y_t + (1-\alpha) \cdot (L_{t-1} + T_{t-1})$

Trendkomponente: $T_t = \beta \cdot (L_t - L_{t-1}) + (1-\beta) \cdot T_{t-1}$

Legende: $\hat{y}_{t+k}$ = Prognosewert für Periode $t+k$ · L_t = Wert des Basislevels · T_t = Wert des Trends · k = Anzahl Perioden in der Zukunft

Logik der Levelkomponente: Bildet die Ausgangslage/den Startwert. Der **1. Term** ist der aktuell verfügbare Ist-Wert, gewichtet mit α . Der **2. Term** ist die letzte Schätzung der Level-Komponente (plus Trend), gewichtet mit $(1-\alpha)$.

Logik der Trendkomponente: Soll die Steigung der Ist-Werte abbilden. Der Trend ist nicht dauerhaft konstant, sondern ändert sich von Periode zu Periode. Der **1. Term** ist der aktuell geschätzte Trend (Veränderung der Levels), gewichtet mit β . Der **2. Term** ist die Trendschätzung der Vorperiode, gewichtet mit $(1-\beta)$.

β stellt dar, wie stark Änderungen im Trend erfasst werden. Je höher β , desto stärker fallen aktuelle Trendänderungen ins Gewicht.

Zielfunktion (Optimierung):

$$\min \sum_{k=1}^K (\hat{y}_{t+k} - y_{t+k})^2 \quad \text{über } \alpha, \beta$$

Intuitive Erklärung (Kurs): Statt nur den letzten Wert von Level und Trend zu nehmen, werden auch vorherige Level- und Trendkomponenten einbezogen — mit exponentiell abnehmenden Gewichten:

$$\begin{aligned} \text{Forecast}_{t+1} = & 0,9 \cdot \text{aktuelles Level} + 0,09 \cdot \text{Level(Vorperiode)} + 0,009 \cdot \text{Level(Vorvorperiode)} + \dots \\ & + 0,9 \cdot \text{aktueller Trend} + 0,09 \cdot \text{Trend(Vorperiode)} + 0,009 \cdot \text{Trend(Vorvorperiode)} + \dots \end{aligned}$$

(bei $\alpha = 0,9$)

⚠️ Prognoseerstellung: Ab der ersten Periode der Validierung werden Level und Trend **nicht mehr aktualisiert**, da keine tatsächlichen Werte mehr vorliegen. Es wird der **letzte verfügbare Level-Wert** verwendet und von einem **konstanten Trend** ausgegangen. → **Das Modell eignet sich daher nur für kurze Prognoseperioden.**

Kritische Analyse: DES funktioniert gut in Zeitreihen **mit Trend und ohne Saisoneffekte**. Durch die Glättung werden auch vergangene Informationen berücksichtigt.

5.6 ★ Triple Exponential Smoothing (Holt-Winters Method, ETS)

Idee: Alle drei Elemente — Level, Trend und **Saisonkomponente** — werden geglättet und in die Prognose aufgenommen. Da mit jeder neuen Periode ein Wert hinzukommt, erfolgt die Glättung permanent.

Additives Modell

$$\hat{y}_{t+k} = L_t + k \cdot T_t + S_{t+k-M}$$

$$L_t = \alpha \cdot (y_t - S_{t-M}) + (1-\alpha) \cdot (L_{t-1} + T_{t-1})$$

$$T_t = \beta \cdot (L_t - L_{t-1}) + (1-\beta) \cdot T_{t-1}$$

$$S_t = \gamma \cdot (y_t - L_t) + (1-\gamma) \cdot S_{t-M}$$

Multiplikatives Modell

$$\hat{y}_{t+k} = (L_t + k \cdot T_t) \cdot S_{t+k-M}$$

$$L_t = \alpha \cdot y_t / S_{t-M} + (1-\alpha) \cdot (L_{t-1} + T_{t-1})$$

$$T_t = \beta \cdot (L_t - L_{t-1}) + (1-\beta) \cdot T_{t-1}$$

$$S_t = \gamma \cdot y_t / (L_{t-1} + T_{t-1}) + (1-\gamma) \cdot S_{t-M}$$

Legende: S_t = Wert des Saisoneffekts · M = Anzahl der Saisoneffekte (z.B. 12 bei Monaten) · α = Glättungsparameter für Level · β = für Trend · γ = für Saison

★ Additiv oder multiplikativ?

- **Multiplikatives Modell:** besonders geeignet für Zeitreihen mit **steigenden oder fallenden** Saisonkomponenten
- **Additives Modell:** besser für Zeitreihen mit **konstanten** Saisonkomponenten

Optimierung: Die Glättungsparameter α , β , γ werden in einem **iterativen Verfahren** so gewählt, dass das Zielfehlermaß minimiert wird (Methode der kleinsten Quadrate). Als Zielfehlermaß wird i.d.R. der **MAPE** verwendet.

5.7 ★ Ergebnisübersicht Smoothing (Airline, Validierungsperiode 1960)

Modell	MAPE	R ² (adj)
Naive Forecast	14,3 %	—
Double Exponential Smoothing (Holt's Method)	12,3 %	92,0 %
Triple Exponential Smoothing (Holt-Winters, additiv)	2,6 %	98,8 %
Triple Exponential Smoothing (Holt-Winters, additiv, in Excel)	3,1 %	—
Triple Exponential Smoothing (Holt-Winters, multiplikativ)	2,1 % ★	99,1 %

⚠ Anmerkung zur Software

Die Ergebnisse sind **nicht immer identisch** zwischen XLSTAT, SPSS und anderen Programmen:

- Sie verwenden bei der Optimierung teilweise **andere Startwerte** oder **andere Optimierungskriterien** (z.B. RMSE oder MAE statt MAPE), die nicht bekannt sind.
- Da es **mehrere lokale Optima** geben kann, führt dies zu anderen α , β , γ und damit zu anderen Prognosen — manchmal besser, manchmal schlechter.

Empfehlung: Nutzen Sie in Ihrer Arbeit **eine** Methode. Versuche, identische Ergebnisse über verschiedene Programme zu erhalten, scheitern regelmäßig.

6. Methode 3: ARIMA-Modelle

★ Die 5-Schritte-Vorgehensweise

1. Problemstellung und Datensatz
2. Modellidentifikation
3. Modellschätzung
4. Modellevaluierung
5. Prognoseerstellung

6.1 Begriffe, Symbole, Abkürzungen

Abkürzung	Inhalt
AR	Autoregressiv
MA	Moving Average
t	Zeitindex, Periode (Monat, Tag, Jahr)
$\hat{y}_t$	Schätzung eines Wertes für Periode t
y_t	tatsächlicher Wert in Periode t
p	Anzahl der autoregressiven Komponenten
i / d	Anzahl der Differenzierungen
q	Anzahl der Moving-Average -Komponenten

6.2 ★ Lag-Variable, Korrelation, Autokorrelation, partielle Autokorrelation

Lag-Variable: eine Variable, deren Wert sich aus einem **vorhergehenden Wert** der Zeitreihe ergibt.

Woche	Umsatz	Lag_1	Lag_2
1	19		
2	21	19	
3	17	21	19
4	19	17	21

In Woche 4: $y_4 = 19$, $Lag(1) = 17$ (y_{4-1}), $Lag(2) = 21$ (y_{4-2}).

Korrelation

- Zusammenhang zwischen **zwei Variablen**; Stärke gemessen mit den Korrelationskoeffizienten von **Pearson** oder **Spearman**.
- Wird i.d.R. in **Querschnittsdaten** verwendet.
- ★ **Die Korrelation ist die Wurzel des Bestimmtheitsmaßes R^2 .**
- Werte immer zwischen **-1 und +1**. +1 = beide Variablen gehen in dieselbe Richtung im gleichen Verhältnis; -1 = eine steigt im gleichen Verhältnis, wie die andere fällt.

Autokorrelation

Definition: Korrelation zwischen einem **aktuellen Wert und vergangenen Werten** (Variable und Lag-Variable). Wird bei **Längsschnittdaten** verwendet, um zu prüfen, ob man aus Vergangenheitsdaten auf zukünftige Werte schließen kann.

Berechnungsformel:

$$r_k = \frac{\sum_{t=k+1}^N (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^N (Y_t - \bar{Y})^2}$$

N = Anzahl Beobachtungen · k = Anzahl Lags · Y_t = tatsächlicher Wert · $\bar{Y}$ = Durchschnitt aller Beobachtungen

⚠ In Excel gibt es **keine vordefinierte Funktion** für die Autokorrelation.

Kursbeispiel Neuprodukteverkäufe (15 Monate): Korrelation Lag 1 = **0,832** · Korrelation Lag 2 = **0,656** → Lag 1 und Lag 2 sind stark mit den aktuellen Daten korreliert. *Ökonomisch sinnvoll: Kunden kaufen die Produkte, finden sie gut, kaufen wieder; neue Kunden kommen hinzu.*

Gegenbeispiel (keine Autokorrelation): Die Zufallszahl beim **Roulette** — ob zuvor die 36, die 17 oder die 4 gefallen ist, hat keine Auswirkung auf den nachfolgenden Lauf der Kugel.

Autokorrelation bei weiter entfernten Lags: Liegt auch bei **Saisonalitätseffekten** vor. Sind die Besucherzahlen eines Hotels immer im August besonders hoch, sind die Daten in **Lag 12** stark korreliert.

★ Partielle Autokorrelation

Definition: Misst die Korrelation zwischen dem Wert an einem Datum und einem definierten Lag-Wert **unter Ausschaltung der Effekte der dazwischen liegenden Zeitpunkte.**

Warum wichtig? Bei einer konstant steigenden Kurve sind in der Autokorrelation **sämtliche** Punkte stark korreliert — auch mit sehr weit zurückliegenden Werten. Zur guten Vorhersage braucht man aber **nur den letzten verfügbaren Wert**. Die davor liegenden Punkte sind **nutzlos**, da der Haupteffekt durch den letzten Wert getrieben wird. Daher werden im PACF die **indirekten Effekte** eliminiert.

Plot	Zeigt an
ACF-Plot (Autocorrelation Function)	wie stark die Vormonatswerte (Lag 1, Lag 2, ...) mit dem aktuellen Wert korreliert sind. Bei konstantem Trend sind die Autokorrelationen i.d.R. sehr hoch.
PACF-Plot (Partial ACF)	wieviel Nutzen/Information in weiter entfernten Korrelationen liegt. Ist die Korrelation mit dem Vormonat sehr hoch, hat die Korrelation mit dem Wert vor 2 Monaten so gut wie keinen Nutzen mehr.

📊 Bratwurst-Beispiel:

Effekt	Erklärung
Effekt 1: Direkter Effekt der Vorperiode (Autokorrelation 1)	Es ist ein Trend erkennbar. Wenn man den Wert der Vorperiode hat, kann man auf den Wert der aktuellen Periode schließen.
Effekt 2: Indirekter Effekt der Vor-Vorperiode (Partielle Autokorrelation 2)	Kennt man den Wert der Vorperiode, braucht man den der Vorvorperiode nicht — es sei denn , dort sind wichtige Informationen enthalten (z.B. Saisoneffekte), die nicht schon in der Autokorrelation 1 enthalten sind. Der Einfluss einer früheren Periode auf heute unter Abzug des Einflusses einer nähergelegenen Periode.

→ Fazit im Beispiel: Das Modell sollte **nur den ersten Vorperiodenwert** einbeziehen: $\hat{y}_t = \alpha \cdot y_{t-1}$

6.3 ★ Stationarität

Um ARIMA-Modelle anwenden zu können, muss die Zeitreihe stationär sein, da sonst keine statistischen Schätzungen bzw. sinnvollen Interpretationen möglich sind.

Eine Zeitreihe ist stationär, wenn:

1. sie einen **konstanten Durchschnittswert** hat (constant mean, d.h. **ohne Trendkomponente**) und
2. eine **konstante Varianz** hat.

6.4 Schritt 1 — Die AR-Komponente (autoregressiv)

Definition: In einem autoregressiven Modell wird der Prognosewert **aus Werten der Vergangenheit (Lag-Variablen)** geschätzt.

$$\hat{y}_t = \beta_0 + \beta_1 \cdot y_{t-1} + \varepsilon_t \quad (\text{AR}(1)\text{-Modell})$$

Es können mehr Lag-Variablen einbezogen werden, wenn die **partiellen Autokorrelationen hoch** sind → AR(2), AR(3) etc.

Hier zeigt sich die **Ähnlichkeit zu den Smoothing-Modellen**, die auch vergangene Werte einbeziehen und gewichten.

★ Durbin-Watson-Test (Test auf Autokorrelation 1. Ordnung)

Vorgehen: Zuerst eine normale Regression mit Zeit als erklärender Variable → dann die **Residuen** analysieren: Ist die Korrelation zwischen zwei aufeinanderfolgenden Residuen ungleich null?

- **H₀:** Es liegt **keine** Autokorrelation vor
- **H₁:** Es liegt Autokorrelation vor

Wert der Teststatistik d	Korrelation	Bedeutung
d = 2	0	Keine Autokorrelation
d = 0	+1	Perfekte positive Autokorrelation
d = 4	-1	Perfekte negative Autokorrelation

Liegt Autokorrelation vor, sollte ein AR-Modell angewendet werden.

★ Box-Ljung-Test

Prüft die **Nullhypothese, dass alle Autokorrelationskoeffizienten bis zu einem bestimmten Lag k gleich null sind**, gegen die Alternativhypothese, dass mindestens einer von null verschieden ist.

Interpretation im Kursbeispiel: Die Nullhypothese muss nur für Lag(1) verworfen werden ⇒ Autokorrelation mit Lag(1) liegt vor, diese Lag-Variable sollte einbezogen werden ⇒ $\hat{y}_t = \beta_0 + \beta_1 \cdot y_{t-1} + \varepsilon_t$

★ Identifikation über ACF/PACF

Ein AR-Modell liegt vor, wenn

- im **ACF-Chart** ein **exponentielles Fallen** der Autokorrelationen festgestellt werden kann **und**
- im **PACF-Chart** lediglich **eine oder zwei signifikante** partielle Autokorrelationen vorliegen.

Interpretation: ACF → aktuelle Werte stark von der ersten Vergangenheitsperiode abhängig, Autokorrelation liegt vor. PACF → nur Lag 1 enthält Informationen; weiter entfernte Werte enthalten keine. ⇒ **AR(1)-Modell**

6.5 Schritt 2 — Die Differenzierungskomponente (I)

Tests auf Stationarität

Test	H ₀	H ₁	Ziel
ADF-Test (Augmented Dickey-Fuller)	Die Zeitreihe ist nicht stationär (autokorreliert mit $r = 1$; sie hat eine Einheitswurzel / Unit Root)	Die Zeitreihe ist stationär (keine Einheitswurzel)	H₀ soll verworfen werden können → dann ist die Zeitreihe stationär und ARIMA anwendbar
KPSS-Test	Die Zeitreihe ist stationär	Die Zeitreihe ist nicht stationär	H₀ soll <i>nicht</i> verworfen werden → dann kann Stationarität angenommen werden

⚠ **Die H₀ der beiden Tests sind genau umgekehrt!**

Differenzierung (das „I“ in ARIMA)

Bei Vorliegen einer **Trendkomponente** wird die **Differenzierung (Integration)** durchgeführt: Die **Differenzen von zwei Zeitpunkten** werden berechnet und als neue Zeitreihe aufgebaut.

⚠ **Die Daten sind dann nicht mehr leicht interpretierbar.** In der Praxis handelt es sich entweder um Daten mit **keiner (d=0)** oder **einfacher (d=1)** Differenzierung. **Bei notwendiger höherer Differenzierung sind ARIMA-Modelle in der Regel ungeeignet.**

6.6 Schritt 3 — Die MA-Komponente (Moving Average)

Definition und Logik: Die MA-Komponente stellt im ARIMA-Modell das **kurzfristige Gedächtnis** dar. Sie wird berechnet als **Prognosefehler** zwischen Schätzwert und tatsächlichem Wert der aktuellen Periode:

$$\alpha_t = \hat{y}_t - y_t$$

Reines MA(1)-Modell:

$$\hat{y}_{t+1} = \beta_0 + \beta_1 \cdot \alpha_t + \varepsilon_t$$

bzw. in Kursnotation: $\hat{y} = \mu + \alpha \cdot e_{t-1}$

Interpretation: Der Prognosewert ergibt sich aus einem **konstanten Durchschnittswert μ** plus dem **Fehler der Prognose der Vorperiode e_{t-1}** , gewichtet mit einem Koeffizienten α . Im Moving-Average-Modell werden also **auch die Fehlerterme berücksichtigt** und die Prognose um den Fehler angepasst.

📊 **Bratwurst-Beispiel ($\mu = 10$, $\alpha = 0,5$):**

Periode	Prognose $\hat{y}$	Tat. Wert y	Error (e)
1	10	8	-2
2	9	10	+1
3	10,5	10,5	0
4	10	12	+2
5	11	12	+1

Die Prognose beginnt bei einem Startpunkt. Dann wird ein Prognosefehler gemacht. Dieser wird bei der nächsten Prognose geglättet und wieder einbezogen.

★ Wann sollte eine MA-Komponente ergänzt werden?

- wenn die Zeitreihenwerte **um eine Konstante fluktuieren, aber immer wieder zur Konstanten zurückkommen**, und
- das „Zurückkommen“ **nicht ruckartig**, sondern im **langsamen Verlauf** geschieht.

★ Identifikation über ACF/PACF:

Ein MA-Modell liegt vor, wenn

- im **ACF-Chart** **nur eine oder wenige signifikante** Autokorrelationen vorliegen **und**
- im **PACF-Chart** **mehrere signifikante** partielle Autokorrelationen vorliegen, **die abnehmen** („langsameres Zurückkommen“) **und zwischen negativ und positiv schwanken**.

Anzahl der MA-Komponenten = Anzahl der signifikanten Lags im **ACF-Chart**. Sollte grundsätzlich nur zwischen **0 und 2** liegen.

6.7 ★ Zusammenfassung: AR vs. MA erkennen

	ACF-Chart	PACF-Chart
AR-Modell	exponentielles Fallen der Autokorrelationen	nur eine oder zwei signifikante partielle Autokorrelationen
MA-Modell	nur eine oder wenige signifikante Autokorrelationen	mehrere signifikante, abnehmende , zwischen +/- schwankende partielle Autokorrelationen

6.8 Schritt 4 — SARIMA (saisonale Komponente)

ARIMA (p, d, q) (P, D, Q)_m

Parameter	Bedeutung
p	nicht-saisonale AR-Reihenfolge
d	nicht-saisonale Differenzierung
q	nicht-saisonale MA-Reihenfolge
P	saisonale AR-Reihenfolge
D	saisonale Differenzierung
Q	saisonale MA-Reihenfolge
m	Zeitspanne des sich wiederholenden saisonalen Musters (z.B. 12)

Finale Modellgleichung ARIMA(1,1,1):

$$\hat{y}_t = \beta_0 + \beta_1 \cdot y_{t-1} + \beta_2 \cdot \varepsilon_{t-1} + \varepsilon_t$$

↑ Autoregressive Komponente
↑ Moving-Average-Komponente

Mit zusätzlicher Saisonkomponente: **SARIMA(1,1,1)(1,1,1)₁₂**

Im Kurs geschätzte Vergleichsmodelle: ARIMA(1,1,1) · SARIMA(0,1,1)(0,1,1) · SARIMA(1,1,1)(1,1,1)

6.9 Modellschätzung — OLS vs. Maximum Likelihood

Method e	Prinzip	Einschränkung
OLS (Ordinary Least Squares)	Der Error-Term zwischen Schätzfunktion und tatsächlichem Wert wird minimiert, indem die Koeffizienten entsprechend gewählt werden	⚠ Bei Vorliegen einer MA-Komponente nicht ohne weiteres verwendbar , da die Moving-Average-Komponente noch nicht vorliegt, wenn das Modell geschätzt wird — sie muss quasi während der Modellentwicklung geschätzt werden (ähnlich der Solver-Funktion)
Maximum-Likelihood (ML)	Die Wahrscheinlichkeit maximieren , dass die Koeffizienten richtig gewählt sind	Sehr ähnlich zu OLS; gibt unter bestimmten Bedingungen dieselben Ergebnisse

7. Methode 4: Logistische Regression

7.1 Definition und Ziel

Bei der **logistischen Regressionsanalyse** wird die **Wahrscheinlichkeit der Zugehörigkeit einer Beobachtung zu einer Gruppe** (abhängige Variable) in Abhängigkeit von einer oder mehreren unabhängigen Variablen bestimmt. Ziel ist i.d.R. die Vorhersage einer **kategorialen (binären)** Variable. Da zur Schätzung der Eintrittswahrscheinlichkeiten auf die **s-förmige logistische Funktion** zurückgegriffen wird, spricht man von logistischer Regression.

7.2 Typische Fragestellungen

Fragestellung	Bereich	Abhängige Variable	Unabhängige Variablen
Wird ein neuer Kreditnehmer seinen Kredit zurückzahlen?	Banking, Finance	0 = Default, 1 = Rückzahlung	EK-Quote, Cash Flow, Liquiditätsgrad
Wird ein Online-Kunde das Produkt kaufen?	Marketing	0 = Kein Kauf, 1 = Kauf	Geschlecht, Einkommen
Welches Rating wird unser Unternehmen erhalten?	Finance	0 = AAA, 1 = AA, 2 = A, ... 9 = D	EK-Quote, Cash Flow, Liquiditätsgrad
Wird die Maschine ausfallen?	Produktion	0 = Ausfall, 1 = Kein Ausfall	Wartungsintensität, Produktionszeit in h, Hersteller

7.3 ★ Terminologie

Unterscheidung	Erklärung
Binäre vs. Multinomiale logistische Regression	Binär: nur 2 Zustände der abhängigen Variable möglich (Kauf: Ja/Nein). Multinomial: mehrere Zustände (10 Rating-Klassen).
Einfache vs. Multiple logistische Regression	Einfach: eine unabhängige Variable. Multiple: 2 oder mehr .

7.4 ★ Die 5-Schritte-Vorgehensweise

1. Modellformulierung und Logik
2. Schätzung der logistischen Regressionsfunktion
3. Nutzung des Modells
4. Prüfung des Gesamtmodells
5. Prüfung der Merkmalsvariablen

7.5 Die Logik im Detail

Ausgangsproblem: Wahrscheinlichkeiten können nur im Wertebereich **(0;1)** liegen. Daher ist die **normale lineare Regression nicht angebracht** — dort könnten y-Werte auch **größer als 1** geschätzt werden.

1. Die logistische Funktion:

$$p = e^z / (1 + e^z) = 1 / (1 + e^{-z})$$

Die logistische Funktion ist die **Verteilungsfunktion der Normalverteilung**. Die Ergebnisse p liegen daher immer zwischen 0 und 1 und stellen die **Eintrittswahrscheinlichkeit** dar. *Beispiel: Bei einem z-Wert von ca. 1 ergibt sich eine Kaufwahrscheinlichkeit von ca. 70 %.*

2. Aufstellung der Linearkombination:

$$z(x) = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \dots + \beta_J \cdot x_J$$

Jede Beobachtung erhält einen **z-Wert**, der anschließend in die logistische Funktion eingesetzt wird → jede Beobachtung erhält eine **Eintrittswahrscheinlichkeit**.

3. Minimierung der Error-Terms: Die Differenz zwischen tatsächlichem Ergebnis und geschätzter Wahrscheinlichkeit soll minimiert werden. *Beispiel: Person 1 hat gekauft (100 %), Schätzung war 70 % → Differenz 30 %. Person 2 hat nicht gekauft (0 %), Schätzung war 10 % → Differenz 10 %.*

4. Wahl der Parameter: Durch optimale Wahl von $b_0, b_1, \dots, b_n$ kann die logistische Funktion **gedreht bzw. verschoben** werden, sodass sie sich der empirischen Punktwolke annähert.

5. ★ Maximum-Likelihood-Methode:

Prinzip: „Bestimme die Schätzwerte der unbekannten Parameter der Linearkombination so, dass die realisierten Daten **maximale Plausibilität (Likelihood)** haben, d.h. sich maximal nah an die tatsächlichen Realisationen annähern.“

$$LL(a,b) = \sum_{k=1}^K [\ln(p(x_k)) \cdot y_k + \ln(1 - p(x_k)) \cdot (1 - y_k)] \Rightarrow \text{MAXIMIEREN}$$

7.6 ★ Nutzung: Cut-Off-Value

Auf Basis der Wahrscheinlichkeiten wird ein **Cut-Off-Value** festgelegt, mit dem eine klare **Ja/Nein-Prognose** abgegeben werden kann. **In der Regel wird 0,5 verwendet.**

*Beispiel: Person mit Einkommen 2.530 € → Kaufwahrscheinlichkeit 72 % (0,72) > Cut-Off 0,5 ⇒ **Kauf wird prognostiziert.***

7.7 ★ Prüfung des Gesamtmodells

Beurteilung der Anpassungsgüte	Beurteilung der Klassifizierungsgüte
-2LL (-2 Log Likelihood)	Konfusionsmatrix (Trefferquote, Sensitivität, Spezifität)
Likelihood-Ratio-Test (LR-Test)	ROC-Curve
Pseudo-R²-Statistiken: McFadden's R ² , Cox & Snell R ² , Nagelkerke's R ²	AUC (Area Under Curve)

Likelihood-Ratio-Test

Vergleich mit dem **Null-Modell** (constant-only-Modell: keine unabhängige Variable, nur die Regressionskonstante).

$$LLR = -2 \cdot \ln(\text{Likelihood des Null-Modells} / \text{Likelihood des vollständigen Modells})$$

Liegt der LLR-Wert über dem Wert einer theoretischen Chi-Quadrat-Verteilung, trägt das Modell signifikant zur korrekten Klassifizierung bei.

Pseudo-R²-Statistiken

Ein Bestimmtheitsmaß wie in der linearen Regression **existiert für die logistische Regression nicht**. Sämtliche Pseudo-R²-Statistiken vergleichen im Kern die Wahrscheinlichkeiten des vollständigen Modells mit denen des Null-Modells. ★ **Referenzwert: bereits ein Wert von 0,2-0,4 stellt eine gute Anpassungsgüte dar.**

★ Konfusionsmatrix (Klassifizierungstabelle)

Kursbeispiel: 30 Kunden — 14 kauften nicht (0 = NK), 16 kauften (1 = Kauf). Richtig klassifiziert: 7 Nicht-Käufer und 9 Käufer.

	Prognose: Nicht-Kauf	Prognose: Kauf	Σ
Tatsächlich Nicht-Kauf	7 ✓	7 (falsch-positiv)	14
Tatsächlich Kauf	7 (falsch-negativ)	9 ✓	16
Σ	14	16	30

Gütemaß	Formel	Berechnung	Wert
Trefferquote	richtige Prognosen / alle Fälle	(7+9)/30	0,533
Sensitivität	richtig prognostizierte Käufe / alle Käufe	9/16	0,563
Spezifität	richtig prognostizierte Nicht-Käufe / alle Nicht-Käufe	7/14	0,500

★ Fehlerarten:

- **Falsch-positiv** (Class-0-Error): für einen **Nicht-Käufer** wurde ein **Kauf** prognostiziert
- **Falsch-negativ** (Class-1-Error): für einen **Käufer** wurde ein **Nicht-Kauf** prognostiziert

Warum die Unterscheidung wichtig ist: Die **Bedeutung (Kosten) der Fehler ist nicht gleich**. Es ist vermutlich **weniger kostspielig**, wenn ein Kunde mit Werbung kontaktiert wird, der eigentlich nicht kaufen will (falsch-positiv). **Kostspieliger** wird es, wenn ein Kunde, der kaufen würde, fälschlicherweise **nicht** kontaktiert wird (falsch-negativ).

★ ROC-Curve (Receiver Operating Characteristic)

- Ursprünglich in der **Nachrichtentechnik zur Erkennung von Radar-Signalen** entwickelt.
- **y-Achse: Sensitivität · x-Achse: (1 – Spezifität)**
- Die Kurve entsteht durch Nutzung **aller möglichen Cut-Off-Werte**.
- *Beispiel: Bei Cut-Off 0,5 → Sensitivität 0,563, (1-Spezifität) 0,500.*

★ Welchen Cut-Off-Value wählen?

Hängt davon ab, ob **falsch-positive oder falsch-negative** Prognosen kostspieliger sind:

- **Soll auf keinen Fall ein Kunde verpasst werden** → Cut-Off **niedrig** wählen, so dass auch Kunden mit geringer Kaufwahrscheinlichkeit als Käufer klassifiziert werden (**mehr Kaufprognosen**)
- **Ist Werbung teuer** → Cut-Off **hoch** setzen, damit nur Kunden mit hoher Kaufwahrscheinlichkeit klassifiziert werden (**mehr Nichtkauf-Prognosen**)

★ AUC (Area Under Curve)

Die **Diagonale** in der Grafik wäre das Ergebnis bei rein zufälliger Klassifizierung (Modell ohne Nutzen).

AUC-Wert	Bewertung
< 0,7	Ungenügend
0,7 < AUC < 0,8	Akzeptabel
0,8 < AUC < 0,9	Exzellente
> 0,9	Außerordentlich

(Maximum = 1 bei perfekter Klassifizierung für jeden Cut-Off; zufällige Klassifizierung = 0,5.)

7.8 Prüfung der Merkmalsvariablen

Vergleich der **p-Werte** der Variablen mit dem theoretischen Signifikanzniveau:

- **p-Wert (Sig.) < 0,05** ⇒ Variable ist **signifikant**
- **p-Wert (Sig.) > 0,05** ⇒ Variable ist **nicht signifikant**

7.9 Multiple logistische Regression

Die **einzige Veränderung** ist die Erweiterung der Linearkombination:

Einfach: $z(x) = \beta_0 + \beta_1 \cdot \text{Einkommen}$
 Multiple: $z(x) = \beta_0 + \beta_1 \cdot \text{Einkommen} + \beta_2 \cdot \text{Geschlecht}$

Da „Geschlecht“ eine **binäre** Variable ist, wird sie als **Dummy-Variable** integriert (0 = w, 1 = m). Die weitere Vorgehensweise und Analyse ist **identisch**.

8. Methode 5: Monte-Carlo-Simulation

8.1 Definition

Die **Monte-Carlo-Simulation** ist eine Technik, mit der die **Auswirkungen von Risiken und Unsicherheiten** bei Finanz-, Projektmanagement-, Kosten- und anderen Prognosemodellen erfasst werden. Ein Monte-Carlo-Simulator hilft, **die meisten oder alle möglichen Ergebnisse zu visualisieren**, um eine bessere Vorstellung vom **Entscheidungsrisiko** zu erhalten.

Typische Fragestellungen:

- Wie ist die **Risikoverteilung** bei Durchführung eines Projekts?
- Mit welcher **Wahrscheinlichkeit** erreicht ein Unternehmen einen bestimmten **Gewinn** im laufenden Jahr?
- Wie ist die **Spannweite** möglicher **Aktienkurse** für ein Unternehmen?

8.2 ★ Szenario-Planung vs. stochastische Planung

Szenario-Planung (statisch)	Stochastische Planung (Monte Carlo)
Entwicklung von Ergebnis- oder Bilanzgrößen unter vordefinierten Szenarien (Best/Normal/Worst Case)	Nutzung von Verteilungsfunktionen
In Excel mit dem Szenario-Manager umsetzbar	Beschreibt sowohl das erwartete Ergebnis als auch den Umfang möglicher Abweichungen (Risiken)
⚠ Problem: Es können lediglich vordefinierte Szenarien durchgespielt werden, ohne Eintrittswahrscheinlichkeiten zu unterlegen	umfangreicher und realistischer

8.3 ★ Die 5-Schritte-Vorgehensweise

1. Festlegung des Simulationsmodells
2. Festlegung der Input- und Ergebnisvariablen
3. Festlegung der Verteilungen und Korrelationen
4. Durchführung der Simulation
5. Interpretation der Ergebnisse

8.4 Schritt 1 — Simulationsmodell

Ein **Simulationsmodell** ist die **mathematische Darstellung wesentlicher Charakteristiken eines realen Systems** oder einer realen Situation, die zur Einschätzung zukünftigen Verhaltens unter einer Vielzahl unterschiedlicher Bedingungen (**Simulationsläufe**) genutzt werden kann.

Zum Entwicklungsprozess gehört: Definieren des zu analysierenden **Systems**, der zugehörigen **Variablen** und eine möglichst exakte Beschreibung ihrer **Beziehungen untereinander (Korrelationen)**.

Häufig verwendete Simulationsmodelle:

1. **Plan-GuV**
2. **Werttreiberbäume**
3. **Projektbewertungen**
4. **Liquiditätsanalysen**

8.5 Schritt 2 — Input- und Ergebnisvariablen

Kursbeispiel Plan-GuV (Mio. €):

Position	Wert	Rolle
Umsatz	894	● unsichere, zu simulierende Inputvariable
Abschreibungen	100	● Inputvariable
Personalaufwand	271	● Inputvariable
Materialaufwand	268	● Inputvariable
EBIT	255	
Zinsaufwand	50	
EBT	205	
Steueraufwand	51	
Jahresüberschuss	154	● unsichere Ergebnisvariable — „Wie sicher ist dieser Jahresüberschuss?“

⚠ Um die Simulation übersichtlich zu halten, sollte das Modell **nicht zu detailliert** sein (z.B. nicht alle GuV-Positionen, sondern nur wesentliche Komponenten).

8.6 Schritt 3 — Verteilungen und Korrelationen

Eine **Zufallsvariable** ist eine Größe, deren Wert vom Zufall abhängig ist (z.B. Augenzahl bei 2 Würfeln: Ausprägungen 2–12 mit jeweils unterschiedlicher Wahrscheinlichkeit). **Jeder Inputvariable kann eine Verteilung zugeordnet werden**, um festzulegen, in welchem Bereich die Ergebnisse mit welcher Wahrscheinlichkeit erwartet werden.

Verteilung	Beschreibung
Gleichverteilung	Jedes mögliche Ergebnis tritt mit der gleichen Wahrscheinlichkeit ein. Grundgedanke: es gibt keine Präferenz . (Beispiel: Würfeln — sechs mögliche Augenzahlen.)
Normalverteilung	Der mittlere Wert hat eine deutlich höhere Eintrittswahrscheinlichkeit . (Beispiel: Durchschnitts-IQ = 100; sehr wenige haben < 55 oder > 145; 95 % der Bevölkerung liegen zwischen 70 und 130.)

Zuzuordnende Verteilungsparameter (in XLSTAT):

- **Mittelwert (μ)** und **Standardabweichung (σ)**
- **Art der Verteilung** (Normal, Gleich, Weibull, Poisson, ...)
- **Abstumpfung** — absolutes Minimum oder Maximum (z.B. Umsatz nicht unter 0)

★ Für eine realistische Simulation sollten diese Werte auf Basis einer **möglichst großen historischen Datenbasis** oder mit Hilfe von **Experten** geschätzt werden.

★ Korrelationen:

Inputvariablen sind regelmäßig **nicht komplett unabhängig** voneinander. So hängen z.B. **Materialaufwendungen** i.d.R. von den verkauften Einheiten, d.h. vom **Umsatz** ab. I.d.R. korrelieren Inputparameter sogar **stark**. **Warum berücksichtigen?** Damit theoretisch nicht mögliche bzw. sehr unwahrscheinliche Ergebnisse (z.B. **keine Erträge, aber hohe Materialaufwendungen**) **nicht abgebildet** werden. Korrelationen können **geschätzt** oder **über historische Daten erhoben** werden.

8.7 Schritt 4 — Durchführung

Ein **Simulationslauf** ist ein Szenario, in dem **jeder Inputvariable ein zufälliger Wert aus ihrem definierten Intervall zugeordnet** wird, der auch der **Wahrscheinlichkeit des Auftretens** in dieser Verteilung entspricht. Die Ergebnisvariable bildet dann das Ergebnis dieser zufällig ausgewählten Inputvariablen ab. **Eine hohe Anzahl von Simulationsläufen erhöht die Verlässlichkeit der Ergebnisse.**

8.8 Schritt 5 — ★ Interpretation der Ergebnisse

Auswertung	Erklärung
Deskriptive Statistiken	Quantile → wie sicher ist das Erreichen eines bestimmten Ergebnisses (z.B. Gewinn > 0)? Median und Mittelwert → erwartetes Ergebnis. Minimum/Maximum → Maximalergebnisse.
Histogramme	„ Das Herzstück der Monte-Carlo-Simulation“ — hier wird erkennbar, in welchem Rahmen sich das Ergebnis befinden wird. ⚠ Die Dichte gibt die Wahrscheinlichkeit eines marginal kleinen Ereignisses an → man sollte auf die Wahrscheinlichkeit von Intervallen (den Inhalt eines Balkens = Dichte × Breite der X-Achse) fokussieren, denn diese gibt die relative Häufigkeit an.
Kumulative Verteilungen	Gibt die Wahrscheinlichkeiten an, dass das Ergebnis höchstens/mindestens einen bestimmten Wert x annimmt. (Beispiel: positives Ergebnis mit ca. 70 % Wahrscheinlichkeit; mit ca. 90 %-iger Sicherheit wird ein Ergebnis von weniger als -25 nicht erreicht.)

8.9 ★ Value at Risk (VaR)

Der **Value at Risk** kommt aus dem Finanzwesen und ist ein **Risikomaß für die Risikoposition eines Portfolios**. Es handelt sich um das **Quantil der Verlustfunktion**: Der VaR zu einem gegebenen Wahrscheinlichkeitsniveau gibt an, **welche Verlusthöhe innerhalb eines gegebenen Zeitraums mit dieser Wahrscheinlichkeit nicht überschritten wird.**

Beispiel: Ein VaR von **10 Mio. EUR** eines Aktienportfolios bei einer **Haltedauer von einem Tag** und einem **Konfidenzniveau von 97,5 %** bedeutet: Der potenzielle Verlust des Portfolios von einem Tag auf den nächsten wird **mit 97,5 % Wahrscheinlichkeit den Betrag von 10 Mio. EUR nicht überschreiten.**

Anwendung in Industrie- und Handelsunternehmen:

- **EBIT-at-Risk** (Ergebnisgrößen)
- **Cash-Flow-at-Risk** (Cash Position)
- *Kursbeispiel: Jahresüberschuss-at-Risk = -25 Mio. € auf einem Wahrscheinlichkeitsniveau von 90 %.*

8.10 ★ Kritische Würdigung

1. Der Anwendungsbereich erstreckt sich vor allem auf die **anwendungsorientierte Forschung**, wird aber besonders auch für **Risikosimulation und Prognose** in Unternehmen verwendet.
2. **Problematisch:** das Verständnis der **Wahrscheinlichkeitsverteilungen**, die den Inputvariablen zugeordnet werden müssen. **Aber:** Diese Annahmen bilden die Realität **besser und genauer** ab als die in der Praxis gängigen Planszenarien, die i.d.R. nur für einzelne Teilplanungen (z.B. Absatzplanung) isoliert aufgestellt werden.
3. **Die Qualität der Ergebnisse wird durch die zu treffenden Annahmen bestimmt.** Objektiv nachvollziehbare Prämissen liegen in der Praxis häufig nicht vor → man muss auf **subjektive Einschätzungen der Fachexperten** zurückgreifen. Um die **Akzeptanz bei den Entscheidungsträgern** nicht zu gefährden, müssen die Prämissen „**konsensfähig**“ sein, d.h. die Planannahmen müssen die Ansichten des Managements hinreichend genau abbilden.

TEIL B — VISUAL ANALYTICS

9. Grundlagen

Visualisierung = die „**bildhafte Darstellung zum Zwecke des Verständnisses und der Kommunikation von Informationen**“. Zielsetzung: optimale Visualisierung, d.h. optimale **Wahrnehmung** der Informationen.

Visuelle Analyse (Visual Analytics) = Verwendung ausgeklügelter Tools und Prozesse zur Analyse von Datensätzen unter Verwendung **visueller Darstellungen**. Die Visualisierung in Grafiken, Diagrammen und Karten hilft Benutzern, **Muster zu erkennen** und dadurch **umsetzbare Erkenntnisse** zu gewinnen.

Ziel: Die richtigen **Visuals für eine Fragestellung auszuwählen**, sie **richtig zu gestalten** und mit anderen Visuals zu **Dashboards zu kombinieren**.

10. ★ Die vier Gestaltgesetze

Gestaltgesetze sind aus der **Wahrnehmungspsychologie** abgeleitete Grundsätze, die Leitlinien vorgeben, wie Informationen bestmöglich dargestellt werden sollten, um **Effektivität und Effizienz beim Betrachter** zu steigern.

10.1 Gesetz der Sparsamkeit

Der Mensch nimmt Informationen regelmäßig in **bekannten und charakteristischen Strukturen** auf. Eine gute Gestalt zeichnet sich daher durch **Einfachheit und Klarheit** aus. *Gegenbeispiele: Ampelsymbole mit vertauschten Farben · Notenskala mit 6 als bester Note.*

★ Data-Ink-Ratio (Edward Tufte)

$$\text{Data-Ink-Ratio} = \frac{\text{Tinte für Elemente mit wichtigen Informationen im Bericht}}{\text{Gesamtmenge an Tinte im Bericht}}$$

Das Verhältnis soll den Chart-Ersteller dazu anregen, darüber nachzudenken, **welche Elemente tatsächlich notwendig sind und welche nur Ballast. Das Ratio sollte möglichst hoch sein.**

10.2 Gesetz der Nähe und Ähnlichkeit

Menschen nehmen Elemente als **zusammengehörig** wahr, die sich **nahe beieinander** befinden oder **ähnlich aussehen**. Benachbarte Elemente werden als Gruppe wahrgenommen, die für eine gemeinsame Aussage steht. ⇒ **Zusammengehörige Elemente sollten in einer Visualisierung nah beieinander angeordnet werden.**

10.3 Gesetz der Struktur und Symmetrie

Elemente, die einander **symmetrisch** zugeordnet sind, nehmen wir **schneller** wahr. Ebenso Elemente, die **klar strukturiert** sind (z.B. durch zusammengehörige Linien). Grund: Das menschliche Auge probiert stets, **Formen zu erkennen**. *Kursbeispiel: Symmetrisch angeordnete grüne Punkte treten deutlich bewusster in den Vordergrund. Zwischen unsymmetrischen roten Punkten springt das Auge hilflos hin und her, weil der gegenseitige Bezug fehlt.*

Anwendung in wissenschaftlichen Arbeiten:

- Überschriften der ersten Ebene heben sich durch **Abstand und Fettdruck** ab → stärkerer Kontrast, schneller erfasst
- Punkte der zweiten Ebene sind sich ähnlich → wird durch **Nähe** verdeutlicht
- Unterpunkte in Kapiteln **stets gleich benannt** → bildet **Symmetrie** ab
- Anzahl der Worte in Überschriften meist **1-2** → ebenso Symmetrie

10.4 ★ Gesetz der Kontrastbildung

Menschen erkennen **leichter und schneller durch einen Vergleich (Kontrast)**. Dieser sollte allerdings **möglichst eindeutig** sein, so dass **unnötiger Kontrast eliminiert** wird.

Kursbeispiel Wettbewerbsvergleich:

 Schlechter Chart	 Verbesselter Chart
Jeder Wettbewerber bekommt eine eigene Farbe → unnötiger (zu viel) Kontrast , da der Hauptfokus auf dem eigenen Unternehmen liegt. Das Auge schwankt ständig zur Legende.	Alle Wettbewerber grau, nur das eigene Unternehmen blau → Kerninformation schneller erkennbar. Sortiert nach den Eigenschaften, in denen man am besten abschneidet. Auf 0 skaliert . Wettbewerber stets in derselben Reihenfolge .

 **Die Nutzung von Farbe zur Hervorhebung hat nur Nutzen, wenn der Kontrast dadurch stark wird. Werden viele verschiedene Farben verwendet, gibt es zu viele Kontraste, so dass kein einzelner mehr erkennbar ist.**

 **Kursbeispiel Pharma-Rangpositionen:** Statt vieler Farben → **unterschiedliche Intensität derselben Farbe:** höhere Intensität = bessere Produkte, blassere Farben = schlechtere. Der Blick geht direkt auf die fettgedruckten Marktführer.

10.5 ★ Highlighting-Regeln (Lidwell et al., *Universal Principles of Design*)

Grundsätzlich wird empfohlen, nur ca. 10 % der Graphiken zu **highlighten**, damit diese noch genug Kontrast erhalten.

Mittel	Bewertung
Fettdruck	✓ meist bevorzugt — hebt Elemente klar hervor, sorgt für wenig Ablenkung
<i>Kursiv</i>	⚠ wenig Ablenkung, sticht jedoch auch nicht klar heraus
<u>Unterstreich</u> ung	✗ wirkt zu stark ablenkend , sparsam einsetzen
GROSSBUCHSTABEN	✓ fallen sofort auf, wirken wenig ablenkend — für Überschriften geeignet
Schriftart	⚠ Verwendung vieler verschiedener Schriftarten ohne Bedeutung vermeiden
Farbe	✓ effektive Methode zur Hervorhebung

10.6 ★ Positionierung

Die meisten Menschen lesen Text und Folien in einer „Zigzag“-Bewegung von oben links nach rechts unten:

```

1  →  2
    ✓
3  →  4

```

⇒ Die wichtigen Informationen sollten in Position 1 sein, um direkt aufzufallen.

11. Charts richtig auswählen

11.1 Tabellen

- Sollten in Dashboards **sparsam** verwendet werden, da sie zur direkten Interpretation eher schwierig sind.
- Bei der Erstellung der **Rahmen** das **Data-Ink-Ratio** und die Nutzung von Kontrast beachten.
- ★ **Dünne oder keine Rahmen reichen in der Regel aus.** Bei minimalem Rahmen stehen die **Daten deutlich mehr im Vordergrund** als bei fetten Rahmen. **Minimieren Sie Ablenkungen.**

11.2 ★ Balkendiagramme

- Zeigen einen **Vergleich zwischen Items**. Aufgrund ihrer weiten Verbreitung sollten sie in Dashboards verwendet werden, da das Auge die Informationen schnell verarbeiten kann — es **vergleicht einfach die Größe der Balken**.
- ⚠ **Genau deshalb ist es wichtig, die Achsen mit einer NULLLINIE als Basis darzustellen.** Anderenfalls kommt es zu **unabsichtlichen oder beabsichtigten Fehlinformationen**.

 **Kursbeispiel „Fox News“:** Durch die Verzerrung der Y-Achse (Skalierung 32 %–40 %) entsteht die Interpretation, es gäbe eine **starke Steuererhöhung**, wenn Bushs Steuersenkungen auslaufen. In Wahrheit: von 35 % auf 39,6 % = **4,6 Prozentpunkte**.

Die Korrektur:

1. **Achsenskalierung auf 0 %** anpassen → die Veränderung wirkt nicht mehr dramatisch
2. **Achsenbeschriftungen in die Balken packen** → weniger Störung (Noise)
3. **Farbänderung auf Blau** → weniger dramatische Wirkung

11.3 Pie Charts (Kuchendiagramme)

Definition: Zeigen, welchen **Anteil an der Gesamtheit** einzelne Teile haben (z.B. „Unternehmen D hat 24 % am Gesamtumsatz der Branche“).  **Anwendung: nur sparsam einsetzen**, da das menschliche Auge **schlecht im Erkennen kleiner Größenunterschiede** ist — insbesondere dann, wenn die Unterschiede gravierend sind und genau dies hervorgehoben werden soll.

12. Dashboards

Definition: Ein **Dashboard** ist eine **grafische Benutzeroberfläche zur Visualisierung von Daten**. Der Name resultiert aus dem englischen Begriff für ein **Armaturenbrett** im Auto und bezieht sich darauf, dass — wie auf einem Armaturenbrett — **bedarfsgerecht auf einen Blick Informationen aus verschiedenen Quellen** angezeigt werden.

Übung: Praxisfall Controlling-Dashboard

Beurteilen Sie, welches von zwei Dashboards die gesetzten Ziele besser erreicht:

1. **Liquiditätsveränderungen** sollen schnell erkannt werden.
2. **Trends** in der Entwicklung der Liquidität sollen schnell erkannt werden.
3. **Fehler/Ausreißer** bei einzelnen Daten sollen schnell erkannt werden.

13. SPSS-Praxisanleitungen (Zusammenfassung)

13.1 Zeitregression in SPSS

1. **Datensatz vorbereiten (Excel):** Variable `Datensatz` anlegen — Wert „T“ (Training) für alle Zeilen bis Dezember 1959, ab Januar 1960 Wert „V“ (Validierung).
2. **Einlesen:** Datei → Öffnen → Daten
3. **Visualisierung (Excel):** Prüfen auf Trend und Saisoneffekte → additives oder multiplikatives Modell?
4. **Schätzung:** Analysieren → Regression → Linear
 - Unabhängige Variable: **Zeit** (dann schrittweise Dummies und Kausalvariablen ergänzen)
 - Bei „Auswahlvariable“ die Bedingung `Datensatz = T` setzen → SPSS schätzt nur auf dem Trainingsdatensatz; das Ergebnis wird automatisch auf die Validierungsperiode angewendet
5. **Ergebnisse:** `PRE_1` = Prognosen · `LMCI_1` / `UMCI_1` = **95 %-Konfidenzintervall**
6. ⚠ **Der MAPE wird in SPSS nicht automatisch ausgegeben** → Daten nach Excel kopieren und die Fehler für die Validierungsperiode händisch berechnen.
7. **Verbesserung:** Nicht signifikante Dummy-Variablen aus dem Modell nehmen, um das **adjustierte R^2** zu erhöhen (meist nur geringe Effekte).

13.2 Smoothing-Methoden in SPSS

1. ⚠ **Die Daten des letzten Jahres (1960) händisch löschen**, sonst verwendet SPSS diese auch im Schätzmodell.
2. Messniveau in der Variablenansicht auf „metrisch“ stellen.
3. **Analysieren → Vorhersage → Traditionelle Modelle erstellen**
4. Zuerst „Datum und Uhrzeit definieren“ → „Jahre, Monate“ → erster Fall 1949, Monat 1 → SPSS hinterlegt einen eigenen Zeitindex.
5. **Methode: Exponentielles Glätten**; unter „Kriterien“ die Modellart festlegen (z.B. **multiplikatives Holt-Winters mit Periodizität 12**).
6. **Statistik:** R^2 und MAPE ausgeben · **Diagramm:** Vorhersagediagramm · **Speichern:** Vorhersagen mit Konfidenzintervallen und Parameter speichern
7. ⚠ **SPSS macht keine Angaben darüber, für welchen Zeitraum der MAPE berechnet wird** — in jedem Fall **nicht** für die Validierungsperiode → Prognosespalte nach Excel kopieren und MAPE für das letzte Jahr selbst berechnen.
8. ⚠ **SPSS-Notation weicht ab:** statt α , β , γ verwendet SPSS **alpha, Gamma und Delta**.



SELBSTTEST — Fragen zum Abfragen

▼ Grundlagen

1. Definiere Business Analytics (IOR/MS-Definition) und Business Intelligence.
2. Nenne vier Unterschiede zwischen BI und BA.
3. Nenne die drei Analytics-Stufen mit ihrer jeweiligen Leitfrage.
4. Ordne zu: Data Queries, Data Mining, Dashboards, Predictive Modeling, Forecasting, Simulation, Optimization, Rule-Based Models.
5. Erkläre den Bayer-Fall: Problem, Ansatz, zwei Ergebnisse (13 % vs. 3 %).
6. Nenne fünf Anwendungsfelder von Business Analytics mit je einem Beispiel.
7. Was war „Moneyball“ methodisch?

▼ Zeitreihen-Grundlagen

8. Definiere Zeitreihe und Zeitreihenanalyse. Wovon ist sie eine Spezialform?
9. Nenne die 5 Schritte der Zeitreihenanalyse.
10. Nenne die vier Zeitreihenkomponenten mit Symbol und Bedeutung.
11. Additives vs. multiplikatives Modell — Formel und Annahme.
12. Wann wählt man welches Modell? (Bezug: Airline-Datensatz)
13. Definiere Trainings-, Validierungs- und Testset. Warum braucht man alle drei?
14. Was ist Backtesting?
15. Nenne MAD, MAPE, MSE, RMSE mit Formel. Wann nimmt man welches?
16. Erkläre R^2 über SST, SSE, SSR. In welchem Bereich liegt es?
17. Was sagt eine Autokorrelation in den Residuen über das Modell aus?

▼ Lineare Zeitregression

18. Deterministisches vs. stochastisches Modell — Formel.
19. Wie lautet die Modellgleichung ohne / mit Saison / mit Saison und Kausalvariablen?
20. Was ist eine Dummy-Variable? Wie viele braucht man bei 12 Monaten?
21. Was ist eine Kausalvariable? Nenne zwei Beispiele aus dem Airline-Fall.
22. Was ist eine Lag-Variable? Erkläre am Bauunternehmens-Beispiel.
23. Nenne die MAPE-Werte der drei Regressionsmodelle im Airline-Fall.
24. Interpretiere den Koeffizienten $\beta_1 = 2,664$.

▼ Smoothing

25. Naive Forecast: Formel, zwei Probleme, zwei sinnvolle Nutzungen.
26. Simple Average: Formel, Vorteil, drei Nachteile.
27. Trailing vs. Weighted Moving Average — Unterschied und Formel.
28. Wann sind Moving Averages zur Prognose geeignet?
29. SES: Formel und die Rolle von α . Was passiert bei $\alpha = 1$?
30. Nenne die drei Probleme des SES und ihre Lösungen.
31. DES (Holt): Alle drei Formeln. Was bewirkt ein hohes β ?
32. Warum eignet sich DES nur für kurze Prognoseperioden?
33. TES (Holt-Winters): additive und multiplikative Formeln.
34. Wann additiv, wann multiplikativ?
35. Nenne die MAPE-Werte der fünf Smoothing-Modelle im Airline-Fall. Welches gewinnt?
36. Warum liefern SPSS und XLSTAT unterschiedliche Ergebnisse?

▼ ARIMA

37. Wofür stehen p, d, q in ARIMA?
38. Was ist eine Lag-Variable? Erstelle die Lag-1- und Lag-2-Spalte für 19/21/17/19.
39. Korrelation vs. Autokorrelation vs. partielle Autokorrelation.
40. In welcher Beziehung stehen Korrelation und R^2 ?
41. Warum ist Roulette ein Beispiel für fehlende Autokorrelation?
42. Wann liegt Autokorrelation bei Lag 12 vor?
43. Erkläre die partielle Autokorrelation am Bratwurst-Beispiel (Effekt 1 und Effekt 2).
44. Was heißt Stationarität? Zwei Bedingungen.
45. Durbin-Watson: H_0 , H_1 und die Bedeutung von $d = 0, 2, 4$.
46. Box-Ljung: Was wird getestet?
47. ADF-Test vs. KPSS-Test: H_0 , H_1 , jeweiliges Ziel. Warum sind sie umgekehrt?
48. Was ist Differenzierung? Bis zu welchem d sind ARIMA-Modelle sinnvoll?
49. Was ist die MA-Komponente inhaltlich? Formel für MA(1).
50. Wann sollte man eine MA-Komponente ergänzen?
51. **Wie erkennt man an ACF und PACF ein AR- bzw. ein MA-Modell?**
52. SARIMA-Notation: Was bedeuten P, D, Q, m?
53. OLS vs. Maximum Likelihood — warum ist OLS bei MA-Komponenten problematisch?

▼ Logistische Regression

54. Definiere logistische Regression und ihr Ziel.
55. Binär vs. multinomial · einfach vs. multiple.
56. Warum kann man hier keine lineare Regression verwenden?
57. Wie lautet die logistische Funktion? Warum liegt p immer in $(0;1)$?
58. Was ist die Linearkombination $z(x)$?
59. Formuliere das Maximum-Likelihood-Prinzip. Wie lautet die Log-Likelihood-Funktion?
60. Was ist der Cut-Off-Value? Welcher Standardwert?
61. Nenne die Maße für Anpassungsgüte und für Klassifizierungsgüte.
62. Likelihood-Ratio-Test: Formel und Entscheidungsregel.
63. Warum gibt es kein echtes R^2 ? Referenzwert für Pseudo- R^2 ?
64. Berechne aus der Konfusionsmatrix (7/7/7/9) Trefferquote, Sensitivität und Spezifität.
65. Falsch-positiv vs. falsch-negativ — Definition und warum die Kosten unterschiedlich sind.
66. Was zeigt die ROC-Curve auf welchen Achsen?
67. **Wann wählt man einen niedrigen, wann einen hohen Cut-Off-Value?**
68. Nenne die vier AUC-Bewertungsstufen mit Grenzwerten.
69. Ab welchem p-Wert ist eine Variable signifikant?

▼ Monte-Carlo-Simulation

70. Definiere die Monte-Carlo-Simulation und ihren Zweck.
71. Nenne drei typische Fragestellungen.
72. Szenario-Planung vs. stochastische Planung — was ist das zentrale Problem der Szenario-Planung?
73. Nenne die 5 Schritte.
74. Was ist ein Simulationsmodell? Nenne vier typische Modelltypen.
75. Erkläre am Plan-GuV-Beispiel Input- und Ergebnisvariablen.
76. Gleichverteilung vs. Normalverteilung. Welche Parameter müssen zugeordnet werden?
77. Was ist eine Abstumpfung?
78. **Warum müssen Korrelationen zwischen Inputvariablen berücksichtigt werden?** Nenne ein Beispiel für ein unrealistisches Ergebnis.
79. Was ist ein Simulationslauf?
80. Was zeigen Histogramm und kumulative Verteilung? Warum darf man die Dichte nicht direkt als Wahrscheinlichkeit lesen?
81. Definiere Value at Risk. Erkläre „VaR 10 Mio. EUR, 1 Tag, 97,5 %“.
82. Was sind EBIT-at-Risk und Cash-Flow-at-Risk?
83. Nenne die drei Punkte der kritischen Würdigung. Was heißt „konsensfähige Prämissen“?

▼ Visual Analytics

84. Definiere Visualisierung und Visual Analytics.
85. Nenne die vier Gestaltgesetze.
86. Was ist das Data-Ink-Ratio? Formel und Zweck. Soll es hoch oder niedrig sein?
87. Erkläre das Gesetz der Nähe und Ähnlichkeit mit einer Handlungsempfehlung.
88. Erkläre das Gesetz der Struktur und Symmetrie. Warum funktioniert es?
89. **Wann ist Kontrast zu viel Kontrast?** Erkläre am Wettbewerbsvergleich.
90. Nenne die drei Verbesserungen im Wettbewerbs-Chart.
91. Wieviel Prozent einer Grafik sollte man highlighten?
92. Bewerte Fettdruck, Kursiv, Unterstreichung, Großbuchstaben als Highlighting-Mittel.
93. Wie lesen Menschen Folien? Wo gehört die wichtigste Information hin?
94. **Warum ist bei Balkendiagrammen die Nulllinie zwingend?** Erkläre den Fox-News-Fall.
95. Wann sollte man Pie Charts vermeiden und warum?
96. Wie sollten Tabellen in Dashboards gestaltet sein?
97. Woher kommt der Begriff „Dashboard“ und was ist die Kernidee?

Datensätze im Modul

Datei	Verwendung
1 - Forecasting - Zeitregression - Airline Passengers.xlsx	Lineare Zeitregression (Modelle 1–3)
2 - Forecasting - Smoothing Methods - Airline Passengers.xlsx	Naive/SA/MA/SES/DES/TES
3 - Forecasting - ARIMA - Airline Passengers.xlsx	ARIMA / SARIMA
4 - Simulation - Monte-Carlo.xlsx	Monte-Carlo-Simulation (Plan-GuV)
6 - Logistische Regression - Einkaufsentscheidung.xlsx	Logistische Regression (30 Kunden, Einkommen + Geschlecht)
Ergebnisübersicht - MAPE der getesteten Smoothingmodelle...xlsx	Vorlage für den Modellvergleich