Übungsblatt 3 – Data Exploration & Visualisierungsarten

Data Visualization | DHBW

Aufgabe 1 – Grundbegriffe: Wann welche Visualisierung?

(a) Erläutern Sie den Hauptunterschied zwischen einem *Bar Plot* und einem *Line Plot*. Für welche Datentypen ist die jeweilige Darstellung geeignet?

(b) Nennen Sie die vier Varianten des Bar Plots und beschreiben Sie kurz den Anwendungsfall jeder Variante.

(c) Wann sollte ein *Histogram* statt eines Bar Plots verwendet werden? Nennen Sie einen Datensatz als Beispiel für jeden der beiden Diagrammtypen.

(d) Erklären Sie den Unterschied zwischen einem *Violin Plot* und einem *Box Plot*. Welchen Mehrwert bietet der Violin Plot?

(e) Wann ist ein *Pie Chart* sinnvoll und wann sollte er vermieden werden? Nennen Sie je ein konkretes Beispiel.

Aufgabe 2 – Histogram-Berechnung *(Berechnung)*

Gegeben seien folgende 20 Messwerte (Reaktionszeiten in Millisekunden) eines Systems:

142	158	134	167	149	173	138	161	145	156
170	143	152	165	137	148	162	155	144	159

(a) Berechnen Sie die optimale Bin-Anzahl mit dem *Square-Root-Ansatz*: $k = \lceil \sqrt{n} \rceil$.

(b) Bestimmen Sie Minimum, Maximum und Gesamtbereich (Range) der Daten. Berechnen Sie daraus die Bin-Breite: Bin-Breite $= \frac{\text{Range}}{k}$ (auf ganze Zahl aufrunden).

(c) Erstellen Sie eine vollständige Häufigkeitstabelle mit Bins, absoluter Häufigkeit und relativer Häufigkeit (in %).

(d) Bestimmen Sie die Distributionsform dieses Histogramms und begründen Sie Ihre Antwort.

Aufgabe 3 – Bar Plot vs. Histogram

(a) Erklären Sie drei wesentliche strukturelle Unterschiede zwischen einem Bar Plot und einem Histogram. Gehen Sie dabei auf Datentypen, Abstände zwischen Balken und die Bedeutung der x-Achse ein.

(b) Ordnen Sie die folgenden vier Szenarien jeweils dem passenden Diagrammtyp (Bar Plot oder Histogram) zu und begründen Sie kurz Ihre Wahl:

1. Anzahl verkaufter Produkte je Produktkategorie (Elektronik, Kleidung, Lebensmittel).
2. Verteilung der Körpergrößen in einer Schulklasse von 30 Schülerinnen und Schülern.
3. Durchschnittliche Kundenbewertung (1–5 Sterne) für fünf verschiedene Restaurants.
4. Verteilung der täglich zurückgelegten Pendelstrecken von 500 Berufstätigen.

(c) Welche Best Practice gilt für die Basislinie beim Bar Plot? Warum gilt diese Regel beim Line Plot nicht zwingend?

Aufgabe 4 – Korrelation & Heatmap *(Berechnung)*

Für einen Datensatz mit drei Variablen (Temperatur in °C, Eisverkauf in Stück, Sonnenstunden pro Tag) wurden folgende Pearson-Korrelationskoeffizienten berechnet:

	Temperatur	**Eisverkauf**	**Sonnenstunden**
Temperatur	1,00	0,92	0,71
Eisverkauf	0,92	1,00	0,58
Sonnenstunden	0,71	0,58	1,00

(a) Erläutern Sie die Formel für den Pearson-Korrelationskoeffizienten:

$$r_{xy} = \frac{\mathrm{Cov}(x, y)}{\sigma_x \cdot \sigma_y}$$

Welche Werte kann r_{xy} annehmen und was bedeuten die Extremwerte?

(b) Interpretieren Sie den Wert $r = 0{,}92$ zwischen Temperatur und Eisverkauf. Ist dieser Zusammenhang kausal? Begründen Sie.

(c) Welche zwei Variablen weisen die schwächste Korrelation auf? Was könnte das inhaltlich bedeuten?

(d) Ein Kollege möchte die Korrelation zwischen der Variable „Kundenaltersgruppe“ (jung, mittel, alt) und dem Eisverkauf berechnen und dabei Pearson verwenden. Warum ist das problematisch? Welche Alternative empfehlen Sie?

Aufgabe 5 – Best Practices: Fehler identifizieren

Ein Praktikant erstellt fünf Visualisierungen. Jede enthält mindestens einen Fehler. Identifizieren Sie den Fehler und beschreiben Sie, wie er behoben werden sollte:

(a) Ein Bar Chart zeigt monatliche Umsatzzahlen. Die y-Achse beginnt bei 980.000 €, sodass ein Unterschied von 5 % zwischen den Monaten als riesiger Balkenunterschied erscheint.

(b) Ein Line Plot vergleicht die Entwicklung von acht verschiedenen Produktkategorien über 12 Monate in einem einzigen Diagramm mit acht Linien.

(c) Eine Heatmap zur Korrelationsmatrix hat keine Legende (Colorbar). Die Felder sind farbig kodiert, aber es ist nicht ersichtlich, welche Farbe welchem Zahlenwert entspricht.

(d) Ein Histogram hat sehr breite Bins: Alle 500 Datenpunkte werden in nur 3 Bins zusammengefasst. Die Bin-Breite ist $\frac{\text{Range}}{3}$.

(e) Ein Pie Chart zeigt die Marktanteile von acht Unternehmen. Das kleinste Segment hat einen Anteil von 1 %. Alle Segmente sind in ähnlichen Farbtönen eingefärbt.

Aufgabe 6 – Vergleichstabelle Visualisierungsarten

Erstellen Sie eine Vergleichstabelle für die sechs Visualisierungsarten Bar Plot, Line Plot, Histogram, Heatmap, Violin Plot und Pie Chart. Die Tabelle soll folgende Spalten enthalten: *Datentyp*, *typischer Einsatz*, *Stärke* und *Schwäche*.

Lösungen – Übungsblatt 3

Aufgabe 1 – Grundbegriffe: Wann welche Visualisierung?

(a) **Bar Plot:** Stellt numerische Werte diskreter Kategorien als Balken dar. Die x-Achse ist kategorisch (z. B. Produktnamen, Länder). Geeignet für *kategoriale* oder *nominale* Daten, bei denen der Vergleich zwischen Gruppen im Vordergrund steht.
Line Plot: Verbindet Datenpunkte durch Linien und zeigt damit Wertveränderungen. Die x-Achse ist numerisch oder zeitlich geordnet. Geeignet für *zeitliche Verläufe* oder *kontinuierliche numerische Relationen*, bei denen die Veränderungsrate interessiert.

(b) **Vertikaler Bar Plot** (Column Chart): Standardform mit senkrechten Balken – geeignet für wenige Kategorien mit langen Bezeichnungen, die auf der x-Achse gut lesbar sind.
Horizontaler Bar Plot: Balken liegen waagerecht – besonders geeignet, wenn viele Kategorien mit langen Beschriftungen verglichen werden; die y-Achse bietet mehr Platz für Text.
Stacked Bar Plot: Mehrere Gruppen werden in einem Balken gestapelt – zeigt Gesamtgröße und Zusammensetzung gleichzeitig, z. B. Umsatz aufgeteilt nach Produktkategorien pro Quartal.
Grouped Bar Plot: Mehrere Balken stehen nebeneinander – ermöglicht direkten Vergleich mehrerer Gruppen pro Kategorie, z. B. Verkaufszahlen nach Region und Produktlinie.

(c) Ein **Histogram** wird verwendet, wenn die Verteilung *kontinuierlicher numerischer Daten* untersucht werden soll – die Daten werden in Intervalle (Bins) eingeteilt und die Häufigkeit pro Bin abgelesen. Beispiel: Verteilung der Körpergröße von 1.000 Personen.
Ein **Bar Plot** wird verwendet, wenn *diskrete Kategorien* verglichen werden sollen. Die Abstände zwischen Balken signalisieren, dass keine Kontinuität besteht. Beispiel: Anzahl der Studierenden pro Studiengang.

(d) Ein **Violin Plot** kombiniert die Box-Plot-Darstellung (Median, Quartile) mit einer gespiegelten Kernel-Dichteschätzung (KDE). Die Breite der "Violine" an einer bestimmten Stelle zeigt, wie viele Datenpunkte in diesem Wertebereich liegen. Der Mehrwert gegenüber dem Box Plot: Während der Box Plot nur Quartile und Ausreißer zeigt, visualisiert der Violin Plot die gesamte *Dichteverteilung* und macht Muster wie Bimodalität oder Schiefe sichtbar.

(e) Ein **Pie Chart** ist sinnvoll, wenn Teil-Gesamt-Verhältnisse von *wenigen Kategorien* (maximal 5–6) gezeigt werden sollen und die Anteile deutlich unterschiedlich sind. Beispiel: Marktanteile von drei dominierenden Unternehmen.
Er sollte vermieden werden, wenn viele Kategorien verglichen werden, kleine Unterschiede erkennbar sein sollen oder genaue Werte kommuniziert werden müssen. Beispiel: Marktanteile von zehn Unternehmen mit ähnlichen Anteilen – hier wäre ein Bar Plot übersichtlicher.

Aufgabe 2 – Histogram-Berechnung

(a) **Optimale Bin-Anzahl (Square-Root-Ansatz):**

$$k = \lceil \sqrt{n} \rceil = \lceil \sqrt{20} \rceil = \lceil 4{,}47 \rceil = 5$$

Mit $n = 20$ Datenpunkten ergibt sich eine optimale Bin-Anzahl von $k = 5$. Der Square-Root-Ansatz ist eine einfache Faustregel, die bei kleinen bis mittleren Datensätzen gute Ergebnisse liefert. Für sehr große Datensätze (z. B. $n > 1000$) gibt es präzisere Methoden wie die Sturges- oder Rice-Regel.

(b) **Wertebereich:**

$$\text{Minimum} = 134, \quad \text{Maximum} = 173, \quad \text{Range} = 173 - 134 = 39$$

$$\text{Bin-Breite} = \left\lceil \frac{39}{5} \right\rceil = \lceil 7{,}8 \rceil = 8$$

Die Bins beginnen bei 134 (dem Minimum) und haben jeweils eine Breite von 8 ms.

(c) **Häufigkeitstabelle:**

Bin (ms)	Enthaltene Werte	Abs. Häufigkeit	Rel. Häufigkeit
$[134, 142)$	134, 137, 138	3	15 %
$[142, 150)$	142, 143, 144, 145, 148, 149	6	30 %
$[150, 158)$	152, 155, 156	3	15 %
$[158, 166)$	158, 159, 161, 162, 165	5	25 %
$[166, 174]$	167, 170, 173	3	15 %
Gesamt		**20**	**100 %**

(d) **Distributionsform:** Das Histogram zeigt eine *leicht rechtsschiefe Verteilung* (rechtsschief / positiv schief). Der größte Bin liegt im Bereich $[142, 150)$ mit 30 % aller Werte, und nach rechts (höhere Werte) nimmt die Häufigkeit ab, mit einem leichten Anstieg bei $[158, 166)$. Die Verteilung ist nicht perfekt symmetrisch, da der Modalwert links der Mitte liegt und der rechte Ausläufer etwas länger ist. In der Praxis würde man bei einem größeren Datensatz genauer bestimmen können, ob eine Normalverteilung vorliegt.

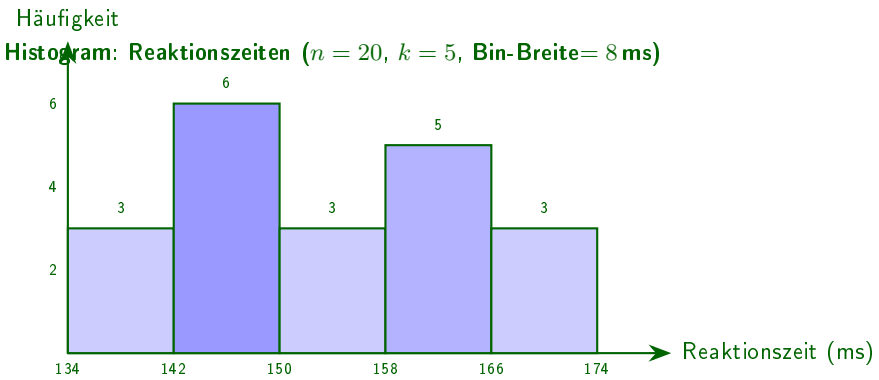

Aufgabe 3 – Bar Plot vs. Histogram

(a) **Drei strukturelle Unterschiede:**

1. Datentyp: Bar Plots stellen *kategoriale* (nominale oder ordinale) Daten dar – jeder Balken repräsentiert eine diskrete Kategorie (z. B. Land, Produktname). Histograms zeigen *kontinuierliche numerische* Daten, die in Intervalle (Bins) eingeteilt werden.

2. Abstände zwischen Balken: Beim Bar Plot gibt es sichtbare Lücken zwischen den Balken – sie signalisieren, dass keine kontinuierliche Skala vorliegt und die Kategorien unabhängig voneinander sind. Beim Histogram sind die Balken direkt benachbart (keine Lücken), da die Bins ein zusammenhängendes numerisches Intervall darstellen.

3. x-Achse: Beim Bar Plot ist die x-Achse *kategorisch beschriftet* (Kategorienamen). Beim Histogram ist die x-Achse eine *numerische Skala* mit kontinuierlichen Grenzwerten der Bins.

(b) **Zuordnung der Szenarien:**
1. Produktkategorien → Bar Plot. Elektronik, Kleidung und Lebensmittel sind diskrete, ungeordnete Kategorien. Es gibt keine natürliche Reihenfolge zwischen ihnen, daher kein Histogram.
2. Körpergrößenverteilung → Histogram. Körpergröße ist eine kontinuierliche Messvariable. Die Verteilung über einen Wertebereich (z. B. 150–200 cm) mit Bins von z. B. 5 cm ist typisches Histogram-Terrain.
3. Kundenbewertung → Bar Plot. Obwohl die Skala 1–5 numerisch ist, handelt es sich um eine *diskrete ordinale* Skala mit nur 5 definierten Werten. Die durchschnittliche Bewertung pro Restaurant ist ein kategorischer Vergleich.
4. Pendelstrecken → Histogram. 500 kontinuierliche Kilometerangaben sollten in Bins eingeteilt und als Histogram dargestellt werden, um die Verteilung (z. B. Häufung bei 20–40 km) sichtbar zu machen.

(c) **Bar Plot:** Die Basislinie muss bei 0 beginnen. Startet die y-Achse bei einem anderen Wert (z. B. 80 %), wird die Länge der Balken verzerrt und kleine Unterschiede erscheinen dramatisch groß – das ist irreführend.
Line Plot: Hier muss die Basislinie *nicht zwingend* bei 0 liegen, da beim Line Plot die *Steigung* (Veränderungsrate) und nicht die absolute Balkenlänge kommuniziert wird. Ein ausgeschnittener y-Achsenbereich kann helfen, kleine aber bedeutsame Schwankungen im Verlauf sichtbar zu machen.

Aufgabe 4 – Korrelation & Heatmap

(a) **Pearson-Korrelationskoeffizient:**

$$r_{xy} = \frac{\mathrm{Cov}(x, y)}{\sigma_x \cdot \sigma_y}$$

Der Zähler $\mathrm{Cov}(x, y)$ misst, ob x und y gemeinsam über oder unter ihrem Mittelwert liegen (gemeinsame Varianz). Die Normierung durch die Standardabweichungen σ_x und σ_y macht den Wert einheitenlos und begrenzt ihn auf den Bereich $[-1, +1]$.
$r = +1$: perfekte positive lineare Korrelation (wenn x steigt, steigt y proportional).
$r = -1$: perfekte negative lineare Korrelation (wenn x steigt, sinkt y proportional).
$r = 0$: kein linearer Zusammenhang (es kann dennoch eine nicht-lineare Beziehung bestehen).

(b) **Interpretation $r = 0{,}92$:** Ein Pearson-Koeffizient von 0,92 zeigt eine *sehr starke positive lineare Korrelation* zwischen Temperatur und Eisverkauf. Wenn die Temperatur steigt, steigt auch der Eisverkauf fast proportional. Dieser Zusammenhang ist jedoch *nicht zwingend kausal*: Es könnte ein Drittvariableneffekt vorliegen. Die Sommersaison erhöht gleichzeitig Temperatur und Eiskonsum – der Zusammenhang könnte also durch die latente Variable "Jahreszeit" erklärt werden (Scheinkorrelation durch gemeinsame Ursache).

(c) **Schwächste Korrelation:** Eisverkauf und Sonnenstunden ($r = 0{,}58$) weisen die schwächste Korrelation auf. Inhaltlich bedeutet das: Die Anzahl der Sonnenstunden allein erklärt den Eisverkauf weniger gut als die Temperatur. Möglicherweise gibt es an bewölkten aber warmen Tagen ebenfalls hohen Eisverkauf – die Temperatur ist also der entscheidendere Treiber als das bloße Sonnenscheinen.

(d) **Problem mit Pearson für Altersgruppen:** Pearson setzt voraus, dass beide Variablen *metrisch skaliert* sind und ein linearer Zusammenhang vorliegt. "Kundenaltersgruppe" (jung, mittel, alt) ist eine *ordinale* Variable – die Abstände zwischen den Stufen sind nicht gleichmäßig und nicht quantifizierbar. Eine Kodierung als 1, 2, 3 wäre willkürlich.
Alternative: *Spearman-Rangkorrelation* – diese setzt nur eine Rangordnung voraus, keine metrische Skala, und ist robust gegenüber Ausreißern und nicht-normalverteilten Daten.

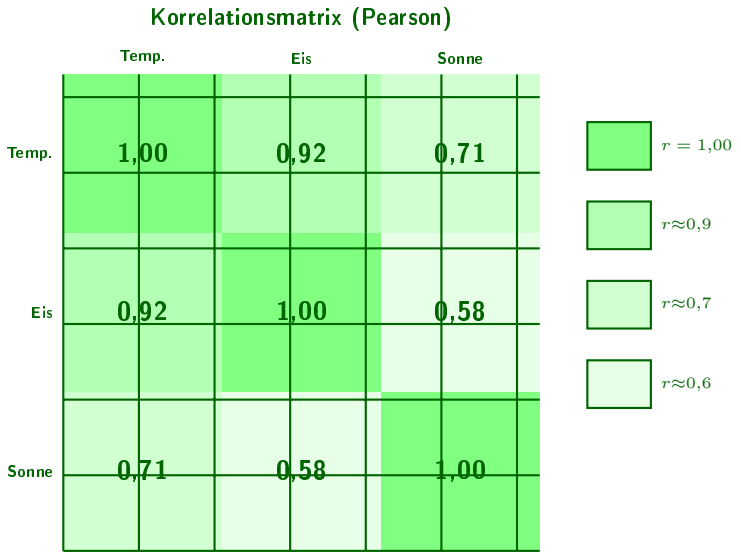

Aufgabe 5 – Best Practices: Fehler identifizieren

(a) **Fehler: Abgeschnittene y-Achse.** Die y-Achse beginnt bei 980.000 € statt bei 0. Dadurch werden die Balken optisch stark verzerrt – kleine Unterschiede erscheinen als riesige Abweichungen. **Korrektur:** Die y-Achse eines Bar Charts muss immer bei 0 beginnen, da die visuelle Länge eines Balkens proportional zum absoluten Wert sein muss.

(b) **Fehler: Zu viele Linien im Line Plot.** Best Practice empfiehlt maximal 5 Linien pro Diagramm. Acht Linien überfordern den Betrachter, die Linien überlappen und einzelne Verläufe sind nicht mehr erkennbar. **Korrektur:** Aufteilung in zwei separate Diagramme (z. B. Top-4-Kategorien vs. Bottom-4), oder Aggregation auf weniger Gruppen. Alternativ Small Multiples (separate Teilplots für jede Kategorie).

(c) **Fehler: Fehlende Legende/Colorbar.** Eine Heatmap kommuniziert Werte ausschließlich über Farbe. Ohne Colorbar ist nicht erkennbar, welcher Farbton welchem Korrelationswert entspricht – die Visualisierung ist unlesbar. **Korrektur:** Immer eine Colorbar mit Skalierung hinzufügen (z. B. -1 bis $+1$ für Korrelationsmatrizen, mit klarer Farbzuordnung von z. B. Rot über Weiß bis Grün).

(d) **Fehler: Zu wenige Bins.** Nur 3 Bins für 500 Datenpunkte führt zu massivem *Underfitting* der Verteilung. Details der Verteilung (Modalwert, Schiefe, Bimodalität) werden unsichtbar. **Korrektur:** Mit dem Square-Root-Ansatz: $k = \lceil\sqrt{500}\rceil = \lceil 22{,}4\rceil = 23$ Bins – das würde die Verteilungsform deutlich besser sichtbar machen.

(e) **Zwei Fehler: Zu viele Segmente und ähnliche Farben.** Acht Segmente sind für einen Pie Chart zu viele – kleine Segmente (1 %) sind kaum erkennbar, und Winkelunterschiede bei ähnlich großen Segmenten sind schwer zu vergleichen. Ähnliche Farbtöne machen die Unterscheidung der Segmente zusätzlich unmöglich. **Korrektur:** Kleine Segmente in einer "Sonstige"-Kategorie zusammenfassen; gut unterscheidbare Farben verwenden. Alternativ: Wechsel zu einem Bar Chart, der Größenvergleiche präziser ermöglicht.

Aufgabe 6 – Vergleichstabelle Visualisierungsarten

Typ	Datentyp	Typischer Einsatz	Stärke	Schwäche
Bar Plot	Kategorial	Vergleich diskreter Kategorien (Umsatz je Produkt, Länderdaten)	Einfach lesbar, klare Vergleiche, viele Varianten (grouped, stacked)	Ungeeignet für Verläufe; Basislinie bei 0 zwingend
Line Plot	Numerisch, zeitlich	Zeitreihen, Wachstumskurven, Trendanalyse	Veränderungsrate gut sichtbar; flexibel bei Basislinie	Ungeeignet für kategoriale Daten; max. 5 Linien empfohlen
Histogram	Numerisch, stetig	Verteilungsanalyse (Alter, Gewicht, Messwerte)	Zeigt Distributionsform, Modalwert, Schiefe	Ergebnis abhängig von Bin-Anzahl; keine Kategorien
Heatmap	Numerisch (Matrix)	Korrelationsmatrizen, zeitlich-räumliche Dichten	Viele Variablen gleichzeitig, Muster auf einen Blick	Colorbar zwingend; exakte Werte schwer ablesbar
Violin Plot	Numerisch, stetig	Dichteverteilung vergleichen (z. B. Gruppen)	Zeigt gesamte Verteilung inkl. Bimodalität	Weniger intuitiv; bei kleinen Stichproben irreführend
Pie Chart	Kategorial	Teil-Gesamt-Verhältnisse (Marktanteile, Budget)	Anteile sofort erkennbar bei wenigen Kategorien	Ungeeignet bei > 5 Kategorien; Winkel schwer vergleichbar

Die Wahl der richtigen Visualisierung hängt von drei Schlüsselfragen ab: 1. Welchen *Skalentyp* haben die Daten (kategorial, ordinal, metrisch)? 2. Was soll kommuniziert werden (Vergleich, Verteilung, Zusammenhang, Anteil, Verlauf)? 3. Wie viele Variablen und Datenpunkte sind beteiligt? Als Faustregel gilt: Bar Plots und Histograms für einen Blick auf eine Variable, Heatmaps und Scatter Plots für Beziehungen zwischen Variablen, Line Plots für zeitliche Entwicklungen.
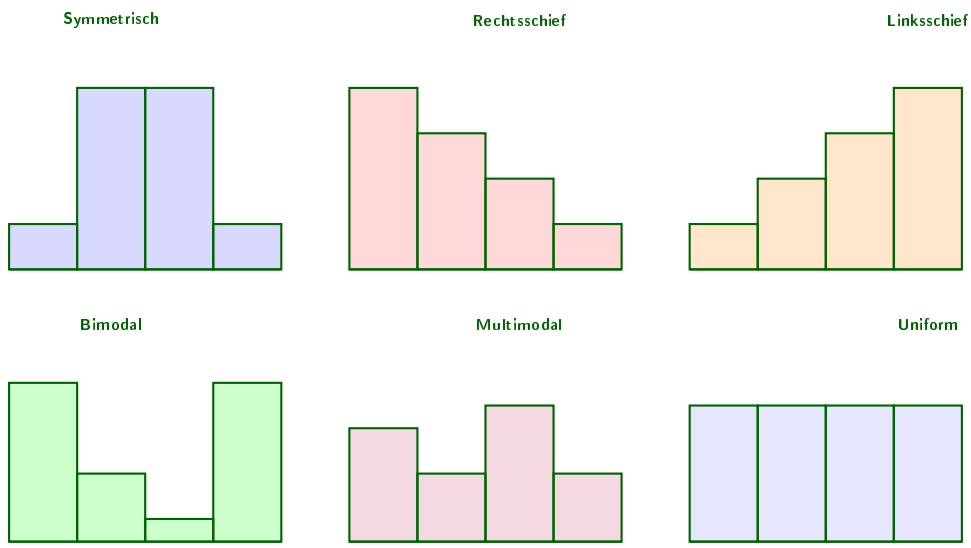
Zusatz: Die sechs Distributionsformen im Überblick