Klausur B – Grundlagen Data Science & KI

MUSTERLÖSUNG

40 Punkte | 60 Minuten

Hilfsmittel: Taschenrechner (nicht programmierbar)

Aufgabe	**1**	**2**	**3**	**4**	**5**	**6**	**7**	$\sum$
Maximale Punktzahl	6	7	6	7	5	5	4	40

1. (6 Punkte) Assoziationsanalyse

(a) **(1,5 Punkte)** Geben Sie die Formeln für **Support**, **Konfidenz** und **Lift** an. Was bedeutet ein Lift > 1, $= 1$, < 1?

Lösung:

$$\text{Support}(X) = \frac{|\{t : X \subseteq t\}|}{|T|}$$

$$\text{Konfidenz}(X \to Y) = \frac{\text{Support}(X \cap Y)}{\text{Support}(X)}$$

$$\text{Lift}(X \to Y) = \frac{\text{Support}(X \cap Y)}{\text{Support}(X) \cdot \text{Support}(Y)}$$

Lift > 1: Positive Assoziation – X und Y werden häufiger zusammen gekauft als bei Unabhängigkeit erwartet.
Lift $= 1$: Unabhängigkeit – kein Zusammenhang zwischen X und Y.
Lift < 1: Negative Assoziation – X und Y werden seltener zusammen gekauft als erwartet.

(b) **(3 Punkte)** Berechnung für die Regel **Brot** $\to$ **Milch**:

Trans.	**Brot**	**Milch**	**Butter**	**Käse**
T1	✓	✓		✓
T2	✓		✓	
T3		✓	✓	✓
T4	✓	✓	✓	
T5	✓			✓
T6		✓	✓	
T7	✓	✓	✓	✓
T8	✓	✓		
T9			✓	✓
T10	✓	✓	✓	
T11	✓		✓	
T12		✓		✓

Lösung:

Brot kommt vor in: T1, T2, T4, T5, T7, T8, T10, T11 → 8 Transaktionen.

$\text{Support(Brot)} = \frac{8}{12} = \frac{2}{3} \approx 0{,}667$

Milch kommt vor in: T1, T3, T4, T6, T7, T8, T10, T12 → 8 Transaktionen.

$\text{Support(Milch)} = \frac{8}{12} = \frac{2}{3} \approx 0{,}667$

Brot ∩ **Milch** kommt vor in: T1, T4, T7, T8, T10 → 5 Transaktionen.

$\text{Support(Brot} \cap \text{Milch)} = \frac{5}{12} \approx 0{,}417$

$\text{Konfidenz(Brot} \rightarrow \text{Milch)} = \frac{\text{Support(Brot} \cap \text{Milch)}}{\text{Support(Brot)}} = \frac{5/12}{8/12} = \frac{5}{8} = 0{,}625 = 62{,}5\,\%$

$\text{Lift(Brot} \rightarrow \text{Milch)} = \frac{\text{Support(Brot} \cap \text{Milch)}}{\text{Support(Brot)} \cdot \text{Support(Milch)}} = \frac{5/12}{(8/12) \cdot (8/12)} = \frac{5/12}{64/144} = \frac{5/12}{4/9} = \frac{5 \cdot 9}{12 \cdot 4} = \frac{45}{48} = 0{,}9375$

(c) **(1,5 Punkte)** Interpretation des Lift-Ergebnisses.

Lösung:

Lift $= 0{,}9375 < 1 \rightarrow$ **negative Assoziation**. Brot und Milch werden nicht häufiger zusammen gekauft als bei Unabhängigkeit erwartet. Die Kaufwahrscheinlichkeit von Milch sinkt sogar leicht, wenn Brot bereits im Warenkorb ist. Eine gezielte Cross-Selling-Aktion „Brot + Milch“ wäre daher nicht empfehlenswert.

2. (7 Punkte) Decision Trees & Ensemble-Methoden

(a) **(1,5 Punkte)** Vier Knotentypen eines CART + Classification vs. Regression Tree.

Lösung:

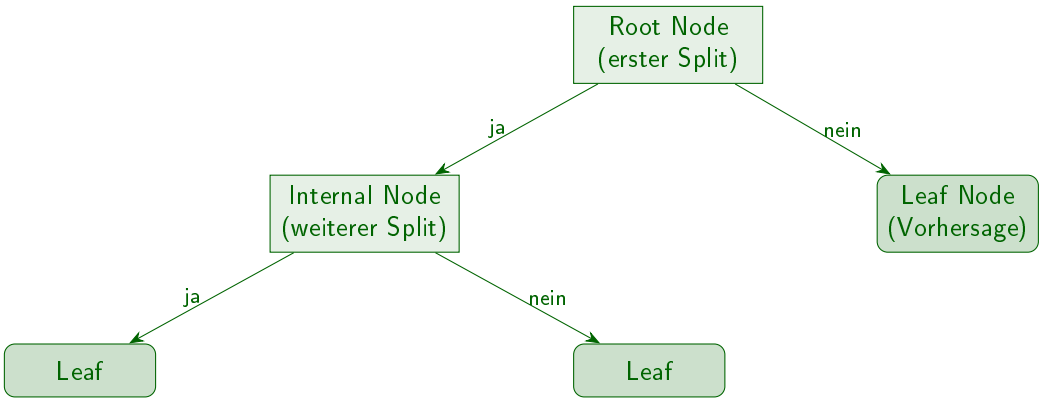

Root Node: Oberster Knoten, erster Split des gesamten Datensatzes.
Splitter/Internal Node: Zwischenknoten, die weitere Splits durchführen.
Leaf Node: Endknoten, enthält die Vorhersage (Klasse oder Wert).

Classification Tree: Kategoriale Zielvariable → Majority Voting in Blättern.
Regression Tree: Kontinuierliche Zielvariable → Mittelwert in Blättern.

(b) **(1 Punkt)** Missing Values und Surrogate Rules.

Lösung:
Der Algorithmus prüft, welche Zuordnung (alle Missings links oder rechts) zur höchsten Purity führt. **Surrogate Rules:** Ersatzvariable für den Split, die bei fehlenden Werten der primären Split-Variable verwendet wird. Die Surrogate-Variable hat eine ähnliche Trennwirkung wie die Originalvariable.

(c) **(1,5 Punkte)** Pre-Pruning vs. Post-Pruning.

Lösung:
Pre-Pruning: Stopp *während* des Baumwachstums basierend auf Information Gain / Schwellenwerten (z. B. minimale Blattgröße, maximale Tiefe). Risiko: Zu frühes Stoppen kann gute Splits verpassen.

Post-Pruning: Baum *vollständig* wachsen lassen, dann zurückschneiden (z. B. Cost-Complexity Pruning). Vorteil: Berücksichtigt den gesamten Baum.

Ziel: Optimaler Baum mit niedrigem Bias + niedriger Varianz → gute Generalisierung, Vermeidung von Overfitting.

(d) **(2 Punkte)** Bagging vs. Boosting.

Lösung:
Bagging: K Bootstrapped Samples → K Bäume **parallel** trainiert → Aggregation (Mehrheitsvotum / Mittelwert). Reduziert **Varianz** (Bias bleibt gleich).

Boosting (AdaBoost): K Bäume **sequenziell** trainiert. Nach jeder Iteration: Gewichte auf fehlklassifizierte Fälle erhöhen. Gewichtsformel (Arc-x4): $w_i = \frac{1+f_i^4}{\sum(1+f_i^4)}$, wobei f_i die Anzahl der Fehlklassifikationen von Beobachtung i ist. Reduziert **Bias** (und teils Varianz).

	Bagging	**Boosting**
Training	parallel	sequenziell
Reduziert	Varianz	Bias
Gewichtung	gleich	fehlklassifizierte hoch

(e) **(1 Punkt)** Random Forest, mtry und OOB.

Lösung:
Random Forest = Bagging + zufällige Feature-Auswahl pro Split (**mtry**). mtry = Anzahl zufällig ausgewählter Features pro Split-Entscheidung ($\approx \sqrt{p}$ für Klassifikation, $\approx p/3$ für Regression). **OOB-Sample** = Beobachtungen, die nicht in einem Bootstrap-Sample enthalten sind ($\approx 37\,\%$) $\rightarrow$ zur Modellkalibrierung/Validierung ohne separates Testset.

3. (6 Punkte) Neuronale Netze

(a) **(1 Punkt)** Biologische Analogie.

Lösung:

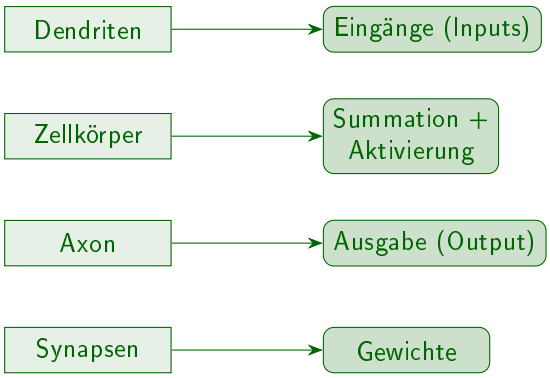

Dendriten → Eingänge (Inputs), Zellkörper → Summation + Aktivierungsfunktion, Axon → Ausgabe (Output), Synapsen → Gewichte (Verbindungen zwischen Neuronen).

(b) **(1 Punkt)** Aufbau eines neuronalen Netzes.

Lösung:
Input Layer: Eingabe-Features (eine Neuron pro Variable).
Hidden Layer(s): Verarbeitungsschichten mit nichtlinearen Transformationen.
Output Layer: Ausgabeschicht (1 Neuron für Regression, k Neuronen für k-Klassen-Klassifikation).
Tiefe = Anzahl Hidden Layers → bestimmt die Komplexität des Netzes (Deep Learning: ≥ 2 Hidden Layers).

(c) **(2,5 Punkte)** Wahrheitstabelle AND-Funktion mit $w_1 = w_2 = 1$, $T = 1{,}5$.

Lösung:

x_1	x_2	$\sum w_i x_i$	$\geq T = 1{,}5$?	Output
0	0	$0 \cdot 1 + 0 \cdot 1 = 0$	Nein $(0 < 1{,}5)$	0
0	1	$0 \cdot 1 + 1 \cdot 1 = 1$	Nein $(1 < 1{,}5)$	0
1	0	$1 \cdot 1 + 0 \cdot 1 = 1$	Nein $(1 < 1{,}5)$	0
1	1	$1 \cdot 1 + 1 \cdot 1 = 2$	Ja $(2 \geq 1{,}5)$	1

→ AND-Funktion korrekt abgebildet! Nur wenn *beide* Eingänge 1 sind, ist die gewichtete Summe $\geq T$.

(d) **(1,5 Punkte)** XOR-Problem.

Lösung:
XOR (Exclusive OR): Output $= 1$ bei genau einer 1. Ein einzelnes Neuron definiert eine **lineare Trennlinie** im 2D-Raum. Die XOR-Datenpunkte ($(0{,}0) \to 0$, $(0{,}1) \to 1$, $(1{,}0) \to 1$, $(1{,}1) \to 0$) sind **nicht linear trennbar** – die „1er“ liegen diagonal gegenüber.

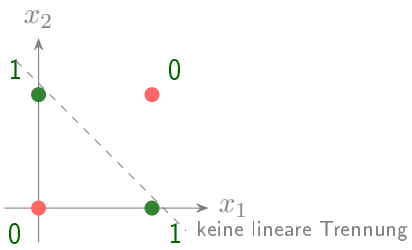

Lösung: Mehrstufiges Netz mit mindestens einem Hidden Layer, das nichtlineare Entscheidungsgrenzen lernen kann.

4. (7 Punkte) ROC/AUC & Kostenfunktion

(a) **(2 Punkte)** ROC-Kurve.

Lösung:

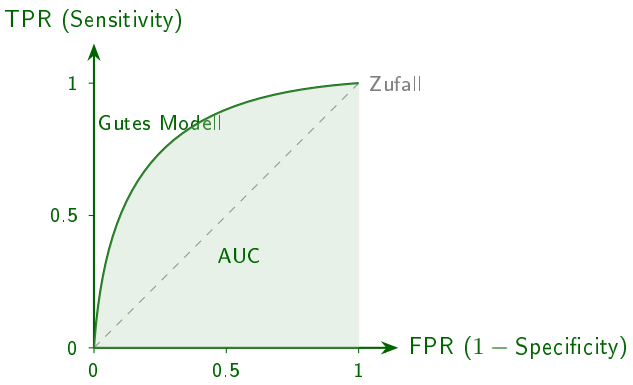

X-Achse: FPR $= 1 -$ Specificity (Anteil fälschlich als positiv klassifizierter Negativer).
Y-Achse: Sensitivity / TPR (Anteil korrekt erkannter Positiver).
Diagonale: Zufallsmodell (AUC $= 0{,}5$).
Kurve oben links: Gutes Modell (hohe TPR bei niedriger FPR).
Kurve unter Diagonale: Schlechter als Zufall $\rightarrow$ Vorhersage umkehren.

(b) **(1,5 Punkte)** Gini-Koeffizient und AUC-Interpretation.

Lösung:
Gini $= 2 \cdot$ AUC $- 1 = 2 \cdot 0{,}82 - 1 = \mathbf{0{,}64}$

AUC-Interpretation:

- $0{,}5$ = Zufallsmodell (keine Trennkraft)
- $0{,}7$–$0{,}8$ = akzeptables Modell
- $0{,}8$–$0{,}9$ = gutes Modell ($\leftarrow$ hier: 0,82)
- $> 0{,}9$ = exzellentes Modell

(c) **(3,5 Punkte)** Direktmarketing-Szenario.

	Predicted Response	**Predicted No Response**
Actual Response	TP = 80	FN = 40
Actual No Response	FP = 180	TN = 1.700

Lösung:
Mit Modell (nur predicted Response anschreiben: $80 + 180 = 260$ Briefe):

- Revenue aus TP: $80 \times (200 - 3) = 80 \times 197 = 15.760$ €
- Kosten aus FP: $180 \times 3 = 540$ €
- Entgangener Gewinn aus FN (Opportunity Cost): $40 \times 200 = 8.000$ €
- Kosten TN: 0 €

Nettoergebnis mit Modell: $15.760 - 540 = \mathbf{15.220}$ €

EV pro Prediction $= \dfrac{15.220}{2.000} = \mathbf{7{,}61}$ €

Naiv-Strategie (alle 2.000 anschreiben):

- Response-Rate: $\frac{80+40}{2.000} = \frac{120}{2.000} = 6\,\%$

- Revenue: $120 \times 200 = 24.000$ €
- Kosten: $2.000 \times 3 = 6.000$ €
- Nettoergebnis: $24.000 - 6.000 = \mathbf{18.000}$ €
- EV $= \frac{18.000}{2.000} = \mathbf{9{,}00}$ €

$\rightarrow$ Die **Naiv-Strategie ist hier besser** ($9{,}00 > 7{,}61$ €), weil das Modell 40 FN produziert und damit 8.000 € Opportunity Cost verursacht. Das Modell spart zwar Briefkosten, verpasst aber zu viele Responder.

5. (5 Punkte) Clustering & Anomalieerkennung

(a) **(1,5 Punkte)** Vier Schritte des k-means-Algorithmus.

Lösung:

1. **Initialisierung:** Zufällige Platzierung von k Clusterzentren (Zentroide).
2. **Zuordnung:** Jeder Datenpunkt wird dem nächstgelegenen Zentrum zugeordnet (z. B. euklidische Distanz).
3. **Neuberechnung:** Zentren als Mittelwerte der zugeordneten Punkte neu berechnen.
4. **Iteration:** Wiederhole Schritte 2–3 bis Konvergenz (keine Änderung der Zuordnungen).

(b) **(1 Punkt)** Elbow-Methode.

Lösung:
Man berechnet die **Within-Cluster-Sum-of-Squares (WCSS)** für verschiedene k-Werte und plottet sie. Der „Ellbogen" (Knick) im Diagramm zeigt das optimale k an, ab dem zusätzliche Cluster kaum noch Verbesserung (Reduktion der WCSS) bringen. Wird verwendet, um die **optimale Clusteranzahl** zu bestimmen.

(c) **(1,5 Punkte)** Boxplot vs. PCA + Isolation Forest.

Lösung:
Boxplot (univariat): Analyse einzelner Variablen (z. B. IQR-Regel: Werte $> Q_3 + 1{,}5 \cdot \text{IQR}$ oder $< Q_1 - 1{,}5 \cdot \text{IQR}$). Leicht interpretierbar, geeignet für einfache Fälle mit wenigen Variablen.

PCA + Isolation Forest (multivariat): Für hochdimensionale Daten. PCA reduziert Dimensionen, Isolation Forest erkennt Anomalien im n-dimensionalen Raum, die univariat nicht sichtbar sind (z. B. ungewöhnliche Kombinationen normaler Einzelwerte).

$\rightarrow$ Multivariater Ansatz bei vielen Variablen und komplexen Zusammenhängen.

(d) **(1 Punkt)** Use Case Computerchiphersteller.

Lösung:
Ausgangslage: 50 Mio. Chips/Jahr, nur 50 echte Ausfälle ($\rightarrow$ extrem seltene Events), 8.000 Chips pro Wafer, 560+ Produktionsvariablen.

Ansatz: PCA zur Dimensionsreduktion (560+ Variablen $\rightarrow$ wenige Hauptkomponenten), dann Isolation Forest zur Anomalieerkennung.

Ergebnis: 50 % der Ausfälle vermieden bei nur 6 % Material Loss – deutliche Kostenersparnis trotz seltenem Event.

6. (5 Punkte) Methodenüberblick & Regression

(a) **(1 Punkt)** 4 Analyserichtungen + Moving Window.

Lösung:

4 Analyserichtungen in Data Science:

1. General Data Science (Regression, Klassifikation, Clustering, Assoziation, Anomalie)
2. Text Mining / NLP
3. Image Recognition / Computer Vision
4. Time Series (Zeitreihenanalyse)

Moving Window Concept: Zeitreihe wird in überlappende Fenster zerlegt. Beispiel bei Window-Größe $= 3$:
Input $[y_1, y_2, y_3] \rightarrow$ Label y_4, Input $[y_2, y_3, y_4] \rightarrow$ Label y_5, usw.
Dadurch wird das Zeitreihenproblem in ein Supervised-Learning-Problem überführt.

(b) **(2,5 Punkte)** Lineare Regression $\hat{Y} = 2{,}0 + 1{,}5 \cdot X$.

Lösung:

Beob.	X	Y	$\hat{Y} = 2{,}0 + 1{,}5 \cdot X$	Residuum $= Y - \hat{Y}$
1	2	6	$2{,}0 + 1{,}5 \cdot 2 = 5{,}0$	$6 - 5 = \mathbf{1{,}0}$
2	4	10	$2{,}0 + 1{,}5 \cdot 4 = 8{,}0$	$10 - 8 = \mathbf{2{,}0}$
3	6	8	$2{,}0 + 1{,}5 \cdot 6 = 11{,}0$	$8 - 11 = \mathbf{-3{,}0}$
4	8	15	$2{,}0 + 1{,}5 \cdot 8 = 14{,}0$	$15 - 14 = \mathbf{1{,}0}$
5	10	18	$2{,}0 + 1{,}5 \cdot 10 = 17{,}0$	$18 - 17 = \mathbf{1{,}0}$

Summe der Residuen: $1{,}0 + 2{,}0 + (-3{,}0) + 1{,}0 + 1{,}0 = 2{,}0$ (nahe 0, typisch für OLS-Regression).

(c) **(1,5 Punkte)** Overfitting, Underfitting, Good Fit.

Lösung:

Modell 1 (Trainingsfehler 2 %, Testfehler 25 %): $\rightarrow$ **Overfitting**.
Niedriger Trainingsfehler aber hoher Testfehler $\rightarrow$ Modell hat Rauschen gelernt, generalisiert nicht. Große Lücke zwischen Training und Test.

Modell 2 (Trainingsfehler 15 %, Testfehler 18 %): $\rightarrow$ **Good Fit**.
Beide Fehler moderat und nah beieinander $\rightarrow$ gute Balance zwischen Bias und Varianz.

Modell 3 (Trainingsfehler 35 %, Testfehler 37 %): $\rightarrow$ **Underfitting**.
Beide Fehler hoch $\rightarrow$ Modell zu einfach, erfasst die Muster in den Daten nicht (hoher Bias).

7. (4 Punkte) Wahr oder Falsch

(a) **(0,5 Punkte)** Korrelation impliziert Kausalität, insbesondere bei großen Datenmengen.

Lösung:
Falsch. Korrelation $\neq$ Kausalität, auch bei großen Datenmengen nicht. Scheinkorrelationen (Spurious Correlations) entstehen durch Confounding-Variablen oder Zufall. Für Kausalaussagen braucht es Theorie und kontrollierte Experimente.

(b) **(0,5 Punkte)** Recommendation Engines können durch verschiedene Algorithmen gestaltet werden, darunter Matrix Factorization, Classification und Clustering.

Lösung:
Wahr. Recommendation Engines können durch Matrix Factorization, Classification, Clustering und Rule-Based Models gestaltet werden.

(c) **(0,5 Punkte)** Bei der Prognosemodellierung sollten mindestens 1.000 Positivfälle („1er“) im Datensatz vorhanden sein.

Lösung:
Wahr. Rule of Thumb: ≥ 1.000 „1er“ (Positivfälle) für robuste Prognosemodellierung.

(d) **(0,5 Punkte)** Der RMSE (Root Mean Squared Error) eignet sich nur für binäre Klassifikation.

Lösung:
Falsch. RMSE ist ein Fehlermaß für *kontinuierliche* Prognosen (Regression). Je niedriger der RMSE, desto besser. Für binäre Klassifikation verwendet man Accuracy, AUC, F1-Score etc.

(e) **(0,5 Punkte)** Pre-Pruning schneidet einen vollständig gewachsenen Baum nachträglich zurück, Post-Pruning stoppt das Wachstum frühzeitig.

Lösung:
Falsch. Die Begriffe sind vertauscht. **Post**-Pruning schneidet einen vollständig gewachsenen Baum nachträglich zurück. **Pre**-Pruning stoppt das Wachstum frühzeitig basierend auf Information Gain / Schwellenwerten.

(f) **(0,5 Punkte)** AIC und SBC (BIC) sind absolute Gütemaße, die ohne Vergleichsmodell interpretierbar sind.

Lösung:
Falsch. AIC und SBC/BIC sind *relative* Maße zum Modellvergleich. Ein einzelner AIC-Wert ist nicht absolut interpretierbar – nur der Vergleich zwischen Modellen ist aussagekräftig (niedrigerer Wert = besseres Modell).

(g) **(0,5 Punkte)** Laut dem Modellübersicht-Cheat-Sheet können Decision Trees und Random Forest mit Missing Values umgehen, lineare Regression und neuronale Netze hingegen nicht.

Lösung:
Wahr. Decision Trees und Random Forest können Missing Values nativ handhaben (Surrogate Rules). Lineare Regression und neuronale Netze benötigen vorherige Imputation fehlender Werte.

(h) **(0,5 Punkte)** Der Gini-Koeffizient und die AUC stehen in keinem direkten mathematischen Zusammenhang.

Lösung:

Falsch. Es gilt Gini $= 2 \cdot$ AUC $- 1$. Bei AUC $= 0{,}5$ (Zufall) ist Gini $= 0$, bei AUC $= 1{,}0$ (perfekt) ist Gini $= 1{,}0$.