Lernzettel – Grundlagen Data Science & KI

Inhaltsverzeichnis

1 Grundlagen Data Science & KI (BUT) **2**

1.1 Data Science – Definition & Abgrenzung . . . 2
1.2 Big Data – Die 7 V's . . . 2
1.3 KI – Begriffsabgrenzung . . . 2
1.4 Die Reise der Analytik (Analytics Maturity) . . . 2
1.5 Prozessmodelle . . . 3
1.6 Data Literacy & AI Literacy . . . 4
1.7 Data Scientist – Rolle & Kompetenzen . . . 5
1.8 Datenverständnis & Deskriptive Statistik . . . 5
1.9 Methodenüberblick . . . 6
1.10 Baumbasierte Verfahren . . . 6
1.11 Neuronale Netze . . . 7
1.12 Modellevaluation . . . 7
1.13 Text Mining, NLP & NLU . . . 8
1.14 Computer Vision & Image Recognition . . . 8
1.15 Ethik, Regulierung & Nachhaltigkeit . . . 8
1.16 Data Strategy & Implementierung . . . 9
1.17 Datenquellen-Portale . . . 10
1.18 Use Cases nach Funktionsbereich . . . 10
1.19 Modellübersicht (Cheat Sheet) . . . 10

Data Science – Definition & Abgrenzung

Data Science = Extraktion von Wissen aus Daten. Schnittmenge aus (Venn-Diagramm nach Drew Conway):

- Computer Science / IT
- Mathematik & Statistik
- Business-/Domänenwissen

Überlappungen: CS ∩ Math = Software-Entwicklung; Math ∩ Business = Empirische Forschung; CS ∩ Business = AI/ML; Alle drei = **Data Science**.

Wertschöpfungskette: Daten → Information → Wissen/Insight → Weisheit (angewandt). Bsp. Ampel: Rohdaten (Rot, IP, v2.0) → Information (Ampel ist rot) → Wissen (meine Ampel ist rot) → Weisheit (ich halte an).

Kontext – Industrielle Revolutionen: 1.0 Mechanisierung (Wasser-/Dampfkraft, Ende 18. Jh.) → 2.0 Elektrifizierung (Massenproduktion, Ende 19. Jh.) → 3.0 Automatisierung (Computer/Robotik, 1970er) → 4.0 Vernetzung (Smart Factory, IoT, ML, heute).

Warum jetzt? Steigende Datenmengen (Digitalisierung) + steigende Rechenleistung (GPUs). Marktkapitalisierung 2024: Top-10 dominiert von Technologieunternehmen (Apple, NVIDIA, Microsoft, Alphabet, Amazon), die Daten strategisch nutzen – 2010 noch Öl-/Rohstoffkonzerne.

Big Data – Die 7 V's

1. **Volume** – Datenmenge
2. **Variety** – Datenvielfalt (strukturiert, unstrukturiert)
3. **Velocity** – Geschwindigkeit der Datenerzeugung
4. **Veracity** – Datenqualität / Glaubwürdigkeit
5. **Variability** – Schwankungen in Datenströmen
6. **Visualization** – Darstellung
7. **Value** – Geschäftswert

V's 1–3 nach Laney (2001), V4 nach IBM (2011), V5–7 nach McNulty (2014).

Big-Data-Geschichte: 1869 Garfield: Statistik verändert Gesellschaftssteuerung; 1890 Hollerith-Lochkarten; 1996 digitale Speicherung günstiger als Papier; 1997 Cox & Ellsworth prägen "Big Data"; 2001 Laney: 3 V's.

Erstes Big-Data-Problem: US-Volkszählung 1880 ($N = 50$ Mio., > 80 Variablen), Bearbeitung > 7 Jahre. **Lösung:** Hollerith-Tabellierungssystem (Lochkarten) → Volkszählung 1890 in 6 Wochen. Herman Hollerith wurde außerdem als Gründer von IBM bekannt.

KI – Begriffsabgrenzung

Hierarchie (Teilmengen):

- **Algorithmus:** automatisierte Anweisung
- **Artificial Intelligence (AI):** Algorithmen, die menschliches Verhalten nachahmen
- **Machine Learning (ML):** Algorithmen, die lernen, ohne explizit programmiert zu werden
- **Deep Learning:** neuronale Netze mit vielen Schichten
- **Generative AI:** z. B. ChatGPT – erzeugt neue Inhalte

AI-Definition: "The ability of a computer system to perform tasks that have typically required human smarts, such as understanding speech, recognizing faces, finding patterns, and making decisions."

ChatGPT: Release November 2022 durch OpenAI. GPT = Generative Pre-trained Transformer. Sprachmodell, das natürliche Sprache versteht und generiert; trainiert auf vielfältigen Datenquellen für breites Sprachverständnis. Anwendungen: Texterstellung, Fragebeantwortung, Codegenerierung.

Traditionelle Programmierung vs. ML:

- Traditionell: Regeln + Daten → Antworten
- ML: Daten + Antworten → Regeln → zukünftige Antworten

Beispiel (Sonnenbrand): Daten: Person, Wetter, Sonnencreme, Sonnenbrand (5 Datensätze). ML erlernt die Regel: If (Weather = Sunny & Sunscreen = No) Then Sunburn.

Drei ML-Lernparadigmen:

1. **Supervised Learning** – gelabelte Daten (Klassifikation, Regression)
2. **Unsupervised Learning** – keine Labels (Clustering, Assoziation)
3. **Reinforcement Learning** – Belohnung/Bestrafung durch Umgebung

KI-Geschichte (Meilensteine)

1936	Turing: Rechenmaschine kann kognitive Prozesse ausführen
1956	McCarthy prägt den Begriff "Künstliche Intelligenz"
1966	Weizenbaum (MIT): ELIZA – erster Chatbot
1972	MYCIN – Expertensystem in der Medizin (Stanford)
1986	NETtalk – neuronales Netz lernt sprechen
1997	IBM Deep Blue schlägt Schachweltmeister
2011	Apple Siri – KI im Alltag
2018	Google Duplex – autonomer Telefonanruf
2022	OpenAI ChatGPT (Nov. 2022, basiert auf GPT-3.5) → Durchbruch generativer KI

KI-Einfluss auf den Arbeitsmarkt

- 85 Mio. Jobs werden in den nächsten 10 Jahren durch KI wegfallen
- 130+ Mio. Arbeitnehmer weltweit benötigen Umschulung/Weiterbildung
- ∼100 Mio. neue Jobs bis 2030 durch KI möglich
- 15,7 Bio. USD potentieller Wirtschaftswert durch KI

(Quellen: McKinsey, Harvard Business Review)

Die Reise der Analytik (Analytics Maturity)

1. **Descriptive Analytics** – Was ist passiert? (BI, Reporting, Dashboards)
2. **Diagnostic Analytics** – Warum? (Root Cause Analysis, EDA)
3. **Predictive Analytics** – Was wird passieren? (ML-Modelle, Prognose)
4. **Prescriptive Analytics** – Was tun? (KI, Simulation, Optimierung)

Komplexität und Wertschöpfung steigen von 1 → 4.

BI vs. Data Science:

	BI	Data Science
Perspektive	rückwärtsgewandt	vorausschauend
Reaktivität	reaktiv	proaktiv
Analytik	deskriptiv, diagnostisch	prädiktiv, präskriptiv
Methoden	Reporting, Dashboards	Modelle, Simulation
Tools	Tableau, Power BI, Excel	R, Python, SQL, Shiny

Prozessmodelle

CRISP-DM

CRISP-DM (Cross Industry Standard Process for Data Mining, Shearer 2000): 6 Phasen, iterativer Kreislauf – Rücksprünge zwischen Phasen möglich. Entwickelt durch Konsortium aus NCR, DaimlerChrysler, SPSS und OHRA.

1. **Business Understanding** – Geschäftsziele definieren (wahres Ziel des Kunden verstehen, um nicht "richtige Antworten auf falsche Fragen" zu liefern), Situation bewerten (Ressourcen, verfügbare Daten, Annahmen, Risiken, Glossar, Kosten-Nutzen-Analyse), DM-Ziele ableiten (in Geschäftsbegriffen formulieren, Erfolgskriterien je Geschäftsziel), Projektplan erstellen
2. **Data Understanding** – 4 Teilschritte: (a) *Sammlung* der Ausgangsdaten (erfassen, integrieren, Zeitverzögerungen prüfen); (b) *Qualitätsprüfung* (Vollständigkeit, fehlende Attribute, Plausibilität, Konsistenz); (c) *Beschreibung* (Eigenschaften, Formate, Anzahl Felder/Records); (d) *Exploration* (Visualisierung, Querying, univariate + bivariate Statistiken)
3. **Data Preparation** – Daten selektieren (Relevanz, Qualität, technische Grenzen), bereinigen (ohne saubere Daten sind Ergebnisse fragwürdig), konstruieren (neue Records, abgeleitete Attribute z. B. Fläche = Länge × Breite, Transformationen wie Altersgruppen), integrieren (Tabellen joinen, Aggregation z. B. ein Record pro Kunde), formatieren (illegale Zeichen entfernen, Reorganisation)
4. **Modeling** – Modellierungstechnik wählen (z. B. C4.5, Backpropagation), **Testdesign VOR Modellbau** erstellen (Train/Test-Split, Error Rates als Qualitätsmaß), Modell bauen, Modell bewerten (Zusammenarbeit mit Domänenexperten, Modelle ranken)
5. **Evaluation** – Ergebnisse gegen Geschäftsziele bewerten, Prozess reviewen, nächste Schritte bestimmen (Deploy oder weitere Iteration)
6. **Deployment** – Deployment-Strategie, Monitoring & Maintenance planen, Abschlussbericht, Projekt-Review

Data Preparation beansprucht 50–70 % des Gesamtaufwands. Typische Aufwandsverteilung: Integration & Aufbereitung 30 %, Datensichtung & Verständnis 35 %, Predictive Modelling 5 %, Clustering & Dashboarding 10 %, Releasezeit/Ausfälle 20 %. *Aufwandsverteilung nach CRISP-DM (Shearer 2000):* Data Preparation 50–70 %, Data Understanding 20–30 %, Modeling/Evaluation/Business Understanding je 10–20 %, Deployment Planning 5–10 %. IBM veröffentlichte ASUM-DM als Erweiterung von CRISP-DM.

Data-Mining-Problemtypen (nach CRISP-DM, Shearer 2000):

- **Beschreibung/Zusammenfassung** – Dateneigenschaften in elementarer und aggregierter Form beschreiben (Reporting, OLAP)
- **Segmentierung** – Daten in bedeutungsvolle Untergruppen trennen (Clustering, NN, Visualisierung)
- **Konzeptbeschreibung** – Verständliche Beschreibung von Konzepten/Klassen; Erkenntnisse statt Vorhersage (Rule Induction, Conceptual Clustering)
- **Klassifikation** – Neuen Objekten korrekte Labels zuweisen (Discriminant Analysis, Decision Trees, NN, KNN, Genetic Algorithms)
- **Prognose (Regression)** – Kontinuierliches Zielattribut vorhersagen; bei Zeitreihen: Forecasting (Regression, Regression Trees, NN, Box-Jenkins)
- **Abhängigkeitsanalyse** – Signifikante Zusammenhänge finden; Assoziationsregeln (häufig zusammen auftretende Items); Sequenzmuster (Reihenfolge von Ereignissen) (Association Rules, Bayesian Networks, Korrelationsanalyse)

DASC-PM

DASC-PM (Data Science Process Model, Schulz et al. 2022): Erweiterung von CRISP-DM für DS-Projekte.

Abgrenzung zu anderen Prozessmodellen:

- **KDD** (Fayyad et al. 1996) – Knowledge Discovery in Databases; Fokus auf Datenbank-zentrierte Wissensextraktion
- **SEMMA** (SAS) – Sample, Explore, Modify, Model, Assess; tool-spezifisch (SAS)
- **TDSP** (Microsoft) – Team Data Science Process; agil, cloud-orientiert
- **CRISP-DM** (Shearer 2000) – am weitesten verbreitet, aber kein Fokus auf Wissenschaftlichkeit, Rollen, IT-Infrastruktur

DASC-PM ergänzt CRISP-DM um: Querschnittsthemen (Domäne, Wissenschaftlichkeit, IT-Infrastruktur), explizite Rollenverteilung und Berücksichtigung gesellschaftlicher Auswirkungen.

DS-Definition (DASC-PM): Interdisziplinäres Fachgebiet, das mit wissenschaftlichem Vorgehen, semiautomatisch und unter Anwendung bestehender oder zu entwickelnder Analyseverfahren Erkenntnisse aus teils komplexen Daten extrahiert und unter Berücksichtigung gesellschaftlicher Auswirkungen nutzbar macht.

8 Merkmale der Definition:

1. **Interdisziplinarität** – Kooperation von Mathematik, Informatik, Domänenwissen
2. **Wissenschaftlichkeit** – systematisches, nachvollziehbares Vorgehen
3. **Analyseverfahren** – bestehende anwenden oder neue entwickeln
4. **Semiautomatik** – nicht vollautomatisch; menschliche Expertise nötig
5. **Erkenntnisextraktion** – Wissen aus Daten gewinnen
6. **Datenkomplexität** – teils große, heterogene, unstrukturierte Datenmengen
7. **Nutzbarmachung** – Ergebnisse in Prozesse und Entscheidungen integrieren
8. **Gesellschaftliche Auswirkungen** – ethische, rechtliche und soziale Folgen berücksichtigen

7 Schlüsselbereiche:

- *4 zentrale:* Daten, Analyseverfahren, Nutzbarmachung, Nutzung
- *3 übergreifende:* Domäne, Wissenschaftlichkeit, IT-Infrastruktur

Wissenschaftlichkeit erfordert: **Objektivität** (unabhängig von durchführender Person), **Reliabilität** (wiederholbare Er-

gebnisse), **Validität** (misst, was es messen soll). Minimum: vollständige Replizierbarkeit + statistische Validität.

5 Phasen (iterativ, Abbruch/Rücksprung jederzeit möglich):

1. **Projektauftrag** – Use-Case-Entwicklung (Interviews, Workshops, Design Thinking), Priorisierung, Eignungsprüfung, Kosten-Nutzen-Analyse → Projektskizze
2. **Datenbereitstellung** – *Kernaufgabe Datenaufbereitung* (15 Teilaufgaben): Merkmalserzeugung, Anonymisierung, Aggregation, Annotation, Bereinigung, Filterung, Integration, Strukturierung, Transformation, Dimensionsreduzierung, Aufbereitungspläne, Formatanpassung, Protokollierung, Prozessautomatisierung, Schemaintegration. *Begleitend:* Datenmanagement (Archivierung, Datenschutz, Sicherung, Speicherung, Zugriff, Metadatenmanagement). *Explorative Datenanalyse:* Ausreißeridentifikation, Datenvalidierung, Visualisierung, zentrale Attribute identifizieren, inhaltliches Verständnis, statistische Analysen, Transformationsprüfung, fehlende Werte untersuchen → analytische Datenquelle
3. **Analyse** – *3 Kernaufgaben:* (a) Identifikation geeigneter Verfahren (Anforderungen klären, Problemklasse bestimmen, vergleichbare Problemstellungen recherchieren); (b) Anwendung (Entwicklungsumgebung aufsetzen, Dimensionsreduktion, Validität sicherstellen, mehrere Verfahren erproben, Parameterkonfiguration optimieren, Reproduzierbarkeit gewährleisten); (c) ggf. Entwicklung neuer Verfahren (Gap-Analyse, Konzeption, Test, Implementierung). *Begleitend:* Werkzeugauswahl (SW/HW-Recherche, Fähigkeitsabgleich), Evaluation (Benchmarking, Performance-Tests, Mehrwertschätzung, Verfahrensvergleich) → Analyseergebnis
4. **Nutzbarmachung** – Technisch-methodische Bereitstellung (Bericht, Modell, kont. Lernen), fachliche Bereitstellung (Schulung, Handbuch, Integration in Prozesse). *Begleitende Aufgaben:* Sicherstellung technischer Umsetzbarkeit (Zeitkritikalität, Laufzeiten, HW-/SW-Stack, Lizenzen, Betrieb/Support), Anwendbarkeitssicherstellung (Adressaten identifizieren, UI/UX-Design, Zugriff, Dokumentation, Schulungskonzept) → Analyseartefakt
5. **Nutzung** – Verwendung der Analyseartefakte. *Monitoring:* korrekte Anwendungsdomäne sicherstellen, Aussagekraft/Vorhersagegüte wiederkehrend bewerten, Nachhaltigkeit prüfen, Datenqualität neuer Daten prüfen, Fehlerberichte sammeln, Performance überwachen, Nutzungsdaten auswerten → Evaluationsbericht

Use-Case-Identifikation – Methoden:

- **Fokusgruppen** – schnelle Ergebnisse, max. 12 Personen; fördert neue Ideen, erfordert neutralen Moderator
- **Fish Bowl** (Innen-/Außenkreis) – größere Gruppen, dynamischer Wechsel; gezieltes Vorantreiben durch Innenkreis
- **Design Thinking** – Fokus auf Endanwender, interdisziplinäre Teams; eher kreativ
- **Hackathons** – Prototyp/MVP in kurzer Zeit; Wettbewerb fördert Innovation; hoher organisatorischer Aufwand

Best Practices Use-Case-Auswahl: (1) Ausrichtung an Organisations-/Bereichsstrategie; (2) Quick Wins (schnelle Erfolge mit wenig Aufwand); (3) Leuchtturmprojekte (Blueprints für zukünftige Projekte); (4) Proof of Concept (schnell und ressourcensparend, aber Gefahr von Quick-and-Dirty-Lösungen).

Eignungsprüfung: Eignung des Use Cases für DS, Eignung der Methode, Bewertung der Datengrundlage, Abgleich erwarteter Ergebnisse, Berücksichtigung früherer Projekte, Priorisierung.

6 Rollen im DASC-PM:

- **Data Scientist** – Analyseauswahl, Durchführung, Interpretation
- **Data Engineer** – Datenbeschaffung, -aufbereitung, -speicherung, IT-Infrastruktur
- **Domänenexperte** – Fachwissen der Anwendungsdomäne
- **Projektmanager** – Planung, Steuerung, Koordination
- Technischer Support – IT-Infrastruktur, Entwicklung
- Compliance-Support – Datenschutz, Regulatorik, Ethik

Unterrollen: *Data Scientist:* Data Analyst (explorative Analyse, Visualisierung), Methodenspezialist (Erforschung/Weiterentwicklung von DS-Methoden), DS Consultant (methodisches + domänenspezifisches Beratungswissen).
Data Engineer: Data Steward (Datenzugang, Datenschutz, Datenqualität).
Domänenexperte: Business Developer (domänenspezifische Use Cases), Business Analyst (Nutzung der Analysemodelle).

Kompetenzbereiche (Conway 2010): Mathematik/Statistik, Informationstechnik, Anwendungs-/Domänenwissen, Kommunikation, Strategie/Management.

3 Erfolgsfaktoren für DS-Projekte (Buck 2019):

1. Hohes Maß zielgerichteter Kommunikation & ehrliches Erwartungsmanagement
2. Ausgeprägtes Business Understanding → Matching mit Data Understanding
3. Iteratives Vorgehen mit Mut zu Entscheidungen und Fokus auf Fortschritt

5 Formen der Bereitstellung (Phase Nutzbarmachung):

1. Manuelle Verwendung (Ergebnisse in Workshops vermitteln)
2. Umsetzung der Ergebnisse (einmaliger Bericht)
3. Anwendung des trainierten Modells auf neue Daten
4. Kontinuierliches Lernen (selbsttätige Modellanpassung)
5. Veröffentlichung des entwickelten Verfahrens

4 wissenschaftliche Anforderungen an DS-Projekte:

1. Forschungsgegenstand muss für Dritte erkennbar umrissen sein
2. Resultat muss neue/neuartige Aussage sein
3. Resultat muss nützlich sein
4. Projekt muss so dokumentiert sein, dass Aussagen nachprüfbar sind (Replizierbarkeit)

Data Literacy & AI Literacy

Data Literacy = Fähigkeit, Daten zu **lesen**, mit Daten zu **arbeiten** und Ergebnisse zu **kommunizieren** (Gartner). **Neues Kernmodell** (Gartner): Neben People, Process, Technology wird **Data** zur vierten Dimension der digitalen Gesellschaft.

Skillset:

- Kritisches Denken über Analyseergebnisse
- Verstehen von Tools und Methoden
- Interpretation von Visualisierungen
- Erkennen von Fehlinterpretationen/Manipulation
- Wissen, wann Daten wofür nutzbar sind
- Data Storytelling

3 Vorteile gut strukturierter Data-Literacy-Initiativen:

1. **Transformationslust & Innovationsneugierde** – AI-Literacy-Trainings schaffen Awareness, bauen Berührungsängste ab, fördern kreative Ideen
2. **Sinnvoller Einsatz & maximaler Nutzen** – KI muss im Feld entwickelt werden, nicht im Elfenbeinturm (Bottom-up); optimiert wirtschaftliches Potenzial
3. **Weiterentwicklung & Partizipation** – Demokratisierung von AI; Mitarbeitende wachsen mit Innovationen

Data Scientist – Rolle & Kompetenzen

"Data Scientist: The Sexiest Job of the 21st Century" (Davenport & Patil, HBR 2012). Begriff 2008 geprägt von D.J. Patil (LinkedIn) & Jeff Hammerbacher (Facebook). Schlüsseltechnologien der Big-Data-Ära: Hadoop (Yahoo), Hive (Facebook), Cloud Computing, Open-Source-Tools. Patil wurde später erster *Chief Data Scientist* der US-Regierung (Obama-Administration).

Definition: Hybrid aus Data Hacker, Analyst, Communicator und Trusted Adviser. Bringt Struktur in große, unstrukturierte Datenmengen; identifiziert Datenquellen, bereinigt Daten, kommuniziert Ergebnisse visuell und verbal.

Kernkompetenzen:

- Programmierung (grundlegendste Fähigkeit)
- Kommunikation & Data Storytelling
- Intensive Neugier – unter die Oberfläche gehen, Hypothesen bilden
- Mathematik, Statistik, Informatik
- Business-Intuition & Domänenwissen
- Schnelles Lernen neuer Technologien

AutoML & Citizen Data Scientist (Davenport 2018): Automated ML (DataRobot, SAS, AutoWEKA, Google Cloud) automatisiert Datenvorbereitung, Feature Engineering, Algorithmenauswahl, Deployment. ⇒ "Citizen Data Scientists" – Analysten mit wenig DS-Erfahrung können mit AutoML-Tools arbeiten. Data Scientists bleiben relevant durch: (1) AutoML-Tools nutzen, (2) Business-Verständnis vertiefen, (3) auf nicht-automatisierbare Bereiche fokussieren (z.B. Deep Learning).

Historische Parallele: Data Scientists heute wie Wall-Street-Quants der 1980er/1990er – Physiker/Mathematiker strömten zu Investmentbanken, dann entstanden spezialisierte Master-Programme. Gleiches Muster wird für DS erwartet. IIA (2018): Übergang in eine "post-algorithmische Ära" – AutoML macht Algorithmenauswahl weniger relevant, Business-Verständnis wird wichtiger.

LinkedIn-Fallstudie (Davenport & Patil, HBR 2012): Jonathan Goldman (PhD Physik, Stanford) kam 2006 zu LinkedIn. Entwickelte "People You May Know" – empfahl Nutzern Kontakte basierend auf Profildaten und "Triangle Closing" (wenn du A und B kennst, kennen sich A und B wahrscheinlich). Ergebnis: höchste Click-Through-Rate aller Zeiten, Millionen neue Page Views, signifikanter Wachstumsschub für LinkedIn.

Hal Varian (Google Chief Economist): "Der sexy Job der nächsten 10 Jahre wird Statistiker sein."

Datenverständnis & Deskriptive Statistik

Datentypen und -formate

Datentypen: int, float, complex, bool, string.
Austauschformate: JSON, XML, CSV, TXT, SAV, DTA, RDS.

Grundbegriffe

- **Grundgesamtheit** – alle relevanten Objekte
- **Stichprobe** – Teilmenge der Grundgesamtheit
- **Merkmal** – beobachtete Eigenschaft
- **Merkmalsausprägung** – konkreter Wert eines Merkmals

Merkmalsarten: diskret, stetig, quasi-stetig.

Skalenniveaus

Nominal	Klassifikation (Geschlecht, Beruf)
Ordinal	Rangfolge, keine Differenz (Schulnoten)
Intervall	konst. Einheiten, kein natürl. Nullpunkt (Temperatur
Verhältnis	konst. Einheiten + natürl. Nullpunkt (Alter, Umsatz)

Höheres Skalenniveau ⇒ mehr Rechenoperationen möglich.

Lageparameter

- **Mittelwert** (Mean): $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ – anfällig für Ausreißer, Verhältnisskalierung nötig
- **Median**: Wert in der Mitte der sortierten Liste – robust gegenüber Ausreißern; bei gerader Anzahl: arithm. Mittel der beiden mittleren Werte
- **Modus** (Mode): häufigster Wert – auch bei Nominaldaten nutzbar
- **Quantile**: Perzentile, Quartile → Box-Whisker-Plot (Median, unteres/oberes Quartil, Whisker z.B. 1./9. Dezil, Ausreißer als Punkte)

Rechenbeispiel: Werte: $5, 9, 6, 25, 5$
Mean $= (5 + 9 + 6 + 25 + 5)/5 = 10$; Median: sortiert $5, 5, 6, 9, 25 \Rightarrow 6$; Modus $= 5$ (häufigster Wert).

Fehlende Werte

- Betroffene Zeilen löschen
- Mean/Mode Imputation
- Lineare Interpolation
- MICE (Multiple Imputation by Chained Equations)
- KNN (K-Nearest Neighbours)

Ausreißer

Zwei Arten:

- **Univariate Ausreißer** – leichter analysierbar durch Verteilungsuntersuchung (z.B. Boxplot)
- **Multivariate Ausreißer** – im n-dimensionalen Raum ($n > 3$), schwer für menschliches Gehirn → ML-Modelle nötig (z.B. PCA + Isolation Forest)

Häufigste Ursachen: Datenerfassungsfehler (menschlich), Messfehler (technisch), Fehler im Experiment, Datenverarbeitungsfehler, Samplingfehler, natürliches Auftreten (kein Fehler).

Visualisierung zur Exploration

Histogramm	Verteilung einer Variablen
Scatter Plot	Abhängigkeit zweier Variablen
Zeitreihendiagramm	Trends, Saisonalität
Heatmap	Korrelationen zwischen Variablen
Karte	räumliche Verteilung

Methodenüberblick

Analyserichtungen:

- **General Data Science:** Regression, Klassifikation, Clustering, Assoziationsanalyse, Anomalieerkennung
- **Text Mining / NLP:** Insights aus Textdaten
- **Image Recognition / CV:** Insights aus Bild-/Videodaten
- **Time Series:** Analyse zeitabhängiger Daten (IoT, Sensordaten); eigene Datenstruktur $Y_t, Y_{t-1}, \ldots$ und Algorithmik. **Moving Window Concept:** Sequenz in überlappende Fenster zerlegen, z. B. Window-Größe $= 3$, Label $= 1$: Input $[1, 2, 3] \rightarrow$ Label $[4]$; Input $[2, 3, 4] \rightarrow$ Label $[5]$; usw.

Zuordnung Aufgaben → Verfahren (Chamoni 2019): Klassifikation/Regression → Lin./Log. Regression, NN, Entscheidungsbäume; Abhängigkeitsanalyse → Assoziationsanalyse; Clustering/Segmentierung → Clusterverfahren.

Korrelation vs. Kausalität

Korrelation $\neq$ Kausalität. Anderson (2008) "The End of Theory": Genügt Korrelation bei hinreichend großen Datenmengen?

Gegenargumente: Stichprobenprobleme bestehen auch bei großen Datenmengen (Wu et al. 2014); Daten sozialer Netzwerke: verzerrte Nutzerbasis (Graham 2012); es braucht Theorie, um Beobachtungen einzuordnen (Reiss 2011) – Big Data allein ersetzt keine wissenschaftliche Methodik. ⇒ Explorative Forschung, Muster dokumentieren, Hypothesen bilden.

Kausalinferenz-Techniken: Propensity Score Matching, Inverse Probability-Weighted Regression Adjustment. Goldstandard: Randomized Controlled Trial (RCT) – aber ökonomische Techniken können weit vom RCT-Ergebnis entfernt sein (Gordon et al. 2016).

Regressionsanalyse

Statistisches Verfahren zur Modellierung von Beziehungen: $Y_i = \beta_0 + \beta_1 x_1 + \ldots + \beta_k x_k + \varepsilon_i$

Kritisch: In-Sample-Fit vs. Out-of-Sample-Fit; empfindlich gegenüber Annahmeverletzungen.
Die einfachste Form eines neuronalen Netzes ist eine logistische Regression.

Overfitting vs. Underfitting

- **Underfitting:** Modell zu einfach, hoher Bias, erfasst Muster nicht
- **Good Fit:** Balance zwischen Bias und Varianz
- **Overfitting:** Modell zu komplex, hohe Varianz, erfasst Rauschen

Extremfall Overfitting: je Beobachtung ein eigenes Blatt → kein Transfer auf neue Daten.

Prognosemodellierung (Supervised)

Überwachte Verfahren: historische Daten → Modell → Prognose auf neuen Daten.

Zielgröße: binär $(0/1)$, multinomial, ordinal oder metrisch.

Kritisch: Overfitting; ausreichend Positiv-/Negativfälle (Rule of Thumb: ≥ 1000 "1er"); korrekt historisierte Daten.

Clustering (Unsupervised)

Erkennung von Gruppen ähnlicher Beobachtungen ohne Zielvariable.
Klassiker: **k-means**. Cluster = Gruppierungen, die auf neue Beobachtungen angewendet werden können (Data Reduction Method). Sehr herausfordernd: keine Modellvalidierung möglich.
Kritisch: Interpretation erfordert Domänenwissen; hohe Anforderungen an Datenqualität & Standardisierung.

Recommendation Engines können durch verschiedene Algorithmen gestaltet werden: Matrix Factorization, Classification, Clustering, Rule-Based Models.

Assoziations- & Sequenzanalyse

Erkennung von Zusammenhängen: Regeln der Form $A \Rightarrow B$.

Kennzahlen:

- **Support:** $\text{support}(X) = \frac{|\{t \in T : X \subseteq t\}|}{|T|}$
- **Konfidenz:** $\text{conf}(X \Rightarrow Y) = \frac{\text{support}(X \cap Y)}{\text{support}(X)}$
- **Lift:** $\text{lift}(X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X) \cdot \text{support}(Y)}$

Lift > 1: positive Assoziation; Lift $= 1$: unabhängig; Lift < 1: negative Assoziation.

Einsatz: Warenkorbanalyse (Crossselling).

Beispiel (Brot & Butter): 10 Transaktionen, 7×Brot, 8×Butter, 5×beide ⇒ Lift < 1 → keine positive Assoziation (Kaufwahrscheinlichkeit von Butter ca. 11 % reduziert nach Brot-Auswahl).

Anomalieerkennung

Unüberwacht; explorativer Ansatz zur Erkennung abweichender Muster.
Kritisch: großer Suchraum; Ergebnisvalidierung schwierig.
Methoden: Boxplot (univariat), PCA + Isolation Forest (multivariat).

Use Case Computerchiphersteller: 50 Mio. Chips/Jahr, davon nur 50 echte Ausfälle; 8.000 Chips pro Wafer, über 560 Variablen. Ansatz: PCA zur Dimensionsreduktion, Isolation Forest zur Anomalieerkennung. Ergebnis: 50 % der Ausfälle vermieden bei nur 6 % Material Loss.

Baumbasierte Verfahren

Decision Trees (Entscheidungsbäume)

CART (Classification And Regression Tree): **Aufbau:** Root Node → Splitter Nodes → Internal Nodes → Leaf Nodes.

- Classification Tree: kategoriale Zielvariable → Majority Voting
- Regression Tree: kontinuierliche Zielvariable → Mittelwert

Splitting: Variable + Schwellenwert, die Purity maximieren (Classification) bzw. Varianz minimieren (Regression). Rekur-

sive Partitionierung. Jede Variable kann für mehr als einen Split verwendet werden (nichtlineare Assoziationen).

Missing Values: Algorithmus prüft, welche Zuordnung (alle Missings links oder rechts) zur höchsten Purity führt. Alternative: *Surrogate Rules* (Ersatzvariable für den Split).

Stopping/Pruning:

- Pre-Pruning: Stopp basierend auf Information Gain / Schwellenwerten
- Post-Pruning: Baum vollständig wachsen lassen, dann zurückschneiden

⇒ Optimaler Baum: niedriger Bias + niedrige Varianz.

Vorteile: Missing-Value-Handling, nichtlineare Beziehungen, Interpretierbarkeit.
Nachteile: Informationsverlust durch binäre Splits; keine Extrapolation.

Ensemble Modeling

Meta-Algorithmus: mehrere Modelle kombinieren → bessere Vorhersage.
Kombination durch Voting (Klassifikation) oder Averaging (Regression).

Bias-Variance-Trade-off: einfache Modelle = High Bias + Low Variance; komplexe = Low Bias + High Variance. Benefit hängt ab von Strength (Accuracy) und Diversity (Fehlerkorrelation) der Basismodelle.

Bagging (Bootstrapped Aggregation):

- K Bootstrapped Samples → K Bäume → Aggregation
- Reduziert **Varianz** (Bias bleibt gleich)
- Out-of-Bag Sample zur Modellkalibrierung

Boosting (z. B. AdaBoost):

- K Bäume werden **sequenziell** trainiert
- Nach jeder Iteration: Gewichte auf fehlklassifizierte Fälle erhöhen
- Arc-x4 Gewichtsformel: $w_i = \frac{1+f_i^4}{\sum_i(1+f_i^4)}$
- Reduziert **Bias** (und teils Varianz)

Random Forest:

- Kombination aus Bagging + zufällige Feature-Auswahl pro Split (`mtry`)
- Parameter: Anzahl Bäume, Tiefe, mtry, OOB-Anteil, Validierung

Neuronale Netze

Biologische Analogie: Lose Analogie zu neuronalen Netzwerken im Gehirn. Ein Neuron ist eine elektrisch erregbare Zelle, die Informationen über Synapsen (Axon-Terminals → Dendriten) empfängt, verarbeitet und weitergibt. Durch Bildung riesiger Netzwerke leisten Sammlungen von Neuronen komplexe Informationsverarbeitung.

Aufbau: Input Layer → Hidden Layer(s) → Output Layer.

- Knoten benachbarter Schichten: vollständig oder dünn verbunden
- Tiefe des Netzes = Anzahl Hidden Layers → bestimmt Komplexität

Funktionsweise:

1. Eingabe-Features x_i gewichtet summieren: $\sum w_i x_i$
2. Nichtlineare Aktivierungsfunktion anwenden → Ausgabe h
3. Wenn $\sum w_i x_i \geq T$ (Threshold): Neuron aktiviert (Output $= 1$)

Training: Parameter (Gewichte w, Schwellenwerte T) werden iterativ angepasst (Backpropagation). In der Praxis: Milliarden von Neuronen und Gewichten.

Beispiel (Münzwurf-Spiel): Zwei Münzwürfe, Erfolg = 2×Kopf. Neuron: $\sum w_i x_i \geq T \Rightarrow 1$. Startwerte: $w_1 = w_2 = 1$, $T = 1$ → Fehler bei (T,H) und (H,T). Korrektur: $T = 1{,}5$ → alle 4 Fälle korrekt. Für XOR-Problem (1×K + 1×Z): einfaches Neuron reicht nicht → mehrstufiges Netz (Hidden Layer) nötig.

Modellevaluation

Leitfragen (vor Metriken)

1. Bildet das Modell die Business-Frage ab?
2. Ist Interpretierbarkeit gefordert?
3. Wie oft muss trainiert/angewendet werden?
4. Welche Genauigkeit ist erforderlich?
5. Wie ist das Kosten-Nutzen-Profil?

⇒ Bei gleicher Vorhersagekraft: einfacheres Modell bevorzugen (Parsimonie).

Kostenfunktion (Beispiel Direktmarketing)

1.000 Kunden, Brief kostet 2 €, erwarteter Barwert bei Response = 5.000 €.

	Pred. 1	Pred. 0
Actual 1	TP = 100 (Rev. 5.000 €, Cost 2 €)	FN = 75 (Cost 5.0
Actual 0	FP = 25 (Cost 2 €)	TN = 800 (Cost

EV/Pred. $= 4998 \cdot 10\% - 5000 \cdot 7{,}5\% - 2 \cdot 2{,}5\% = 124{,}75$ €

⇒ Optimalen Schwellenwert über Kosten-Nutzen-Profil bestimmen.

Binäre Klassifikation – Confusion Matrix

	Predicted 1	Predicted 0
Actual 1	TP	FN
Actual 0	FP	TN

- $\text{Accuracy} = \frac{TP+TN}{TP+FN+TN+FP}$
- $\text{ErrorRate} = 1 - \text{Accuracy}$
- $\text{Sensitivity(TPR)} = \frac{TP}{TP+FN}$
- $\text{Specificity} = \frac{TN}{TN+FP}$
- $\text{FPR} = 1 - \text{Specificity} = \frac{FP}{TN+FP}$

Kostenfunktion: Expected Value pro Prediction aus Revenue/Costs für TP/FN/FP/TN berechnen → optimalen Schwellenwert bestimmen.

ROC-Kurve & AUC

ROC: Sensitivity (Y) vs. $1 -$ Specificity (X) für alle Schwellenwerte.
Je steiler die Kurve → desto besser das Modell.
AUC (Area Under Curve): $0 \leq \text{AUC} \leq 1$; Random $= 0.5$.
Gini $= 2 \cdot \text{AUC} - 1$.

Lift

$\text{Lift} = \frac{\delta}{\delta_0}$ mit δ = Hit-Rate mit Modell, δ_0 = Baseline-Response-Rate. Bsp.: Modellbasiert 30 % Response in Top-

50 %, Baseline 17,5 % $\Rightarrow$ Lift $= 1{,}71$.

Kontinuierliche Prognose

- **RMSE**: mittlerer quadratischer Fehler $\rightarrow$ je niedriger, desto besser
- R^2: erklärte Varianz $\rightarrow$ je näher an 1, desto besser (In-Sample)
- AIC, SBC: Modellvergleich (relative Maße)

Feature Selection

- Forward/Backward/Stepwise Regression
- Variable Importance (aus Boosted Trees, Random Forest)
- PCA (Alternative, aber schwer interpretierbar)
- Rule of Thumb: ≤ 30 Prädiktoren
- Feature Selection immer mit Domänenexperten besprechen

Praktische Evaluationstipps

1. Top-Features zusammen mit Zielvariable visualisieren und mit Fachbereich besprechen
2. Prognoseergebnisse stichprobenartig prüfen
3. Prognostizierte Wahrscheinlichkeiten als Histogramm darstellen – Auffälligkeiten?
4. Fachlich nachvollziehen, welche Beobachtungen hoch gescored werden

Text Mining, NLP & NLU

NLP = Natural Language Processing; **NLU** = Natural Language Understanding.

Ablauf:

1. Datenakquisition
2. Vorbereitung: Formatumwandlung, Tokenization
3. Feature Extraction: Bag-of-Words, **tf-idf**
4. Analyse: Klassifikation, Clustering etc.
5. Evaluation

tf-idf = Term Frequency $\times$ Inverse Document Frequency.
Zipf'sches Gesetz: Wörter folgen Exponentialverteilung; sehr häufige Wörter ("der", "und") tragen wenig Bedeutung.

Korpus = endliche Sammlung maschinenlesbarer, natürlich vorkommender Texte.

Google N-grams	1 Mrd.	viele Sprachen
British National Corpus	100 Mio.	brit. Englisch
DWDS Kernkorpus	100 Mio.	Deutsch (20. Jh.)
UN/EU Proceedings	20 Mio.	10 Sprachpaare
Switchboard	2,4 Mio.	am. Englisch (Dialog)
Penn Treebank	1 Mio.	am. Englisch (News)

Computer Vision & Image Recognition

Definition: Fähigkeit eines Computers, Eigenschaften/Objekte in Bildern zu erkennen.

Warum Hype? GPU-Leistung $\uparrow$, Hardware-Kosten $\downarrow$, CNN-Architekturen (AlexNet, VGG, ResNet), Backpropagation, große Community.

Typische Fragestellungen: (1) Ist Objekt vorhanden? (2) Wie häufig? (3) Wo im Bild (2D)? (4) Wo (3D)? (5) Erfüllt Objekt bestimmte Eigenschaft?

Methoden: Objekterkennung, Segmentierung, Anomalieanalyse.

Methodenkategorien: Globale Methoden (2D-Korrelation, PCA), Transformations-Such-basiert (Hough-Transformation), geometrische Korrespondenz, 3D-Objekterkennung, flexibles Shape-Matching, Interest Point Detection.

Pixelebene: SW (1 Bit), Graustufen (2+ Bit), Farbe (3 Byte/Pixel).

Herausforderungen: Belichtung, Rotation, teilweise Überdeckung, Perspektivwechsel (3D$\rightarrow$2D), Hintergrundgeräusche.

Anforderungen an Algorithmen: Realtime-Auswertungszeit, Genauigkeit (abhängig von Pixelanzahl), Zuverlässigkeit (abhängig vom Anwendungsfall).

Branchen-Use-Cases: Sicherheit (Überwachung), Industrie (QS), Verkehr (autonomes Fahren), Medizin (Krebsdiagnose), Social Media (Monitoring).

Best Practices: Nie Rohdaten verändern; Verknüpfung zwischen Original- und verarbeitetem Bild beibehalten; Aufzeichnungen zu einzelnen Schritten des Analyse-Prozesses führen.

Ethik, Regulierung & Nachhaltigkeit

FACT-Prinzipien (Responsible Data Science)

van der Aalst et al. (2017): Data Science muss "responsible by design" sein.

- **F**airness – keine Diskriminierung. Trainingsdaten können verzerrt sein; selbst ohne sensible Attribute (Rasse, Geschlecht) kann algorithmische Diskriminierung entstehen; Profiling kann Stigmatisierung verstärken
- **A**ccuracy – Genauigkeit der Ergebnisse. Mehr Daten $\neq$ genauere Ergebnisse; Multiple-Testing-Problem (spuriöse Korrelationen); Simpson-Paradoxon (Trend in Untergruppen kehrt sich bei Aggregation um)
- **C**onfidentiality – Vertraulichkeit. Daten sicher und kontrolliert nutzen; Ansätze: polymorphe Verschlüsselung, Pseudonymisierung, Privacy Budgets
- **T**ransparency – Nachvollziehbarkeit. Keine Black Box; Accountability und Erklärbarkeit; Korrelation $\neq$ Kausalität. Besonders kritisch: Deep-Learning-Modelle sind nicht von Menschen verstehbar und können Entscheidungen nicht begründen – in vielen Domänen inakzeptabel

FACT vs. FAIR: FACT = wissenschaftliche Grundlagen (Fairness, Accuracy, Confidentiality, Transparency); FAIR = praktische Datenteilung (Findable, Accessible, Interoperable, Re-usable).

Ergänzend C4-Ansatz (van der Aalst): **C**omprehensibility (Verständlichkeit von Ergebnissen), **C**orrectness (statistische Korrektheit), **C**onfidentiality (Datenschutz), **C**onnectivity (Einbettung in Geschäftsprozesse).

Fallstudie: Target Schwangerschaftsprognose

Target (US-Einzelhändler) erkannte durch Datenanalyse die Schwangerschaft einer Teenagerin, bevor ihr Vater davon wusste (Hill, Forbes 2012; NYT 2012).
$\Rightarrow$ Ethische Grenzen der Datennutzung – auch legale Datenanalyse kann moralisch problematisch sein.

Fallstudie: Racial Bias in Algorithmen

Obermeyer et al. (2019, Science): Kommerzieller Algorithmus zur Identifikation von Hochrisikopatienten diskriminiert systematisch (~200 Mio. Patienten/Jahr betroffen). **Weitere Beispiele algorithmischer Diskriminierung:** Jobanzeigen für hochbezahlte Positionen werden Frauen seltener angezeigt; Bildersuche für "CEO" zeigt weniger Frauen; Gesichtserkennung funktioniert schlechter bei Frauen und Schwarzen; NLP-Algorithmen kodieren Sprache geschlechtsspezifisch. **Ursache:** Algorithmus prognostiziert *Gesundheitskosten* statt *Gesundheitszustand*. Bei gleichem Gesundheitszustand verursachen schwarze Patienten $1.801 weniger Kosten/Jahr (Zugangsbarrieren, historisches Misstrauen). ⇒ Bei gleichem Risiko-Score haben schwarze Patienten 26,3 % mehr chronische Erkrankungen.

Counterfactual-Simulation: Korrektur der Verzerrung würde den Anteil schwarzer Patienten im Programm von 17,7 % auf 46,5 % erhöhen. **Ursachen der Kostendisparität:** (1) Armut/Zugangsbarrieren (Geographie, Transport, konkurrierende Anforderungen); (2) direkte Rassenwirkung (reduziertes Vertrauen, z. B. Tuskegee-Studie; unterschiedliche Arzt-Wahrnehmungen). **Alternative Labels getestet:** Gesamtkosten, vermeidbare Kosten (nur Notaufnahmen/Hospitalisierungen), Gesundheitsindex (chronische Erkrankungen). Rassenzusammensetzung der Hochrisikogruppe variiert fast um Faktor 2 je nach Label-Wahl (14,1 % bis 26,7 % Schwarz).

Lösung: Label ändern (Kosten → Gesundheitsindex) → 84 % Bias-Reduktion.

Lesson Learned: Die **Label-Wahl** (Zielvariable) ist die wichtigste Entscheidung und häufigste Quelle algorithmischer Verzerrung.

Label Choice Bias (Definition): Differenz zwischen optimaler Vorhersage und Vorhersage eines auf beobachtetem (verzerrtem) Label trainierten Algorithmus. Beispiele in anderen Sektoren: Kredit-Scoring (inkorporiert Einkommens-Ungleichheiten), Polizei-Algorithmen (spiegeln erhöhte Überwachung wider), Einstellungs-Algorithmen (Rasse-/Gender-Bias in Vorgesetztenbewertungen).

Problem Formulation: Die Aufgabe, ein oft amorphes Konzept in eine konkrete, vorhersagbare Variable zu übersetzen – entscheidender Schritt, der über Fairness und Qualität des Algorithmus bestimmt.

EU AI Act

Erstes umfassendes KI-Gesetz der Welt (Vorschlag EU-Kommission April 2021; vorläufige Einigung Parlament & Rat 9. Dez. 2023):

- Inakzeptables Risiko (z. B. Social Scoring) → Verbot
- Hohes Risiko (z. B. CV-Screening) → Regulierung
- Risikofreie Anwendungen → unreguliert

Anforderungen: technische Dokumentation, Trainings-/Testdaten offenlegen, Urheberrechtsnachweis, digitale Wasserzeichen.

Green AI

- KI *für* Nachhaltigkeit: Energieeffizienz, Klimamodellierung, Kreislaufwirtschaft, Ressourceneffizienz, Mobilität, Naturschutz, Bauwirtschaft. 2,9 Bio. USD geschätzte Kosteneinsparungen bis 2025 durch KI-Energieeffizienz weltweit (World Economic Forum)
- Nachhaltigkeit *in* KI: CO_2-Fußabdruck minimieren. Kritische Bereiche: Modelltraining, Algorithmen, Hardware, Daten, Monitoring & Bewertung, Recycling & Reusage

Green Data Science (van der Aalst 2016): Innovative Lösungen, die Individuen, Organisationen und Gesellschaft ermöglichen, von Datenverfügbarkeit zu profitieren und gleichzeitig FACT sicherzustellen – Fokus auf negative Nebeneffekte von Daten auf das Leben von Menschen (nicht zu verwechseln mit energieeffizienten Rechenzentren).

EU-DSGVO (2016): Stärkung und Vereinheitlichung des Datenschutzes für Individuen in der EU; kann Innovationsschub für neue "FACT-konforme" Datennutzung bieten.

Data Strategy & Implementierung

Datenstrategie: Daten = strategisches Asset ⇒ Exploration → Refining → Utilization.

Wertschöpfung im Datenstrom (Porter): Datenquellen (intern: Unternehmen, Kunden, Partner; extern) → Vorverarbeitung → Data Lake → Analytics (Descriptive → Diagnostic → Predictive → Prescriptive) → Deeper Insights. Komplexere Analysen auf Data Lake mit verschiedenen Quellen = tiefere Einblicke.

5 Kerninputs für DS/AI: Daten, Algorithmen, Computer (Rechenleistung), Use Cases, Menschen + Kollaboration.

9 Herausforderungen bei DS/AI-Implementierung:

1. Unternehmenskultur
2. Datenverfügbarkeit & -qualität
3. Talente & Rollen
4. Erwartungsmanagement & Hype
5. Use Cases & Zielsetzungen
6. Data Ownership
7. Model Deployment & Plattform
8. Projektmanagement
9. Prozesse

Data Governance: kein einmaliges Projekt, sondern kontinuierliche Praxis; kulturell verankert, dezentral, unbürokratisch, alle Mitarbeitende einbeziehen.

Datenqualität (ISO/IEC 25012): Vollständigkeit, Präzision, Genauigkeit, Konsistenz, Aktualität, Verständlichkeit, Handhabbarkeit, Glaubwürdigkeit, Regulatorik. Ergänzend: Helfert et al. (2001) identifizieren 75 Datenqualitätskriterien, u. a. Fehlerfreiheit, Korrektheit, Relevanz, Reliabilität, Validität, Objektivität, Zugänglichkeit, Wiederverwendbarkeit, Zeitadäquanz, Verfügbarkeit.

5 Schritte zur DS-Implementierung:

1. Strategie (Use Cases identifizieren, Analytical Roadmap)
2. Prozesse (Governance, Lifecycle Management)
3. Technische Infrastruktur (DS-Plattform)
4. Organisation (Rollen, Trainings, zentral/dezentral)
5. Use-Case-Umsetzung (PoC → MVP → Produktion)

Analytical Roadmap: Strategisches Vorgehen statt "Jugend forscht" – Zusammenfassung & Priorisierung von Use Cases (Kosten/Nutzen), Empfehlungen für Quick Wins, benötigte Tools, Rollen & Zeitplan.

6 AI-Reifegrade:

1. Identifizierung (PoCs)

2. Exploration + Experimentieren (Prototypen, Quick Wins) → *DS Lab*
3. Erweiterung + Operationalisierung (MVPs) → *DS Lab/Factory*
4. Nutzung & Ausweitung (Piloten, Data Products) → *DS Factory*
5. Stabilisierung + Produktion (Data Driven Company)
6. Industrialisierung (Enterprise-Scale AI)

DS Lab: entwickelt Use Cases in interdisziplinären Teams (Prototyping), iterativ nach CRISP-DM, experimentell, getrennt von Produktion.
DS Factory: übernimmt getestete Modelle, transformiert in produktive Lösungen, integriert in IT-Infrastruktur, verantwortet Monitoring & Retraining.

Projektansatz: Agil-iterativ ("fail fast"), SCRUM-artig, nicht Wasserfall.
MVP = Minimal Viable Product: kleinstmöglicher Business Use Case.

Datenquellen-Portale

Frei zugängliche Datenquellen für Data-Science-Projekte:

- Google Public Data Directory
- AWS Open Data Registry
- GovData (Deutschland)
- WHO Global Health Observatory
- DESTATIS (Genesis-Online)
- Eurostat
- Kaggle Datasets

Use Cases nach Funktionsbereich

Commercial: Customer Segmentation, CLV & Churn Prediction, Targeting, Marketing-Optimierung, Sales Forecasting, Next Best Offer, Anomalie-/Fraud-Erkennung, OOS Detection, Chatbots, OCR.

Finance: Fraud & Risk Detection, Finanzplanungsoptimierung, Gross-to-Net-Optimierung, Rückstellungsplanung, automatisiertes Echtzeit-Reporting, Optimized Inventory Valuation.

R&D & Medical: Medikamentenentwicklung optimieren, Krankheitsvorhersage, medizinische Bildanalyse (Tumorerkennung), Genetik/Genomik (personalisierte Behandlung).

Procurement: Einsparpotenziale identifizieren, Lieferantenbewertung, Sourcing-Potenziale, Bestellzyklen messen, Zahlungsgenauigkeit prüfen.

Production: Predictive Maintenance, Smart Factory (AR/VR), Produktions-/Wartungsplanung, Muster in Ausfallzeiten erkennen.

Supply Chain: Warehouse-/Bestandsoptimierung, Demand Forecasting, Lieferrouten-Optimierung, Energie-/Kraftstoffmanagement, Vorhersage von Lieferengpässen, Replenishment-/Lead-Time-Optimierung, On-Time Production & Delivery, Gesamtlieferzeiten schätzen.

Beispiele für die 4 Analytics-Stufen:

- Descriptive: 360°-View auf Produktebene
- Diagnostic: Verifizierung von Spill-Over-Effekten
- Predictive: Vorhersage des Bestellverhaltens von Krankenhauskunden
- Prescriptive: E-Commerce-Treiber verstehen & Marketing-Budgetierung optimieren

Modellübersicht (Cheat Sheet)

Modell	Typ	Missing	Stärke
Lineare Regression	Cont.	Nein	Interpretierbar (β-
Logistische Regression	Binär	Nein	Odds Ratio, interp
Decision Tree	Any	Ja	Missing-Handling,
Random Forest	Any	Ja	Robust, Variable I
Gradient Boosting	Any	Ja	Bias-Reduktion, se
SVM	Binär	Nein	Wenige Parameter
Neuronale Netze	Any	Nein	Komplexe Funktio
LASSO	Any	Nein	Variablenselektion
LAR	Cont.	Nein	Kollinearitätsrobus
GLM	Any	Nein	Flex. Fehlerverteil
PLS Regression	Any	Nein	Mehr Var. als Bec
Quantile Regression	Cont.	Nein	Median statt Mitt
k-Means	Clustering	Nein	Einfach, schnell

Use-Case-Priorisierung: Feasibility vs. Business Value → Matrix:
Now! (einfach + hoher Wert), *Wow!* (komplex + hoher Wert), *How?* (einfach + niedriger Wert), *No!* (komplex + niedriger Wert).