Übungsblatt 3 – Deskriptive Statistik & Datenverständnis

Grundlagen Data Science & KI | DHBW

Aufgabe 1 – Grundbegriffe

(a) Erklären Sie den Unterschied zwischen *Grundgesamtheit* und *Stichprobe*. Wann wird eine Stichprobe statt der Grundgesamtheit verwendet?

(b) Definieren Sie die Begriffe *Merkmal* und *Merkmalsausprägung*. Geben Sie jeweils ein konkretes Beispiel.

(c) Unterscheiden Sie *diskrete*, *stetige* und *quasi-stetige* Merkmale. Ordnen Sie folgende Variablen zu: Anzahl Kinder, Körpergröße in cm, Monatseinkommen in Euro.

(d) Ordnen Sie jede der folgenden Variablen dem passenden Skalenniveau zu (Nominal, Ordinal, Intervall, Verhältnis) und begründen Sie:

- Schulnoten (1–6)
- Temperatur in Grad Celsius
- Postleitzahl
- Alter in Jahren
- Beruf (Arzt, Lehrer, Ingenieur)
- Umsatz in Euro

(e) Warum erlaubt ein höheres Skalenniveau mehr Rechenoperationen? Nennen Sie je eine erlaubte Operation für Ordinal- und Verhältnisskalenniveau.

Aufgabe 2 – Lagemaße berechnen *(Berechnung)*

Ein Online-Shop erfasst die Anzahl der Bestellungen pro Tag über zehn Werktage:

Tag	1	2	3	4	5	6	7	8	9	10
Bestellungen	8	15	12	20	12	18	7	15	11	12

(a) Berechnen Sie den **arithmetischen Mittelwert** $\bar{x}$. Verwenden Sie die Formel $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$.

(b) Bestimmen Sie den **Median**. Sortieren Sie dazu die Werte aufsteigend und erläutern Sie Ihr Vorgehen.

(c) Bestimmen Sie den **Modus** (häufigsten Wert).

(d) Vergleichen Sie Mittelwert, Median und Modus. Was sagt jeder dieser Werte über die Verteilung der Bestellungen aus?

Aufgabe 3 – Streuungsmaße berechnen *(Berechnung)*

Verwenden Sie die gleichen Bestellungsdaten aus Aufgabe 2.

(a) Berechnen Sie die **Varianz** s^2 mit vollständigen Zwischenschritten. Verwenden Sie die Stichprobenvarianz: $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$.

(b) Berechnen Sie die **Standardabweichung** $s = \sqrt{s^2}$.

(c) Bestimmen Sie das **erste Quartil** Q_1 und das **dritte Quartil** Q_3. Berechnen Sie daraus den **Interquartilsabstand** IQR $= Q_3 - Q_1$.

(d) Berechnen Sie die **Spannweite** $R = x_{\max} - x_{\min}$. Warum ist die Spannweite weniger robust als der IQR?

Aufgabe 4 – Korrelation vs. Kausalität

(a) Erklären Sie den Unterschied zwischen *Korrelation* und *Kausalität*. Warum ist der Satz „Korrelation impliziert keine Kausalität" so wichtig?

(b) An heißen Sommertagen steigen sowohl der Eisverkauf als auch die Anzahl der Sonnenbrandverletzungen. Beides korreliert stark positiv miteinander.

- Handelt es sich um Kausalität? Begründen Sie.
- Handelt es sich um Kausalität? Erklären Sie, was die Beobachtung alternativ erklären könnte, und benennen Sie den Fachbegriff.

(c) Nennen Sie zwei weitere alltägliche Beispiele für eine Scheinkorrelation (Spurious Correlation).

(d) Was ist ein *Randomized Controlled Trial* (RCT) und warum gilt es als Goldstandard für den Nachweis von Kausalität?

(e) Nennen Sie zwei Methoden der Kausalinferenz, die ohne randomisierte Experimente auskommen, und erläutern Sie kurz, was sie leisten.

Aufgabe 5 – Overfitting vs. Underfitting *(Szenario)*

Ein Data-Science-Team modelliert den Zusammenhang zwischen dem Alter eines Kunden (x) und seinem jährlichen Kaufbetrag (y). Drei verschiedene Modelle werden ausprobiert:

Modell	Art	Fehler Training	Fehler Test
A	Konstante (Mittelwert)	hoch	hoch
B	Lineare Regression	mittel	mittel
C	Polynom 15. Grades	sehr niedrig	sehr hoch

(a) Welches Modell zeigt *Underfitting*, welches *Overfitting*, welches einen *Good Fit*? Begründen Sie jeweils.

(b) Erklären Sie den Begriff *Bias-Varianz-Dilemma*. Welches Modell hat hohen Bias, welches hohe Varianz?

(c) Was ist der Unterschied zwischen *In-Sample Fit* und *Out-of-Sample Fit*? Warum ist der Out-of-Sample Fit die entscheidende Metrik für die Praxis?

(d) Nennen Sie zwei Maßnahmen, um Overfitting zu vermeiden.

Aufgabe 6 – Wahr oder Falsch

Beurteilen Sie die folgenden Aussagen als *wahr* oder *falsch* und begründen Sie Ihre Entscheidung in einem Satz:

(a) Der Median ist robuster gegenüber Ausreißern als der arithmetische Mittelwert.

(b) Auf einer Nominalskala ist es sinnvoll, den Mittelwert zu berechnen.

(c) Eine Korrelation von $r = -0{,}9$ bedeutet, dass Variable A Variable B verursacht.

(d) Bei einer symmetrischen Verteilung ohne Ausreißer sind Mittelwert und Median ungefähr gleich.

(e) Das Skalenniveau einer Variable beeinflusst, welche statistischen Methoden zulässig sind.

(f) Eine Standardabweichung von 0 bedeutet, dass alle Messwerte identisch sind.

Lösungen – Übungsblatt 3

Aufgabe 1 – Grundbegriffe

(a) **Grundgesamtheit:** Die Grundgesamtheit umfasst alle Einheiten (Personen, Objekte, Ereignisse), über die eine Aussage getroffen werden soll – zum Beispiel alle Einwohner Deutschlands bei einer Wahl. Eine **Stichprobe** ist eine Teilmenge der Grundgesamtheit, die nach einem definierten Verfahren ausgewählt wird. Stichproben werden eingesetzt, wenn die vollständige Erhebung der Grundgesamtheit zu teuer, zu zeitaufwändig oder praktisch unmöglich ist (z. B. Qualitätskontrolle: nicht jedes Produkt zerstörend testen).

(b) Ein **Merkmal** (auch: Variable) ist eine messbare Eigenschaft der untersuchten Einheiten, z. B. das Alter einer Person. Eine **Merkmalsausprägung** ist der konkrete Wert, den ein Merkmal bei einer bestimmten Einheit annimmt, z. B. Alter = 34 Jahre oder Beruf = "Ingenieur". Merkmale beschreiben, was gemessen wird; Merkmalsausprägungen beschreiben das konkrete Ergebnis der Messung.

(c) **Diskrete Merkmale** können nur ganzzahlige oder abzählbare Werte annehmen (z. B. Anzahl Kinder: 0, 1, 2, ... – kein Wert wie 1,5 Kinder ist sinnvoll). **Stetige Merkmale** können jeden Wert in einem kontinuierlichen Intervall annehmen (z. B. Körpergröße in cm: 175,3 cm ist möglich). **Quasi-stetige Merkmale** sind theoretisch diskret, aber mit so vielen möglichen Ausprägungen, dass sie praktisch wie stetige Merkmale behandelt werden (z. B. Monatseinkommen in Euro: zwar ganzzahlig, aber mit tausenden möglichen Werten).

(d) Zuordnung der Variablen:

- Schulnoten (1–6): **Ordinal** – es gibt eine Rangfolge (1 besser als 2), aber der Abstand zwischen den Noten ist nicht gleichmäßig oder interpretierbar.
- Temperatur in Grad Celsius: **Intervall** – gleiche Abstände (10 °C Unterschied ist überall gleich), aber kein natürlicher Nullpunkt (0 °C bedeutet nicht "keine Temperatur").
- Postleitzahl: **Nominal** – reiner Bezeichner ohne Rangfolge oder Abstandsinfo; PLZ 70000 ist nicht "mehr" als PLZ 10000.
- Alter in Jahren: **Verhältnis** – gleiche Abstände und natürlicher Nullpunkt (0 Jahre = Geburt); Verhältnisaussagen sind sinnvoll (20 Jahre ist doppelt so alt wie 10 Jahre).
- Beruf: **Nominal** – reine Klassifikation, keine natürliche Reihenfolge.
- Umsatz in Euro: **Verhältnis** – echter Nullpunkt (0 € = kein Umsatz), Verhältnisse sinnvoll (200 € ist doppelt so viel wie 100 €).

(e) Ein höheres Skalenniveau enthält mehr Informationen über die Abstände und Verhältnisse zwischen Werten, weshalb mehr mathematische Operationen sinnvoll sind. Auf **Ordinalskala** ist die Rangordnung erlaubt (Median, Größer-/Kleiner-Vergleiche), aber kein Mittelwert, da die Abstände nicht definiert sind. Auf **Verhältnisskala** sind alle arithmetischen Operationen zulässig, einschließlich Multiplikation und Division (z. B. "doppelt so viel").

Aufgabe 2 – Lagemaße berechnen

(a) Arithmetischer Mittelwert:

Die Datenwerte sind: 8, 15, 12, 20, 12, 18, 7, 15, 11, 12. Summe der Werte:

$$\sum_{i=1}^{10} x_i = 8 + 15 + 12 + 20 + 12 + 18 + 7 + 15 + 11 + 12 = 130$$

$$\bar{x} = \frac{1}{10} \cdot 130 = \mathbf{13{,}0}$$

(b) Median:

Aufsteigend sortiert: 7, 8, 11, **12, 12**, 12, 15, 15, 18, 20. Da $n = 10$ gerade ist, liegt der Median zwischen dem 5. und 6. Wert:

$$\tilde{x} = \frac{x_{(5)} + x_{(6)}}{2} = \frac{12 + 12}{2} = \mathbf{12{,}0}$$

(c) Modus:

Der Wert 12 tritt dreimal auf (Tage 3, 5, 10) – häufiger als alle anderen Werte. Der Modus ist **12**.

(d) Vergleich der Lagemaße:

Mittelwert ($\bar{x} = 13{,}0$) liegt etwas über Median und Modus, weil der Ausreißer 20 den Mittelwert nach oben zieht. Der Median ($\tilde{x} = 12{,}0$) spiegelt den "typischen" Tag besser wider und ist robuster gegenüber diesem Ausreißer. Der Modus ($= 12$) zeigt, dass 12 Bestellungen der häufigste Tageswert ist. Die leichte Rechtsschiefe der Verteilung ($\bar{x} > \tilde{x}$) deutet darauf hin, dass es einzelne Tage mit überdurchschnittlich vielen Bestellungen gibt.

Aufgabe 3 – Streuungsmaße berechnen

(a) Varianz (Stichprobenvarianz):

Mit $\bar{x} = 13{,}0$ berechnen wir alle quadratischen Abweichungen $(x_i - \bar{x})^2$:

Tag	x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	8	$-5{,}0$	$25{,}00$
2	15	$+2{,}0$	$4{,}00$
3	12	$-1{,}0$	$1{,}00$
4	20	$+7{,}0$	$49{,}00$
5	12	$-1{,}0$	$1{,}00$
6	18	$+5{,}0$	$25{,}00$
7	7	$-6{,}0$	$36{,}00$
8	15	$+2{,}0$	$4{,}00$
9	11	$-2{,}0$	$4{,}00$
10	12	$-1{,}0$	$1{,}00$
Summe	130	0	$\mathbf{150{,}00}$

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{150{,}00}{9} \approx \mathbf{16{,}67}$$

(b) Standardabweichung:

$$s = \sqrt{s^2} = \sqrt{16{,}67} \approx \mathbf{4{,}08}$$

Die Standardabweichung von ≈ 4 Bestellungen gibt die typische Abweichung vom Mittelwert in der ursprünglichen Einheit (Anzahl Bestellungen) an.

(c) Quartile und IQR:

Aufsteigend sortiert ($n = 10$): 7, 8, 11, 12, 12, 12, 15, 15, 18, 20.

Das erste Quartil Q_1 ist der Median der unteren Hälfte (Werte 1–5): $7, 8, 11, 12, 12 \Rightarrow Q_1 = 11$.

Das dritte Quartil Q_3 ist der Median der oberen Hälfte (Werte 6–10): $12, 15, 15, 18, 20 \Rightarrow Q_3 = 15$.

$$\text{IQR} = Q_3 - Q_1 = 15 - 11 = \mathbf{4}$$

(d) Spannweite:

$$R = x_{\max} - x_{\min} = 20 - 7 = \mathbf{13}$$

Die Spannweite ist weniger robust als der IQR, weil sie ausschließlich von den beiden Extremwerten abhängt: ein einziger sehr großer oder sehr kleiner Ausreißer verändert die Spannweite stark, während der IQR nur die mittleren 50 % der Daten berücksichtigt und damit stabil gegenüber Ausreißern bleibt.

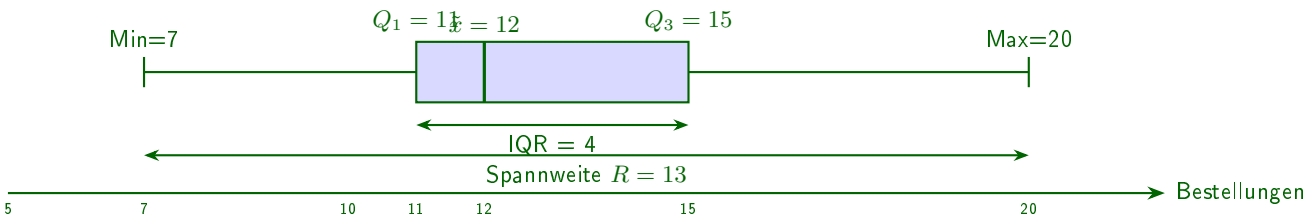

Aufgabe 4 – Korrelation vs. Kausalität

(a) **Korrelation** bedeutet, dass zwei Variablen einen statistischen Zusammenhang aufweisen – wenn die eine steigt, tendiert auch die andere zu steigen (positive Korrelation) oder zu fallen (negative Korrelation). **Kausalität** bedeutet, dass eine Variable die andere direkt *verursacht*. Der Satz "Korrelation impliziert keine Kausalität" ist zentral, weil aus einer beobachteten Korrelation voreilige Schlüsse auf Ursache-Wirkungs-Beziehungen gezogen werden könnten, was zu falschen Entscheidungen führt (z. B. falsche Politikmaßnahmen oder Behandlungen).

(b) Das Eisverkaufs-Sonnenbrand-Beispiel:

- Es handelt sich **nicht** um Kausalität. Eis essen verursacht keinen Sonnenbrand, und Sonnenbrand verursacht keinen erhöhten Eisverkauf.
- Die eigentliche Ursache ist die **Temperatur** (Hitze): Bei hohen Temperaturen kaufen Menschen mehr Eis *und* verbringen mehr Zeit in der Sonne. Eine solche Drittvariable, die scheinbar zwei Variablen zusammenbringt, nennt man **Konfundierungsvariable** (Confounder) oder Störvariable.

(c) Zwei weitere Beispiele für Scheinkorrelationen:

- Die Anzahl der Scheidungen in Maine korreliert mit dem Pro-Kopf-Verbrauch von Margarine (beide sanken über Jahre im Gleichschritt – reiner Zufall).
- Die Zahl der Nicolas-Cage-Filmauftritte pro Jahr korreliert mit der Anzahl von Ertrinkungsunfällen in Swimmingpools (klassisches Beispiel für Spurious Correlation).

(d) Ein **Randomized Controlled Trial (RCT)** ist ein Experiment, bei dem Teilnehmer *zufällig* (randomisiert) einer Behandlungsgruppe oder einer Kontrollgruppe zugewiesen werden. Da die Zufallszuteilung alle bekannten und unbekannten Störvariablen gleichmäßig auf beide Gruppen verteilt, kann ein verbleibender Unterschied im Ergebnis kausal auf die Behandlung zurückgeführt werden. Deshalb gilt das RCT als Goldstandard: Es eliminiert systematische Verzerrungen (Bias) durch Confounder.

(e) Zwei Methoden der Kausalinferenz ohne RCT:

- **Propensity Score Matching (PSM):** Behandelte und unbehandelte Einheiten werden anhand ihrer Wahrscheinlichkeit, die Behandlung zu erhalten (Propensity Score), zu möglichst ähnlichen Paaren zusammengeführt, um den Selektionsbias zu reduzieren.

- **Inverse Probability of Treatment Weighting (IPTW/IPRWA):** Beobachtungen werden mit dem Kehrwert ihrer Behandlungswahrscheinlichkeit gewichtet, sodass die Stichprobe eine Pseudo-Population erzeugt, in der Behandlung und Kovariablen unabhängig sind.

Aufgabe 5 – Overfitting vs. Underfitting

(a) **Modell A (Konstante):** zeigt **Underfitting** – der Fehler ist sowohl auf den Trainingsdaten als auch auf den Testdaten hoch, weil das Modell zu einfach ist, um den echten Zusammenhang zwischen Alter und Kaufbetrag zu erfassen. **Modell B (lineare Regression):** zeigt einen **Good Fit** – der Fehler ist auf Trainings- und Testdaten ähnlich mittel; das Modell generalisiert gut. **Modell C (Polynom 15. Grades):** zeigt **Overfitting** – der Trainingsfehler ist sehr niedrig (das Modell "lernt" jeden Datenpunkt auswendig), aber der Testfehler ist sehr hoch, weil das Modell das Rauschen in den Trainingsdaten mitgelernt hat und nicht generalisiert.

(b) Das **Bias-Varianz-Dilemma** beschreibt den Zielkonflikt zwischen zwei Fehlerquellen: **Bias** (systematischer Fehler durch zu einfache Modellannahmen) und **Varianz** (Empfindlichkeit des Modells gegenüber kleinen Änderungen in den Trainingsdaten). Modell A hat **hohen Bias** (underfittet, übersieht systematisch den echten Trend). Modell C hat **hohe Varianz** (overfittet, reagiert stark auf zufällige Schwankungen in den Trainingsdaten). Ein gutes Modell findet die Balance zwischen beiden.

(c) **In-Sample Fit** bezeichnet die Güte eines Modells auf den Daten, mit denen es trainiert wurde. **Out-of-Sample Fit** bezeichnet die Güte auf neuen, ungesehenen Testdaten. In der Praxis ist der Out-of-Sample Fit entscheidend, weil das Modell auf unbekannte Daten angewendet werden soll – ein Modell, das auf Trainingsdaten perfekt funktioniert, aber auf neuen Daten versagt, hat keinen praktischen Nutzen.

(d) Zwei Maßnahmen gegen Overfitting:

- **Regularisierung** (z. B. Ridge, Lasso): Strafterm bestraft zu große Koeffizienten und zwingt das Modell zur Einfachheit.
- **Cross-Validation (Kreuzvalidierung):** Das Modell wird auf mehreren Trainings-/Testaufteilungen evaluiert, sodass keine zufällige Aufteilung das Ergebnis verzerrt und die Modellkomplexität gezielt gewählt werden kann.

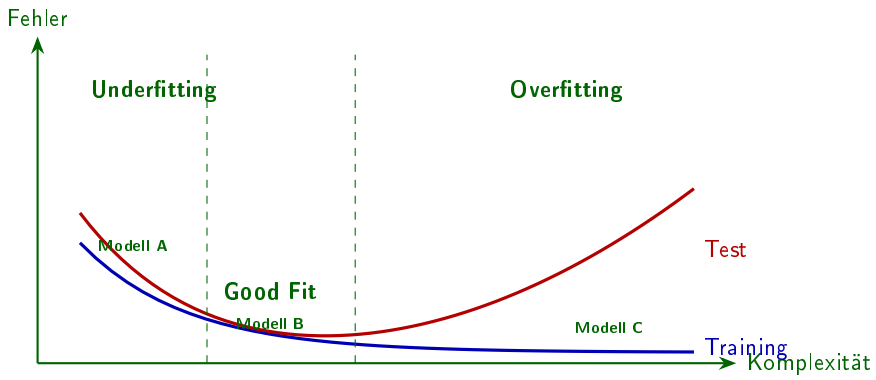

Aufgabe 6 – Wahr oder Falsch

(a) **Wahr.** Der Median teilt die sortierten Daten in der Mitte und wird von einem einzelnen extremen Ausreißer kaum beeinflusst, während der Mittelwert jeden Wert gleichgewichtet in die Berechnung einbezieht und dadurch empfindlich auf Ausreißer reagiert.

(b) **Falsch.** Auf einer Nominalskala sind die Kategorien nur Bezeichnungen ohne numerischen Abstand – ein Mittelwert aus Werten wie "Arzt=1, Lehrer=2, Ingenieur=3" wäre bedeutungslos, da keine quantitative Beziehung zwischen den Kategorien besteht.

(c) **Falsch.** Eine Korrelation von $r = -0{,}9$ zeigt einen starken negativen statistischen Zusammenhang, sagt aber nichts über Kausalität aus – es könnte eine gemeinsame Ursache (Confounder) oder ein zufälliger Zusammenhang vorliegen.

(d) **Wahr.** Bei einer symmetrischen, ausreißerfreien Verteilung (z. B. Normalverteilung) befinden sich Mittelwert und Median beide in der Mitte der Verteilung und weichen kaum voneinander ab.

(e) **Wahr.** Das Skalenniveau bestimmt, welche Informationen in den Daten kodiert sind: auf Nominalskala ist nur ein Modalwert sinnvoll, auf Intervallskala ein Mittelwert, und auf Verhältnisskala sind alle Operationen einschließlich Quotienten erlaubt.

(f) **Wahr.** Die Varianz $s^2 = \frac{1}{n-1}\sum(x_i - \bar{x})^2$ wird genau dann null, wenn alle Abweichungen $x_i - \bar{x}$ null sind, also wenn alle x_i gleich sind. Damit ist auch die Standardabweichung $s = 0$, und alle Messwerte sind identisch.
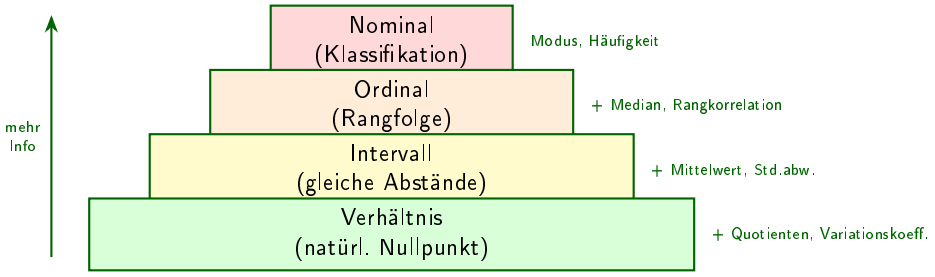
Zusammenfassung: Skalenniveaus