

Grundlagen Statistik (WDS224 · JER)

Quelle: WDS224 - Grundlagen Statistik (JER).zip **Dozent und Autor des Skriptes: Prof. Dr. Roland Jeske**, DHBW Ravensburg (Stand 2025) **Materialien:** Statistik Jeske Gesamtskriptum.pdf (235 Folien) · Statistik Jeske Teil 1_erg.pdf (124 S.) · Uebung mit Lösungen 2025.pdf (38 S., 23 Aufgaben) · Übungen ohne Lösungen 2025.pdf · Modulteil Statistik mit/ohne Lösungen DS Q2 2025.pdf (Klausur) · Excel-Daten (Daten.xlsx, Zeitreihen.xlsx, 241011 Gruppe 2.xlsx)

KLAUSUR — Modulteil Statistik-1

Zugelassene Hilfsmittel	★ Taschenrechner, persönliche Unterlagen (Skripten, Bücher etc.), auch mit Anmerkungen — „sozusagen OPEN-BOOK-KLAUSUR“
Aufbau	4 Aufgaben + 1 Zusatzaufgabe
Gesamtpunktzahl	50 Punkte

Punkteverteilung (Klausur Juni 2025):

Aufgabe	Thema	Punkte
1	Datenformate, Lagemaße, Quartilsabstand, Schiefe	14
2	Trendregression, Bestimmtheitsmaß, Prognose	16
3	Verhältniszahlen (gewogenes arithm./harmon. Mittel)	10
4	Totale Wahrscheinlichkeit + Bayes	10
ZA	Zusatzaufgabe (Theorie/Beweis)	max. 5
	gesamt	50

Wichtige Hinweise aus der Klausur:

- „Mit Bleistift oder roter Tinte bearbeitete Aufgaben können NICHT in die Bewertung einbezogen werden.“
- ★ „LÖSUNGSWEGE SIND HINREICHEND ZU DOKUMENTIEREN.“
- „Der Klausurteil enthält KEINEN Wahlpflichtteil, d.h. sämtliche Standardaufgaben sollten bearbeitet werden, um die maximale Punktzahl zu erreichen.“
- ★ „Die Punkte der Zusatzaufgabe können ERGÄNZEND erworben werden, um etwa kleinere Rechenfehler bei anderen Aufgaben auszugleichen und trotzdem die Punktzahl von 50 Punkten zu erreichen. Da sie eine besondere Herausforderung darstellt, wird empfohlen, diese Aufgabe NICHT VORRANGIG zu bearbeiten.“

Literatur

- Jeske, R. (2017): *Kochbuch der Quantitativen Methoden, Band 3: Statistik*, 2. Auflage, Lulu
- Jeske, R. (2018): *Aufgabenbuch Statistik*, Lulu
- ... sowie viele weitere einführende Statistik-Bücher

Inhaltsverzeichnis

Kapitel	Thema	Kapitel	Thema
1	Einführung und Grundlagen	7	Bivariate Daten
2	Einfache Grafiken	8	Zusammenhangsmaße
3	Lagemaße	9	Einfache lineare Regression
4	Streuungsmaße	10	Zeitreihenanalyse
5	Schiefte und Wölbung	11	Verhältniszahlen
6	Hochwertige Grafiken	12/13	Wahrscheinlichkeiten und Zufallsvariablen

Die Zitate der Einführungsfolien

- „Ich traue keiner Statistik, die ich nicht selbst gefälscht habe.“ — **Winston Churchill (?)**
- „Es gibt drei Arten von Lügen: Notlüge, gemeine Lüge und Statistik.“ — **Benjamin Disraeli**

Die „Orangensaft-Metapher“ des Dozenten (Leitmotiv der Vorlesung!)

„Statistik sollte wie die effiziente Zubereitung eines Glases frischgepressten Orangensaftes sein: Werfen Sie nicht das halbe Fruchtfleisch weg, d.h. **VERSCHWENDEN SIE KEINE INFORMATIONEN** Ihrer Daten. Aber vermeiden Sie auch **ÜBERINTERPRETATIONEN**, denn wenn Sie zu dem Fruchtfleisch auch noch die Schale auspressen, wird das Ergebnis im Saftladen wie auch in der Statistik zuweilen **BITTER...**“ — *Roland Jeske*

KAPITEL 1 — EINFÜHRUNG UND GRUNDLAGEN

1. ★★ Statistische „Vokabeln“ (KLAUSURDEFINITIONEN!)

Begriff	Definition
Statistische Einheiten (auch: Untersuchungseinheiten, Merkmalsträger)	Personen oder Objekte, an denen interessierende Größen gemessen/erhoben werden.
Grundgesamtheit (auch: Population)	Menge ALLER in Frage kommenden statistischen Einheiten
Teilgesamtheit (auch: Subpopulation)	Teilmenge der Grundgesamtheit
Stichprobe	Teilmenge der Grundgesamtheit (im Regelfall deutlich kleiner), Menge der statistischen Einheiten, die ERFASST wurden
Merkmal(e) (auch: Variablen)	Größe(n), die erfasst wurde(n)
Merkmalsausprägung	Wert eines Merkmals

2. ★★★★★ Merkmalstypen und Skalenniveaus (Klausurgrundlage!)

2.1 Quantitativ vs. Qualitativ

	Definition	Beispiele
QUANTITATIVE Merkmale	unterscheiden sich durch ihre GRÖSSE, es wird GEZÄHLT oder GEMESSEN	Alter, Körpergröße, Einkommen, Umsatz
QUALITATIVE Merkmale	unterscheiden sich nur durch ihre ART UND WEISE	Geschlecht, Nationalität

2.2 Stetig vs. Diskret

	Definition	Beispiele
STETIGE Merkmale	können JEDEN BELIEBIGEN Wert annehmen (beliebig exakt messbare Größen)	Länge, Gewicht, Zeit
DISKRETE Merkmale	haben ENDLICH viele Ausprägungen oder auf der Achse mit Ausprägungen LÜCKEN	Alter in Jahren
★ QUASI-STETIGE Merkmale	sind eigentlich DISKRET, werden aber als STETIG aufgefasst	Geldbeträge wie Umsatz oder Einkommen

2.3 ★★★★★ Die drei Skalenniveaus (AUSWENDIG!)

Skala	Definition	Beispiele
NOMINALSKALIERT	Unterscheiden sich nur durch ihre ART UND WEISE und können in KEINE SINNVOLLE REIHENFOLGE gebracht werden	Geschlecht, Nationalität
ORDINALSKALIERT	Weisen hinsichtlich ihrer Ausprägungen eine REIHENFOLGE auf, die ABSTÄNDE sind aber NICHT INTERPRETIERBAR	Güteklassen, Leistungsklassen, Noten, Ratings
KARDINALSKALIERT (metrisch skaliert)	Unterliegen einer REIHENFOLGE UND die ABSTÄNDE der Merkmalsausprägungen sind INTERPRETIERBAR	Alter, Größe, Geldbeträge

★★ **KLAUSURREGEL:** „Man orientiert sich stets am NIEDRIGER SKALIERTEN Merkmal!“ (Beispiel: Alter kardinal + Platzierung ordinal $\Rightarrow$ nur ordinale Verfahren zulässig $\Rightarrow$ **Spearman** statt Bravais-Pearson)

3. ★★★★★ Datenerhebung

Art	Definition	Beispiele
TOTALERHEBUNG (Vollerhebung)	Aus der Grundgesamtheit werden ALLE Untersuchungseinheiten erhoben.	Volkszählung (bis 1987) · Inventuren (gesetzlich vorgeschrieben bis 1979)
STICHPROBE	Aus der Grundgesamtheit wird nur ein TEIL (häufig: ein sehr geringer Anteil) der Untersuchungseinheiten erhoben.	Zensus (ab 2011) · Inventuren (möglich ab 1980)

Anwendung von Stichproben in allen Bereichen:

- Sonntagsfrage ($\rightarrow$ Kosten!)
- Pharmazeutische Forschung ($\rightarrow$ ethische Aspekte)

⚠ **ABER:** Rückschluss von Stichprobe auf Grundgesamtheit muss ZULÄSSIG sein!

4. ★ Datenherkunft

Art	Definition
PRIMÄRDATEN	Selbst erhobene Daten
SEKUNDÄRDATEN	Daten aus FREMDEN Bezugsquellen, die weiteren Anwendern zur Verfügung stehen

Bekannte Sekundärdatenlieferanten: Wirtschaftsforschungsinstitute · Markt- und Meinungsforschungsinstitute · Verbände · Gewerkschaften · Kommerzielle Anbieter

★ Amtliche Statistik

Statistisches Bundesamt (Destatis) · Statistische Landesämter · EUROSTAT · Bundesagentur für Arbeit · Bundesbank · Kraftfahrtbundesamt ⚠ „In Deutschland gehört die **KOMMUNALSTATISTIK NICHT** zur amtlichen Statistik, liefert aber wichtige Beiträge.“

5. ★★★★★ Datenarten (Klausurfrage!)

Art	Definition	Schreibweise	Beispiele
QUERSCHNITTSDATEN	Zu EINEM BESTIMMTEN ZEITPUNKT wird an OBJEKTEN der Grundgesamtheit ein (oder mehrere) Merkmal(e) erhoben.	$x_1, x_2, \dots, x_n$	Krankenhausaufenthalt von Patienten
ZEITREIHENDATEN (auch: Längsschnittdaten)	An EINEM EINZIGEN OBJEKT wird in REGELMÄSSIGEN ABSTÄNDEN ein (oder mehrere) Merkmal(e) erhoben.	$y_1, y_2, \dots, y_T$	DAX, Herzfrequenzkurve
PANELDATEN (Kombination)	Zu BESTIMMTEN ZEITPUNKTEN wird an MEHREREN OBJEKTEN der Grundgesamtheit ein (oder mehrere) Merkmal(e) erhoben.		Sozioökonomisches Panel (SOEP)

★ Panels: Vor- und Nachteil

Vorteil von Panels: AUSWERTUNG IN BEIDE RICHTUNGEN möglich ⚠ **Nachteil von Panels:** PANELSTERBLICHKEIT

6. ★★★★★ Datenformate (der zentrale Klausurbegriff!)

Format	Beschreibung
① ORIGINALDATEN (Urliste, Rohdaten)	Die einzelnen Beobachtungen in Erhebungsreihenfolge
② GEORDNETER DATENSATZ / geordnete Stichprobe	„Ein erster Schritt der Aufarbeitung besteht darin, den Datensatz der Reihe nach zu SORTIEREN.“ Notation: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$
③ HÄUFIGKEITSTABELLE OHNE KLASSIERUNG (auch „GRUPPIERTE Daten“)	Ausprägung a_i mit absoluter Häufigkeit n_i · relative Häufigkeit $r_i = n_i / n$
④ HÄUFIGKEITSTABELLE MIT KLASSIERUNG (auch „KLASSIERTE Daten“)	Klassen mit Klassenmitten m_i , Klassenbreiten Δ_i

★★ Kumulierte Häufigkeiten

„Wenn Merkmale MINDESTENS ORDINAL skaliert sind, ergänzt man in der Häufigkeitstabelle noch die kumulierten Häufigkeiten:“

Kumulierte ABSOLUTE Häufigkeit: $\sum_{j=1..i} n_j$

Kumulierte RELATIVE Häufigkeit: $\sum_{j=1..i} r_j = (1/n) \cdot \sum_{j=1..i} n_j$

★★ Klassierungsregeln

Regel	Formel
Velleman	$k = 2 \cdot \sqrt{n}$
Dixon/Kronmal	$k = 10 \cdot \log_{10}(n)$
Praxis	„Vielfach ist »PERSÖNLICHES« AUGENMASS gefragt!“

Sinnvoll:

- ✓ Gleiche Klassenbreiten
- ✓ Keine offenen Endklassen — ⚠ „Aber: manchmal unumgänglich!“

KAPITEL 2 — EINFACHE GRAFIKEN

7. ★ Die fünf Grundgrafiken

Grafik	Beschreibung
Kreisdiagramm (Tortendiagramm)	„Gemäß der Häufigkeit werden KREISSEKTOREN (Tortenstücke) eingezeichnet.“ Die Winkel berechnen sich über $\alpha_i = r_i \cdot 360^\circ$
Blockdiagramm (Säulen-/Balkendiagramm)	„Gemäß der relativen oder absoluten Häufigkeit werden die BLÖCKE gezeichnet.“
Stabdiagramm	„Gemäß der relativen oder absoluten Häufigkeit werden die STÄBE gezeichnet.“
Polygonzug (Liniendiagramm)	„Gemäß der relativen oder absoluten Häufigkeit werden aufeinanderfolgende ENDPUNKTE mit VERBINDUNGSLINIEN versehen.“
Histogramm	siehe unten

8. ★★★★★ Das Histogramm (KLAUSURFALLE!)

- „Wird insbesondere bei KLASSIERTEN Daten verwendet.“
- ⚠️★★★★ „ACHTUNG! Im Gegensatz zum Blockdiagramm wird die FLÄCHE, NICHT DIE HÖHE proportional zur Häufigkeit gezeichnet.“

★★★★★ Die Häufigkeitsdichte

Fläche des Blocks = r_i (relative Häufigkeit)

⇒ HÖHE = HÄUFIGKEITSDICHTE: $f_i = \frac{r_i}{\Delta_i}$

wobei Δ_i = Klassenbreite der i-ten Klasse

KAPITEL 3 — LAGEMASSE

9. ★★★★★ Sinn und Voraussetzung

„Sinn eines Lagemaßes: BESCHREIBT DAS ZENTRUM EINES DATENSATZES.“ ⚠️★ „ACHTUNG! Nur sinnvoll, wenn es sich um eine UNIMODALE (EINGIPFLIGE) Verteilung handelt. Bei MEHRGIPFLIGEN Verteilungen ist eher eine GRAFIK angebracht, als die Daten auf einen einzigen Wert zu reduzieren!“

10. ★★★★★ Arithmetisches Mittel

Idee: berechne Durchschnittswert

✓ Vorteile	✗ Nachteile
Einfach zu berechnen	⚠️ AUSREISSEREMPFLINDLICH
Populär	⚠️ Verlangt KARDINALES Skalenniveau

★★★★ Die drei Formeln nach Datenformat

ORIGINALDATEN (Urliste):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

HÄUFIGKEITSTABELLE OHNE KLASSIERUNG (gruppierte Daten):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i \cdot a_i = \sum_{i=1}^k r_i \cdot a_i$$

HÄUFIGKEITSTABELLE MIT KLASSIERUNG (klassierte Daten):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i \cdot m_i = \sum_{i=1}^k r_i \cdot m_i$$

wobei m_i = KLASSENMITTE der i -ten Klasse

11. ★★★★★ Median $\tilde{x}$

Idee: berechne MITTE (nicht Mittel) eines Datensatzes, d.h. der Median TEILT DIE DATEN IN ZWEI HÄLFTEN, die jeweils 50 % einnehmen.

✓ Vorteile	✗ Nachteile
★ AUSREISSERUNEMPFINDLICH	Mitunter schwieriger zu berechnen als arithm. Mittel
★ Bereits ab ORDINALEM Skalenniveau einsetzbar	⚠ Bei kardinalen Daten geht INFORMATION VERLOREN!

★★★★ Die drei Berechnungswege

ORIGINALDATEN (geordnete Stichprobe $x_{(1)} \leq \dots \leq x_{(n)}$):

$$\tilde{x} = \begin{cases} x_{(n+1)/2} & \text{falls } n \text{ UNGERADE} \\ \frac{1}{2} \cdot (x_{(n/2)} + x_{(n/2+1)}) & \text{falls } n \text{ GERADE} \end{cases}$$

GRUPPIERTE DATEN:

„Suche die Merkmalsausprägung, bei der die KUMULIERTE RELATIVE HÄUFIGKEIT erstmals den Wert 0,5 ÜBERSCHREITET.“

KLASSIERTE DATEN (lineare Interpolation in der Einfallsklasse):

$$\tilde{x} = x_u + \frac{0,5 - F(\text{untere Klassengrenze})}{r_{\text{Einfallsklasse}}} \cdot \Delta$$

⚠ ★ SONDERFALL (Klausurfalle!): Fällt der Median bereits in die ERSTE Klasse, ist als kumulierte Häufigkeit der „Vorgängerkategorie“ NULL zu setzen!

12. ★★★★★ Quantile

„Die Idee des Medians lässt sich VERALLGEMEINERN: Suche einen Wert, der den Datensatz in BELIEBIGE ANTEILE teilt, etwa im Verhältnis 90 % zu 10 %." ★ „GEZÄHLT WIRD IMMER DER ANTEIL, DER VOR DEM QUANTIL LIEGT, dieser wird als INDEX notiert."

Definition

„ x_p ist derjenige Wert, den der Anteil p der Daten NICHT ÜBERSCHREITET und der Anteil $(1-p)$ der Daten NICHT UNTERSCHREITET."

★★★★★ Berechnung bei Originaldaten (die Klausurregel!)

Berechne $n \cdot p$:

$$\begin{cases} n \cdot p \notin \mathbb{N} & \Rightarrow x_p = x_{(\lceil n \cdot p \rceil)} & (\text{aufrunden!}) \\ n \cdot p \in \mathbb{N} & \Rightarrow x_p = \frac{1}{2} \cdot (x_{(n \cdot p)} + x_{(n \cdot p + 1)}) \end{cases}$$

★★★ Berechnung bei klassierten Daten

$$x_p = x_u + \frac{p - F(\text{untere Klassengrenze})}{r_{\text{Einfallsklasse}}} \cdot \Delta$$

★ Besondere Quantile

Bezeichnung	Definition
QUARTILE	„In diesem Fall wird der Datensatz GEVIERTELT." $x_{0,25}$ heißt unteres Quartil , $x_{0,75}$ heißt oberes Quartil , $x_{0,5}$ — das „mittlere" Quartil — stellt gerade den MEDIAN dar.
PERZENTILE	„Bei Quantilen, die BELIEBIGE PROZENTANTEILE beschreiben" — etwa das 5 %-Perzentil $x_{0,05}$

★ „In der Statistik werden häufig, auch für die Zusammensetzung weiterer Maßzahlen, QUARTILE verwendet."

13. ★★★★★ Modus x_M

= HÄUFIGSTE Merkmalsausprägung (falls eindeutig)

✓ Vorteile	✗ Nachteile
Einfach zu berechnen	⚠ „Vergleichsweise PRIMITIVES Lagemaß, sollte bei höherem Skalenniveau NICHT ALLEINIGES KRITERIUM sein!"
★ Bereits ab NOMINALEM Skalenniveau einsetzbar	

Datenformat	Berechnung
Originaldaten	„Daten gruppieren, dann siehe dort...“
Gruppierte Daten	Ausprägung mit größter Häufigkeit n_i
Klassierte Daten	★ MITTELPUNKT der Klasse mit der HÖCHSTEN HÄUFIGKEITSDICHTE f_i (nicht der höchsten Häufigkeit!)

14. ★★★★★ Gewogenes arithmetisches Mittel

Bislang: gleiche Gewichtung aller Beobachtungen (mit $1/n$). Idee: gezielte UNTERSCHIEDLICHE Gewichtung von Beobachtungen:

$$\bar{x}_g = \sum_{i=1}^k g_i \cdot x_i \quad \text{mit } \sum g_i = 1$$

★★★★★ DIE KLAUSURANWENDUNG: Mittelung von Verhältniszahlen

„MITTELUNG VON VERHÄLTNISZAHLEN (Quotienten), wenn die **NENNERVERTEILUNG** bekannt ist.“

Musterbeispiel „Do Ping“ (gewogenes arithmetisches Mittel)

Der chinesische Radprofi **Do Ping** fährt in einem Rennen **2,5 Stunden** lang mit **42 km/h**. Anschließend fährt er **3 Stunden** lang mit **31 km/h**. Mit welcher Durchschnittsgeschwindigkeit befährt er die Gesamtstrecke?

✓ Lösung 1 (direkt):

In den ersten 2,5 Stunden: $2,5 \cdot 42 = 105 \text{ km}$
 In der zweiten Etappe: $3 \cdot 31 = 93 \text{ km}$
 $\Rightarrow$ insgesamt 5,5 Stunden und 198 km

$$\text{Durchschnittsgeschwindigkeit} = \frac{198 \text{ km}}{5,5 \text{ h}} = 36 \text{ km/h}$$

✓ Lösung 2 (gewogenes arithmetisches Mittel):

$$\bar{x} = \frac{2,5}{3 + 2,5} \cdot 42 + \frac{3}{3 + 2,5} \cdot 31 = 36 \text{ km/h}$$

★ **Warum arithmetisch? Weil die NENNERGRÖSSE (Zeit) bekannt ist!** (km/h — Nenner = Stunden)

15. ★★★★★ Geometrisches Mittel

ORIGINALDATEN:

$$\bar{x}_g = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$$

GRUPPIERTE DATEN:

$$\bar{x}_g = \sqrt[n]{a_1^{n_1} \cdot a_2^{n_2} \cdot \dots \cdot a_k^{n_k}}$$

⚠ „Geometrisches Mittel für KLASSIERTE Daten eher UNÜBLICH, da zu viel Information durch die Klassierung verloren geht.“

★★★★★ DIE KLAUSURANWENDUNG: Mittelung von WACHSTUMSRATEN

📝 **Beispiel:** *Der Wert einer Aktie steigt im ersten Jahr um 30 %, im zweiten Jahr fällt er um 20 %.*

⚠ **POPULÄRER IRRTUM:** „Das durchschnittliche jährliche Wachstum beträgt 5 %.“ ★
Tatsächlich liegt das durchschnittliche Wachstum UNTERHALB VON 2 %!

✅ **Lösung mit Hilfe der WACHSTUMSFAKTOREN:**

$$K_2 = K_0 \cdot (1 + 0,3) \cdot (1 - 0,2) = K_0 \cdot 1,3 \cdot 0,8$$

Hätte sich das Kapital gleichmäßig mit dem Zinssatz i verzinst:

$$K_2 = K_0 \cdot (1 + i)^2$$

$$\Rightarrow i = \sqrt[2]{1,3 \cdot 0,8} - 1 = 0,0198 = 1,98 \%$$

⚠★★★★ „ACHTUNG! Sie müssen das geometrische Mittel auf die WACHSTUMSFAKTOREN, NICHT auf die WACHSTUMSRATEN anwenden!“

📋 **Das Umrechnungsschema (immer erst diese Tabelle aufstellen!)**

Wachstumsrate in Prozent	in Dezimalschreibweise	Wachstumsfaktor
+10 %	0,10	$1 + 0,10 = 1,10$
+2 %	0,02	$1 + 0,02 = 1,02$
-8 %	-0,08	$1 - 0,08 = 0,92$
+5 %	0,05	$1 + 0,05 = 1,05$
+6 %	0,06	$1 + 0,06 = 1,06$

$$\bar{x}_g = \sqrt[5]{1,1 \cdot 1,02 \cdot 0,92 \cdot 1,05 \cdot 1,06} = 1,0281 \Rightarrow \text{durchschnittliches Wachstum} = 1,0281 - 1 = 2,81 \%$$

16. ★★★★★ Harmonisches Mittel

💬 „Anblick des harmonischen Mittels ist zunächst gewöhnungsbedürftig...“

ORIGINALDATEN:

$$\bar{x}_h = \frac{n}{\sum_{i=1}^n (1/x_i)}$$

GEWOGENES HARMONISCHES MITTEL:

$$\bar{x}_h = \left[\sum_{i=1}^k g_i \cdot \frac{1}{x_i} \right]^{-1}$$

⚠ „Harmonisches Mittel für klassierte Daten eher unüblich.“

★★★★★ DIE KLAUSURANWENDUNG

„Mittlung von VERHÄLTNISZAHLEN (Quotienten), wenn die ZÄHLERVERTEILUNG bekannt ist.“



Musterbeispiel „Anna Bolika“ (gewogenes harmonisches Mittel)

Die Radsportlerin **Anna Bolika** fährt **90 km** lang mit **36 km/h**. Anschließend fährt sie **40 km** lang mit **32 km/h**. Mit welcher Durchschnittsgeschwindigkeit befährt sie die Gesamtstrecke?

✓ Lösung 1 (direkt):

Für die ersten 90 km: $90/36 = 2,50$ Stunden

Für die weiteren 40 km: $40/32 = 1,25$ Stunden

⇒ insgesamt 3,75 Stunden und 130 km

Durchschnittsgeschwindigkeit = $130 / 3,75 = 34,67$ km/h

✓ Lösung 2 (gewogenes harmonisches Mittel):

$$\bar{x}_h = \left[\frac{90}{90 + 40} \cdot \frac{1}{36} + \frac{40}{90 + 40} \cdot \frac{1}{32} \right]^{-1} = 34,67 \text{ km/h}$$

★ **Warum harmonisch? Weil die ZÄHLERGRÖSSE (Strecke) bekannt ist!** (km/h — Zähler = Kilometer)

🔑★★★★ DIE ENTSCHEIDUNGSREGEL (die wichtigste Regel des Kapitels!)

Verhältniszahl $V = Z / N$

ZÄHLERVERTEILUNG bekannt	⇒ GEWOGENES HARMONISCHES MITTEL
NENNERVERTEILUNG bekannt	⇒ GEWOGENES ARITHMETISCHES M.

17. ★★ Abschließende Bemerkungen zu den Lagemaßen

Konsequenzen:

1. „Geometrisches und harmonisches Mittel haben **BESONDERE ANWENDUNGSGEBIETE**.“
2. „Bei **NOMINALEN** Daten kann **NUR DER MODUS** verwendet werden.“
3. „Bei höherwertigen Skalen ist der Modus **PRIMITIV** und sollte **NICHT ALS ALLEINIGES Lagemaß** berechnet werden.“
4. „Bei **KARDINALEN** Daten stellt sich vielfach die Frage, ob arithmetisches Mittel **ODER** Median eingesetzt werden sollten...“

★★ Arithmetisches Mittel oder Median?

EINERSEITS: „Das arithmetische Mittel ist aufgrund seiner **SCHWERPUNKTEIGENSCHAFT** **AUSREISSEREMPFINDLICH**, der Median nicht.“

ANDERERSEITS: ★★ „Der Median einer Gesamtpopulation lässt sich **NICHT AUS DEN MEDIANEN DER TEILPOPULATIONEN** berechnen, wie ein Mittelwert. Grund ist, dass der Median auf die **ABSTANDSMESSUNG** (kardinale Eigenschaft) **VERZICHTET** (es geht Information verloren!). Diese **NICHTAGGREGIERBARKEIT** kann zu eigentümlichen Ergebnissen in der Praxis führen, etwa bei der Berechnung der **ARMUTSGEFÄHRDUNGSGRENZE**.“

🔑 **Fazit:** „In der Praxis ist die Frage nach dem sinnvollsten Lagemaß gar nicht so einfach zu beantworten...“

📝 Übungsbeispiel (Nichtaggrierbarkeit):

Population	Werte
Pop. I	1, 2, 5, 5, 6, 7, 11, 16, 20, 33, 37
Pop. II	3, 3, 16, 25, 33
Pop. III	4, 4, 7, 11, 15, 19, 25, 33, 35

Aufgabe: Berechnen Sie jeweils arithmetisches Mittel, Median und Modus für die Teilpopulationen UND die Gesamtpopulation. Welche Schlüsse können Sie ziehen?

18. ★★★ Lineare Transformationen der Lagemaße

Für $y_i = a + b \cdot x_i$ gilt:

Maß	Transformation
Arithmetisches Mittel	$\bar{y} = a + b \cdot \bar{x}$
Median	$\tilde{y} = a + b \cdot \tilde{x}$
Modus	$y_M = a + b \cdot x_M$
Quantil	$y_p = a + b \cdot x_p$ (für $b > 0$)

Speziell für $y_i = b \cdot x_i$ gilt zusätzlich:

Maß	Transformation
Geometrisches Mittel	$\bar{y}_g = b \cdot \bar{x}_g$
Harmonisches Mittel	$\bar{y}_h = b \cdot \bar{x}_h$

Musterbeispiel (Oktoberfestdaten)

„Der Bierkonsum soll nicht in Maßkrügen, sondern in Litern gemessen werden. Es hat sich herausgestellt, dass ein Maßkrug auf der Wies'n nur mit **0,9 l** gefüllt wird.“

Transformation: $y_i = a + b \cdot x_i = 0 + 0,9 \cdot x_i$

$$\bar{y} = 0,9 \cdot \bar{x} = 0,9 \cdot 3,5 = 3,15$$

$$\tilde{y} = 0,9 \cdot \tilde{x} = 0,9 \cdot 3 = 2,70$$

$$y_M = 0,9 \cdot x_M = 0,9 \cdot 3 = 2,70$$

KAPITEL 4 — STREUUNGSMASSE

19. ★★★ Wie misst man Streuung?

Erste Idee: mittlere ABSOLUTE Abweichung vom Mittelwert

$$MAD = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

 **Problem:**

1. „Vielfach möchte man Streuung MINIMIEREN“ (siehe etwa Regressionsmodell)
2. „MINIMIEREN heißt meistens ABLEITEN“
3. ★ „ABER: BETRAGSFUNKTION IST NICHT DIFFERENZIERBAR!“

→ AUSWEG: Betrachte QUADRATISCHE Abweichungen!

20. ★★★★★ Varianz und Stichprobenvarianz

VARIANZ (Divisor n):

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

STICHPROBENVARIANZ (Divisor $n-1$):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

★★★ **DIE PRAXISREGEL:** „Verwende σ^2 , wenn die Varianz einer TOTALERHEBUNG berechnet wird, und s^2 , wenn die Varianz einer STICHPROBE berechnet wird.“

★★★ Die Formeln nach Datenformat

	ORIGINALDATEN	GRUPPIERTE DATEN	KLASSIERTE DATEN
$\sigma^2 = (1/n) \cdot$	$\sum (x_i - \bar{x})^2$	$\sum n_i (a_i - \bar{x})^2$	$\sum n_i (m_i - \bar{x})^2$
$s^2 = 1/(n-1) \cdot$	$\sum (x_i - \bar{x})^2$	$\sum n_i (a_i - \bar{x})^2$	$\sum n_i (m_i - \bar{x})^2$

★★★★★ DER VERSCHIEBUNGSSATZ (Klausur-Rechenhilfe!)

„Für σ^2 gilt der sogenannte VERSCHIEBUNGSSATZ, der die MANUELLE BERECHNUNG der Varianz VEREINFACHT.“

ORIGINALDATEN:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

GRUPPIERTE DATEN:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^k n_i \cdot a_i^2 - \bar{x}^2$$

KLASSIERTE DATEN:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^k n_i \cdot m_i^2 - \bar{x}^2$$

★★★★ Umrechnung $\sigma^2 \leftrightarrow s^2$ (die Klausurabkürzung!)

„Will man den Verschiebungssatz für s^2 nutzen, so kann man ZUNÄCHST σ^2 BERECHNEN und dann in s^2 UMRECHNEN:"

$$s^2 = \frac{n}{n-1} \cdot \sigma^2 \quad \text{bzw.} \quad \sigma^2 = \frac{n-1}{n} \cdot s^2$$

💡 „Unterschiede sind nur bei KLEINEN Stichprobenumfängen gravierend, bei GROSSEN Stichprobenumfängen VERNACHLÄSSIGBAR."

★ Kritik an der Varianz

- „Starke Bedeutung ausgehend von der INDUKTIVEN Statistik"
- ⚠️ AUSREISSEREMPFINDLICH
- ⚠️ „Verwendet die QUADRIERTE MASSEINHEIT des Ausgangsdatensatzes und ist daher SCHWIERIG ZU INTERPRETIEREN."
- → AUSWEG: WURZELZIEHEN ⇒ STANDARDABWEICHUNG

21. ★★★★★ Standardabweichung

$$\sigma = \sqrt{\sigma^2} \quad s = \sqrt{s^2}$$

✓ Vorteile	✗ Nachteile
★ „GLEICHE EINHEIT wie Ausgangsdatensatz"	⚠️ „Nach wie vor AUSREISSEREMPFINDLICH (Eigenschaft überträgt sich von der Varianz)"
★ „POPULÄRSTES Streuungsmaß"	

📝 Kursbeispiele:

Datensatz	σ	s
Patientendaten	$\sqrt{436,8} = 20,9$	$\sqrt{485} = 22,03$
Oktoberfestdaten	$\sqrt{1,55} = 1,24$	$\sqrt{1,56} = 1,25$
Klassierte Trinkgelddaten	$\sqrt{2,21} = 1,49$	$\sqrt{2,33} = 1,53$

22. ★ Spannweite R

$$R = x_{\max} - x_{\min}$$

⚠️ ★ „Die Spannweite ist REIN AXIOMATISCH ein Streuungsmaß, aber als solches EHER UNGEEIGNET, da EXTREM AUSREISSEREMPFINDLICH. Sie dient eher als ORIENTIERUNGSHILFE, etwa bei der KLASSENBUILDUNG." ⚠️ Für klassierte Daten: unüblich.

 **Beispiele:** Patientendaten: $R = 89 - 18 = 71$ · Oktoberfestdaten: $R = 6 - 1 = 5$

23. ★★★★★ Quartilsabstand IQR (Interquartilsabstand)

$$IQR = x_{0,75} - x_{0,25}$$

✓ **Vorteil**

✗ **Nachteil**

★ **AUSREISSERUNEMPFINDLICH**

⚠ „NICHT UNMITTELBAR VERGLEICHBAR mit der Standardabweichung!“

 **Beispiele:** Patientendaten $IQR = 46 - 21 = 25$ · Oktoberfestdaten $IQR = 4 - 2,5 = 1,5$ · Apothekendaten $IQR = 2,19 - 1,15 = 1,04$

24. ★★★★★ Lineare Transformationen der Streuungsmaße

Für $y_i = a + b \cdot x_i$ gilt:

Maß	Transformation
Varianz	$\sigma^2_y = b^2 \cdot \sigma^2_x$
Standardabweichung	$\sigma_y = b \cdot \sigma_x$
Spannweite	$R_y = b \cdot R_x$
(Inter-)Quartilsabstand	$IQR_y = b \cdot IQR_x$

★★ **MERKE:** Der ADDITIVE Term a fällt bei ALLEN Streuungsmaßen WEG — nur der multiplikative Faktor b wirkt!

 **Beispiel Oktoberfestdaten:** $s_x = 1,25$ (Maßkrüge), Transformation 0,9 l pro Krug

$$s_y = 0,9 \cdot s_x = 0,9 \cdot 1,25 = 1,125$$

25. ★★★★★ Variationskoeffizient V

„Bislang: Maße der ABSOLUTEN Streuung.“ **Leitfrage:** *„Ist die Streuung des Konsumverhaltens eine andere, wenn man Maßkrüge oder Liter misst? — JA UND NEIN...“*

- „Natürlich ist die ABSOLUTE Streuung SKALENABHÄNGIG und ändert sich damit, je nachdem, ob man die Einheit in Litern, Millilitern etc. misst.“
- ★ „Die den Daten EIGENE Streuung sollte aber NICHT skalenabhängig sein.“ → Maß der RELATIVEN Streuung

$$V = \frac{\sigma}{\bar{x}} \quad (\text{setzt Standardabweichung und arithmetisches Mittel ins Verhältnis})$$

★ Für lineare Transformationen $y_i = b \cdot x_i$ mit $b > 0$ gilt daher: $V_y = V_x$ — der Variationskoeffizient ist SKALENINVARIANT!

KAPITEL 5 — SCHIEFE UND WÖLBUNG

26. ★★ Momente

„Welche weiteren Maßzahlen sind informativ zur Beschreibung des Datensatzes?“

1. **SCHIEFE** versus **SYMMETRIE** eines Datensatzes
2. Verhalten in den **AUSSENBEREICHEN** einer Verteilung (**WÖLBUNG**) → Beurteilung über sogenannte **MOMENTE**.

$$\text{k-tes (NICHT-ZENTRIERTES) Moment: } m_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

$$\text{k-tes ZENTRIERTES Moment: } \mu_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$$

27. ★★★ Schiefe

Die drei Verteilungsformen

SYMMETRISCH
($\gamma = 0$)



RECHTSSCHIEF
($\gamma > 0$)

(langer Schwanz
nach RECHTS)



LINKSSCHIEF
($\gamma < 0$)

(langer Schwanz
nach LINKS)



★★★ Schiefe nach FISHER (γ_1)

$$\gamma_1 = \frac{(1/n) \cdot \sum (x_i - \bar{x})^3}{\sigma^3} = \frac{\mu_3}{\sigma^3}$$

⚠ Probleme:

- „AUFWÄNDIG in der manuellen Berechnung (KEIN ANALOGON zum Verschiebungssatz der Varianz)“
- „EXTREM AUSREISSEREMPFLINDLICH — aber POPULÄRSTES Maß für Schiefe!“

★★★ Die LAGEREGEL NACH FECHNER (die einfache Beurteilung!)

$$\begin{array}{ll} \bar{x} = \tilde{x} = x_M & \Rightarrow \text{Verteilung ist SYMMETRISCH} \\ \bar{x} > \tilde{x} > x_M & \Rightarrow \text{Verteilung ist RECHTSSCHIEF} \\ \bar{x} < \tilde{x} < x_M & \Rightarrow \text{Verteilung ist LINKSSCHIEF} \end{array}$$

💡 **Merkregel:** Der Mittelwert wird vom „Schwanz“ der Verteilung gezogen.

★★★★ QUARTILSKOEFFIZIENT DER SCHIEFE (QS)

$$QS = \frac{(x_{0,75} - \bar{x}) - (\bar{x} - x_{0,25})}{x_{0,75} - x_{0,25}}$$

✓ Vorteile

Einfach zu berechnen

★ AUSREISSERUNEMPFLINDLICH

Interpretation: $QS > 0 \Rightarrow$ rechtsschief · $QS = 0 \Rightarrow$ symmetrisch · $QS < 0 \Rightarrow$ linksschief

!★ Das Fazit des Dozenten zur Schiefe

- „Implikationen für die Praxis in die FALSCHER RICHTUNG (es gibt MEHR als Symmetrie und Schiefe!)“
- ★★ „SCHIEFE MACHT KEINEN SINN FÜR KLEINE DATENSÄTZE, sondern ist eine Eigenschaft für GROSSE Datensätze (ab $n = 100$).“

 **Übungsbeispiel:** *Liegedauern (in Tagen) von Patient/innen nach einer bestimmten OP:*

7, 4, 10, 5, 6, 8, 8, 9, 7, 8, 18, 8, 7, 9, 6

Aufgaben: a) Schiefe nach Fisher berechnen · b) Fechner'sche Regel anwenden · c) Quartilkoeffizient der Schiefe berechnen

28. ★★★★★ Wölbung (Kurtosis)

Die drei Wölbungsformen

Form	Fachbegriff	Beschreibung
Normalgewölbt	MESOKURTISCH	wie die Normalverteilung
Spitz	LEPTOKURTISCH	steiler als die Normalverteilung, „fat tails“
Flach	PLATYKURTISCH	flacher als die Normalverteilung

★★★★ Wölbung nach FISHER

$$\gamma_2 = \frac{(1/n) \cdot \sum (x_i - \bar{x})^4}{\sigma^4} = \frac{\mu_4}{\sigma^4} \quad (\text{WÖLBUNG})$$

$$\text{Exzess} = \frac{\mu_4}{\sigma^4} - 3 \quad (\text{EXZESS})$$

⚠★★★★ „In der DEUTSCHEN Literatur wird der EXZESS auch häufig als WÖLBUNG bezeichnet (AUFPASSEN, ob 3 bereits abgezogen wurde!), die ENGLISCHE Literatur unterscheidet EINDEUTIG zwischen Wölbung (kurtosis) und Exzess (excess kurtosis)."

Interpretation des Exzesses: $> 0 \Rightarrow$ leptokurtisch (spitz) $\cdot = 0 \Rightarrow$ mesokurtisch $\cdot < 0 \Rightarrow$ platykurtisch (flach)

KAPITEL 6 — HOCHWERTIGE GRAFIKEN

29. ★★★★★ Die 5-Number-Summary und der Boxplot

„Welche Informationen sind für die Beschreibung eines Datensatzes wichtig?" $\Rightarrow$ 5-NUMBER-SUMMARY:

$x_{\min} \cdot x_{0,25} \cdot \bar{x} \text{ (Median)} \cdot x_{0,75} \cdot x_{\max}$

★★★★ Interpretationen des Boxplots (KLAUSURFRAGE!)

Ablesbar	Erläuterung
① LAGEMASS	„Am Boxplot kann mit dem MEDIAN (Strich in der Boxmitte) ein Lagemaß abgelesen werden. Anhänger des Boxplots legen Wert darauf, dass dieses Lagemaß ein AUSREISSERUNEMPFLINDLICHES Maß ist."
② AUSREISSER	„Mögliche Ausreißer kann man an den STRICHEN zum Stichprobenmaximum oder -minimum erkennen. Vielfach werden diese auch in einem verfeinerten Boxplot, dem sog. PUNKTIERTEN BOXPLOT, individuell dargestellt."
③ STREUUNGSMASS	„Mit der BREITE DER BOX kann ein Streuungsmaß abgelesen werden, nämlich der QUARTILSABSTAND. Auch dieses Maß wurde bewusst ausreißerunempfindlich gewählt."
④ SCHIEFE / SYMMETRIE	Visualisierung des Quartilkoeffizienten der Schiefe (siehe unten)

★★★★ Schiefe-Ablesung am Boxplot

- Liegt der Median (etwa) MITTIG in der Box $\Rightarrow$ (annähernd) SYMMETRISCHE Verteilung
- Liegt der Median mehr zum UNTEREN Quartil hin $\Rightarrow$ RECHTSSCHIEFE Verteilung
- Liegt der Median mehr zum OBEREN Quartil hin $\Rightarrow$ LINKSSCHIEFE Verteilung

★ „Es handelt sich bei dieser Schiefebetrachtung wiederum um ein ROBUSTES, d.h. AUSREISSERUNEMPFLINDLICHES Maß.“

★★★ Der punktierte Boxplot — Außenpunkte und Fernpunkte

Besondere Information zu „Ausreißern“:

- ★ „Bei NORMALVERTEILTEN Daten kann man etwa 1 AUSSENUNKT unter 143 Beobachtungen erwarten $\Rightarrow$ GAR NICHT SO UNGEWÖHNLICH“
- ★ „Bei NORMALVERTEILTEN Daten kann man etwa 1 FERNPUNKT unter 427.000 Beobachtungen erwarten $\Rightarrow$ SEHR UNWAHRSCHEINLICH“

Weitere Modifikationen: gekerbter Boxplot · Violinplot · Beeswarmplot

30. ★★★ Quantilsplot (QQ-Plot / Normal-Probability-Plot)

Idee: „Plote die THEORETISCHEN (unter Normalverteilung erwarteten) Quantile gegen die EMPIRISCHEN Quantile.“ (Auch umgekehrt möglich — Vertauschen von x- und y-Achse.)

- ★ „Falls die Daten NORMALVERTEILT sind, liegen die Punkte auf einer GERADEN.“
- „ABWEICHUNGEN lassen SCHIEFE und/oder WÖLBUNG erkennen.“

★★★★ Die Ableseregeln (KLAUSURFRAGE!)

Muster	Bedeutung
Punkte auf einer Geraden	Normalverteilung
★ BOGENFÖRMIGER Verlauf	SCHIEFE — nach oben gewölbt = rechtsschief, nach unten = linksschief
★ SCHLANGENFÖRMIGER Verlauf	WÖLBUNG — leptokurtisch (spitz) bzw. platykurtisch (flach)

⚠ „ABER: Falls x-/y-Achse vertauscht werden, GENAU UMGEKEHRT!“

31. ★★★ Kerndichteschätzung

„Kerndichteschätzer beseitigen das Problem, dass die Daten in der Praxis NICHT GLEICHMÄSSIG VERTEILT sind und bei UNTERSCHIEDLICHER WAHL VON URSPRUNG UND KLASSENBREITE STARK UNTERSCHIEDLICHE HISTOGRAMME entstehen lassen, die unterschiedliche Eindrücke zu Symmetrie und Schiefe aufkommen lassen können.“

★ Die fünf Kernfunktionen im Kurs

Kern	Eigenschaft
RECHTECKSKERN	„Führt zu MITTELUNG VON HISTOGRAMMEN" (allerdings nach wie vor mit Sprüngen , d.h. nicht glatt)
DREIECKSKERN	glatter als Rechteck
EPANECHNIKOW-KERN	theoretisch optimal (minimaler MISE)
BISQUARE-KERN	(Quartic-Kern)
NORMAL-KERN	Gauß-Kern, glatteste Variante

KAPITEL 7 — BIVARIATE DATEN

32. ★ Übergang zu bivariaten Daten

„Bislang: UNIVARIATE Daten, d.h., es wurde jeweils nur EIN EINZELNES Merkmal betrachtet. Zukünftig wird das ZUSAMMENWIRKEN ZWEIER MERKMALE (BIVARIATE Untersuchung) betrachtet."

Mögliche Datenformate: Originaldaten $(x_1, y_1), \dots, (x_n, y_n)$ · Gruppierte Daten (Kontingenztafel) · Klassierte Daten · ★ auch GEMISCHTE Datenformen (z.B. gruppiert/klassiert) sind möglich

33. ★ Der Scatterplot

Die Standardgrafik bivariater Daten — jede Beobachtung als Punkt (x_i, y_i) im Koordinatensystem.

KAPITEL 8 — ZUSAMMENHANGSMASSE

34. ★★★ Die Grundunterscheidung (Klausurfrage!)

Begriff	Definition
KORRELATION	Zusammenhangsmaß zwischen KARDINAL oder ORDINAL skalierten Merkmalen
KONTINGENZ	Zusammenhangsmaß bei NOMINAL skalierten Merkmalen
ASSOZIATION	Spezialfall der Kontingenz: BEIDE Merkmale haben JEWEILS NUR ZWEI Ausprägungen → VIERFELDERTAFEL

35. ★★ Kovarianz

$$\sigma_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Verschiebungssatz:

$$\sigma_{xy} = \frac{1}{n} \sum_{i=1}^n x_i \cdot y_i - \bar{x} \cdot \bar{y}$$

Geometrische Deutung (Quadranten um den Schwerpunkt):

- ★ „VIELE und GROSSE Flächen im ERSTEN und DRITTEN Quadranten führen zu POSITIVEN Werten (»positiver Zusammenhang«)“
- ★ „VIELE und GROSSE Flächen im ZWEITEN und VIERTEN Quadranten führen zu NEGATIVEN Werten (»negativer Zusammenhang«)“

⚠️ ★ **PROBLEM:** „Die Kovarianz ist UNBESCHRÄNKT und kann JEDEN REELLEN WERT annehmen!“
→ **AUSWEG:** STANDARDISIERUNG

36. ★★★ Korrelation nach BRAVAIS-PEARSON

$$r_{xy} = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y}$$

RECHENFORMEL (Klausurformel!):

$$r_{xy} = \frac{\sum x_i y_i - n \cdot \bar{x} \cdot \bar{y}}{\sqrt{(\sum x_i^2 - n \cdot \bar{x}^2)} \cdot \sqrt{(\sum y_i^2 - n \cdot \bar{y}^2)}}$$

Wertebereich: $-1 \leq r_{xy} \leq +1$

⚠️ ★★ **WAS MISST r GENAU? (die zentrale Klausurwarnung!)**

Der Korrelationskoeffizient nach Bravais-Pearson misst NUR den LINEAREN Zusammenhang!

★★ „Es kann aber SEHR WOHL EIN NICHTLINEARER ZUSAMMENHANG VORLIEGEN, wenn eine Korrelation von NULL ausgewiesen wird!“

💬 **Praxistipp des Dozenten:** „ZEITGEWINN bedeutet in der Klausur häufig PUNKTEZUWACHS...“ →
Immer den Verschiebungssatz / die Rechenformel verwenden, nicht die Definitionsformel!

37. ★★★ Rangkorrelation nach SPEARMAN

„Wie gelangt man zu einem Zusammenhangsmaß für ORDINAL skalierte Merkmale?" ★ Idee: „Verwende den Korrelationskoeffizienten nach BRAVAIS-PEARSON für die RÄNGE statt für die Beobachtungen."

$$R_{xy} = r_{\{R(x), R(y)\}}$$

VEREINFACHTE FORMEL (nur wenn KEINE BINDUNGEN vorliegen!):

$$R_{xy} = 1 - \frac{6 \cdot \sum d_i^2}{n \cdot (n^2 - 1)} \quad \text{mit } d_i = R(x_i) - R(y_i)$$

⚠ Achtung: In den Kursunterlagen wird der Nenner auch als $(n-1) \cdot n \cdot (n+1)$ geschrieben — das ist dasselbe!

⚠ ★★★ WAS MISST SPEARMAN GENAU?

Spearman misst den MONOTONEN Zusammenhang. ★ „ABER es kann sehr wohl ein NICHT-MONOTONER Zusammenhang vorliegen, wenn eine Korrelation von Null ausgewiesen wird!"

📝 ★★★ Musterbeispiel Spearman (Noten Mathematik/Physik)

Die Noten von sechs zufällig ausgewählten Schülern in Mathematik (x_i) und Physik (y_i):

x_i	y_i	$R(x_i)$	$R(y_i)$	$[R(x)-R(y)]^2$
2+	1-	2	1	1
2-	2	3	2	1
1	2-	1	3	4
3-	3+	4	4	0
5	4+	6	5	1
4-	4	5	6	1
			Summe:	8

✓ Lösung: „Es liegen keine Bindungen vor, daher kann mit der vereinfachten Formel gerechnet werden."

$$R_{xy} = 1 - \frac{6 \cdot 8}{5 \cdot 6 \cdot 7} = 1 - 8/35 = 0,77$$

38. ★★★ Yule'scher Assoziationskoeffizient (Vierfeldertafel)

„Populärstes Maß für die Vierfeldertafel“

	B	$\bar{B}$
A	a	b
$\bar{A}$	c	d

$$Q = \frac{a \cdot d - b \cdot c}{a \cdot d + b \cdot c}$$

Wertebereich: $-1 \leq Q \leq +1$

39. ★★★ Der Kontingenzkoeffizient nach PEARSON

„Liegt eine BELIEBIG GROSSE Kontingenztafel vor, so ist der Yule'sche Assoziationskoeffizient NICHT MEHR ANWENDBAR.“

Idee:

1. „Betrachte eine Kontingenztafel mit GLEICHEN RANDVERTEILUNGEN, aber UNABHÄNGIGKEIT“
2. „Messe die ABWEICHUNG zwischen den Zelleinträgen BEIDER Tabellen“

★★★ Die Berechnung in DREI STUFEN (Klausurschema!)

① ERWARTETE Häufigkeiten unter Unabhängigkeit:

$$\hat{n}_{ij} = \frac{n_{i\cdot} \cdot n_{\cdot j}}{n}$$

② CHI-QUADRAT:

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}}$$

③ KONTINGENZKOEFFIZIENT nach PEARSON:

$$K = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

④ KORRIGIERTER Kontingenzkoeffizient:

$$K^* = \sqrt{\frac{M}{M-1}} \cdot K \quad \text{mit } M = \min\{\text{Zeilenzahl}; \text{Spaltenzahl}\}$$

⚠️★★★★ ZUR INTERPRETATION DER KONTINGENZ (KLAUSURFRAGE!)

„Steht etwa ein Wert von 0,2 für eine starke oder schwache Abhängigkeit?“

1. ⚠️ „INTERPRETATION IN DER PRAXIS ERFOLGT HÄUFIG FALSCH! Anwender neigen mitunter dazu, Größenwerte ÄHNLICH WIE DEN ABSOLUTEN WERT EINES KORRELATIONSKOEFFIZIENTEN zu interpretieren — DAS IST FALSCH!“
2. ★ „In der THEORIE kann der korrigierte Kontingenzkoeffizient Werte in [0;1] annehmen, in der PRAXIS liegen Werte DEUTLICH UNTER 1!“
3. ★ „Aussagen über den Zusammenhang sollten daher STATISTISCH in Form eines KONTINGENZTESTS (siehe Statistik 2) ABGESICHERT werden.“
4. ★★ „Zudem kann man die ART DER ABHÄNGIGKEIT NUR ÜBER DIE BEDINGTEN VERTEILUNGEN klären.“

 **Kursbeispiel (bedingte Verteilungen):** *Geschlechtsverteilung nach Altersklassen*

Klasse	männlich	weiblich
Kinder und Jugendliche	0,513	0,487
Personen im Erwerbsalter	0,502	0,498
Personen im Rentenalter	0,425	0,575

★ Erst diese bedingten Verteilungen zeigen, WORIN die Abhängigkeit besteht: der Frauenanteil steigt deutlich im Rentenalter.

KAPITEL 9 — EINFACHE LINEARE REGRESSION

40. ★★★★★ Korrelation vs. Regression (die Kernabgrenzung!)

KORRELATION: $x \leftrightarrow y$ d.h. WECHSELSEITIGE Beziehung

REGRESSION: $x \rightarrow y$ d.h. EINSEITIGE EINFLUSSNAHME von x auf y

41. ★★★★★ Die Regressionsgerade (KLAUSURFORMELN!)

$$\hat{y} = \hat{a} + \hat{b} \cdot x$$

STEIGUNGSPARAMETER:

$$\hat{b} = \frac{\sigma_{xy}}{\sigma_x^2} = \frac{\sum x_i y_i - n \cdot \bar{x} \cdot \bar{y}}{\sum x_i^2 - n \cdot \bar{x}^2}$$

ACHSENABSCHNITT:

$$\hat{a} = \bar{y} - \hat{b} \cdot \bar{x}$$

42. ★★★★★ Das Bestimmtheitsmaß R^2

„Idee für ein Gütemaß: Messe den ANTEIL DER STREUUNG DER ABHÄNGIGEN VARIABLEN, DER DURCH DIE REGRESSION ERKLÄRT WIRD.“

$$R^2 = \frac{ES}{GS} = \frac{\text{erklärte Streuung}}{\text{gesamte Streuung}} \quad \text{mit } GS = ES + NS$$

Bei der EINFACHEN linearen Regression gilt zudem:

$$R^2 = (r_{xy})^2 \quad \star \text{ (die schnelle Klausurformel!)}$$

★ „Ziel: MÖGLICHST HOHES Bestimmtheitsmaß!“ Zerlegung: $GS = ES$ (erklärte Streuung) + NS (nicht erklärte Streuung)

💬 **„Einmal mehr: ZEIT SIND PUNKTE IN DER KLAUSUR!“ → immer $R^2 = r^2$ verwenden, nicht die Streuungszersetzung ausrechnen!**

43. ★★★★★ Standardfehler und relativer Standardfehler

STANDARDFEHLER:

$$SE = \sqrt{\frac{NS}{n}} \quad (NS = \text{nicht erklärte Streuung})$$

RELATIVER STANDARDFEHLER:

$$RSE = \frac{SE}{\bar{y}}$$

44. ★★★★★ Scheinkorrelation

★ „Eigentlich müsste es SCHEINZUSAMMENHANG heißen, denn dieses Phänomen tritt NICHT NUR bei kardinal und ordinal skalierten Daten auf, sondern AUCH BEI NOMINAL skalierten!"

Das Kursbeispiel

„Sinkt mit steigender Zahl von Elektroautos die Anzahl von Toten im Straßenverkehr?" Immerhin: $r = -0,74$!

★★★★★ Die Ursache

„Das Phänomen tritt IMMER DANN auf, wenn BEIDE Merkmale jeweils eine STARKE KORRELATION ZU EINER DRITTVARIABLEN besitzen." ★★ „HÄUFIGE DRITTVARIABLE: DIE ZEIT!"
 ★★ „Für Merkmale mit TREND (insbesondere ZEITREIHEN) berechnet man IMMER eine STARKE (SCHEIN-)KORRELATION."

★★★★★ Der Ausweg: PARTIELLE KORRELATION

Weg 1 — über Residuen:

① Regressiere beide Merkmale gegen die Drittvariable z :

$$\hat{x} = \hat{a}_x + \hat{b}_x \cdot z$$

$$\hat{y} = \hat{a}_y + \hat{b}_y \cdot z$$

② Rechne die Effekte heraus (Residuen):

$$\hat{u}_x = x_i - \hat{x}_i$$

$$\hat{u}_y = y_i - \hat{y}_i$$

③ Berechne die PARTIELLE KORRELATION:

$$r_{\{\hat{u}_x, \hat{u}_y\}}$$

Weg 2 — die einfache Formel (Klausurformel!):

$$r_{xy|z} = \frac{r_{xy} - r_{xz} \cdot r_{yz}}{\sqrt{(1 - r_{xz}^2)} \cdot \sqrt{(1 - r_{yz}^2)}}$$

 Im Kursbeispiel: mit $r_{xy} = 0,74$, $r_{xz} = 0,91$, $r_{yz} = -0,88$ erhält man

$$r_{xy|z} = -0,3$$

★ Die scheinbar starke Korrelation von $-0,74$ schrumpft auf $-0,3$, sobald man die Zeit herausrechnet!

KAPITEL 10 — ZEITREIHENANALYSE

45. ★★ Grundlagen

Gegeben: Zeitreihendaten $y_1, y_2, y_3, \dots, y_T$

Ziele bei Zeitreihen:

1. **PROGNOSE**
2. **GLÄTTUNG**
3. **SAISONBEREINIGUNG** (*nicht in dieser Vorlesung*)

★ Das additive Komponentenmodell

$$y_t = T_t + S_t + u_t$$

$$T_t = \text{TREND (glatte Komponente)} \cdot S_t = \text{SAISONkomponente} \cdot u_t = \text{RESTkomponente}$$

46. ★★★ Glättung durch gleitende Durchschnitte

★★ UNGERADE Länge ($2k+1$)

Gleitender DREIERdurchschnitt:

$$y^*_t = (1/3) \cdot (y_{t-1} + y_t + y_{t+1})$$

ALLGEMEIN (Länge $2k+1$):

$$y^*_t = 1/(2k+1) \cdot (y_{t-k} + \dots + y_{t-1} + y_t + y_{t+1} + \dots + y_{t+k})$$

★★★★ GERADE Länge ($2k$) — die „halben Randgewichte“ (KLAUSURFORMEL!)

„Zunächst plausibel: Bildung gleitender Mittel mit ungerader Länge — Beobachtung selbst sowie k Vorgänger und k Nachfolger. Wie kann man gleitende Mittel mit GERADER Länge bilden?“

Gleitender ZWEIERdurchschnitt:

$$\begin{aligned} y^*_t &= \frac{1}{2} \cdot \left(\frac{1}{2} \cdot y_{t-1} + y_t + \frac{1}{2} \cdot y_{t+1} \right) \\ &= \frac{1}{4} \cdot y_{t-1} + \frac{1}{2} \cdot y_t + \frac{1}{4} \cdot y_{t+1} \end{aligned}$$

ALLGEMEIN (Länge $2k$):

$$y^*_t = 1/(2k) \cdot \left(\frac{1}{2} \cdot y_{t-k} + y_{t-k+1} + \dots + y_{t-1} + y_t + y_{t+1} + \dots + y_{t+k-1} + \frac{1}{2} \cdot y_{t+k} \right)$$

★★ **MERKE:** Bei GERADER Länge bekommen die BEIDEN RANDWERTE nur das HALBE Gewicht!

★★ Die Auswahlregel

Fall	Regel
Bei SAISONBEHAFTETEN Daten	① Bestimme die LÄNGE DER PERIODE: $m = 12$ bei Monatsdaten · $m = 4$ bei Quartalsdaten · $m = 5, 6$ oder 7 bei Wochentagen ② Verwende den passenden gleitenden Durchschnitt der Länge $m = 2k$ oder $m = 2k+1$
Bei Zeitreihen OHNE Saison	Verwende gleitenden Durchschnitt UNGERADER Länge (Augenmaß gefragt)

47. ★★★ Trendregression

„Weitere Idee zur Beschreibung von Zeitreihen: REGRESSION MIT LINEAREM TREND, d.h. die ERKLÄRENDE VARIABLE im einfachen Regressionsmodell ist DIE ZEIT SELBST:"

$$x_t = t \quad t = 1, 2, \dots, T$$

★★★★ Vergleich gleitende Durchschnitte vs. Trendregression (KLAUSURTABELLE!)

Verfahren	✓ Vorteil	✗ Nachteil
Gleitende Durchschnitte	FLEXIBLE ANPASSUNG der glatten Komponente	⚠ FORTSCHREIBUNG AM AKTUELLEN RAND SCHWIERIG — es fehlen Werte
Trendregression	SEHR EINFACHE FORTSCHREIBUNG am aktuellen Rand	⚠ Nur STARRE Anpassung (GERADE) der glatten Komponente

★ „In der Praxis häufig: KOMBINATION BEIDER VERFAHREN (etwa BERLINER VERFAHREN).“
 Zudem gibt es zahlreiche weitere Verfahren:

- Exponentielles Glätten, HOLT-WINTERS-Verfahren
- ARIMA(p,d,q) — BOX-JENKINS-Verfahren (siehe etwa Hamilton: Time Series Analysis)

KAPITEL 11 — VERHÄLTNISZAHLEN

48. ★★ Grundlagen

„Im alltäglichen Leben werden **INDIKATOREN** berechnet zu unterschiedlichen Themen:"

Demografie-Atlas (demografischer Wandel) · **Armutsberichte** · **Regionalstudien zur wirtschaftlichen Leistungsfähigkeit** · **Glücksatlas** („Wo sind die Menschen glücklich in Deutschland?“)

„Vereinzelt handelt es sich bei Indikatoren um **ABSOLUTZAHLEN**. Aufgrund unterschiedlicher Größen von Regionen und anderer Teilpopulationen werden in den meisten Fällen **RELATIVE GRÖSSEN** betrachtet:" Geburtenziffer · Anteile (z.B. Bevölkerung mit Migrationshintergrund) · Preissteigerungen

★ „Alle diese Größen haben eines gemeinsam: sie setzen eine **ZÄHLERGRÖSSE Z** in Bezug auf eine **NENNERGRÖSSE N**:"

$$V = \frac{Z}{N}$$

⚠ „In der allgemeinen Wahrnehmung sind sie **NUR DATEN WIE ANDERE AUCH...** (mitunter mit **KATASTROPHALEN FOLGEN!**)"

49. ★★★ Die drei Typen von Verhältniszahlen

Typ	Definition	Beispiele
① GLIEDERUNG SZAHLN	„Verhältniszahl, bei der die Größe im ZÄHLER IMMER EINE TEILMENGE DER NENNERGRÖSSE ist: $Z \subset N$ "	Frauenanteil in Führungspositionen · Ausländeranteil in der Bevölkerung · Durchfallquote in der Statistiklausur · Ausschussanteil einer Produktion
② BEZIEHUNGS ZAHLEN	Teilen sich auf in Verursachungs- und Entsprechungszahlen (siehe unten)	
② a) VERURSACHU NGSZAHLN	★ „d.h. NENNERGRÖSSE IST URSÄCHLICH FÜR ZÄHLERGRÖSSE "	Geburtenziffer (Anzahl Geburten / Frauen im gebärfähigen Alter) · Unfalldichte (Anzahl Unfälle / Anzahl zugelassener KFZ)
② b) ENTSPRECHU NGSZAHLN	★ „Zähler- und Nennergröße haben einen SINNVOLLEN BEZUG "	Anzahl Krankenhausbetten / 1.000 Einwohner · Anzahl Studierender / Dozent
③ INDEXZAHLE N / MESSZIFFERN	Zeitliche Vergleiche	siehe unten

🔑★★★★ NOCHMALS ZUR ERINNERUNG (die Klausurregel!)

Für ALLE Verhältniszahlen gilt:

ZÄHLERverteilung bekannt → gewogenes HARMONISCHES Mittel
 NENNERverteilung bekannt → gewogenes ARITHMETISCHES Mittel

50. ★★★★★ Indexzahlen

50.1 Messziffer (einfacher Index)

„Wie misst man Preissteigerungen/Inflation? Erste Idee: Verhältnis NEUER Preis zu ALTEM Preis:“

$$\frac{p_t}{p_{t-1}} \quad \text{oder} \quad \frac{p_t}{p_{t-s}}$$

★ „Werden Zeitreihendaten zu einem VORGÄNGER ins Verhältnis gesetzt, nennt man diese Größe MESSZIFFER (oder auch: EINFACHER INDEX).“

⚠️ PROBLEM: „Mit den Preismessziffern erfasst man NUR PREISSTEIGERUNGEN EINZELNER PRODUKTE: manche Preise steigen tendenziell, manche stagnieren, manche sinken.“

📝 Kursbeispiel (Destatis) — Durchschnittliche jährliche Preissteigerung in Bayern 1995–2010:

Bereich	Steigerung
Alkohol und Tabak	+3,1 % / Jahr
Nachrichtenübermittlung	–2,9 % / Jahr
Freizeit/Kultur/Unterhaltung	+0,07 % / Jahr

⇒ „Wie ermittelt man die Steigerung der GESAMTEN KONSUMKOSTEN?“

50.2 ★★★★★ Der Verbraucherpreisindex (VPI)

„Ermittle den TYPISCHEN WARENKORB eines deutschen Verbrauchers bzw. Haushalts und VERGLEICHE DIE PREISE DIESER WARENKÖRBE zu unterschiedlichen Zeiten, um die Inflation zu messen.“ Notation: $q_{i,t}$ = Menge des konsumierten Produkts i zum Zeitpunkt t · $p_{i,t}$ = Preis des konsumierten Produkts i zum Zeitpunkt t

★★★★ DIE ZWEI PREISINDIZES (KLAUSURFORMELN!)

a) PREISINDEX NACH LASPEYRES (verwendet Warenkorb der BASISperiode):

$$P_L = \frac{\sum p_{\{i,t\}} \cdot q_{\{i,0\}}}{\sum p_{\{i,0\}} \cdot q_{\{i,0\}}}$$

b) PREISINDEX NACH PAASCHE (verwendet Warenkorb der BERICHTSperiode):

$$P_P = \frac{\sum p_{\{i,t\}} \cdot q_{\{i,t\}}}{\sum p_{\{i,0\}} \cdot q_{\{i,t\}}}$$

💡 **MERKREGEL:** L wie „Länger her“ ⇒ Laspeyres nimmt den **ALTEN** Warenkorb (Basisperiode).
Paasche nimmt den **AKTUELLEN** (Berichtsperiode).

⚠️★★★★ Die Nachteile beider Indizes

„Beide haben Nachteile und fangen die Dynamik nicht richtig ein:“

- ⚠️ „Der LASPEYRES-Index hat einen VERALTENDEN Warenkorb.“
- ⚠️ „Der PAASCHE-Index kennt KEINE FRÜHEREN PREISE aktueller Neuheiten im Warenkorb.“
- ⚠️ „Zudem: ERHEBLICHER AUFWAND, stets (MONATLICH!) einen aktuellen Warenkorb zu ermitteln!“

★★ „→ In der Praxis wird ZUMEIST DER LASPEYRES-INDEX verwendet und der Warenkorb wird etwa ALLE 5 JAHRE neu ermittelt (in Deutschland durch die EVS = EINKOMMENS- UND VERBRAUCHSSTICHPROBE).“

★★★★ Die Wertgewichtsmethode (der elegante Zusammenhang!)

„Umformungen (»Wertgewichtsmethode«) lassen die beiden Indizes als GEWOGENE MITTEL DER EINZELNEN PREISMESSZIFFERN schreiben:“

Index	Darstellung	★ Mittelwerttyp
LASPEYRES	$P_L = \sum g_{\{i,0\}} \cdot (p_{\{i,t\}}/p_{\{i,0\}})$ mit $g_{\{i,0\}}$ = Umsatzanteile des Produkts i im Warenkorb der BASISperiode	★★ GEWOGENES ARITHMETISCHES MITTEL!
PAASCHE	$P_P = [\sum g_{\{i,t\}} \cdot (p_{\{i,0\}}/p_{\{i,t\}})]^{-1}$ mit $g_{\{i,t\}}$ = Umsatzanteile des Produkts i im Warenkorb der BERICHTSperiode	★★ GEWOGENES HARMONISCHES MITTEL!



COICOP-Klassifikation

„Classification of Individual Consumption by Purpose“ — der hierarchische Aufbau des Warenkorbs.

KAPITEL 12/13 — WAHRSCHEINLICHKEIT

51. ★★ Die drei Wahrscheinlichkeitsbegriffe

Begriff	Beschreibung
SUBJEKTIVE Wahrscheinlichkeit	→ Experten fragen
FREQUENTISTISCHE Wahrscheinlichkeit	Experimentieren: „Wenn die letzte Glühbirne erloschen ist, kenne ich den Ausschussanteil“
★ THEORETISCHE Wahrscheinlichkeit	„IM FOKUS DIESER VORLESUNG!“

52. ★★ Zufallsexperiment, Ereignisse und Mengen

„Bei einem ZUFALLSEXPERIMENT kennt man MÖGLICHE AUSGÄNGE“ — z.B. Würfelwurf: 1,2,3,4,5,6 · Münzwurf: Kopf, Zahl. ⚠ „ABER: vorab UNBEKANNT, welcher Ausgang eintreten wird!“

Begriff	Notation
Elementarereignis (einzelnes Ereignis)	ω
Zusammengesetzte Ereignisse	A, B, C, ...
Menge aller Elementarereignisse	Ω

★ „Ereignisse werden mathematisch im MENGENKALKÜL dargestellt.“

53. ★★★ Laplace-Wahrscheinlichkeit (klassische Wahrscheinlichkeit)

$$P(A) = \frac{\text{Anzahl der GÜNSTIGEN Fälle}}{\text{Anzahl der MÖGLICHEN Fälle}} = \frac{|A|}{|\Omega|}$$

54. ★★★ Die Rechenregeln (Klausurgrundlage!)

GEGENEREIGNIS:	$P(\bar{A}) = 1 - P(A)$
ADDITIONSSATZ:	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$
UNABHÄNGIGKEIT:	$P(A \cap B) = P(A) \cdot P(B)$
DE MORGAN:	$P(\bar{A} \cap \bar{B}) = P(A \cup B)^{-} = 1 - P(A \cup B)$ $P(\bar{A} \cup \bar{B}) = P(A \cap B)^{-} = 1 - P(A \cap B)$

55. ★★★★★ Bedingte Wahrscheinlichkeit

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

⚠★★★★ **WICHTIGE WARNUNG DES DOZENTEN:** „Die KOLMOGOROFF-AXIOME gelten für das ERSTE Argument, NICHT für das ZWEITE!“ (D.h. $P(\cdot | B)$ ist ein Wahrscheinlichkeitsmaß in A , aber $P(A | \cdot)$ ist KEINES in B !)

56. ★★★★★ Satz von der totalen Wahrscheinlichkeit

$$P(B) = \sum_i P(B | A_i) \cdot P(A_i)$$

(A_i bilden eine vollständige Zerlegung von Ω)

57. ★★★★★ Die BAYES-FORMEL

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)} = \frac{P(B | A) \cdot P(A)}{\sum_i P(B | A_i) \cdot P(A_i)}$$

 **Kursbeispiel:** das „ZIEGENPROBLEM“ (Monty-Hall-Problem)

★★★★★ Die wichtige Anwendung: MEDIZINISCHE DIAGNOSTIK

Begriff	Definition
SENSITIVITÄT	$P(T D)$ — der Test zeigt POSITIV, wenn die Krankheit/Droge vorliegt
SPEZIFITÄT	$P(\bar{T} \bar{D})$ — der Test zeigt NEGATIV, wenn nichts vorliegt
PRÄVALENZ	$P(D)$ — die Grundwahrscheinlichkeit in der Population
Gesuchter Wert (PPV)	$P(D T)$ — Wahrscheinlichkeit, dass tatsächlich etwas vorliegt, wenn der Test positiv ist

$$P(D|T) = \frac{\text{Sensitivität} \cdot \text{Prävalenz}}{\text{Sensitivität} \cdot \text{Prävalenz} + (1 - \text{Spezifität}) \cdot (1 - \text{Prävalenz})}$$

58. ★★★★★ Kombinatorik — die Grundformeln

Situation	Formel	Name
Anordnung von n Objekten	$n!$	Permutation
Anordnung von n Objekten, davon Gruppen à $n_1, n_2, \dots$ gleich	$n! / (n_1! \cdot n_2! \cdot \dots)$	Permutation MIT Wiederholung
k aus n , MIT Reihenfolge, MIT Zurücklegen	n^k	Variation MIT Wiederholung
k aus n , MIT Reihenfolge, OHNE Zurücklegen	$n! / (n-k)!$	Variation OHNE Wiederholung
k aus n , OHNE Reihenfolge, OHNE Zurücklegen	$C(n,k) = n! / (k! \cdot (n-k)!)$	Kombination OHNE Wiederholung
k aus n , OHNE Reihenfolge, MIT Zurücklegen	$C(n+k-1, k)$	Kombination MIT Wiederholung

TEIL A — DIE AUFGABENSAMMLUNG MIT VOLLSTÄNDIGEN MUSTERLÖSUNGEN

★★★★★ Aufgabe 0.1 — Klassierte Daten (Wartezeit Supermarktkasse)

Die Wartezeit an einer Supermarktkasse wurde in einer Stichprobe vom Umfang $n = 120$ erhoben:

Wartezeit in Minuten (von ... bis unter ...)	Häufigkeit
0 – 2	67
2 – 5	32
5 – 10	17
10 – 20	3
20 – 30	1

a) Arithmetisches Mittel, Median und Modus · b) Standardabweichung und Quartilsabstand · c) Histogramm · d) Schiefe nach Fisher

✓ Die Arbeitstabelle (IMMER ZUERST AUFSTELLEN!)

Klasse	n_i	m_i	$n_i \cdot m_i$	$n_i \cdot m_i^2$	r_i	Σr_j	Δ_i	$f_i = r_i / \Delta_i$
[0; 2)	67	1,0	67,0	67,00	0,558	0,558	2	0,2790
[2; 5)	32	3,5	112,0	392,00	0,267	0,825	3	0,0890
[5; 10)	17	7,5	127,5	956,25	0,142	0,967	5	0,0284
[10; 20)	3	15,0	45,0	675,00	0,025	0,992	10	0,0025
[20; 30)	1	25,0	25,0	625,00	0,008	1,000	10	0,0008
Summe	120		376,5	2.715,25	1,000			

✓ a) Lagemaße

ARITHMETISCHES MITTEL:

$$\bar{x} = (1/120) \cdot 376,5 = 3,1375 \approx 3,14$$

MEDIAN – ⚠ SONDERFALL!

„Für den Median ergibt sich bei diesem Datensatz ein SONDERFALL, denn die ERSTE KLASSE stellt bereits die EINFALLSKLASSE für den Median dar.

Als Wert für die kumulierte Häufigkeit für die »Vorgängerkategorie« ist daher NULL zu setzen:"

$$\tilde{x} = 0 + \frac{0,5 - 0}{0,558} \cdot (2-0) = \frac{0,5}{0,558} \cdot 2 = 1,79$$

MODUS – „als Mittelpunkt der Klasse mit der HÖCHSTEN HÄUFIGKEITSDICHTE“:

$$x_M = (0 + 2)/2 = 1$$

✓ b) Streuungsmaße

VARIANZ (Verschiebungssatz):

$$\sigma^2 = (1/120) \cdot 2.715,25 - 3,1375^2 = 12,7832$$

STICHPROBENVARIANZ:

$$s^2 = (120/119) \cdot 12,7832 = 12,8906$$

STANDARDABWEICHUNGEN:

$$\sigma = \sqrt{12,7832} = 3,58 \quad s = \sqrt{12,8906} = 3,59$$

QUARTILE:

Unteres Quartil (⚠ fällt ebenfalls in die ERSTE Klasse ⇒ Vorgänger = 0):

$$x_{0,25} = \frac{0,25 - 0}{0,558} \cdot (2-0) = \frac{0,25}{0,558} \cdot 2 = 0,90$$

Oberes Quartil (Einfallsklasse [2; 5]):

$$x_{0,75} = 2 + \frac{0,75 - 0,558}{0,267} \cdot (5-2) = 4,16$$

QUARTILSABSTAND:

$$IQR = 4,16 - 0,90 = 3,26$$

✓ c) Histogramm

Auf der y-Achse werden die HÄUFIGKEITSDICHTEN f_i aufgetragen ($0,2790 \cdot 0,0890 \cdot 0,0284 \cdot 0,0025 \cdot 0,0008$), nicht die Häufigkeiten!

✓ d) Schiefe nach Fisher

„Das Histogramm aus Aufgabenteil c) lässt bereits eine EXTREME RECHTSSCHIEFE erkennen.“

Klasse	n_i	m_i	$n_i(m_i - \bar{x})^3$
[0; 2)	67	1,0	-654,32
[2; 5)	32	3,5	1,52
[5; 10)	17	7,5	1.411,42
[10; 20)	3	15,0	5.007,83
[20; 30)	1	25,0	10.449,60
Summe	120		16.216,05

$$\gamma_1 = \frac{(1/120) \cdot 16.216,05}{3,59^3} = 2,96$$

✓ „Damit bestätigt sich die deutliche RECHTSSCHIEFE der Verteilung.“

★★ Aufgabe 0.2 — Originaldaten (Mensabesuche)

10 Studierende, Mensabesuche im letzten Monat: 5, 7, 6, 4, 5, 2, 0, 12, 0, 5

✓ Geordnete Stichprobe:

$x_{(1)}$	$x_{(2)}$	$x_{(3)}$	$x_{(4)}$	$x_{(5)}$	$x_{(6)}$	$x_{(7)}$	$x_{(8)}$	$x_{(9)}$	$x_{(10)}$
0	0	2	4	5	5	5	6	7	12

✓ a) LAGEMASSE

$$\bar{x} = (1/10)(5+7+6+4+5+2+0+12+0+5) = 4,6$$

$$n = 10 \text{ GERADE} \Rightarrow \tilde{x} = (x_{(5)} + x_{(6)})/2 = (5+5)/2 = 5$$

$$x_M = 5 \quad (\text{kommt dreimal vor})$$

✓ b) STREUUNGSMASSE

$$\sum x_i^2 = 25+49+36+16+25+4+0+144+0+25 = 324$$

$$\sigma^2 = 324/10 - 4,6^2 = 11,24$$

$$s^2 = (10/9) \cdot 11,24 = 12,49$$

$$s = \sqrt{12,49} = 3,53$$

$$R = 12 - 0 = 12$$

QUARTILE (die Regel!):

$$n \cdot p = 10 \cdot 0,25 = 2,5 \notin \mathbb{N} \Rightarrow x_{0,25} = x_{(3)} = 2 \quad (\text{aufrunden auf 3!})$$

$$n \cdot p = 10 \cdot 0,75 = 7,5 \notin \mathbb{N} \Rightarrow x_{0,75} = x_{(8)} = 6 \quad (\text{aufrunden auf 8!})$$

$$IQR = 6 - 2 = 4$$

★★ Aufgabe 0.3 — Gruppierte Daten (Altersverteilung)

Altersverteilung in einer Gruppe Studierender:

a_i	n_i	$n_i \cdot a_i$	r_i	Σr_j
17	1	17	0,0370	0,0370
18	5	90	0,1852	0,2222
19	11	209	0,4074	0,6296 ★
20	7	140	0,2593	0,8889
21	1	21	0,0370	0,9259
23	1	23	0,0370	0,9630
28	1	28	0,0370	1,0000
Σ	27	528	1,0000	

- ✓ a) $\bar{x} = (1/27) \cdot 528 = 19,5 \approx 19,6$
 $\tilde{x} = 19$ („erste Ausprägung, deren kumulierte Häufigkeit 0,5 übersteigt" – 0,6296)
 $x_M = 19$

✓ b) **Schiefe:** „Die drei Lagemaße Median, Modus und arithmetisches Mittel weisen FAST GLEICHE Werte auf. Eine Betrachtung der Häufigkeitstabelle belegt, dass die Daten NAHEZU SYMMETRISCH verteilt sind. Lediglich der leichte »Ausreißer« in Form eines Studierenden im Alter von 28 ZIEHT DAS ARITHMETISCHE MITTEL LEICHT AN." (→ Fechner-Regel: $\bar{x} > \tilde{x} = x_M \Rightarrow$ leicht rechtsschief)

✎★★★★ Aufgabe 0.4 — Geometrisches Mittel (Umsatzsteigerungen)

Umsatzsteigerungen in fünf Jahren: +10 %, +2 %, –8 %, +5 %, +6 %

Wachstumsrate in %	Dezimal	Wachstumsfaktor
10 %	0,10	1,10
2 %	0,02	1,02
–8 %	–0,08	0,92
5 %	0,05	1,05
6 %	0,06	1,06

$$\bar{x}_g = \sqrt[5]{1,1 \cdot 1,02 \cdot 0,92 \cdot 1,05 \cdot 1,06} = 1,0281$$

$$\Rightarrow \text{durchschnittliches Wachstum} = 1,0281 - 1 = 0,0281 = 2,81 \%$$

✎★★★★ Aufgabe 0.5 — Welches Lagemaß? (Keimzahlen im Hackfleisch)

Anzahl Keime je mg: **180, 175, 190, 180, 185, 250, 175, 190, 175, 195, 195** Drei Lebensmittelchemiker ziehen Schlüsse — wer hat Recht?

✓ **Geordnete Stichprobe:**

175	175	175	180	180	185	190	190	195	195	250
-----	-----	-----	-----	-----	------------	-----	-----	-----	-----	-----

Chemiker	Aussage	Lagemaß	✓/✗
Matt Wurst	„die meisten Proben besaßen 180 Keime je mg“	MODUS	✗ FALSCH — „Die Beobachtung, die am häufigsten vorkommt, ist mit 175 Keimen je mg gegeben“
G. Hackes	„durchschnittlich 190 Keime je mg“	ARITHM. MITTEL	✓ RICHTIG — $\bar{x} = (1/11)(180+175+\dots+195) = 190$
H. Schee	„in gut der Hälfte der Proben mindestens 185 Keime je mg“	MEDIAN	✓ RICHTIG — $\tilde{x} = x_{(6)} = 185$

📝☆☆☆☆ Aufgabe 0.6 — Kaffeeleck (Änderung einer Beobachtung)

$n = 50$ Quartale $\cdot \bar{x} = 40 \cdot \tilde{x} = 38 \cdot \sigma = 3$. Eine Beobachtung mit dem Wert **23** wird fälschlich als **28** interpretiert. Welche Werte berechnet man dann?

✓ Arithmetisches Mittel

$x_{1,neu} = 28 = 23 + 5 = x_{1,alt} + 5$
 $\Rightarrow$ Merkmalssumme wächst um 5
 $\Rightarrow \bar{x}_{neu} = \bar{x}_{alt} + 5/50 = \bar{x}_{alt} + 0,1 = 40,1$

✓ Median

☆☆ „Da **BEIDE** Beobachtungen, alte und neue, auf der **GLEICHEN SEITE** des Medians liegen, bleibt dieser **UNVERÄNDERT** ($\tilde{x} = 38$). Würden die Beobachtungen auf **VERSCHIEDENEN** Seiten des Medians liegen, so könnte aus den gegebenen Informationen allein **KEINE AUSSAGE** über den Median gemacht werden.“

✓ Varianz (die vollständige Herleitung)

Verschiebungsformel: $\sigma^2_{neu} = (1/n)[x^2_{1,neu} + \sum x^2_i] - \bar{x}^2_{neu}$

$$\begin{aligned}\sigma^2_{neu} &= (1/50)[(x_{1,alt} + 5)^2 + \sum x^2_i] - (\bar{x}_{alt} + 0,1)^2 \\ &= \sigma^2_{alt} + (1/50)[10 \cdot x_{1,alt} + 25] - (0,2 \cdot \bar{x}_{alt} + 0,01)\end{aligned}$$

Einsetzen ($x_{1,alt} = 23$, $\bar{x}_{alt} = 40$):

$$\begin{aligned}\sigma^2_{neu} &= \sigma^2_{alt} + (1/50)[10 \cdot 23 + 25] - (0,2 \cdot 40 + 0,01) \\ &= \sigma^2_{alt} + 255/50 - 8,01 \\ &= \sigma^2_{alt} - 2,91\end{aligned}$$

$$\Rightarrow \sigma^2_{neu} = 3^2 - 2,91 = 6,09$$

$$\Rightarrow \sigma_{neu} = \sqrt{6,09} = 2,47$$

★ Die Varianz **SINKT** um 2,91 — weil der Ausreißer 23 näher an den Mittelwert 40 rückt!

✎☆☆☆☆ Aufgabe 0.7 — Welcher Mittelwert? (die Klassiker-Aufgabe!)

Teilaufgabe	Fragestellung	★ Richtiger Mittelwert	Ergebnis
a)	Umsatzveränderungen +10 %, +20 %, -15 %, +5 %, -5 %	★ GEOMETRISCHES Mittel der Wachstumsfaktoren	$\sqrt[5]{(1,1 \cdot 1,2 \cdot 0,85 \cdot 1,05 \cdot 0,95)} = 1,0228 \Rightarrow +2,28 \%$
b)	Autofahrer fährt jeweils gleich lange STRECKE mit 50, 60, 70, 80 km/h	★ HARMONISCHES Mittel (Zähler = Strecke bekannt!)	$[\frac{1}{\frac{1}{50} + \frac{1}{60} + \frac{1}{70} + \frac{1}{80}}]^{-1} = 63,04 \Rightarrow \approx 63 \text{ km/h}$
c)	Tageseinnahmen 100.000, 120.000, 90.000, 130.000, 60.000 €	★ ARITHMETISCHES Mittel	$(1/5) \cdot 500.000 \Rightarrow 100.000 \text{ €}$

✎☆☆ Aufgabe 0.8 — Beobachtung = Mittelwert hinzugefügt

Eine übersehene Beobachtung, die genau den Wert des arithmetischen Mittels hat, wird hinzugefügt. Was passiert mit der Varianz? ☒ Das arithmetische Mittel bleibt UNVERÄNDERT (die neue Beobachtung hat genau diesen Wert). Die Summe der quadrierten Abweichungen bleibt ebenfalls unverändert (der neue Summand ist 0), ABER der Divisor n wächst um 1 $\Rightarrow$ DIE VARIANZ SINKT.

✎☆☆☆☆ Aufgabe 0.9 — Lineare Transformation (Nahrungsergänzungsmittel)

Preise in \$: 30,00 · 29,95 · 35,50 · 28,99 · 32,40 · 30,98 · 29,50 · 28,80 · 31,65 · 33,33 Wechselkurs: 1 USD = 0,80 EUR

☒ a) $\bar{x} = (1/10) \cdot 311,10 = 31,11 \text{ \$}$
 $\sum x_i^2 = 900,0000 + 897,0025 + 1260,2500 + 840,4201 + 1049,7600$
 $+ 959,7604 + 870,2500 + 829,4400 + 1001,7225 + 1110,8889 = 9719,4944$
 $\sigma^2 = 9719,4944/10 - 31,11^2 = 4,12$
 $s^2 = (10/9) \cdot 4,12 = 4,58$
 $s = \sqrt{4,58} = 2,14 \text{ \$}$

☒ b) Transformation: $y_i = 0,8 \cdot x_i$
 $\bar{y} = 0,8 \cdot \bar{x} = 0,8 \cdot 31,11 = 24,89 \text{ €}$
 $s_y = |0,8| \cdot s_x = 0,8 \cdot 2,14 = 1,71 \text{ €}$

✎☆☆☆☆ Aufgabe 0.10 — Arithmetisches vs. geometrisches Mittel

Zwei positive Beobachtungen, eine ist **viermal größer** als die andere. Um welchen Prozentsatz fällt das arithmetische Mittel höher aus als das geometrische?

$$\text{Sei } x_2 = 4 \cdot x_1$$

$$\bar{x} = \frac{1}{2}(x_1 + 4x_1) = (5/2) \cdot x_1 = 2,5 \cdot x_1$$

$$\bar{x}_g = \sqrt{(x_1 \cdot 4x_1)} = \sqrt{(4x_1^2)} = 2 \cdot x_1$$

$$\bar{x} / \bar{x}_g = 2,5x_1 / 2x_1 = 1,25$$

✓ Das arithmetische Mittel ist um 25 % größer als das geometrische Mittel.

Aufgabe 0.11 — Lineare Regression (Aktien- vs. Markttrendite)

⚠️ **Wichtige Vorbemerkung aus der Musterlösung:** „Während für die KORRELATIONSberechnung die Wahl von x_i und y_i UNERHEBLICH ist, wird bei der linearen REGRESSION die ERKLÄRTE Variable mit y_i und die ERKLÄRENDE Variable mit x_i bezeichnet.“

✓ Die Arbeitstabelle

i	y_i (Aktie)	x_i (Index)	y_i^2	x_i^2	$x_i y_i$
1	3,4	2,9	11,56	8,41	9,86
2	4,7	5,2	22,09	27,04	24,44
3	-1,3	-2,1	1,69	4,41	2,73
4	4,5	4,2	20,25	17,64	18,90
5	0,8	1,1	0,64	1,21	0,88
6	2,2	1,3	4,84	1,69	2,86
7	1,5	1,8	2,25	3,24	2,70
8	3,2	2,9	10,24	8,41	9,28
9	2,8	2,5	7,84	6,25	7,00
10	1,4	1,7	1,96	2,89	2,38
Σ	23,2	21,5	83,36	81,19	81,03

$$\bar{x} = 21,5/10 = 2,15 \quad \bar{y} = 23,2/10 = 2,32$$

✓ a) REGRESSION

$$\hat{b} = \frac{81,03 - 10 \cdot 2,15 \cdot 2,32}{81,19 - 10 \cdot 2,15^2} = 0,89$$

$$\hat{a} = 2,32 - 0,89 \cdot 2,15 = 0,4$$

$$\Rightarrow \hat{y}_i = 0,4 + 0,89 \cdot x_i$$

INTERPRETATION: „Die AKTIENRENDITE steigt/sinkt im Schnitt um 0,89 PROZENTPUNKTE, wenn die Rendite des Marktindizes um EINEN PROZENTPUNKT steigt/fällt.“
(→ das ist das „BETA“ der Aktie!)

✓ b) KORRELATION

$$r_{xy} = \frac{81,03 - 10 \cdot 2,15 \cdot 2,32}{\sqrt{(81,19 - 10 \cdot 2,15^2)} \cdot \sqrt{(83,36 - 10 \cdot 2,32^2)}} = 0,97$$

„Damit besteht ein SEHR STARKER POSITIVER Zusammenhang.“

✓ c) BESTIMMTHEITSMASS

$$R^2 = 0,97^2 = 0,94$$

„Damit werden rund 94 % der Variation der Aktienrendite durch die Regression gegen den Marktindex erklärt, lediglich etwa 6 % der Streuung können nicht erklärt werden.“

📝☆☆☆ Aufgabe 0.12 — Spearman (Wettlauf auf der Familienfeier)

⚠☆☆☆ **Die Skalenniveau-Begründung (KLAUSURPUNKTE!):** „Während das Merkmal **Alter** KARDINAL skaliert ist, stellt die **Platzierung** ein ORDINALES Merkmal dar. **Da man sich stets am NIEDRIGER SKALIERTEN Merkmal orientiert, darf KEIN Zusammenhangsmaß für kardinal skalierte Merkmale berechnet werden.** Für ordinale Daten bietet sich allerdings der RANGKORRELATIONSKOEFFIZIENT NACH SPEARMAN an.“

i	Person	x_i (Platz)	y_i (Alter)	$R(x_i)$	$R(y_i)$	$R(x) - R(y)$	$[R(x) - R(y)]^2$
1	Ludwig Lungenschwund	6	18	6	1	5	25
2	Ferdinand Fettpolster	4	37	4	4	0	0
3	Erna Ehrgeiz	2	20	2	2	0	0
4	Arthur Athletikus	1	31	1	3	-2	4
5	Gerda Gefräßig	5	45	5	5	0	0
6	Frieda Fitness	3	80	3	6	-3	9
						Summe:	38

$$R_{xy} = 1 - \frac{6 \cdot 38}{5 \cdot 6 \cdot 7} = 1 - \frac{38}{35} = -\frac{3}{35} = -0,086$$

✓ „Damit ist KAUM EIN ZUSAMMENHANG zu ermitteln.“

**Aufgabe 0.13 — Kontingenzkoeffizient (TITANIC)***Verteilung von geretteten und ertrunkenen Passagieren der „MS Titanic“:***✓ Schritt 1: Beobachtete Kontingenztafel mit Randhäufigkeiten**

n _{ij}	Gerettete	Opfer	Gesamt
1. Klasse	202	123	325
2. Klasse	118	167	285
3. Klasse	178	528	706
Gesamt	498	818	1.316

✓ Schritt 2: Erwartete Werte unter Unabhängigkeit

$$\hat{n}_{11} = (498 \cdot 325) / 1.316 = 122,99 \approx 123$$

$$\hat{n}_{21} = (498 \cdot 285) / 1.316 = 107,85 \approx 108$$

(Rest durch Differenzbildung!)

$\hat{n}_{ij}$	Gerettete	Opfer	Gesamt
1. Klasse	123	202	325
2. Klasse	108	177	285
3. Klasse	267	439	706
Gesamt	498	818	1.316

✓ Schritt 3: Chi-Quadrat

$$\chi^2 = \frac{(202-123)^2}{123} + \frac{(123-202)^2}{202} + \frac{(118-108)^2}{108} + \frac{(167-177)^2}{177} + \frac{(178-267)^2}{267} + \frac{(528-439)^2}{439}$$

$$= 130,8$$

✓ Schritt 4: Kontingenzkoeffizient und Korrektur

$$K = \sqrt{\frac{130,8}{130,8 + 1316}} = 0,3$$

$$M = \min\{3; 2\} = 2$$

$$K^* = \sqrt{\frac{2}{2 - 1}} \cdot 0,3 = 0,43$$

★★★★ **Aufgabe 0.14 — Gleitende Durchschnitte (Elterngeldempfänger)**

Anzahl männlicher Elterngeldempfänger nach Quartalen, I/2009 bis II/2015 (Destatis)

Jahr	1. Quartal	2. Quartal	3. Quartal	4. Quartal
2009	35.686	37.610	42.442	37.184
2010	38.360	40.984	45.935	42.003
2011	44.312	43.163	49.567	43.234
2012	44.312	47.279	53.360	47.978
2013	49.092	53.309	61.074	53.927
2014	55.525	60.455	68.299	60.013
2015	57.721	63.108		

a) Der VIERERDURCHSCHNITT

★ „Die Zeitreihe umfasst QUARTALSDATEN, damit liegt eine Periode der Länge $m = 4$ vor. Aufgrund der Periodizität von 4 eignet sich ein VIERERDURCHSCHNITT:“

$$y^*_t = \frac{1}{4} \cdot \left(\frac{1}{2} \cdot y_{\{t-2\}} + y_{\{t-1\}} + y_t + y_{\{t+1\}} + \frac{1}{2} \cdot y_{\{t+2\}} \right)$$

Beispielrechnungen:

$$\begin{aligned}
 y^*_{2009, III} &= \frac{1}{4} \cdot \left(\frac{1}{2} \cdot 35.686 + 37.610 + 42.442 + 37.184 + \frac{1}{2} \cdot 38.360 \right) = 38.565 \\
 y^*_{2009, IV} &= \frac{1}{4} \cdot \left(\frac{1}{2} \cdot 37.610 + 42.442 + 37.184 + 38.360 + \frac{1}{2} \cdot 40.984 \right) = 39.321 \\
 y^*_{2010, I} &= \frac{1}{4} \cdot \left(\frac{1}{2} \cdot 42.442 + 37.184 + 38.360 + 40.984 + \frac{1}{2} \cdot 45.935 \right) = 40.179 \\
 y^*_{2010, II} &= \frac{1}{4} \cdot \left(\frac{1}{2} \cdot 37.184 + 38.360 + 40.984 + 45.935 + \frac{1}{2} \cdot 42.003 \right) = 41.218
 \end{aligned}$$

Vollständige Glättungsreihe:

Quartal	y^*_t	Quartal	y^*_t	Quartal	y^*_t
2009 III	38.565	2011 III	45.069	2013 III	55.155
2009 IV	39.321	2011 IV	45.584	2013 IV	56.852
2010 I	40.179	2012 I	46.572	2014 I	58.648
2010 II	41.218	2012 II	47.639	2014 II	60.312
2010 III	42.565	2012 III	48.830	2014 III	61.348
2010 IV	43.581	2012 IV	50.181	2014 IV	61.954
2011 I	44.307	2013 I	51.899		
2011 II	44.915	2013 II	53.607		


c) „Die Zeitreihe weist einen DEUTLICHEN AUFWÄRTSTREND auf.“

Beachte: Der erste geglättete Wert liegt bei 2009/III (nicht früher), der letzte bei 2014/IV — die Ränder gehen verloren!

★★★★★ Aufgabe 0.15 — Preisindizes (Mensa)

	Basisjahr		Berichtsjahr	
	Preis	Menge	Preis	Menge
Stammgericht	2,50	1.000	3,00	900
Vegetarisches Gericht	3,20	200	3,50	300

✓ a) LASPEYRES (Warenkorb der BASISperiode: 1.000 / 200)

$$P_L = \frac{1.000 \cdot 3,00 + 200 \cdot 3,50}{1.000 \cdot 2,50 + 200 \cdot 3,20} = \frac{3.700}{3.140} = 1,18$$

✓ b) PAASCHE (Warenkorb der BERICHTSperiode: 900 / 300)

$$P_P = \frac{900 \cdot 3,00 + 300 \cdot 3,50}{900 \cdot 2,50 + 300 \cdot 3,20} = \frac{3.750}{3.210} = 1,17$$

✓ „Damit weist der Index nach LASPEYRES eine Steigerung von 18 % aus, der Index von PAASCHE eine Preissteigerung von 17 %.“

★★★★★ Aufgabe 0.16 — DAS SIMPSON-PARADOXON (Prof. Gertrud Gender)

„An Professorin Gertrud Gender scheiden sich die Geister. Während die einen behaupten, weibliche Klausurteilnehmer würden besser abschneiden, behaupten andere vehement das Gegenteil. Kurioserweise beziehen sich BEIDE auf DIESELBE Erhebung:“

Studiengang	weiblich bestanden	weiblich nicht best.	männlich bestanden	männlich nicht best.
Tourismusmanagement	70	10	4	0
Betriebswirtschaft	10	10	20	8
gesamt	80	20	24	8

✓ Die Durchfallquoten

TOURISMUSMANAGEMENT:

$$D_{T,w} = 10 / (70+10) = 0,125$$

$$D_{T,m} = 0 / (4+0) = 0 \quad \star \text{ Männer besser}$$

BETRIEBSWIRTSCHAFT:

$$D_{B,w} = 10 / (10+10) = 0,500$$

$$D_{B,m} = 8 / (20+8) = 0,286 \quad \star \text{ Männer besser}$$

GESAMT:

$$D_{G,w} = 20 / (80+20) = 0,200$$

$$D_{G,m} = 8 / (24+8) = 0,250 \quad \triangle \text{ FRAUEN besser!}$$

★★★★★ DAS PARADOXON

„Damit ergibt sich das **ERSTAUNLICHE ERGEBNIS**, dass die Durchfallquote **ALLER TEILNEHMER** zwar **GRÖßER** ist als die Durchfallquote aller Teilnehmerinnen, dennoch ist die Durchfallquote der Teilnehmer **GERINGER IN DEN EINZELNEN KLAUSUREN**.“

★★ „Dieses Phänomen ist als **SIMPSON-PARADOXON** bekannt.“

Der Hintergrund: „Die **UNTERSCHIEDLICHE STRUKTUR** der beiden Teilgesamtheiten: Bei den Studierenden des Tourismusmanagements gibt es **VIEL MEHR** Studentinnen als Studenten und zudem ist in dieser Gruppe die Durchfallquote **WESENTLICH GERINGER** als in der Gruppe der BWL-Studierenden.“

Die korrekte Interpretation:

- „Trifft man **ZUFÄLLIG** — etwa auf einer Party — auf Studierende von Prof. Gender, so wird man bei den **STUDENTEN HÄUFIGER** als bei den Studentinnen auf nicht erfolgreiche Teilnehmer/innen treffen.“
- „Betrachtet man hingegen die Ergebnisse **GLEICHER PRÜFUNGEN INNERHALB DER FAKULTÄTEN**, so wird man feststellen, dass **TEILNEHMER HÄUFIGER ERFOLGREICH** sind als Teilnehmerinnen.“

★★★★★ Aufgabe 0.17 — Arbeitslosenquoten (arithmetisch vs. harmonisch)

$$\text{Arbeitslosenquote} = \frac{\text{Arbeitslose}}{\text{Erwerbstätige}}$$

✓ a) Zasterhausen — **NENNER**verteilung bekannt (Erwerbstätige!)

*„In Zasterhausen wohnen **30 % der ERWERBSTÄTIGEN** im Stadtzentrum, der Rest in den Außenbezirken. Zentrum: **6 %**, Außenbezirke: **3,5 %**.“*

⇒ GEWOGENES ARITHMETISCHES MITTEL

$$I = 0,3 \cdot 0,06 + 0,7 \cdot 0,035 = 0,018 + 0,0245 = 0,0425 = 4,25 \%$$

✓ b) Mooslos — **ZÄHLER**verteilung bekannt (Arbeitslose!)

*„In Mooslos findet man **40 % der ARBEITSLOSEN** im Zentrum, den Rest in den umliegenden Stadtteilen. Zentrum: **12 %**, restliche Stadtteile: **27 %**.“*

⇒ GEWOGENES HARMONISCHES MITTEL

$$I = \left[0,4 \cdot \frac{1}{0,12} + 0,6 \cdot \frac{1}{0,27} \right]^{-1} = \left[\frac{10}{3} + \frac{20}{9} \right]^{-1} = \left[\frac{30}{9} + \frac{20}{9} \right]^{-1} = \frac{9}{50} = 0,18$$

⇒ 18 %

★★★★ **Aufgabe 0.18 — Fahrkartenautomaten (Wahrscheinlichkeitsrechnung)**

Alte Automaten: **25 % Ausfall**. Neue Automaten: **10 % Fehlrate**. Beide Generationen bleiben betriebsfähig.

⚠ Achtung: In der Musterlösung werden A und N als die **AUSFALL**-Ereignisse gerechnet!

$$P(A) = 0,25 \quad P(N) = 0,10$$

$$P(\bar{A}) = 0,75 \quad P(\bar{N}) = 0,90$$

Gesucht: „mindestens ein Automat arbeitet“ = $P(\bar{A} \cup \bar{N}) = 1 - P(A \cap N)$

✓ a) UNABHÄNGIGKEIT:

$$P(A \cap N) = 0,25 \cdot 0,10 = 0,025$$

$$\Rightarrow P(\bar{A} \cup \bar{N}) = 1 - 0,025 = 0,975$$

✓ b) GLEICHZEITIGER AUSFALL bekannt (Vandalismus): $P(A \cap N) = 0,05$

$$\Rightarrow P(\bar{A} \cup \bar{N}) = 1 - 0,05 = 0,95$$

★★★★ **Aufgabe 0.19 — Burger-Party (Vierfeldertafel)**

80 % mögen Beefburger, 50 % Veggieburger, **45 % mögen beide**.

$$P(B) = 0,80 \quad P(V) = 0,50 \quad P(B \cap V) = 0,45$$

✓ a) ADDITIONSSATZ:

$$P(B \cup V) = 0,8 + 0,5 - 0,45 = 0,85$$

DE MORGAN + Gegenereignis:

$$P(\bar{B} \cap \bar{V}) = 1 - P(B \cup V) = 1 - 0,85 = 0,15$$

→ 15 % der Partybesucher mögen GAR KEINE Burger.

✓ **Die alternative Lösung über die VIERFELDERTAFEL**

Wahrscheinlichkeit	V	$\bar{V}$	gesamt
B	0,45	0,35	0,80
$\bar{B}$	0,05	0,15	0,20
gesamt	0,50	0,50	1,00

✓ b) BEDINGTE WAHRSCHEINLICHKEIT:

$$P(B|V) = \frac{P(B \cap V)}{P(V)} = \frac{0,45}{0,50} = 0,90$$

★★★★ **Aufgabe 0.20 — Kombinatorik (Vera Vergesslich, Matrikelnummer)**

Sechsstellige Matrikelnummer vergessen.

- ✓ a) KEINE Erinnerung – Variationen MIT Wiederholung:
 $10^6 = 1.000.000$ Möglichkeiten
- ✓ b) Die Zahl „23“ kommt vor:
 Trick: 5 Objekte anordnen – die Zahl „23“ plus 4 unbekannte Ziffern „Z“:
 23, Z, Z, Z, Z
 Anordnungen (Permutation mit Wiederholung): $5!/(1! \cdot 4!) = 5$
 Konkret: 23,Z,Z,Z,Z / Z,23,Z,Z,Z / Z,Z,23,Z,Z / Z,Z,Z,23,Z / Z,Z,Z,Z,23
 Für die 4 Ziffern: $10^4 = 10.000$
 $\Rightarrow 5 \cdot 10.000 = 50.000$ Möglichkeiten
- ✓ c) „23“ weder am Anfang noch am Ende $\Rightarrow$ nur DREI Anordnungen:
 Z,23,Z,Z,Z / Z,Z,23,Z,Z / Z,Z,Z,23,Z
 $\Rightarrow 3 \cdot 10^4 = 30.000$ Möglichkeiten
- ✓ d) Zusätzlich: KEINE Ziffer doppelt (Variationen OHNE Wiederholung):
 Für die 4 verbleibenden Ziffern: $8 \cdot 7 \cdot 6 \cdot 5 = 1.680$
 (die Ziffern 2 und 3 sind bereits verbraucht $\Rightarrow$ noch 8 zur Auswahl)
 $\Rightarrow 8 \cdot 7 \cdot 6 \cdot 5 \cdot 3 = 5.040$ Möglichkeiten

★★★★★ Aufgabe 0.21 — Kombinatorik (Paarbildung, 5 Damen + 7 Herren)

✓ a) Nur gemischtgeschlechtliche Paare („Betreutes Stöhnen“)

Weg 1: Aus 7 Herren 5 auswählen: $C(7,5) = 21$
 Die 5 Damen zuordnen: $5! = 120$
 $\Rightarrow 21 \cdot 120 = 2.520$

Weg 2 (eleganter): Variationen OHNE Wiederholung
 $7! / (7-5)! = 2.520$

✓ b) Beliebige Paare („Let's swing“) — 12 Personen, 6 Paare

Weg 1: $C(12,6) \cdot 6! = 12!$... ABER: innerhalb jedes Paares gibt es KEINE Reihenfolge!
 $\Rightarrow$ durch $(2!)^6$ teilen:

$$\frac{12!}{(2!)^6} = 7.484.400$$

Weg 2: Alle 12 Personen in einer Reihe ($12!$) und benachbarte Positionen zu Paaren zusammenfassen: 1,2|3,4|5,6|7,8|9,10|11,12 $\Rightarrow$ ebenfalls $12!/(2!)^6$

Weg 3: Permutation mit Wiederholung: $12!/(2! \cdot 2! \cdot 2! \cdot 2! \cdot 2! \cdot 2!) = 7.484.400$

Weg 4: Sukzessive Paarbildung:
 $C(12,2) \cdot C(10,2) \cdot C(8,2) \cdot C(6,2) \cdot C(4,2) \cdot C(2,2)$
 $= 66 \cdot 45 \cdot 28 \cdot 15 \cdot 6 \cdot 1 = 7.484.400$

✓ c) Nur gleichgeschlechtliche Paare

HERREN (7 → 3 Paare, einer bleibt übrig): $C(7,2) \cdot C(5,2) \cdot C(3,2) = 21 \cdot 10 \cdot 3$
 DAMEN (5 → 2 Paare, eine bleibt übrig): $C(5,2) \cdot C(3,2) = 10 \cdot 3$

⇒ $21 \cdot 10 \cdot 3 \cdot 10 \cdot 3 = 18.900$ Paarbildungen

📝☆☆☆☆ Aufgabe 0.22 — „Montagsauto“ (totale Wahrscheinlichkeit + Bayes)

*21 % der Produktion je Wochentag Mo–Do, der Rest am Freitag. **3 %** der Montags gefertigten Autos sind mangelhaft, an den übrigen Tagen **1 %**.*

$P(\text{Mo}) = P(\text{Di}) = P(\text{Mi}) = P(\text{Do}) = 0,21$
 $P(\text{Fr}) = 1 - 4 \cdot 0,21 = 0,16$

$P(M|\text{Mo}) = 0,03$
 $P(M|\text{Di}) = P(M|\text{Mi}) = P(M|\text{Do}) = P(M|\text{Fr}) = 0,01$

✓ a) TOTALE WAHRSCHEINLICHKEIT:

$P(M) = 0,03 \cdot 0,21 + 0,01 \cdot 0,21 + 0,01 \cdot 0,21 + 0,01 \cdot 0,21 + 0,01 \cdot 0,16$
 $= 0,0142$
 ⇒ 1,42 % der Autos sind defekt.

✓ b) BAYES:

$$P(\text{Mo}|M) = \frac{P(M|\text{Mo}) \cdot P(\text{Mo})}{P(M)} = \frac{0,03 \cdot 0,21}{0,0142} = \frac{0,0063}{0,0142} = 0,4437$$

 ⇒ mehr als 44 %!

☆☆ Die elegantere Lösung der Musterlösung

„Noch einfacher und eleganter erhält man die Lösung, wenn man erkennt, dass es eigentlich **gar nicht auf die einzelnen Produktionstage ankommt**, sondern nur auf die Frage, **ob das Auto an einem Montag produziert wurde oder nicht**.“

$P(\text{Mo}) = 0,21$ $P(\bar{\text{Mo}}) = 0,79$
 $P(M|\text{Mo}) = 0,03$ $P(M|\bar{\text{Mo}}) = 0,01$

$P(M) = 0,03 \cdot 0,21 + 0,01 \cdot 0,79 = 0,0142$ ✓ (gleiches Ergebnis!)

📝☆☆☆☆ Aufgabe 0.23 — Drogentest (die Bayes-Klassikeraufgabe!)

Test-Kennwerte:

- **Sensitivität:** $P(T|D) = 0,992$ — „zeigt mit 99,2 %-iger Wahrscheinlichkeit ein **POSITIVES** Testergebnis, wenn Drogen genommen wurden“
- **Spezifität:** $P(\bar{T}|\bar{D}) = 0,987$ — „zeigt mit 98,7 %-iger Wahrscheinlichkeit ein **NEGATIVES** Ergebnis, wenn **KEINE** Drogen genommen wurden“

✓ **a) Wachtmeister Peter „Pit“ Bull — testet ALLE (Prävalenz 1 %)**

$$P(D) = 0,01$$

$$P(D|T) = \frac{0,992 \cdot 0,01}{0,992 \cdot 0,01 + (1 - 0,987) \cdot (1 - 0,01)} = 0,435$$

⇒ LEDIGLICH 43,5 %!

✓ **b) Hauptwachtmeister Martin S. Horn — testet nur Personen mit erweiterten Pupillen (Prävalenz 20 %)**

$$P(D) = 0,2$$

$$P(D|T) = \frac{0,992 \cdot 0,2}{0,992 \cdot 0,2 + (1 - 0,987) \cdot (1 - 0,2)} = 0,95$$

⇒ 95 %!

🔑★★★★ **DIE KERNAUSSAGE (klausurrelevante Interpretation!)**

Bei GLEICHEM Test steigt die Aussagekraft eines positiven Ergebnisses von 43,5 % auf 95 %, nur weil die PRÄVALENZ in der getesteten Gruppe von 1 % auf 20 % steigt. ⇒ „Screening der Gesamtbevölkerung“ erzeugt massenhaft FALSCH POSITIVE!

TEIL B — DIE ORIGINALKLAUSUR (Juni 2025) MIT MUSTERLÖSUNG

Aufgabe 1 (14 Punkte) — Karoline „Karo“ Sell, Schaustellerin

Karo Sell betreibt ein Fahrgeschäft auf Jahrmärkten und erhebt stichprobenartig die Verteilung der gekauften Fahrkartenzahlen ihrer Kundschaft:

Anzahl Fahrkarten	Häufigkeit
1	65
2	25
3	10
4	8
5	4
mehr als 5	8

a) Beschreiben Sie das vorliegende „Datenformat“. Welche Probleme entstehen bei der Berechnung eines Lagemaßes? Welche(s) Maß(e) können Sie gesichert ableiten, welche(s) nicht? Ermitteln Sie die „berechenbaren“ Lagemaße. b) Berechnen Sie den Quartilsabstand. c) Was können Sie über die Schiefe aussagen? Beachten Sie, dass der Fisher'sche Schiefekoeffizient hier ungeeignet wäre — argumentieren Sie mit einer Alternative.

a) Datenformat und Lagemaße


DIE MUSTERANTWORT: „Die Daten sind eine **MISCHUNG AUS GRUPPIERTEN DATEN UND KLASSIERTEN DATEN**, denn während die ersten Zeilen der Häufigkeitstabelle **konkrete Merkmalsausprägungen** ausweisen, stellt die letzte Zeile **eine ganze Klasse von Ausprägungen** dar, zudem ist diese **NACH OBEN UNBESCHRÄNKT** (offene Endklasse!). Die Berechnung des **ARITHMETISCHEN MITTELS** wäre daher **PROBLEMATISCH** und würde **enorm von der SUBJEKTIVEN WAHL EINER KLASSENMITTE** für diese letzte Klasse **abhängen**. Hingegen lassen sich auch ohne nähere Kenntnisse über die letzte Klasse **MODUS und MEDIAN** berechnen.“

Die Arbeitstabelle:

Ausprägung	n_i	r_i	kumuliert
1	65	0,5417	0,5417 
2	25	0,2083	0,7500 
3	10	0,0833	0,8333
4	8	0,0667	0,9000
5	4	0,0333	0,9333
> 5	8	0,0667	1,0000
Summe	120	1,0000	

✓ MODUS: $x_M = 1$

✓ MEDIAN: „Da die kumulierte relative Häufigkeit von 0,5 bereits bei 1 zum ersten Mal überschritten wird“: $\tilde{x} = 1$

✓ b) Quartilsabstand

UNTERES QUARTIL:

„Da auch die kumulierte relative Häufigkeit von 0,25 bereits bei 1 überschritten wird“: $x_{0,25} = 1$

OBERES QUARTIL – ⚠ SONDERFALL!

„Bei 2 wird die relative Häufigkeit von 0,75 EXAKT ANGENOMMEN, daher erhält man“: $x_{0,75} = \frac{1}{2} \cdot (2 + 3) = 2,5$

QUARTILSABSTAND:

$$IQR = 2,5 - 1 = 1,5$$

★★ MERKE die Regel bei gruppierten Daten: Wird der Wert p EXAKT erreicht, wird zwischen dieser und der NÄCHSTEN Ausprägung gemittelt!

✓ c) Schiefe über den Quartilkoeffizienten

$$QS = \frac{(x_{0,75} - \tilde{x}) - (\tilde{x} - x_{0,25})}{x_{0,75} - x_{0,25}} = \frac{(2,5 - 1) - (1 - 1)}{2,5 - 1} = \frac{1,5}{1,5} = 1 > 0$$

✓ „Damit liegt eine DEUTLICHE RECHTSSCHIEFE vor.“ ($QS = 1$ ist der Maximalwert!)

✍️ ★★★ Aufgabe 2 (16 Punkte) — Bruttoverdienste (Trendregression)

Die durchschnittlichen monatlichen Bruttoverdienste in Deutschland der letzten 10 Jahre (Destatis):

Jahr	Bruttomonatsverdienst (€)	Jahr	Bruttomonatsverdienst (€)
2015	3.612	2020	3.975
2016	3.703	2021	4.100
2017	3.771	2022	4.244
2018	3.880	2023	4.479
2019	3.994	2024	4.701

a) Lineare Trendgerade · b) Steigungsparameter interpretieren · c) Bestimmtheitsmaß · d) Prognose 2025

✓ Die Hilfstabelle

Nr.	x_t	y_t	$x_t \cdot y_t$	x_t^2	y_t^2
1	2015	3612	7.278.180	4.060.225	13.046.544
2	2016	3703	7.465.248	4.064.256	13.712.209
3	2017	3771	7.606.107	4.068.289	14.220.441
4	2018	3880	7.829.840	4.072.324	15.054.400
5	2019	3994	8.063.886	4.076.361	15.952.036
6	2020	3975	8.029.500	4.080.400	15.800.625
7	2021	4100	8.286.100	4.084.441	16.810.000
8	2022	4244	8.581.368	4.088.484	18.011.536
9	2023	4479	9.061.017	4.092.529	20.061.441
10	2024	4701	9.514.824	4.096.576	22.099.401
Σ	20.195	40.459	81.716.070	40.783.885	164.768.633

💡 ★ **Praxistipp der Musterlösung:** „Da $\hat{y}$ INVARIANT ist unter LINEAREN TRANSFORMATIONEN DES REGRESSORS, kann man die Rechnung ERHEBLICH VEREINFACHEN, indem man als Regressor $x = (1, 2, \dots, 10)^T$ wählt.“

✓ a) Regressionsgerade

$$\bar{x} = 20.195/10 = 2.019,5 \quad \bar{y} = 40.459/10 = 4.045,9$$

$$\hat{b} = \frac{81.716.070 - 10 \cdot 2.019,5 \cdot 4.045,9}{40.783.885 - 10 \cdot 2.019,5^2} = 110,5394$$

$$\hat{a} = 4.045,9 - 110,539 \cdot 2.019,5 = -219.188,42$$

$$\Rightarrow \hat{y} = -219.188,42 + 110,5394 \cdot \text{Jahr}$$

✓ b) Interpretation

„Der Steigungsparameter besagt, dass das durchschnittliche monatliche Bruttoverdienst PRO JAHR UM ETWA 110,54 € STEIGT.“

✓ c) Bestimmtheitsmaß

$$r_{xy} = \frac{9.061.017 - 10 \cdot 2.019,5 \cdot 4.045,9}{\sqrt{(40.783.885 - 10 \cdot 2.019,5^2)} \cdot \sqrt{(22.099.401 - 10 \cdot 4.045,9^2)}} = 0,968$$

$$R^2 = r_{xy}^2 = 0,968^2 = 0,937$$

✓ „Damit besteht ein STARK POSITIVER Zusammenhang zwischen Monatsbrutto und der Zeit. Die Anpassung ist GUT: 93,7 % der Streuung im Monatsbrutto werden durch die Regression gegen die Zeit erklärt.“

✓ d) Prognose 2025 — ⚠ die kritische Würdigung!

$$\hat{y}(2025) = -219.188,42 + 110,5394 \cdot 2025 = 4.633,61 \text{ €}$$

⚠☆☆ „Der Wert erscheint jedoch WENIG PLAUSIBEL, da in diesem Fall das Monatsbrutto GEGENÜBER DEM WERT AM AKTUELLEN RAND (4.701 €) SINKEN würde.“

☆☆ „Zur Prognose wäre es SINNVOLLER, die Regression über WENIGER VORGÄNGERWERTE durchzuführen, etwa nur AB 2020. Dann erhielte man für 2025 einen Prognosewert von etwa 4.849 €.“

✍☆☆☆☆ Aufgabe 3 (10 Punkte) — Landkreis Hinterwälderisch (Verhältniszahlen)

Der Landkreis besteht aus **Einödsbach**, **Deppenhausen** und **Rückstand**:

Ortschaft	Bevölkerungsdichte (Einw./km ²)	KFZ-Dichte (PKW/1.000 Einw.)	Einwohner
Einödsbach	0,5	500	2
Deppenhausen	176	250	88
Rückstand	480	100	160
Landkreis	?	?	?

✓ Schritt 1: Einwohner (am einfachsten)

$$2 + 88 + 160 = 250 \text{ Einwohner}$$

✓ Schritt 2: Bevölkerungsdichte — HARMONISCHES Mittel

$$\text{Bevölkerungsdichte} = \frac{\text{Anzahl Einwohner}}{\text{km}^2}$$

⇒ „Bekannt ist die VERTEILUNG DER EINWOHNER, also die ZÄHLERGRÖSSE.“

⇒ GEWOGENES HARMONISCHES MITTEL

$$V = \left[\frac{2}{250} \cdot \frac{1}{0,5} + \frac{88}{250} \cdot \frac{1}{176} + \frac{160}{250} \cdot \frac{1}{480} \right]^{-1} = 51,7 \text{ Einw./km}^2$$

✓ Schritt 3: KFZ-Dichte — ARITHMETISCHES Mittel

$$\text{KFZ-Dichte} = \frac{\text{Anzahl KFZ}}{1.000 \text{ Einwohner}}$$

⇒ „ist nun die NENNERVERTEILUNG bekannt.“

⇒ GEWOGENES ARITHMETISCHES MITTEL

$$V = \frac{2}{250} \cdot 500 + \frac{88}{250} \cdot 250 + \frac{160}{250} \cdot 100 = 156 \text{ PKW/1.000 Einw.}$$

★★★★ **DIE KLAUSURLEHRE: Dieselben Daten, aber ZWEI VERSCHIEDENE Mittelwerte — entscheidend ist allein, ob die ZÄHLER- oder die NENNERverteilung bekannt ist!**

★★★★ **Aufgabe 4 (10 Punkte) — Pater Noster (totale Wahrscheinlichkeit + Bayes)**

Pater Noster weiß von seinen „Gemeindeschäfchen“, dass **40 % zu Fuß, 20 % mit dem Auto, 25 % mit Zweirädern und 15 % mit öffentlichen Verkehrsmitteln** zum Gottesdienst kommen. Die **Fußgänger sind stets pünktlich**, die **Auto- und Zweiradfahrer kommen in 5 % der Fälle zu spät**, die **Nutzer öffentlicher Verkehrsmittel in jedem fünften Fall**.

✓ **Ereignisse definieren (Punkte für die saubere Notation!)**

V = „Gottesdienstbesucher verspätet sich“
 F = „kommt zu Fuß“ A = „kommt mit dem Auto“
 Z = „kommt mit dem Zweirad“ Ö = „kommt mit öffentlichen Verkehrsmitteln“

$P(F) = 0,40$ $P(V|F) = 0$
 $P(A) = 0,20$ $P(V|A) = 0,05$
 $P(Z) = 0,25$ $P(V|Z) = 0,05$
 $P(Ö) = 0,15$ $P(V|Ö) = 0,20$

✓ **a) Totale Wahrscheinlichkeit**

$$P(V) = P(V|F) \cdot P(F) + P(V|A) \cdot P(A) + P(V|Z) \cdot P(Z) + P(V|Ö) \cdot P(Ö)$$

$$= 0 \cdot 0,4 + 0,05 \cdot 0,2 + 0,05 \cdot 0,25 + 0,2 \cdot 0,15$$

$$= 0 + 0,010 + 0,0125 + 0,030$$

$$= 0,0525$$

✓ **b) Bayes-Formel**

„Nach Beginn des Gottesdienstes geht die Kirchentür auf und Gemeindemitglied **Robert Rein** betritt die Kirche, als Pater Noster bereits die Lesung aus dem Matthäus-Evangelium (Mt. 19,30) vorträgt.“ 💡 „Allem Anschein nach kommt Herr Rein zu spät.“

$$P(Ö|V) = \frac{P(V|Ö) \cdot P(Ö)}{P(V)} = \frac{0,2 \cdot 0,15}{0,0525} = \frac{0,03}{0,0525} = 0,5714$$

⇒ 57,14 %

ZUSATZAUFGABE (max. 5 Punkte) — Kovarianz und Anpassungsgüte

Ein Empiriker führt jeweils einfache Regressionen der erklärten Variable y gegen die erklärenden Variablen x bzw. z durch. **Erstaunlicherweise ergibt sich in beiden Fällen der GLEICHE Steigungsparameter $\hat{b} > 0$.** Welches der Modelle liefert die bessere Anpassung: das mit der **größeren** oder mit der **kleineren** Kovarianz?

Der Beweis

Laut Aufgabenstellung:

$$\frac{\sigma_{xy}}{\sigma_{x^2}} = \frac{\sigma_{yz}}{\sigma_{z^2}} = \hat{b} > 0$$

Da im Nenner jeweils VARIANZEN GRÖßER ALS NULL stehen, müssen folglich auch die beiden KOVARIANZEN im Zähler POSITIV sein: $\sigma_{xy}, \sigma_{yz} > 0$

Sei o.B.d.A. σ_{xy} die KLEINERE: $0 < \sigma_{xy} < \sigma_{yz}$ (1)

Für das Bestimmtheitsmaß der Regression von y gegen x gilt:

$$\begin{aligned}
 R^2_{\{y|x\}} = r_{xy}^2 &= \left(\frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y} \right)^2 = \frac{\sigma_{xy}^2}{\sigma_{x^2} \cdot \sigma_{y^2}} = \underbrace{\frac{\sigma_{xy}}{\sigma_{x^2}}}_{=\hat{b}} \cdot \frac{\sigma_{xy}}{\sigma_{y^2}} = \frac{\sigma_{yz}}{\sigma_{z^2}} \cdot \frac{\sigma_{xy}}{\sigma_{y^2}} \\
 &< \frac{\sigma_{yz}}{\sigma_{z^2}} \cdot \frac{\sigma_{yz}}{\sigma_{y^2}} = \left(\frac{\sigma_{yz}}{\sigma_y \cdot \sigma_z} \right)^2 = r_{yz}^2 = R^2_{\{y|z\}} \\
 &\quad \text{(wegen (1))}
 \end{aligned}$$


„Damit hat die Regression mit der HÖHEREN KOVARIANZ auch die BESSERE ANPASSUNG.“



SELBSTTEST — Fragen zum Abfragen

▼ Kapitel 1: Einführung und Grundlagen

1. Erkläre die „Orangensaft-Metapher“ des Dozenten.
2. Definiere: statistische Einheit · Grundgesamtheit · Teilgesamtheit · Stichprobe · Merkmal · Merkmalsausprägung.
3. Quantitativ vs. qualitativ — Definition und je zwei Beispiele.
4. Stetig vs. diskret vs. quasi-stetig — Definition und je ein Beispiel.
5. ★★ Nenne die drei Skalenniveaus mit Definition und je zwei Beispielen.
6. ★★ Wie lautet die Regel, wenn zwei Merkmale unterschiedliche Skalenniveaus haben?
7. Totalerhebung vs. Stichprobe — Definition und je zwei Beispiele mit Jahreszahlen.
8. Warum werden Stichproben eingesetzt? (Kosten, Ethik) Welche Bedingung muss erfüllt sein?
9. Primär- vs. Sekundärdaten. Nenne vier Sekundärdatenlieferanten und vier Institutionen der amtlichen Statistik.
10. ⚠ Gehört die Kommunalstatistik zur amtlichen Statistik?
11. ★★ Nenne die drei Datenarten (Querschnitt/Zeitreihe/Panel) mit Definition, Schreibweise und Beispiel.
12. Was ist der Vorteil und was der Nachteil von Paneldaten?
13. ★★ Nenne die vier Datenformate. Was ist der Unterschied zwischen „gruppierten“ und „klassierten“ Daten?
14. Wie berechnet man kumulierte absolute und relative Häufigkeiten? Ab welchem Skalenniveau sind sie sinnvoll?
15. Nenne die beiden Klassierungsregeln (Velleman, Dixon/Kronmal) und die beiden Empfehlungen.

▼ Kapitel 2–3: Grafiken und Lagemaße

16. Nenne die fünf einfachen Grafiken. Wie berechnet man die Winkel im Kreisdiagramm?
17. ⚠️☆☆ Was ist der entscheidende Unterschied zwischen Blockdiagramm und Histogramm?
Wie berechnet man die Häufigkeitsdichte?
18. ⚠️ Wann ist ein Lagemaß NICHT sinnvoll?
19. ☆☆☆ Arithmetisches Mittel: zwei Vorteile, zwei Nachteile, drei Formeln (Original/gruppirt/klassiert).
20. ☆☆☆ Median: zwei Vorteile, zwei Nachteile, drei Berechnungswege.
21. ⚠️☆☆ Was ist der Sonderfall beim Median, wenn die Einfallsklasse die ERSTE Klasse ist?
22. Definiere Quantil. Was wird als Index notiert?
23. ☆☆☆ Wie berechnet man ein Quantil bei Originaldaten (beide Fälle $n \cdot p \in \mathbb{N}$ und $\notin \mathbb{N}$)?
24. Wie berechnet man ein Quantil bei klassierten Daten (Interpolationsformel)?
25. Was sind Quartile, was Perzentile?
26. ☆ Modus: Vorteil, Nachteil. Wie berechnet man ihn bei klassierten Daten?
27. ☆☆☆ Do-Ping-Aufgabe: 2,5 h mit 42 km/h, dann 3 h mit 31 km/h. Rechne auf BEIDE Arten.
28. ☆☆☆ Anna-Bolika-Aufgabe: 90 km mit 36 km/h, dann 40 km mit 32 km/h. Rechne auf BEIDE Arten.
29. ☆☆☆ Formuliere die Entscheidungsregel „Zähler-/Nennerverteilung bekannt“ exakt.
30. ☆☆☆ Geometrisches Mittel: Formel und Anwendung. Rechne das Aktienbeispiel (+30 %, –20 %).
31. ⚠️☆☆ Worauf muss man das geometrische Mittel anwenden — Wachstumsraten oder Wachstumsfaktoren?
32. Harmonisches Mittel: Formel (auch gewogen) und Anwendung.
33. ☆ Nenne die vier Konsequenzen aus dem Lagemaß-Vergleich.
34. ☆☆☆ Erkläre die NICHTAGGREGIERBARKEIT des Medians. Welche Praxisfolge hat sie?
35. ☆☆☆ Wie verhalten sich $\bar{x}$, $\tilde{x}$, x_M und x_p bei linearer Transformation $y = a + b \cdot x$?
36. Rechne das Oktoberfest-Transformationsbeispiel (0,9 l pro Maßkrug) für alle drei Lagemaße.

▼ Kapitel 4–5: Streuung, Schiefe, Wölbung

37. ⚠️☆☆ Warum verwendet man nicht die mittlere ABSOLUTE Abweichung? (drei Argumente)
38. ☆☆☆ Varianz vs. Stichprobenvarianz: Formeln und die Praxisregel.
39. ☆☆☆ Schreibe den Verschiebungssatz für alle drei Datenformate auf.
40. ☆☆☆ Wie rechnet man σ^2 in s^2 um (und umgekehrt)? Wann ist der Unterschied gravierend?
41. Standardabweichung: Vorteil und Nachteil gegenüber der Varianz.
42. ⚠️ Warum ist die Spannweite ein schlechtes Streuungsmaß? Wofür ist sie trotzdem nützlich?
43. Quartilsabstand: Vorteil und Nachteil.
44. ☆☆☆ Wie verhalten sich σ^2 , σ , R und IQR bei linearer Transformation? Was passiert mit dem additiven Term a?
45. ☆☆☆ Was ist der Variationskoeffizient? Warum braucht man ihn? Welche Eigenschaft hat er?
46. Definiere das k-te (zentrierte) Moment.
47. ☆☆☆ Formel der Schiefe nach Fisher. Nenne die beiden Kritikpunkte.
48. ☆☆☆ Formuliere die LAGEREGEL NACH FECHNER für alle drei Fälle.
49. ☆☆☆ Formel des Quartilskoeffizienten der Schiefe. Zwei Vorteile.
50. ⚠️☆☆ Ab welcher Stichprobengröße ist Schiefe überhaupt sinnvoll?
51. Nenne die drei Wölbungsformen mit Fachbegriff.
52. ☆☆☆ Formel für Wölbung und Exzess. Was ist die Klausurfalle bei der deutschen vs. englischen Literatur?

▼ Kapitel 6: Hochwertige Grafiken

53. ☆☆☆ Nenne die 5-Number-Summary.
54. ☆☆☆ Nenne die VIER Informationen, die man am Boxplot ablesen kann.
55. ☆☆☆ Wie erkennt man Schiefe am Boxplot? (drei Fälle)
56. ☆☆☆ Punktierte Boxplot: Bei wie vielen Beobachtungen erwartet man 1 Außenpunkt, bei wie vielen 1 Fernpunkt?
57. Nenne drei weitere Boxplot-Modifikationen.
58. ☆☆☆ Was ist ein QQ-Plot? Wie erkennt man Normalverteilung, Schiefe und Wölbung?
59. ⚠️ Was passiert bei der QQ-Plot-Interpretation, wenn x- und y-Achse vertauscht werden?
60. ☆☆☆ Welches Problem lösen Kerndichteschätzer? Nenne die fünf Kernfunktionen.

▼ **Kapitel 7-9: Bivariate Daten, Zusammenhänge, Regression**

61. ★★★★★ Grenze KORRELATION, KONTINGENZ und ASSOZIATION ab (Skalenniveau!).
62. ★★ Kovarianz: Definitionsformel und Verschiebungssatz. Erkläre die Quadranten-Deutung.
63. ⚠️ Was ist das Problem der Kovarianz und wie löst man es?
64. ★★★★★ Rechenformel für r nach Bravais-Pearson. Wertebereich?
65. ⚠️★★★★ Was misst r GENAU? Was gilt, wenn $r = 0$ ist?
66. ★★★★★ Formel für Spearman (vereinfacht). Wann darf man sie verwenden?
67. ⚠️★ Was misst Spearman genau? Was gilt bei $R = 0$?
68. ★★ Rechne das Noten-Beispiel (Mathematik/Physik) nach: $R = 0,77$.
69. ★★ Formel des Yule'schen Assoziationskoeffizienten. Wann verwendet man ihn?
70. ★★★★★ Beschreibe die vier Berechnungsstufen des korrigierten Kontingenzkoeffizienten.
71. ⚠️★★★★ Nenne die VIER Punkte zur korrekten Interpretation der Kontingenz.
72. ★★ Grenze Korrelation und Regression ab (Pfeilrichtung!).
73. ★★★★★ Formeln für $\hat{b}$ und $\hat{a}$ der Regressionsgeraden.
74. ★★★★★ Was misst R^2 ? Wie lautet die schnelle Klausurformel? Wie ist GS zerlegt?
75. Formeln für Standardfehler und relativen Standardfehler.
76. ★★★★★ Was ist Scheinkorrelation? Wann tritt sie auf? Was ist die häufigste Drittvariable?
77. ⚠️★★★★ Was gilt für Merkmale mit Trend / Zeitreihen?
78. ★★★★★ Beschreibe BEIDE Wege zur partiellen Korrelation (Residuen und Formel). Rechne das E-Auto-Beispiel.

▼ **Kapitel 10-11: Zeitreihen und Verhältniszahlen**

79. Nenne die drei Ziele der Zeitreihenanalyse und das additive Komponentenmodell.
80. ★★ Formel des gleitenden Durchschnitts UNGERADER Länge ($2k+1$).
81. ★★★★★ Formel des gleitenden Durchschnitts GERADER Länge ($2k$). Was ist die Besonderheit?
82. Welche Periodenlänge m wählt man bei Monats-, Quartals- und Wochentagsdaten?
83. ★★★★★ Vergleiche gleitende Durchschnitte und Trendregression (je 1 Vor- und Nachteil). Was ist das „Berliner Verfahren“?
84. Nenne zwei weitere Glättungsverfahren.
85. ★★ Was ist eine Verhältniszahl? Nenne vier Anwendungsbeispiele aus dem Alltag.
86. ★★★★★ Nenne die drei Typen von Verhältniszahlen. Grenze Verursachungs- und Entsprechungszahlen ab (je 2 Beispiele).
87. Was ist eine Messziffer? Was ist ihr Problem?
88. ★★★★★ Schreibe die Formeln für Laspeyres und Paasche auf. Welcher Warenkorb wird jeweils verwendet?
89. ⚠️★★★★ Nenne die Nachteile beider Indizes. Welcher wird in der Praxis verwendet und wie oft wird der Warenkorb erneuert?
90. ★★★★★ Wertgewichtsmethode: Welcher Index ist ein gewogenes ARITHMETISCHES, welcher ein gewogenes HARMONISCHES Mittel?
91. Wofür steht COICOP? Wofür EVS?

▼ **Kapitel 12/13: Wahrscheinlichkeit**

92. **Nenne die drei Wahrscheinlichkeitsbegriffe. Welcher steht im Fokus der Vorlesung?**
93. **Was kennt man bei einem Zufallsexperiment, was nicht?**
94. **Erkläre ω , Ω und zusammengesetzte Ereignisse.**
95. **★★ Formel der Laplace-Wahrscheinlichkeit.**
96. **★★★★ Schreibe auf: Gegenereignis · Additionssatz · Unabhängigkeit · beide de-Morgan-Regeln.**
97. **★★ Formel der bedingten Wahrscheinlichkeit. Für welches Argument gelten die Kolmogoroff-Axiome?**
98. **★★★★ Formel des Satzes von der totalen Wahrscheinlichkeit.**
99. **★★★★ Formel des Satzes von Bayes (beide Schreibweisen).**
100. **★★★★ Definiere Sensitivität, Spezifität und Prävalenz. Schreibe die PPV-Formel auf.**
101. **★★ Nenne die sechs kombinatorischen Grundformeln mit Namen.**

▼ Aufgabensammlung und Klausur

102. ★★★★★ Aufgabe 0.1: Stelle die vollständige Arbeitstabelle auf und berechne $\bar{x}$, $\tilde{x}$, x_M , σ , s , IQR und y_1 .
103. ⚠️★ Aufgabe 0.1: Warum wird für die „Vorgängerklasse“ beim Median NULL eingesetzt?
104. ★★ Aufgabe 0.2: Rechne alle Maße für 5,7,6,4,5,2,0,12,0,5 durch.
105. ★★ Aufgabe 0.5: Wer von den drei Chemikern hat Recht — Matt Wurst, G. Hacktes, H. Schee? Begründe mit Lagemaßen.
106. ★★★★★ Aufgabe 0.6: Was passiert mit $\bar{x}$, $\tilde{x}$ und σ^2 , wenn 23 durch 28 ersetzt wird? Führe die Herleitung durch.
107. ⚠️★ Aufgabe 0.6: Wann könnte man KEINE Aussage über den Median machen?
108. ★★★★★ Aufgabe 0.7: Welcher Mittelwert bei a) Umsatzveränderungen, b) gleich langen Strecken, c) Tageseinnahmen? Rechne alle drei.
109. Aufgabe 0.8: Was passiert mit der Varianz, wenn eine Beobachtung mit dem Wert des Mittelwerts hinzukommt?
110. ★★ Aufgabe 0.10: Zwei Beobachtungen, eine viermal größer — um wie viel Prozent ist $\bar{x}$ größer als $\bar{x}_g$?
111. ★★★★★ Aufgabe 0.11: Führe die komplette Regression Aktie/Marktindex durch ($\hat{b}$, $\hat{a}$, r , R^2) und interpretiere alle Werte.
112. ★★★★★ Aufgabe 0.12: Warum Spearman und nicht Bravais-Pearson? Rechne $R = -0,086$ nach.
113. ★★★★★ Aufgabe 0.13 (Titanic): Berechne beide Kontingenztabellen, χ^2 , K und K^* .
114. ★★★★★ Aufgabe 0.14: Welcher gleitende Durchschnitt bei Quartalsdaten? Schreibe die Formel auf und rechne einen Wert nach.
115. ★★★★★ Aufgabe 0.15 (Mensa): Berechne Laspeyres (1,18) und Paasche (1,17).
116. ★★★★★ Aufgabe 0.16: Erkläre das SIMPSON-PARADOXON an Prof. Genders Daten. Berechne alle sechs Durchfallquoten.
117. ★★★★★ Aufgabe 0.17: Warum arithmetisch in Zasterhausen und harmonisch in Mooslos? Rechne beide.
118. ★★ Aufgabe 0.18/0.19: Rechne Fahrkartenautomaten und Burger-Party durch (inkl. Vierfeldertafel).
119. ★★★★★ Aufgabe 0.20: Rechne alle vier Teilaufgaben zur Matrikelnummer.
120. ★★★★★ Aufgabe 0.21: Rechne alle drei Paarbildungs-Szenarien (2.520 / 7.484.400 / 18.900).
121. ★★★★★ Aufgabe 0.22 (Montagsauto): Rechne beide Teile — auch mit der eleganten Lösung.
122. ★★★★★ Aufgabe 0.23 (Drogentest): Rechne beide Prävalenzen. Was ist die Kernaussage?
123. ★★★★★ Klausur A1 (Karo Sell): Beschreibe das Datenformat und begründe, welche Lagemaße berechenbar sind.
124. ⚠️★★★ Klausur A1b: Warum ist $x_{0,75} = 2,5$ und nicht 2?
125. ★★ Klausur A1c: Berechne den Quartilkoeffizienten der Schiefe (QS = 1).
126. ★★★★★ Klausur A2: Führe die Trendregression durch ($\hat{b} = 110,54$) und interpretiere.
127. ⚠️★★★★ Klausur A2d: Warum ist die Prognose 4.633,61 € unplausibel und was schlägt die Musterlösung vor?
128. ★★★★★ Klausur A3 (Hinterwälderisch): Berechne alle drei fehlenden Werte und begründe die Mittelwertwahl.
129. ★★★★★ Klausur A4 (Pater Noster): Definiere alle Ereignisse und rechne $P(V)$ und $P(\bar{O} | V)$.
130. ★★ Zusatzaufgabe: Beweise, dass die Regression mit der höheren Kovarianz die bessere Anpassung hat.

KLAUSUR-SPICKZETTEL

SKALENNIVEAUS

nominal (nur Art) → ordinal (+Reihenfolge) → kardinal/metrisch (+Abstände)

★ Immer am NIEDRIGER skalierten Merkmal orientieren!

DATENFORMATE

Originaldaten · geordnete Stichprobe · gruppiert (a_i, n_i) · klassiert (Klassen, m_i, Δ_i)

$r_i = n_i/n$ Klassierung: Velleman $2\sqrt{n}$ · Dixon/Kronmal $10 \cdot \log_{10} n$

HISTOGRAMM

⚠ FLÄCHE proportional zur Häufigkeit! Häufigkeitsdichte $f_i = r_i / \Delta_i$

LAGEMASSE

	ab Skala	ausreißerempfindlich?
Modus x_M	nominal	nein (aber primitiv)
Median $\tilde{x}$	ordinal	NEIN ★
Arithm. Mittel $\bar{x}$	kardinal	JA ⚠
Geometr. Mittel $\bar{x}_g$	kardinal	→ WACHSTUMSFAKTOREN
Harmon. Mittel $\bar{x}_h$	kardinal	→ Verhältniszahlen (Zähler bekannt)

$\bar{x}$ (klassiert) = $(1/n) \cdot \sum n_i m_i$

Median (klassiert) = $x_u + (0,5 - F_{\text{vor}})/r_{\text{ein}} \cdot \Delta$

Quantil (Originaldaten): $n \cdot p \notin \mathbb{N} \Rightarrow x_{(\text{aufgerundet})}$ · $n \cdot p \in \mathbb{N} \Rightarrow$ Mittel aus zwei

★★★★ VERHÄLTNISSAHLEN $V = Z/N$

ZÄHLERverteilung bekannt → gewogenes HARMONISCHES Mittel

NENNERverteilung bekannt → gewogenes ARITHMETISCHES Mittel

STREUUNG

$\sigma^2 = (1/n) \sum (x_i - \bar{x})^2$

$s^2 = (1/(n-1)) \sum (x_i - \bar{x})^2$

$s^2 = n/(n-1) \cdot \sigma^2$

Verschiebungssatz: $\sigma^2 = (1/n) \sum x_i^2 - \bar{x}^2$

$R = x_{\text{max}} - x_{\text{min}}$

$IQR = x_{0,75} - x_{0,25}$

$V = \sigma/\bar{x}$

Lineare Transformation $y = a + b \cdot x$:

$\bar{x}, \tilde{x}, x_M, x_p \rightarrow a + b \cdot (\dots)$

$\sigma^2 \rightarrow b^2 \cdot \sigma^2$

$\sigma, R, IQR \rightarrow |b| \cdot (\dots)$

SCHIEFE / WÖLBUNG

Fisher: $\gamma_1 = \mu_3/\sigma^3$

Exzess = $\mu_4/\sigma^4 - 3$

Fechner: $\tilde{x} = \bar{x} = x_M$ symmetrisch · $\tilde{x} > \bar{x} > x_M$ rechtsschief · $\tilde{x} < \bar{x} < x_M$ linksschief

Quartilskoeff.: $QS = [(x_{0,75} - \tilde{x}) - (\tilde{x} - x_{0,25})] / (x_{0,75} - x_{0,25})$

BOXPLOT (5-Number-Summary: min · $x_{0,25}$ · $\tilde{x}$ · $x_{0,75}$ · max)

Median mittig = symmetrisch · zum UNTEREN Quartil = RECHTsschief

QQ-Plot: Gerade = NV · Bogen = Schiefe · Schlange = Wölbung

ZUSAMMENHANG

Skalenniveau

Bravais-Pearson r_{xy}

kardinal

misst LINEAREN Zshg.

Spearman $R_{xy} = 1 - 6 \sum d_i^2 / (n(n^2 - 1))$

ordinal

misst MONOTONEN Zshg.

Yule $Q = (ad - bc) / (ad + bc)$

nominal 2x2

Kontingenz $K^* = \sqrt{(M/(M-1)) \cdot K}$

nominal beliebig

$r_{xy} = (\sum x_i y_i - n \cdot \bar{x} \cdot \bar{y}) / [\sqrt{(\sum x_i^2 - n \cdot \bar{x}^2)} \cdot \sqrt{(\sum y_i^2 - n \cdot \bar{y}^2)}]$

REGRESSION

$\hat{b} = \sigma_{xy} / \sigma_{x^2} = (\sum x_i y_i - n \cdot \bar{x} \bar{y}) / (\sum x_i^2 - n \cdot \bar{x}^2)$

$\hat{a} = \bar{y} - \hat{b} \cdot \bar{x}$

$R^2 = ES/GS = r_{xy}^2$

$GS = ES + NS$

Partielle Korrelation: $r_{xy|z} = (r_{xy} - r_{xz} \cdot r_{yz}) / [\sqrt{(1 - r_{xz}^2)} \cdot \sqrt{(1 - r_{yz}^2)}]$

ZEITREIHEN

ungerade ($2k+1$): $y^*_t = 1/(2k+1) \cdot \sum y_{\{t-k..t+k\}}$

gerade ($2k$): $y^*_t = 1/(2k) \cdot (\frac{1}{2} y_{\{t-k\}} + y_{\{t-k+1\}} + \dots + y_{\{t+k-1\}} + \frac{1}{2} y_{\{t+k\}})$

Quartalsdaten $\Rightarrow m = 4$ · Monatsdaten $\Rightarrow m = 12$

INDIZES

Laspeyres $P_L = \frac{\sum p_t \cdot q_0}{\sum p_0 \cdot q_0}$ (BASISkorb, gew. ARITHM. Mittel)

Paasche $P_P = \frac{\sum p_t \cdot q_t}{\sum p_0 \cdot q_t}$ (BERICHTSkorb, gew. HARMON. Mittel)

WAHRSCHEINLICHKEIT

$P(\bar{A}) = 1 - P(A)$ $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Unabhängig: $P(A \cap B) = P(A) \cdot P(B)$ $P(A|B) = P(A \cap B) / P(B)$

Total: $P(B) = \sum P(B|A_i) \cdot P(A_i)$

Bayes: $P(A|B) = P(B|A) \cdot P(A) / P(B)$

KOMBINATORIK

Permutation $n!$ · m. Wdh. $n! / (n_1! n_2! \dots)$

Variation m. Wdh. n^k · o. Wdh. $n! / (n-k)!$

Kombination o. Wdh. $C(n, k)$ · m. Wdh. $C(n+k-1, k)$