Übungsblatt 4 – Lineare Regression

Grundlagen Lineare Algebra | DHBW

Aufgabe 1 – Grundbegriffe

(a) Erklären Sie das Ziel der linearen Regression (Methode der kleinsten Quadrate, OLS). Was wird minimiert und warum ist die quadratische Fehlermetrik sinnvoll?

(b) Definieren Sie den Begriff *Residuum*. Wie unterscheidet sich ein Residuum von einem Vorhersagefehler? Welchen Zusammenhang hat die Summe der quadrierten Residuen (SSE) zur L_2-Norm?

(c) Erklären Sie, wie die *Designmatrix* X für eine lineare Regression mit K Variablen und N Beobachtungen aufgebaut ist. Warum enthält die erste Spalte ausschließlich Einsen? Welche Dimensionen hat X?

(d) Erläutern Sie die drei Fallunterscheidungen ($N < K{+}1$, $N = K{+}1$, $N > K{+}1$) und was jeweils folgt. Warum ist der überbestimmte Fall in der Praxis der Regelfall?

Aufgabe 2 – Einfache Lineare Regression *(Berechnung)*

Gegeben seien vier Datenpunkte:

Beobachtung j	x_j	y_j
1	2	4
2	3	6
3	4	5
4	5	3

(a) Stellen Sie die Designmatrix X und den Zielvektor $\vec{y}$ auf.

(b) Berechnen Sie $X^\top X$ und $X^\top \vec{y}$ explizit (alle Matrixmultiplikationen ausschreiben).

(c) Lösen Sie die Normalengleichung $X^\top X\,\vec{c} = X^\top \vec{y}$ nach $\vec{c} = (c_0, c_1)^\top$. Nutzen Sie die Formel für die Inverse einer $2{\times}2$-Matrix.

(d) Geben Sie das Regressionsmodell $\hat{y} = c_0 + c_1 x$ an. Berechnen Sie die vier Vorhersagewerte $\hat{y}_j$ und das SSE.

Aufgabe 3 – Quadratischer Fall: Exakte Lösung *(Berechnung)*

Gegeben seien genau zwei Datenpunkte: $(x_1, y_1) = (1, 0)$ und $(x_2, y_2) = (2, 4)$.

(a) Erklären Sie, warum in diesem Fall ($N = K{+}1 = 2$) die Designmatrix X quadratisch ist und direkt invertiert werden kann.

(b) Stellen Sie X auf und berechnen Sie X^{-1} mit der $2{\times}2$-Inversionsformel $\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc}\begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$.

(c) Berechnen Sie $\vec{c} = X^{-1}\vec{y}$ und geben Sie das Modell $\hat{y} = c_0 + c_1 x$ an. Überprüfen Sie das Ergebnis: Liegt das Modell exakt durch beide Punkte?

Aufgabe 4 – Multiple Regression *(Berechnung)*

Ein Datensatz enthält drei Beobachtungen mit zwei erklärenden Variablen x_1 und x_2:

j	$x_{j,1}$	$x_{j,2}$	y_j
1	1	2	5
2	2	1	6
3	3	3	10

(a) Stellen Sie die Designmatrix X (3×3) und den Zielvektor $\vec{y}$ auf.

(b) Berechnen Sie $X^\top X$ (3×3) und $X^\top\vec{y}$ (3×1) explizit.

(c) Lösen Sie $X^\top X\,\vec{c} = X^\top\vec{y}$ (z. B. durch Gauß-Elimination oder Cramer) nach $\vec{c} = (c_0, c_1, c_2)^\top$.

(d) Berechnen Sie die Residuen $r_j = y_j - \hat{y}_j$ und das SSE. Was sagt ein SSE = 0 über die Modellgüte aus?

Aufgabe 5 – Polynomielle Regression *(Szenario)*

Sie sollen für die Daten aus Aufgabe 2 ein Polynom zweiten Grades anpassen:

$$\hat{y} = c_0 + c_1 x + c_2 x^2$$

(a) Erklären Sie, warum dieses Modell trotz des Terms x^2 immer noch eine *lineare* Regression ist. Worin liegt die Linearität?

(b) Stellen Sie die neue Designmatrix X für die vier Datenpunkte aus Aufgabe 2 auf (jetzt mit drei Spalten: 1, x, x^2). Welche Dimensionen hat X jetzt?

(c) Welche Fallunterscheidung liegt nun vor (N vs. $K{+}1$)? Muss die Normalengleichung oder die direkte Inverse verwendet werden?

(d) Nennen Sie zwei Risiken, die entstehen können, wenn der Polynomgrad sehr hoch gewählt wird.

Aufgabe 6 – Wahr oder Falsch

Beurteilen Sie die folgenden Aussagen als wahr oder falsch und begründen Sie jeweils kurz:

(a) Die Normalengleichung liefert immer eine eindeutige Lösung, unabhängig von der Designmatrix.

(b) Im überbestimmten Fall ($N > K{+}1$) gilt $\hat{y} = y$ – das Modell passt die Daten exakt an.

(c) Die Moore-Penrose-Pseudoinverse $(X^\top X)^{-1}X^\top$ existiert genau dann, wenn X vollen Spaltenrang hat.

(d) Polynomielle Regression mit Grad 2 ist eine nichtlineare Regression, weil x^2 nichtlinear in x ist.

(e) Wenn zwei Spalten der Designmatrix identisch sind (perfekte Multikollinearität), ist $X^\top X$ nicht invertierbar.

(f) Das SSE kann niemals negativ werden.

Aufgabe 7 – Effiziente Berechnung der Regression *(Numerik)*

(a) Beschreiben Sie zwei Wege, die Normalengleichung $X^\top X\,\vec{c} = X^\top \vec{y}$ numerisch zu lösen: (1) explizite Invertierung von $X^\top X$ und anschließende Matrixmultiplikation, (2) direktes Lösen des linearen Gleichungssystems ohne explizite Inverse. Welcher Weg ist effizienter und warum? Begründen Sie anhand des Rechenaufwands.

(b) Nennen Sie drei weitere numerische Verfahren zur Lösung der Normalengleichung: QR-Zerlegung, Cholesky-Zerlegung (LDL) und Singulärwertzerlegung (SVD). Ordnen Sie die fünf Verfahren (Inverse, LU, QR, Cholesky, SVD) nach numerischer Stabilität (von am wenigsten bis am stabilsten).

(c) Warum ist die explizite Berechnung von $(X^\top X)^{-1}$ problematisch, wenn $X^\top X$ *schlecht konditioniert* ist? Erklären Sie den Begriff der Konditionszahl $\kappa(A)$ und was eine große Konditionszahl für die numerische Genauigkeit bedeutet.

(d) Erstellen Sie eine Vergleichstabelle der fünf Verfahren mit den Spalten: Verfahren, Geschwindigkeit, Numerische Stabilität, Anwendungsfall.

Lösungen – Übungsblatt 4

Aufgabe 1 – Grundbegriffe

(a) **Ziel der OLS:** Die Methode der kleinsten Quadrate (Ordinary Least Squares, OLS) sucht den Koeffizientenvektor $\vec{c}$, der die Summe der quadrierten Abweichungen zwischen den beobachteten Zielwerten y_j und den Modellvorhersagen $\hat{y}_j$ minimiert: $\mathrm{SSE} = \sum_{j=1}^{N}(y_j - \hat{y}_j)^2 \to \min$. Die Quadrierung hat zwei Vorteile: Vorzeichen heben sich nicht auf (positive und negative Fehler werden beide bestraft) und große Abweichungen werden stärker gewichtet, was zu einem mathematisch glatten, differenzierbaren Optimierungsproblem führt.

(b) **Residuum:** Das Residuum $r_j = y_j - \hat{y}_j$ ist die Differenz zwischen dem tatsächlich beobachteten Wert und dem vom Modell vorhergesagten Wert. Im Gegensatz zum "echten" Fehler (Abweichung vom unbekannten wahren Wert) ist das Residuum berechenbar, da es auf den Trainingsdaten basiert. Der Zusammenhang zur L_2-Norm ergibt sich direkt: $\mathrm{SSE} = \sum_j r_j^2 = \vec{r}^\top \vec{r} = \|\vec{r}\|_2^2 = \|\vec{y} - X\vec{c}\|_2^2$.

(c) **Designmatrix:** X hat die Dimension $N \times (K{+}1)$, wobei N die Anzahl der Beobachtungen und K die Anzahl der Variablen ist. Die erste Spalte besteht vollständig aus Einsen, weil sie den *Intercept* c_0 kodiert – das ist der Term $c_0 \cdot 1$, also eine konstante Spalte, die es dem Modell erlaubt, einen von null verschiedenen Achsenschnittpunkt zu haben. Jede Zeile i lautet: $(1, x_{i,1}, x_{i,2}, \ldots, x_{i,K})$.

(d) **Fallunterscheidungen:** Für $N < K{+}1$ ist das Gleichungssystem *unterbestimmt* – es gibt unendlich viele Lösungen, das Modell ist nicht eindeutig bestimmbar. Für $N = K{+}1$ ist X quadratisch und (bei vollem Rang) direkt invertierbar: $\vec{c} = X^{-1}\vec{y}$, das Modell verläuft exakt durch alle Datenpunkte. Für $N > K{+}1$ ist das System *überbestimmt* – eine exakte Lösung existiert i. A. nicht, weshalb OLS den besten Kompromiss (kleinstes SSE) liefert. Dieser Fall ist der Regelfall, weil in der Praxis stets viel mehr Beobachtungen als Parameter vorliegen.

Aufgabe 2 – Einfache Lineare Regression

(a) Designmatrix und Zielvektor:

$$X = \begin{pmatrix} 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \qquad \vec{y} = \begin{pmatrix} 4 \\ 6 \\ 5 \\ 3 \end{pmatrix}$$

(b) Berechnung von $X^\top X$ und $X^\top \vec{y}$:

$$X^\top X = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} 1{+}1{+}1{+}1 & 2{+}3{+}4{+}5 \\ 2{+}3{+}4{+}5 & 4{+}9{+}16{+}25 \end{pmatrix} = \begin{pmatrix} 4 & 14 \\ 14 & 54 \end{pmatrix}$$

$$X^\top \vec{y} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 4 \\ 6 \\ 5 \\ 3 \end{pmatrix} = \begin{pmatrix} 4{+}6{+}5{+}3 \\ 8{+}18{+}20{+}15 \end{pmatrix} = \begin{pmatrix} 18 \\ 61 \end{pmatrix}$$

(c) Normalengleichung lösen:

Für eine 2×2-Matrix $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$ mit $\det = ad - bc$:

$$(X^\top X)^{-1} = \frac{1}{4 \cdot 54 - 14 \cdot 14} \begin{pmatrix} 54 & -14 \\ -14 & 4 \end{pmatrix} = \frac{1}{216 - 196} \begin{pmatrix} 54 & -14 \\ -14 & 4 \end{pmatrix} = \frac{1}{20} \begin{pmatrix} 54 & -14 \\ -14 & 4 \end{pmatrix}$$

$$\vec{c} = (X^\top X)^{-1} X^\top \vec{y} = \frac{1}{20} \begin{pmatrix} 54 & -14 \\ -14 & 4 \end{pmatrix} \begin{pmatrix} 18 \\ 61 \end{pmatrix} = \frac{1}{20} \begin{pmatrix} 54 \cdot 18 - 14 \cdot 61 \\ -14 \cdot 18 + 4 \cdot 61 \end{pmatrix} = \frac{1}{20} \begin{pmatrix} 972 - 854 \\ -252 + 244 \end{pmatrix} = \frac{1}{20} \begin{pmatrix} 118 \\ -8 \end{pmatrix} = \begin{pmatrix} 5 \\ - \end{pmatrix}$$

(d) Modell und SSE:

Modell: $\hat{y} = 5{,}9 - 0{,}4\,x$

j	x_j	y_j	$\hat{y}_j = 5{,}9 - 0{,}4\,x_j$	$r_j = y_j - \hat{y}_j$
1	2	4	$5{,}9 - 0{,}8 = 5{,}1$	$-1{,}1$
2	3	6	$5{,}9 - 1{,}2 = 4{,}7$	$1{,}3$
3	4	5	$5{,}9 - 1{,}6 = 4{,}3$	$0{,}7$
4	5	3	$5{,}9 - 2{,}0 = 3{,}9$	$-0{,}9$

$$\text{SSE} = (-1{,}1)^2 + (1{,}3)^2 + (0{,}7)^2 + (-0{,}9)^2 = 1{,}21 + 1{,}69 + 0{,}49 + 0{,}81 = 4{,}20$$

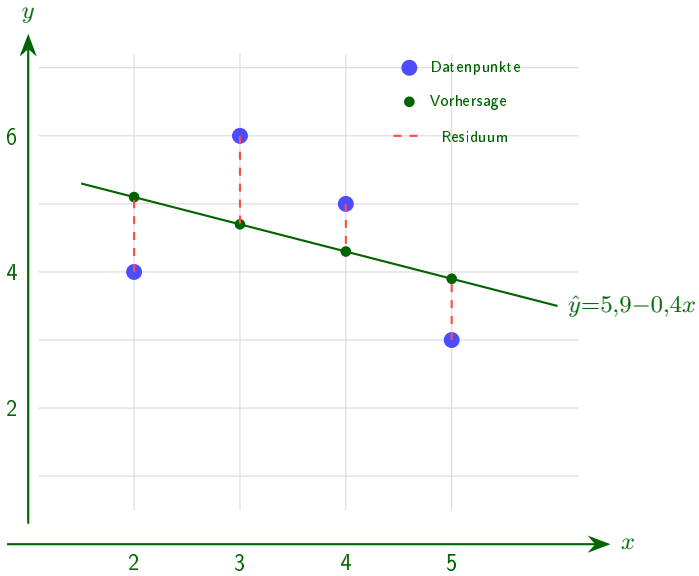

Aufgabe 3 – Quadratischer Fall: Exakte Lösung

(a) **Quadratischer Fall:** Mit $K = 1$ Variable und $N = 2$ Beobachtungen gilt $N = K+1 = 2$. Damit ist die Designmatrix X eine 2×2-Matrix und somit quadratisch. Bei Invertierbarkeit (Determinante $\neq 0$) existiert X^{-1} direkt, und das Gleichungssystem $X\vec{c} = \vec{y}$ hat die eindeutige exakte Lösung $\vec{c} = X^{-1}\vec{y}$. Die Normalengleichung wird nicht benötigt – das Modell verläuft exakt durch beide Punkte, was einem SSE = 0 entspricht.

(b) **Designmatrix und Inverse:**

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \det(X) = 1 \cdot 2 - 1 \cdot 1 = 1$$

$$X^{-1} = \frac{1}{1} \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix}$$

(c) **Koeffizienten und Modell:**

$$\vec{c} = X^{-1}\vec{y} = \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 4 \end{pmatrix} = \begin{pmatrix} 2 \cdot 0 + (-1) \cdot 4 \\ (-1) \cdot 0 + 1 \cdot 4 \end{pmatrix} = \begin{pmatrix} -4 \\ 4 \end{pmatrix}$$

Modell: $\hat{y} = -4 + 4x$. **Überprüfung:** $\hat{y}(1) = -4 + 4 = 0 = y_1$ ✓ und $\hat{y}(2) = -4 + 8 = 4 = y_2$ ✓. Das Modell verläuft exakt durch beide Punkte, SSE = 0.

Aufgabe 4 – Multiple Regression

(a) Designmatrix und Zielvektor:

$$X = \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & 1 \\ 1 & 3 & 3 \end{pmatrix}, \qquad \vec{y} = \begin{pmatrix} 5 \\ 6 \\ 10 \end{pmatrix}$$

(b) $X^\top X$ und $X^\top \vec{y}$:

$$X^\top X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 2 & 1 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 & 2 \\ 1 & 2 & 1 \\ 1 & 3 & 3 \end{pmatrix} = \begin{pmatrix} 3 & 6 & 6 \\ 6 & 14 & 13 \\ 6 & 13 & 14 \end{pmatrix}$$

Probe Eintrag (1,2): $1{\cdot}1 + 1{\cdot}2 + 1{\cdot}3 = 6$ ✓ *Eintrag (2,2):* $1^2 + 2^2 + 3^2 = 14$ ✓

$$X^\top \vec{y} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 2 & 1 & 3 \end{pmatrix} \begin{pmatrix} 5 \\ 6 \\ 10 \end{pmatrix} = \begin{pmatrix} 5{+}6{+}10 \\ 5{+}12{+}30 \\ 10{+}6{+}30 \end{pmatrix} = \begin{pmatrix} 21 \\ 47 \\ 46 \end{pmatrix}$$

(c) Lösung der Normalengleichung (Gauß-Elimination):

Erweitertes System $[X^\top X \mid X^\top \vec{y}]$:

$$\left(\begin{array}{ccc|c} 3 & 6 & 6 & 21 \\ 6 & 14 & 13 & 47 \\ 6 & 13 & 14 & 46 \end{array}\right)$$

$Z_2 \leftarrow Z_2 - 2Z_1$: $(0,\, 2,\, 1 \mid 5)$ $Z_3 \leftarrow Z_3 - 2Z_1$: $(0,\, 1,\, 2 \mid 4)$

$$\left(\begin{array}{ccc|c} 3 & 6 & 6 & 21 \\ 0 & 2 & 1 & 5 \\ 0 & 1 & 2 & 4 \end{array}\right)$$

$Z_3 \leftarrow Z_3 - \frac{1}{2}Z_2$: $(0,\, 0,\, \frac{3}{2} \mid \frac{3}{2})$, also $c_2 = 1$.

Rückwärtseinsetzen: $2c_1 + c_2 = 5 \Rightarrow 2c_1 = 4 \Rightarrow c_1 = 2$.

$3c_0 + 6c_1 + 6c_2 = 21 \Rightarrow 3c_0 + 12 + 6 = 21 \Rightarrow c_0 = 1$.

$$\vec{c} = \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} \qquad \Rightarrow \qquad \hat{y} = 1 + 2x_1 + 1 \cdot x_2$$

(d) Residuen und SSE:

j	$x_{j,1}$	$x_{j,2}$	y_j	$\hat{y}_j = 1 + 2x_{j,1} + x_{j,2}$	r_j
1	1	2	5	$1+2+2=5$	0
2	2	1	6	$1+4+1=6$	0
3	3	3	10	$1+6+3=10$	0

$$\mathrm{SSE} = 0^2 + 0^2 + 0^2 = 0$$

Ein SSE = 0 bedeutet, dass das Modell die Daten *exakt* anpasst – jeder beobachtete Wert wird perfekt vorhergesagt. Dies ist möglich, weil $N = K{+}1 = 3$ (quadratischer Fall): die Designmatrix X ist quadratisch und invertierbar, sodass das LGS eine exakte Lösung besitzt. In der Praxis ist SSE = 0 auf den Trainingsdaten kein Zeichen für ein gutes Modell – es kann Überanpassung (Overfitting) signalisieren.

Aufgabe 5 – Polynomielle Regression

(a) **Linearität in den Koeffizienten:** Der Begriff "lineare Regression" bezieht sich *nicht* auf die Linearität in x, sondern auf die Linearität im Parametervektor $\vec{c}$. Das Modell $\hat{y} = c_0 + c_1 x + c_2 x^2$ ist linear in c_0, c_1 und c_2 – alle Koeffizienten treten als einfache Faktoren auf, ohne Quadrierung oder andere nichtlineare Transformationen. Das Merkmal x^2 wird als neue Variable $x_2 := x^2$ behandelt; damit bleibt die Designmatrix-Struktur erhalten und dieselbe Normalengleichung kann verwendet werden.

(b) **Designmatrix für Grad 2:**

$$X = \begin{pmatrix} 1 & 2 & 4 \\ 1 & 3 & 9 \\ 1 & 4 & 16 \\ 1 & 5 & 25 \end{pmatrix}$$

Dimensionen: $4{\times}3$ ($N = 4$ Zeilen, $K{+}1 = 3$ Spalten).

(c) **Fallunterscheidung:** $N = 4 > K{+}1 = 3$: *überbestimmter* Fall. Die direkte Inverse X^{-1} existiert nicht (nicht-quadratische Matrix). Es muss die Normalengleichung $X^\top X\,\vec{c} = X^\top \vec{y}$ mit der $(3{\times}3)$-Matrix $X^\top X$ gelöst werden.

(d) **Risiken hoher Polynomgrade:**

- **Overfitting (Überanpassung):** Bei sehr hohem Grad K passt das Modell die Trainingsdaten sehr genau an (kleines SSE), verallgemeinert aber schlecht auf neue Daten – die Kurve oszilliert stark (Runge-Phänomen).
- **Numerische Instabilität:** Hohe Potenzen von x können extrem große Einträge in X erzeugen, was $X^\top X$ schlecht konditioniert und die Inversion numerisch ungenau macht.

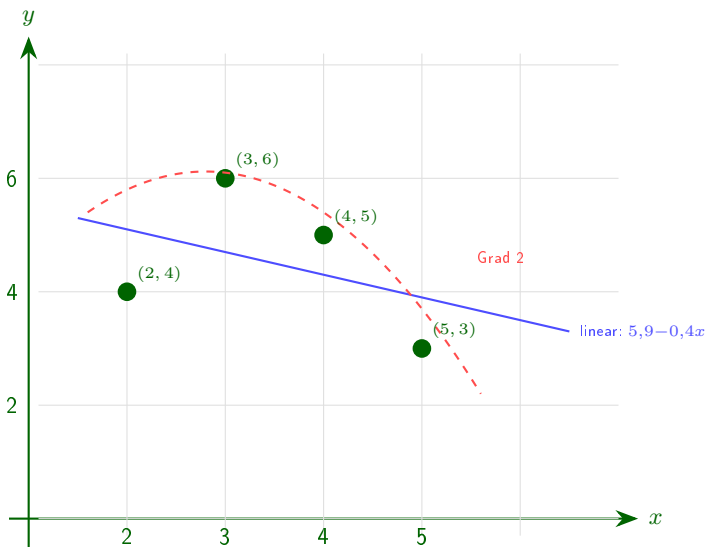

Aufgabe 6 – Wahr oder Falsch

(a) **Falsch.** Die Normalengleichung liefert nur dann eine eindeutige Lösung, wenn $X^\top X$ invertierbar ist – das ist gleichbedeutend damit, dass X vollen Spaltenrang hat. Liegt Multikollinearität vor (eine Spalte ist Linearkombination anderer Spalten), ist $X^\top X$ singulär, und die Normalengleichung hat keine eindeutige Lösung.

(b) **Falsch.** Im überbestimmten Fall ($N > K{+}1$) hat das Gleichungssystem $X\vec{c} = \vec{y}$ i. A. keine exakte Lösung – man spricht von einem inkonsistenten System. OLS liefert den Koeffizientenvektor $\vec{c}$, der den Fehler $\|\vec{y} - X\vec{c}\|_2^2$ minimiert, aber typischerweise gilt $\hat{y} \neq y$. Das Residuum $\vec{r} = \vec{y} - X\vec{c}$ ist im Allgemeinen $\neq \vec{0}$.

(c) **Wahr.** Die Moore-Penrose-Pseudoinverse $(X^\top X)^{-1}X^\top$ existiert genau dann, wenn $X^\top X$ invertierbar ist. Dies ist äquivalent dazu, dass X vollen Spaltenrang $K{+}1$ hat, also keine Spalte von X als Linearkombination der übrigen Spalten darstellbar ist. Ist diese Bedingung erfüllt, liefert die Pseudoinverse die eindeutige OLS-Lösung.

(d) **Falsch.** Der Begriff "lineare Regression" bezieht sich auf die Linearität in den *Koeffizienten* $\vec{c}$, nicht auf die Linearität in der Variablen x. Das Modell $c_0 + c_1x + c_2x^2$ ist linear in c_0, c_1, c_2, daher handelt es sich weiterhin um eine lineare Regression. Die Variable x^2 wird einfach als neue Feature-Variable behandelt.

(e) **Wahr.** Sind zwei Spalten der Designmatrix identisch, so sind sie linear abhängig, und X hat keinen vollen Spaltenrang. Damit gilt $\det(X^\top X) = 0$ – die Matrix $X^\top X$ ist singulär und nicht invertierbar. Dies ist der klassische Fall perfekter Multikollinearität; die Normalengleichung hat unendlich viele Lösungen.

(f) **Wahr.** Das SSE ist definiert als $\mathrm{SSE} = \sum_{j=1}^{N}(y_j - \hat{y}_j)^2$. Da jeder Summand ein quadratischer Term $(y_j - \hat{y}_j)^2 \geq 0$ ist, ist die Summe stets nicht-negativ. SSE = 0 ist nur möglich, wenn *alle* Residuen null sind, das Modell also alle Punkte exakt trifft.

Kriterium	$N < K{+}1$	$N = K{+}1$	$N > K{+}1$	**Anmerkung**
LGS-Typ	unterbestimmt	quadratisch	überbestimmt	Regelfall in der Praxis: $N \gg K$
Lösungsmethode	∞ Lösungen	$\vec{c} = X^{-1}\vec{y}$	OLS: Normalengleichung	NGL: $(X^\top X)\vec{c} = X^\top \vec{y}$
SSE	0 (eine davon)	0	> 0 (i. A.)	Exakter Fit nur für $N \leq K{+}1$
Rang-Bedingung	nicht eindeutig	$\det(X) \neq 0$	X voll-spalten-rangig	Multikollinearität vermeiden
Typischer Einsatz	vermeiden	2 Punkte / 1 Var.	jede echte Regression	Polynomielle Reg., Multiple Reg.

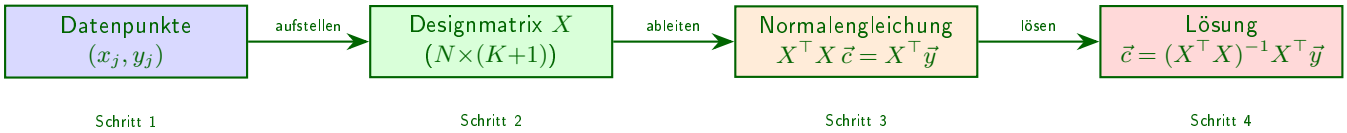

Aufgabe 7 – Effiziente Berechnung der Regression

(a) **Weg 1 – Explizite Invertierung:** Zuerst wird $(X^\top X)^{-1}$ berechnet, dann die Matrixmultiplikation $(X^\top X)^{-1} \cdot X^\top \vec{y}$ ausgeführt.

Weg 2 – Direktes LGS-Lösen: Die Normalengleichung $X^\top X\,\vec{c} = X^\top \vec{y}$ wird als LGS behandelt und direkt gelöst (z. B. via LU-Zerlegung), ohne $(X^\top X)^{-1}$ explizit zu berechnen.

Weg 2 ist effizienter, weil die explizite Matrixinversion $\mathcal{O}(n^3)$ Operationen erfordert und anschließend noch eine Multiplikation nötig ist. Das direkte Lösen via LU-Zerlegung (Vorwärts- und Rückwärtssubstitution) spart die Inversionsschritte und ist zudem numerisch stabiler, da weniger Rundungsfehler akkumuliert werden.

(b) Die fünf Verfahren, geordnet nach **numerischer Stabilität** (am wenigsten stabil zuerst):

1. **Explizite Inverse** – am anfälligsten für Rundungsfehler
2. **LU-Zerlegung** – Standard-LGS-Löser, stabiler als Invertierung
3. **Cholesky/LDL** – nutzt die symmetrische, positiv definite Struktur von $X^\top X$; schneller als LU, aber nur anwendbar wenn $X^\top X$ positiv definit ist
4. **QR-Zerlegung** – zerlegt $X = QR$ direkt (umgeht $X^\top X$); numerisch deutlich stabiler, da die Konditionszahl nicht quadriert wird
5. **SVD** – $X = U\Sigma V^T$; numerisch am stabilsten, erkennt Rangdefekte automatisch

(c) Die Konditionszahl $\kappa(A) = \|A\| \cdot \|A^{-1}\|$ misst, wie stark sich kleine Eingabefehler auf das Ergebnis auswirken. Bei der expliziten Berechnung von $(X^\top X)^{-1}$ gilt: $\kappa(X^\top X) = \kappa(X)^2$. Das bedeutet, dass die Konditionszahl *quadriert* wird – aus einer moderaten Konditionszahl von z. B. 10^4 wird 10^8. Bei Gleitkommazahlen mit ca. 16 signifikanten Stellen (double precision) bleiben dann nur noch $16 - 8 = 8$ korrekte Stellen übrig. Im Extremfall kann das Ergebnis vollständig unbrauchbar werden. Direkte LGS-Löser und insbesondere QR/SVD vermeiden dieses Problem, da sie $X^\top X$ gar nicht erst bilden müssen.

(d) Vergleichstabelle:

Verfahren	**Geschwindigkeit**	**Stabilität**	**Anwendungsfall**
Explizite Inverse	langsam	gering	Nur wenn A^{-1} mehrfach benötigt; in der Praxis vermeiden
LU-Zerlegung	schnell	mittel	Standard-LGS-Löser; gut für einzelne rechte Seiten
Cholesky/LDL	sehr schnell	mittel–hoch	Wenn $X^\top X$ positiv definit; ca. doppelt so schnell wie LU
QR-Zerlegung	mittel	hoch	arbeitet direkt auf X, nicht auf $X^\top X$
SVD	langsam	sehr hoch	Rangdefekte, schlecht konditionierte Systeme, PCA