

Grundbegriffe der Optimierung

- **unimodal:** nur ein Optimum
- **multi-modal:** mehrere Optima (lokale und globale)
- **lokaler Algorithmus:** löst nur unimodale Probleme
- **globaler Algorithmus:** löst auch multimodale Probleme

$$\text{lokal: } \arg \min_{x \in N(x_0)} f \quad \text{global: } \arg \min_{x \in \Omega} f$$

$N(x_0)$ Umgebung, Ω ganzer Suchraum. Bei konvexen Problemen: lokal = global.

Modellierung

$\min_{\vec{x}} f(\vec{x})$ unter $h_k(\vec{x}) = 0$, $g_j(\vec{x}) \leq 0$, $x_i^l \leq x_i \leq x_i^u$

- Entscheidungsvariablen (mit Einheit!)
- Zielfunktion f : was wird minimiert oder maximiert?
- Nebenbedingungen: Gleichungen h , Ungleichungen g , Grenzen

Linear genau dann, wenn f und alle Nebenbedingungen linear in $\vec{x}$ sind (kein $\sqrt{\cdot}$, x^2 , $\sin$, $x_i x_j$).

Lineare Optimierung: Standardform

Solver verlangen eine einheitliche Form:

- nur Minimierung
- nur Gleichheits-Nebenbedingungen
- nur nicht-negative Variablen ($x_i \geq 0$)
- rechte Seite stets positiv ($b_j \geq 0$)

$$\min_{\vec{x}} \vec{c}^\top \vec{x} \quad \text{unter} \quad A\vec{x} = \vec{b}, \quad \vec{x} \geq 0$$

Ungleichung $\rightarrow$ Gleichung über Slackvariablen.

Simplex-Algorithmus

- Start an einem Eckpunkt des zulässigen Bereichs
- entlang der Kante mit der größten Verbesserung zum nächsten Eckpunkt gehen
- beenden, wenn keine Verbesserung mehr möglich

Im Kern wiederholtes Lösen linearer Gleichungssysteme (Gauß); Optimum liegt in einem Eckpunkt.

Ganzzahlige lineare Optimierung

Variablen müssen ganzzahlig sein ($\vec{x} \in \mathbb{Z}^n$).

- **naiv:** kontinuierlich lösen, dann auf nächste zulässige ganze Zahl runden (nicht immer optimal)
- **Schnittebenenverfahren:** (1) kontinuierlich lösen; (2) ganzzahlig? dann fertig; (3) sonst einen Schnitt hinzufügen, der die nicht-ganzzahlige Lösung ausschließt, alle ganzzahligen aber erlaubt; (4) wiederholen

Grafische Lösung (2 Variablen)

Linear

- Nebenbedingungen als Geraden $\Rightarrow$ zulässiger Bereich (Schnitt der Halbebenen)
- Isolinien von f verschieben, Optimum meist in einer Ecke

Nichtlinear

Zulässig sind die Punkte, die alle Nebenbedingungen erfüllen (bei Gleichungs-Nebenbedingungen: **Schnittpunkte** der Kurven *innerhalb* der Grenzen). Davon den mit bestem Wert von f wählen; $\vec{x}$ und $f(\vec{x})$ ablesen.

Slackvariable $s_j \geq 0$

$$g_j(\vec{x}) + s_j = b_j$$

aktive Nebenbedingung (Gerade berührt) $\Rightarrow s_j = 0$; **inaktiv** $\Rightarrow s_j > 0$.

Klassisches Transportproblem

m Werke (Angebot a_i) $\rightarrow$ n Läden (Nachfrage b_j), Kosten c_{ij} , Mengen $x_{ij} \geq 0$.

- **zulässig:** Zeilensumme = a_i , Spaltensumme = b_j
- **klassisch/balanciert:** $\sum a_i = \sum b_j$
- Kosten = $\sum_{i,j} c_{ij} x_{ij}$

Startlösung

- **Nord-West-Ecken-Regel:** nordwestlichste leere Zelle mit Minimum aus Angebot und Nachfrage füllen; Angebot/Nachfrage verringern; wiederholen (*ignoriert Kosten*)
- **Matrixminimum-Methode:** immer die Zelle mit den geringsten Kosten zuerst füllen (*meist günstiger*)
- **Vogel-Methode:** pro Zeile/Spalte Opportunitätskosten (zweitkleinste – kleinste Kosten); höchste wählen, dort günstigste Zelle füllen

Optimale Lösung

Verbesserung der Startlösung über **Stepping-Stone** oder **MODI**.

Stationäre Punkte & Hesse

Notwendig

$$\nabla f(\vec{x}) = \vec{0} \Rightarrow \text{stationäre Punkte}$$

Hinreichend ($H = \nabla^2 f$ im Punkt)

- H positiv definit $\Rightarrow$ Minimum
- H negativ definit $\Rightarrow$ Maximum
- H indefinit $\Rightarrow$ Sattelpunkt
- semidefinit $\Rightarrow$ unentscheidbar

Bei einer 2×2 -Matrix: positiv definit $\Leftrightarrow H_{11} > 0$ und $\det H > 0$; negativ definit $\Leftrightarrow H_{11} < 0$ und $\det H > 0$; indefinit $\Leftrightarrow \det H < 0$.

Gradientenverfahren

$$\vec{x}_{k+1} = \vec{x}_k - \eta \nabla f(\vec{x}_k), \quad \eta > 0$$

η zu groß $\rightarrow$ Divergenz, zu klein $\rightarrow$ langsam. Findet nur **lokales Min**, braucht Gradient.

Lagrange & Karush-Kuhn-Tucker

Minimiere f unter $h(\vec{x}) = 0$ (Multiplikator a) und $g(\vec{x}) \leq 0$ (Multiplikator b):

$$L(\vec{x}, a, b) = f(\vec{x}) + a h(\vec{x}) + b g(\vec{x})$$

Bedingungen:

- Stationarität: $\nabla_{\vec{x}} L = \vec{0}$
- Zulässigkeit: $h = 0$, $g \leq 0$
- Komplementärschlupf: $b \cdot g(\vec{x}) = 0$
- Vorzeichen: $b \geq 0$ (Minimierung mit $g \leq 0$)

Quadratische Optimierung

Quadratische Zielfunktion, lineare Nebenbedingungen:

$$\min_{\vec{x}} \frac{1}{2} \vec{x}^\top Q \vec{x} + \vec{c}^\top \vec{x} \quad \text{unter} \quad A\vec{x} \leq \vec{b}, \quad A_{eq}\vec{x} = \vec{b}_{eq}$$

- Q symmetrisch ($Q = Q^\top$)
 - Q positiv definit $\Rightarrow$ konvex, eindeutige Lösung
- Verfahren: Innere-Punkte, konjugierter Gradient, Simplex-Varianten, erweiterte Lagrange-Methode.

Sequentielle quadratische Optimierung

Für nichtlineare Probleme mit Nebenbedingungen: in jeder Iteration eine **quadratische Näherung** lösen.

$$\min_{\vec{d}} f(\vec{x}_i) + \nabla f(\vec{x}_i)^\top \vec{d} + \frac{1}{2} \vec{d}^\top H \vec{d}$$

H = Hesse-Matrix der Lagrange-Funktion (oft genähert, BFGS).

- Lösung des Teilproblems liefert Suchrichtung $\vec{d}$
- Schrittweite $c > 0$ per Liniensuche
- $\vec{x}_{i+1} = \vec{x}_i + c \vec{d}$, bis Konvergenz

lokal, gradientenbasiert, deterministisch, behandelt Nebenbedingungen.

Nelder-Mead (Simplex)

Gradientenfreies Verfahren. Simplex aus $n+1$ Punkten, sortiert von x_0 (bestes) bis x_n (schlechtestes).

$$x_c = \frac{1}{n} \sum_{i \neq n} x_i, \quad x_r = x_c + \alpha(x_c - x_n)$$

- $f(x_r) < f(x_0)$ (*neuer Bester*) $\Rightarrow$ **Expansion**
- $f(x_0) \leq f(x_r) < f(x_{n-1}) \Rightarrow x_r$ übernehmen
- $f(x_r) \geq f(x_{n-1}) \Rightarrow$ **Kontraktion**
- sonst $\Rightarrow$ **Schrumpfen** (zu x_0)

lokal; für multimodale Probleme mit wiederholten Neustarts global machen.

DIRECT (Diving RECTangles)

Global, gradientenfrei, deterministisch; nur Grenzen (Box). Je Iteration:

- Menge der **potentiell optimalen** Rechtecke bestimmen (*auf der konvexen Hülle aus Größe gegen Güte*)
 - jedes davon **abtasten und dritteln** (größte Dimension teilen)
 - wiederholen bis zur maximalen Iterationszahl
- Größe d_i = Abstand Mittelpunkt $\rightarrow$ Ecke, Güte = f im Mittelpunkt.

Evolutionäre Algorithmen

Population von Lösungskandidaten; pro Generation: Eltern auswählen $\rightarrow$ rekombinieren $\rightarrow$ mutieren $\rightarrow$ auswerten $\rightarrow$ Überlebende auswählen.

- **Mutation:** kleine zufällige Änderung, etwa $\vec{x} + \vec{\epsilon}$ mit $\vec{\epsilon} \sim N(0, \sigma)$; bei Bitstrings ein Bit kippen
- **Rekombination:** z. B. Mittelwert $(\vec{x}_1 + \vec{x}_2)/2$ oder Crossover
- **Fitness** = Zielfunktion $f(\vec{x})$

stochastisch, gradientenfrei, lokal (kleine Mutationen) und global (Population). Hyperparameter: Populationsgröße, Mutationsrate und -schrittweite.

(1+1)-Evolutionstrategie (1/5-Erfolgsregel)

Der Elternpunkt wird mutiert; die bessere Lösung überlebt. **Erfolg** (bei Minimierung): $f(x_{\text{next}}) < f(x)$. Erfolgsrate p über das Fenster (Speicherlänge), Zielrate $1/5$:

- $p > 1/5 \Rightarrow \sigma \leftarrow \sigma \cdot \alpha$ (vergrößern)
- $p < 1/5 \Rightarrow \sigma \leftarrow \sigma / \alpha$ (verkleinern)
- $p = 1/5 \Rightarrow \sigma$ unverändert

Rate einschließlich aktuellem Schritt: Erfolge geteilt durch Fensterlänge.

CMA-ES

Covariance Matrix Adaptation Evolution Strategy: Evolutionsstrategie, die eine fortlaufend angepasste **Kovarianzmatrix** verwendet, um die ideale Verteilung der Individuen im Suchraum anzunähern. Stand der Technik für kontinuierliche Optimierung; global bei ausnutzbarer globaler Struktur, sonst Neustarts oder große Population.

Simulated Annealing

Inspiriert vom Abkühlen von Metall: hohe Temperatur $\rightarrow$ viele zufällige Änderungen, langsames Abkühlen $\rightarrow$ immer kleinere Änderungen.

Verschlechterung Δf akzeptiert mit $\exp\left(-\frac{\Delta f}{T}\right)$, T

erlaubt das Verlassen lokaler Optima.

Particle Swarm Optimization

Inspiriert von Schwärmen (Vögel, Insekten). Jedes Teilchen ist ein Lösungskandidat; gute Lösungen beeinflussen, wohin sich schlechtere

Ant Colony Optimization

Schwarm-Verfahren: Ameisen hinterlassen Pheromone auf ihrem Weg und folgen stärkeren Spuren wahrscheinlicher; kurze Wege erhalten mehr Pheromone. typisch für Routing-Probleme.

Surrogatmodell-basierte Optimierung

Für teure Zielfunktionen: ein günstiges Surrogatmodell (Modell aus maschinellem Lernen) ersetzt die teure Auswertung.

- Startpunkte auswerten (Versuchsplanung)
- Surrogatmodell anpassen
- auf dem Modell vielversprechenden nächsten Punkt wählen
- dort echte Zielfunktion auswerten, Modell aktualisieren, wiederholen

Mehrzieloptimierung

Dominanz (alle Ziele minimieren)
P dominiert Q: $P \leq Q$ in allen Zielen und $<$ in mindestens einem.

- Pareto-optimal: von keinem Punkt dominiert
- Pareto-Menge: alle Pareto-optimalen Punkte; ihr Bild im Zielraum = Pareto-Front
- Non-Dominated-Sorting: Rang 1 = alle nicht dominierten; diese entfernen, im Rest erneut die nicht dominierten = Rang 2, und so weiter

Crowding Distance

Maß für die Diversität innerhalb einer Front. Pro Zielfunktion:

- Punkte nach dieser Zielfunktion sortieren
- Randpunkte (kleinster und größter Wert): Distanz = ∞
- innere Punkte i :

Distanz += $\frac{f_{i+1} - f_{i-1}}{f_{\max} - f_{\min}}$

f_{i-1}, f_{i+1} = Werte des linken und rechten Nachbarn. Über alle Zielfunktionen summieren; große Distanz wird bevorzugt.

NSGA-II

Evolutionärer Algorithmus für mehrere Ziele; Auswahl über Rang und Crowding Distance:

- initiale Population
- Eltern wählen (Rang, dann Crowding Distance)
- rekombinieren, mutieren
- Überlebende der nächsten Generation wählen (Rang, dann Crowding Distance)
- wiederholen

Hypervolumen

Vom Rand (Referenzpunkt) bis zur Front „überdecktes“ Volumen; größer = bessere Front. Der Hypervolumenbeitrag eines Punktes ist sein Anteil daran (Randpunkte oft ∞) — alternativer Tie-Break zur Crowding Distance.

Eigenschaften der Optimierungsmethoden

Methode	Global	Gradienten- basiert	Neben- bedingungen	Ziele	Linear	Ansatz	Genauigkeit	Determi- nistisch	Variablen
Stationäre Punkte / Hesse-Matrix	✓	✓	ohne	1	×	analytisch	exakt	✓	$\mathbb{R}^n$
Gradientenverfahren	×	✓	ohne	1	×	numerisch	?	✓	$\mathbb{R}^n$
Simplex (lineare Optimierung)	×	✓	alle	1	✓	numerisch	exakt	✓	$\mathbb{R}^n, \mathbb{Z}^n$
Quadratische Optimierung	×	✓	alle	1	teilweise	numerisch	?	✓	$\mathbb{R}^n$
Karush-Kuhn-Tucker	✓	✓	alle	1	×	analytisch	exakt	✓	$\mathbb{R}^n$
Sequentielle quadratische Optimierung	×	✓	alle	1	×	numerisch	?	✓	$\mathbb{R}^n$
Nelder-Mead	×	×	ohne	1	×	numerisch	näherungsweise	✓	$\mathbb{R}^n$
DIRECT	✓	×	Grenzen	1	×	numerisch	näherungsweise	✓	$\mathbb{R}^n$
Evolutionäre Algorithmen	✓ (?)	×	/	/	×	numerisch	näherungsweise	×	/
(1+1)- Evolutionsstrategie	×	×	ohne	1	×	numerisch	näherungsweise	×	$\mathbb{R}^n$
CMA-ES	✓ (?)	×	ohne	1	×	numerisch	näherungsweise	×	$\mathbb{R}^n$
Simulated Annealing	✓	×	ohne	1	×	numerisch	näherungsweise	×	$\mathbb{R}^n, \mathbb{Z}^n$
Particle Swarm Optimization	✓	×	ohne	1	×	numerisch	näherungsweise	×	$\mathbb{R}^n$
Ant Colony Optimization	✓	×	ohne	1	×	numerisch	näherungsweise	×	$\mathbb{Z}^n$
Surrogatmodell- basierte Optimierung	✓ (?)	×	/	/	×	numerisch	näherungsweise	/	/
NSGA-II	✓	×	ohne	mehrere	×	numerisch	näherungsweise	×	$\mathbb{R}^n$

✓ = ja × = nein (?) = abhängig von Problem und Parametern „teilweise“ = linear nur in den Nebenbedingungen „/“ = nicht festgelegt