

Fortgeschrittene Stochastik & Statistik (WDS224 · BLD)

Quelle: WDS224 - Fortgeschrittene Statistik (BLD).zip **Dozent/Autor/Illustration:** Prof. Dr. Daniel Blochinger · Zentrum für Angewandte Ökonomik (ZAÖ) der DHBW Ravensburg **Stand des Foliensatzes:** 10. Juni 2026 · **Lizenz:** CC BY-NC-SA 4.0 **Materialien:** Foliensatz (226 Folien), Tafelaufschriebe (handschriftlich, nur Bildscans), Übungsklausur + Lösung, Code und Datensätze.zip (R/Python-Notebooks zu ANOVA, Chi-Quadrat, Normalität, Regression-OLS, Regression-Herausforderungen, T-Test, Verteilungen, Z-Test, Mensa-Aufgaben)

KLAUSUR (Übungsklausur = Blaupause)

Modul	W4DSKI_206 Stochastik · Veranstaltung W4DSKI_206.2 Fortgeschrittene Stochastik und Statistik
Bearbeitungszeit	60 Minuten
Max. Punktzahl	50 Punkte
Hilfsmittel	★ Alle gedruckten oder handschriftlichen Unterlagen auf Papier + nicht programmierbarer Taschenrechner

Punkteverteilung der Übungsklausur:

Aufgabe	Thema	Punkte
A1	Zufallsvariablen, Verteilungen & Z-Test	13
A2	Statistische Modellierung mit Verteilungen	7
A3	Statistische Tests	12
A4	Regressionsanalyse	13
A5	Gemischtes (Richtig/Falsch)	5
	Gesamt	50

Inhaltsverzeichnis (Foliennummern)

Kapitel	Folien	Kapitel	Folien
Zufallsvariablen & Verteilungen	4 – 21	Test auf Normalität	130 – 142
Momente von Zufallsvariablen	22 – 44	Die Chi-Quadrat-Testfamilie	143 – 154
Ausgewählte Verteilungen	45 – 69	Lineare Regression & OLS-Schätzung	155 – 182
Zentraler Grenzwertsatz	70 – 76	Herausforderungen bei Regression	183 – 215
Gauss-Test (Z-Test)	77 – 92	Maximum-Likelihood-Schätzung	216 – 226
Induktive Statistik am Beispiel t-Test	93 – 125		
ANOVA als erweiterter t-Test	126 – 129		

TEIL 1 — ZUFALLSVARIABLEN & VERTEILUNGEN

1. ★★ Zufallsvariablen

Definition: Zufallsvariablen sind Abbildungsvorschriften, die jedem Ereignis der Ereignismenge Ω eine reelle Zahl zuweisen.

$$X: \Omega \rightarrow \mathbb{R} \quad \text{mit } E \subseteq \mathbb{R}$$

Zufallsvariablen sind **mathematische Funktionen**, deren Definitionsbereich eine Ereignismenge ist.

Die zwei Fälle:

- **Sind die Ereignisse bereits reelle Zahlen** (z.B. Würfel), kann der zugewiesene Wert einfach das Ereignis sein: $X: \{1, 2, 3, 4, 5, 6\} \rightarrow \{1, 2, 3, 4, 5, 6\}$
- **Ist dies nicht der Fall** (z.B. Münze), müssen wir uns eine Vorschrift überlegen: $X: \{\text{Kopf}, \text{Zahl}\} \rightarrow \{0, 1\}$

Standardbeispiele im Kurs:

Ω	Beispiel	Typ
$\{1, 2, 3, 4, 5, 6\}$	Würfel	DISKRET
$\{\text{Kopf}, \text{Zahl}\}$	Münze	DISKRET
$\{00, 0, 1, 2, \dots, 36\}$	amerikanisches Roulette	DISKRET
$(0, 1)$	Zufallsgenerator	KONTINUIERLICH

2. ★★ Wahrscheinlichkeitsmaß und Kolmogorov-Axiome

Ein **Wahrscheinlichkeitsmaß** ist eine Abbildung, die jedem Element aus E eine Zahl von 0 bis 1 zuordnet:

$$p(X): E \rightarrow [0, 1]$$

★ Die drei Kolmogorov-Axiome

#	Axiom	Bedeutung
1	$P(X=x) \in [0, 1] \quad \forall x \in E$	Wahrscheinlichkeiten liegen zwischen 0 und 1
2	$P(X \in E) = 1$	Die Gesamtwahrscheinlichkeit über alle Ereignisse ist 1
3	$P(X=x_1 \vee X=x_2) = P(X=x_1) + P(X=x_2) \quad \text{mit } x_1 \neq x_2$	Additivität disjunkter Ereignisse

3. ★★ Die vier definierenden Funktionen

Über die Ereignismenge und die Wahrscheinlichkeiten der enthaltenen Ereignisse entscheidet die **Verteilung**.

	Wkt. dass $ZV \leq x$	Wkt. dass $ZV = x$
diskret	Verteilungsfunktion $F(x)$	Wahrscheinlichkeitsfunktion $f(x)$
kontinuierlich	Verteilungsfunktion $F(x)$	Dichtefunktion $\phi(x)$

- **Diskrete Verteilungen** besitzen **endlich oder abzählbar unendlich** viele Ereignisse.
- **Kontinuierliche Verteilungen** besitzen **nicht abzählbar unendlich** viele Ereignisse.

3.1 ★ Verteilungsfunktion $F(x)$

$$F(x) = P(X \leq x)$$

Eigenschaften:

- $F(x) \in [0, 1] \quad \forall x \in E$
- **$F(x)$ monoton steigend in E**
- $\lim_{x \rightarrow -\infty} F(x) = 0 \quad \lim_{x \rightarrow +\infty} F(x) = 1$

 **Beispiel Würfel:**

$$F(x) = \begin{cases} 0 & x < 0 \\ 1/6 \cdot \lfloor x \rfloor & 0 \leq x \leq 6 \\ 1 & x > 6 \end{cases}$$

Beim Würfel ist dies eine **Treppe**, die bei jeder ganzen Zahl um **1/6 nach oben** geht, bis sie die 1 erreicht.

 **Abrundungsfunktion** $\lfloor x \rfloor$ bzw. `floor(x)` gibt die nächstkleinere ganze Zahl an. Pendant: **Aufrundungsfunktion** $\lceil x \rceil$ bzw. `ceil(x)`.

3.2 ★ Wahrscheinlichkeitsfunktion $f(x)$ (nur diskret)

$$f(x) = P(X = x)$$

Eigenschaften: $f(x) \in [0, 1] \quad \forall x \in E$ und $\sum_{x \in E} f(x) = 1$

 **Beispiel Würfel:**

$$f(x) = \begin{cases} 1/6 & x \in \{1, 2, 3, 4, 5, 6\} \\ 0 & \text{sonst} \end{cases}$$

★★★ Der Zusammenhang (diskret)

$f(x)$ — Summation —→ $F(x)$ („Sprünge“ der Treppenfunktion)

3.3 ★★★ Dichtefunktion $\phi(x)$ (nur kontinuierlich)

⚠ **Die Dichtefunktion gibt anders als die Wahrscheinlichkeitsfunktion NICHT die Wahrscheinlichkeit an, dass x genau einen bestimmten Wert hat!** Stattdessen gilt: die Wahrscheinlichkeit, dass x einen Wert **zwischen a und b** annimmt, ist:

$$P(a \leq X \leq b) = \int_a^b \phi(x) \, dx$$

Zusammenhang zur Verteilungsfunktion:

$$F(x) = \int_{-\infty}^x \phi(t) \, dt \quad (\text{Integration})$$

$$\phi(x) = F'(x) \quad (\text{Ableitung})$$

📝 **Beispiel Zufallsgenerator „0 bis 1“ (kontinuierliche Gleichverteilung):**

$$\phi(x) = \begin{cases} 1 & x \in [0, 1] \\ 0 & \text{sonst} \end{cases} \quad F(x) = \max(\min(x, 1), 0)$$

Verteilungsfunktion: ...**0** für alle Werte von x bis zur 0 · ... **x** für alle Werte zwischen 0 und 1 · ...**1** für alle Werte größer als 1

Wahrscheinlichkeit zwischen 0.2 und 0.5:

$$P(0.2 \leq X \leq 0.5) = \int_{0.2}^{0.5} \phi(x) \, dx = [x]_{0.2}^{0.5} = 0.5 - 0.2 = 0.3$$

★★★ Folgerung aus dem 2. Kolmogorov-Axiom

Die Gesamtfläche unter der Dichtefunktion muss genau 1 sein:

$$P(-\infty \leq X \leq \infty) = \int_{-\infty}^{\infty} \phi(x) \, dx = 1$$

⚠ Bei einer Gleichverteilung über **[0,2]** wäre die Höhe der Dichtefunktion daher konstant **0.5**.

TEIL 2 — MOMENTE VON ZUFALLSVARIABLEN

4. ★★ Erwartungswert $\mu = E(X)$

DISKRET (aus der Wahrscheinlichkeitsfunktion):

$$\mu = E(X) = \sum_{x \in E} x \cdot f(x)$$

KONTINUIERLICH (aus der Dichtefunktion):

$$\mu = E(X) = \int_{-\infty}^{\infty} x \cdot \varphi(x) \, dx$$

 **Beispiel Würfel:**

$$E(X) = 1 \cdot (1/6) + 2 \cdot (1/6) + 3 \cdot (1/6) + 4 \cdot (1/6) + 5 \cdot (1/6) + 6 \cdot (1/6) = 21/6 = 3.5$$

 **Beispiel Zufallsgenerator [0,1]:**

$$E(X) = \int_0^1 x \, dx = [0.5x^2]_0^1 = 0.5 \cdot 1^2 - 0.5 \cdot 0^2 = 0.5$$

★★ Linearität des Erwartungswerts

$$E(aX + bY) = a \cdot E(X) + b \cdot E(Y)$$

 **Beispiel:** Wir würfeln mit einem 6-seitigen (D6) und einem 20-seitigen (D20) Würfel und berechnen die Augensumme. Der D6 zählt **dreifach**:

$$E(3X + Y) = 3 \cdot 3.5 + 10.5 = 21$$

5. ★★ Varianz $\text{Var}(X) = \sigma^2$

DISKRET:

$$\text{Var}(X) = \sum_{x \in E} [x - E(X)]^2 \cdot f(x)$$

KONTINUIERLICH:

$$\text{Var}(X) = \int_{-\infty}^{\infty} [x - E(X)]^2 \cdot \varphi(x) \, dx$$

Standardabweichung: $\sigma_X = \sqrt{\text{Var}(X)}$

 Beispiel Würfel:

$$\begin{aligned} \text{Var}(X) = & (-2.5)^2 \cdot (1/6) + (-1.5)^2 \cdot (1/6) + (-0.5)^2 \cdot (1/6) \\ & + (0.5)^2 \cdot (1/6) + (1.5)^2 \cdot (1/6) + (2.5)^2 \cdot (1/6) = 2.91 \end{aligned}$$

 Beispiel Zufallsgenerator [0,1]:

$$\text{Var}(X) = \int_0^1 (x-0.5)^2 dx = \int_0^1 (x^2 - x + 0.25) dx = \left[\frac{1}{3}x^3 - 0.5x^2 + 0.25x \right]_0^1 = 0.08333$$

 Additivität der Varianz

Die Varianz ist **NUR** dann linear additiv, wenn die Zufallsvariablen **UNABHÄNGIG** sind. Allgemein gilt:

$$\text{Var}(aX + bY) = a^2 \cdot \text{Var}(X) + b^2 \cdot \text{Var}(Y) + 2ab \cdot \text{Cov}(X, Y)$$

 Musterbeispiel Glücksrad

*Ein Glücksrad mit 10 Feldern: **4× 0 €**, **3× 1 €**, **2× 2 €**, **1× 5 €**. X = erspielte Auszahlung.*

$$E(X) = 0 \cdot (4/10) + 1 \cdot (3/10) + 2 \cdot (2/10) + 5 \cdot (1/10) = 1.20 \text{ €}$$

$$\text{Var}(X) = (-1.2)^2 \cdot (4/10) + (-0.2)^2 \cdot (3/10) + (0.8)^2 \cdot (2/10) + (3.8)^2 \cdot (1/10) = 2.16$$

$$\sigma_X = \sqrt{2.16} = 1.47 \text{ €}$$

 Musterbeispiel Amerikanisches Roulette

$\Omega = \{00, 0, 1, 2, \dots, 36\}$. Wir setzen **10 € auf Schwarz**. Zu **47.36 %** gewinnen wir 10 € dazu, zu **52.64 %** verlieren wir 10 €.

$$E(X) = 0.4736 \cdot 10 - 0.5264 \cdot 10 = -0.528 \text{ €}$$

$$\text{Var}(X) = (10.528)^2 \cdot 0.4736 + (-9.472)^2 \cdot 0.5264 = 99.72$$

$$\sigma_X = \sqrt{99.72} = 9.985 \text{ €}$$

 **Der negative Erwartungswert ist der Hausvorteil des Casinos.**

 Musterbeispiel Zwei Zufallsgeneratoren

X gleichverteilt auf [2,3], Y gleichverteilt auf [2,4].

$$E(X) = \int_2^3 x dx = [0.5x^2]_2^3 = 0.5 \cdot 3^2 - 0.5 \cdot 2^2 = 2.5$$

$$E(Y) = \int_2^4 0.5y dy = [0.25y^2]_2^4 = 0.25 \cdot 16 - 0.25 \cdot 4 = 3$$

$$E(X+Y) = E(X) + E(Y) = 2.5 + 3 = 5.5$$

6. ★ Momente allgemein

MOMENTE (nicht-zentral):

$$m_k = E(X^k) = \sum_{x \in E} x^k \cdot f(x) \quad \text{bzw.} \quad m_k = \int_{-\infty}^{\infty} x^k \cdot \varphi(x) \, dx$$

ZENTRALE MOMENTE:

$$\mu_k = \sum_{x \in E} (x - \mu)^k \cdot f(x) \quad \text{bzw.} \quad \mu_k = \int_{-\infty}^{\infty} (x - \mu)^k \cdot \varphi(x) \, dx$$

Ordnung	Moment	Zentrales Moment
1.	Erwartungswert	0
2.	m_2	Varianz
3.	m_3	(Schiefe)
4.	m_4	(Wölbung)

Der Erwartungswert ist das wichtigste Moment, die Varianz das wichtigste zentrale Moment einer Zufallsvariable.

6.1 ★ Schiefe (3. zentrales Moment)

$$\gamma_m = \mu_3 / \sigma^3$$

Unabhängig von der Normierung gilt:

- $\gamma = 0 \Rightarrow$ Verteilung ist **symmetrisch**
- $\gamma > 0 \Rightarrow$ Verteilung ist **rechtsschief**
- $\gamma < 0 \Rightarrow$ Verteilung ist **linksschief**

6.2 ★ Wölbung / Exzess (4. zentrales Moment)

$$\gamma = \mu_4 / \sigma^4 - 3$$

Durch die **-3** wird die „Spitzigkeit“ der Verteilung **mit der der Normalverteilung** verglichen.

- $\gamma > 0 \Rightarrow$ Verteilung ist **steiler**
- $\gamma < 0 \Rightarrow$ Verteilung ist **breiter**

TEIL 3 — AUSGEWÄHLTE VERTEILUNGEN

7. ★ Übersichtstabelle (Klausur-Spickzettel)

Verteilung	Typ	Funktion	μ	σ^2
Gleichverteilung (kontinuierlich)	kont.	$\varphi(x) = 1/(b-a)$ für $x \in [a,b]$	$(a+b)/2$	$(b-a)^2/12$
Binomialverteilung	diskret	$f(k) = C(n,k) \cdot p^k (1-p)^{n-k}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Poisson-Verteilung	diskret	$f(k) = e^{-\lambda} \lambda^k / k!$	λ	λ
Exponentialverteilung	kont.	$\varphi(x) = \lambda e^{-\lambda x}$ für $x \geq 0$	$1/\lambda$	$1/\lambda^2$
Normalverteilung	kont.	$\varphi(x) = 1/\sqrt{2\pi\sigma^2} \cdot e^{-\frac{1}{2}((x-\mu)/\sigma)^2}$	μ	σ^2

8. Gleichverteilung

Kontinuierliche Variante: zwei Parameter — **Untergrenze a** und **Obergrenze b**.

$$\mu = (a+b)/2 \quad \sigma^2 = (b-a)^2/12$$

Herleitung des Erwartungswerts:

$$E(X) = \int_a^b x/(b-a) dx = [0.5x^2/(b-a)]_a^b = 0.5(b^2-a^2)/(b-a) = 0.5(a+b)$$

Herleitung der Varianz:

$$\text{Var}(X) = \int_a^b (x - 0.5(a+b))^2 \cdot 1/(b-a) dx = (b-a)^2/12$$

9. ★★ Binomialverteilung

Die Binomialverteilung beschreibt die Wahrscheinlichkeit für k aus n erfolgreichen Versuchen, wenn die Erfolgswahrscheinlichkeit eines einzelnen Versuches p ist.

$$f(k) = \binom{n}{k} p^k (1-p)^{n-k} \quad \mu = np \quad \sigma^2 = np(1-p)$$

9.1 Fakultät und Binomialkoeffizient

Fakultät — Anzahl Möglichkeiten, n verschiedene Dinge anzuordnen:

$$n! = \prod_{i=1}^n i = 1 \cdot 2 \cdot \dots \cdot n$$

Binomialkoeffizient „n über k“ — Anzahl Möglichkeiten, **k aus n** Elemente auszuwählen:

$$\binom{n}{k} = \frac{n!}{k! (n-k)!}$$

 **Beispiel:** 3 aus 5 Elfmetern, die getroffen werden:

$$C(5,3) = 120 / (6 \cdot 2) = 10 \qquad C(5,2) = 120 / (2 \cdot 6) = 10$$

  **Musterrechnung Elfmeter**

*Torchance eines Elfmeters: **75 %**. Gesucht: Chance auf **4 Treffer aus 5 Versuchen**.*

$$\begin{aligned} P &= C(5,4) \cdot P_{\text{Tor}}^4 \cdot (1-P_{\text{Tor}})^1 \\ &= 5! / (4! \cdot 1!) \cdot 0.75^4 \cdot 0.25 \\ &= 5 \cdot 0.75^4 \cdot 0.25 \\ &= 39.6 \% \end{aligned}$$

Warum der Faktor 5? Es gibt **5 mögliche Reihenfolgen**, jede mit 7.91 % Wahrscheinlichkeit:

$$\begin{array}{rcl} 0.75^4 \cdot 0.25 & = & 7.91 \% \\ 0.75^3 \cdot 0.25 \cdot 0.75 & = & 7.91 \% \\ 0.75^2 \cdot 0.25 \cdot 0.75^2 & = & 7.91 \% \\ 0.75 \cdot 0.25 \cdot 0.75^3 & = & 7.91 \% \\ 0.25 \cdot 0.75^4 & = & 7.91 \% \\ \hline & = & 39.6 \% \end{array}$$

9.2 Herleitung des Erwartungswerts $\mu = np$ (Nebenrechnung)

$$\begin{aligned} \mu &= \sum_{k=0}^n k \cdot \binom{n}{k} p^k (1-p)^{n-k} && (\text{Summand für } k=0 \text{ ist } 0) \\ & && \text{Trick: } k \cdot \binom{n}{k} = k \frac{n!}{k!(n-k)!} = \frac{n!}{(k-1)!(n-k)!} = n \cdot \binom{n-1}{k-1} \\ &= n \cdot \sum_{k=1}^n \binom{n-1}{k-1} p^k (1-p)^{n-k} && \text{Substitution } j = k-1 \\ &= np \cdot \sum_{j=0}^{n-1} \binom{n-1}{j} p^j (1-p)^{(n-1)-j} = np && (\text{Summe aller Wkt.} = 1) \end{aligned}$$

10. ★★ Poisson-Verteilung

Die Poisson-Verteilung beschreibt die Wahrscheinlichkeit von k Ereignissen pro Zeiteinheit, wenn die durchschnittliche Auftrittshäufigkeit λ pro Zeiteinheit beträgt.

$$f(k) = \frac{e^{(-\lambda)} \cdot \lambda^k}{k!} \quad \mu = \lambda \quad \sigma^2 = \lambda$$

💡 Rekursive Eigenschaft (spart Rechenzeit)

$$f(k+1) = f(k) \cdot \lambda / (k+1)$$

10.1 ★★ Zusammenhang zur Binomialverteilung

Beide Verteilungen beschreiben die Wahrscheinlichkeiten einer bestimmten Anzahl an „Erfolgen“. Anstelle eines **Limits an Versuchen** gibt es einen **begrenzten Zeitraum**, in dem die Erfolge eintreten sollen.

Mathematisch entspricht das der Grenzwertbetrachtung:

$$\lim_{n \rightarrow \infty} \binom{n}{k} p^k (1-p)^{n-k} = \frac{e^{(-\lambda)} \lambda^k}{k!} \quad \text{mit } p = \frac{\lambda}{n}$$

Beweisskizze (Kernschritte):

1. $n! / (n-k)!$ durch n^k kürzen $\rightarrow (n/n) \cdot ((n-1)/n) \cdots ((n-k+1)/n) \rightarrow 1$
2. $(1-\lambda/n)^{n-k}$ splitten in $(1-\lambda/n)^n \cdot (1-\lambda/n)^{-k}$
3. $(1-\lambda/n)^n \rightarrow e^{(-\lambda)}$ und $(1-\lambda/n)^{-k} \rightarrow 1$

Kursbeispiel: Wahrscheinlichkeit für n IT-Probleme in einer Stunde, wenn es an der DHBW RV **im Schnitt zu 1.5 IT-Problemen pro Stunde** kommt.

11. ★★ Exponentialverteilung

Die Exponentialverteilung beschreibt die Wahrscheinlichkeit von einer **PAUSE ZWISCHEN ZWEI EREIGNISSEN**, wenn die durchschnittliche Auftrittshäufigkeit eines Ereignisses λ pro Zeiteinheit ist. ★ Sie ist eng verwandt mit der Poisson-Verteilung.

$$\varphi(x) = \begin{cases} \lambda e^{(-\lambda x)} & x \geq 0 \\ 0 & x < 0 \end{cases} \quad F(x) = 1 - e^{(-\lambda x)}$$

$$\mu = 1/\lambda \quad \sigma^2 = 1/\lambda^2$$

Herleitung der Verteilungsfunktion:

$$F(x) = \int_0^x \lambda e^{(-\lambda t)} dt = [-e^{(-\lambda t)}]_0^x = -e^{(-\lambda x)} - (-1) = 1 - e^{(-\lambda x)}$$

Herleitung des Erwartungswerts (partielle Integration):

$$\mu = \int_0^{\infty} x \cdot \lambda e^{(-\lambda x)} dx = [-e^{(-\lambda x)} \cdot x]_0^{\infty} - \int_0^{\infty} -e^{(-\lambda x)} dx = [-\frac{1}{\lambda} e^{(-\lambda x)}]_0^{\infty} = 1/\lambda$$

11.1 ★★ Gedächtnislosigkeit (klausurrelevante Interpretation!)

$$P(X \geq x+t \mid X \geq x) = P(X \geq t)$$

- Eine Roulettekugel landet nicht auf Rot, weil sie in den letzten 3 Spins auf Schwarz gelandet ist.
- Ein IT-Problem wird nicht wahrscheinlicher, weil es schon länger keinen Anruf mehr bei der IT.S gab.

Beweis:

$$P(X \geq x) = 1 - P(X \leq x) = 1 - (1 - e^{(-\lambda x)}) = e^{(-\lambda x)}$$

$$P(X \geq x+t \mid X \geq x) = \frac{P(A \cap B)}{P(B)} = \frac{e^{(-\lambda(x+t))}}{e^{(-\lambda x)}} = \frac{e^{(-\lambda x)} \cdot e^{(-\lambda t)}}{e^{(-\lambda x)}} = e^{(-\lambda t)} = P(X \geq t) \quad \checkmark$$

12. ★★ Normalverteilung

Die Normalverteilung ist die wichtigste Verteilung der Statistik. Mit Erwartungswert μ und Varianz σ^2 schreiben wir $N(\mu, \sigma^2)$:

$$\varphi(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{1}{2}((x-\mu)/\sigma)^2}$$

$$\Phi(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \int_{-\infty}^x e^{-\frac{1}{2}((t-\mu)/\sigma)^2} dt$$

Warum heißt sie „normal“?

1. Es gibt **viele Merkmale in der Natur**, deren Verteilung gut zu dieser Normalverteilung passt.
2. Es gibt einen **interessanten Zusammenhang zwischen der Normalverteilung und vielen anderen Verteilungen** → **Zentraler Grenzwertsatz**.

TEIL 4 — ZENTRALER GRENZWERTSATZ (ZGS)

13. ★★ Motivation: Zwei Würfel

Wir werfen zwei 6-seitige Würfel und definieren X als Summe der Augenzahlen $X_1 + X_2$. Die einzelnen Augenzahlen sind gleichverteilt mit $\mu = 3.5$ und $\sigma^2 = 2.91$.

Frage: Ist X dann gleichverteilt mit Erwartungswert 7 und Varianz 5.82? ⚠ NEIN! Die Werte für Erwartungswert und Varianz sind zwar richtig, **aber X ist nicht mehr gleichverteilt! Die mittlere 7 wird zum wahrscheinlichsten Ergebnis, während besonders kleine/große Augensummen sehr selten sind** — es entsteht eine dreiecks-/glockenähnliche Form.

14. ★★ Der Zentrale Grenzwertsatz

Seien $X_1, X_2, \dots, X_n$ **identisch verteilte und unabhängige** Zufallsvariablen mit Erwartungswert μ und Varianz σ^2 . **Für große n ist die Summe der Zufallsvariablen normalverteilt.** Im Grenzwert für $n \rightarrow \infty$ gilt:

$$\lim_{n \rightarrow \infty} P(\bar{X}_n \leq x) = \Phi(z)$$

★★ Die zwei Formen (KLAUSURFORMELN!)

$$\text{SUMME: } X = \sum_{i=1}^n x_i \sim N(n \cdot \mu, n \cdot \sigma^2)$$

$$\text{MITTELWERT: } \bar{X} = 1/n \sum_{i=1}^n x_i \sim N(\mu, \sigma^2/n)$$

⚠ ★★ Faustregel für „großes n “


Der Grenzwert gegen unendlich vermittelt den Eindruck, dass mit einem großen n eine Zahl in den Tausendern oder Millionen gemeint ist. **Als Faustregel werden aber oft 30 Beobachtungen genannt — bzw. 100, falls die Verteilung der einzelnen Zufallsvariablen schwierig ist (z.B. bimodal, multimodal oder sehr schief).**

15. ★★ Die Sigma-Regeln (auswendig!)

Innerhalb ... Standardabweichungen um μ	Anteil
1 σ	68.2 %
2 σ	95.4 %
3 σ	99.6 %

Anteil	... Standardabweichungen
90.0 %	1.64 σ
95.0 %	1.96 σ ★
99.0 %	2.32 σ
99.9 %	3.09 σ

Flächenaufteilung der NV (Standard-Grafik):



TEIL 5 — INDUKTIVE STATISTIK & Z-TEST

16. ★ Induktive Statistik

In der induktiven Statistik schließen wir von einer **STICHPROBE** auf die zugrunde liegende **VERTEILUNG** bzw. **GRUNDGESAMTHEIT**. Dabei werden **statistische Tests** angewendet, um **Hypothesenpaare** zu untersuchen. (Abgrenzung zu: **Deskriptive Statistik** und **Kombinatorik**)

17. ★★ Der Z-Test (Gauss-Test)

✎ ★★ Musterbeispiel Würfel (40 Würfe)

Wir würfeln 40-mal und erhalten die Augensumme 128 bzw. eine **durchschnittliche Augenzahl von 3.2**. Wir wissen: jede einzelne Augenzahl X_i ist gleichverteilt mit $\mu = 3.5$ und $\sigma^2 = 2.91$.

Schritt 1 — Verteilung des Stichprobenmittelwerts (per ZGS):

$$\mu = 3.5 \quad \sigma^2_{\bar{X}} = \sigma^2/n = 2.91/40 = 0.07275$$

Schritt 2 — Hypothesenpaar aufstellen (LINKSSEITIG/einseitig):

Nullhypothese H_0 : Der Würfel zeigt durchschnittlich 3.5 Augen. **Alternativhypothese H_1 :** Der Würfel zeigt durchschnittlich **weniger als 3.5** Augen.

Schritt 3 — Standardabweichung und z-Wert:

$$\sigma_{\bar{X}} = \sqrt{0.07275} = 0.270$$

$$z = \frac{\bar{x} - \mu}{\sigma_{\bar{X}}} = \frac{3.2 - 3.5}{0.270} = -1.112$$

Unsere Stichprobe liegt **1.11 Standardabweichungen unter dem Erwartungswert**.

Schritt 4 — p-Wert aus der Verteilungsfunktion:

$$p = \Phi(z) = \int_{-\infty}^{-1.112} \varphi(x) dx = 0.133 = 13.3 \%$$

Excel: =NORM.VERT(3,2;3,5;0,270;WAHR) = 13.3 %

Schritt 5 — Interpretation:

★ „Wäre die Nullhypothese wahr, würden wir bei der gegebenen Stichprobengröße mit Wahrscheinlichkeit von 13.3 % eine Abweichung von mindestens 0.3 Augen nach unten erhalten.“ Erst wenn diese Wahrscheinlichkeit **kleiner als 5 %** ist, lehnen wir die Nullhypothese ab. Hier ist der p-Wert über der kritischen Schwelle ⇒ wir **BEHALTEN** die Nullhypothese bei.

18. ★★ Einseitig vs. Zweiseitig

	Einseitig (hier: linksseitig)	Zweiseitig
H_0	Der Würfel zeigt im Durchschnitt 3.5 Augen.	Der Würfel zeigt im Durchschnitt 3.5 Augen.
H_1	Der Würfel zeigt im Durchschnitt weniger als 3.5 Augen.	Der Würfel zeigt im Durchschnitt mehr oder weniger als 3.5 Augen.
p-Wert	$p = \Phi(-1.112) = 0.133 = 13.3 \%$	$p = 1 - \int \text{von } -1.112 \text{ bis } 1.112 = 0.266 = 26.6 \%$

Die Berechnung der Standardabweichung bleibt dieselbe ($\sigma = 0.270$, $z = -1.112$). Nur die Integrationsgrenzen ändern sich. **Flächenaufteilung zweiseitig: 13.3 % | 73.4 % | 13.3 %**
Begründung für zweiseitig: „Ein guter Würfel sollte im Durchschnitt genau 3.5 Augen zeigen, **nicht mehr und nicht weniger!**“

★ ★ Musterbeispiel Prüfmaschine (10.000 Würfe)

Augensumme 33.290 ⇒ $\bar{x} = 3.329$.

$$\sigma^2_{\bar{X}} = 2.91 / 10000 = 0.000291 \quad \sigma_{\bar{X}} = 0.0171$$

$$z = (3.329 - 3.5) / 0.0171 \approx -10$$

Mit $\bar{X} = 3.329$ sind wir also **10 Standardabweichungen unter dem Erwartungswert!** Die Wahrscheinlichkeit ist extrem niedrig und weit unterhalb der 5 %-Schwelle. **Wir verwerfen die Nullhypothese!** ★ **Kernaussage: Bei größerer Stichprobe wird dieselbe absolute Abweichung hochsignifikant** ($n = 40 \Rightarrow$ behalten; $n = 10.000 \Rightarrow$ verwerfen).

📝☆☆ Musterbeispiel Roulette (Anteilstest)

Ein Casino zählt die Häufigkeiten von Rot und Schwarz an einem amerikanischen Roulettetisch mit 0 und 00. Von 500 Spins sind nur 218 rot.

Schritt 1 — Beobachteter Anteil und theoretische Wahrscheinlichkeit:

Beobachtet: $218/500 = 0.436$
Theoretisch: $18/38 = 0.473$

Schritt 2 — Bernoulli-Zufallsvariable definieren:

$$X_i = \begin{cases} 1 & \text{wenn Spin } i \text{ rot} \\ 0 & \text{wenn Spin } i \text{ nicht rot} \end{cases}$$

$$E(X) = 0.473 \cdot 1 + 0.473 \cdot 0 + 0.054 \cdot 0 = 0.473$$

$$\text{Var}(X) = 0.473 \cdot (0.527)^2 + 0.473 \cdot (-0.473)^2 + 0.054 \cdot (-0.473)^2 = 0.249$$

Schritt 3 — Varianz des Mittelwerts über 500 Spins:

$$\sigma^2_{\bar{X}} = 0.249 / 500 = 0.000498 \quad \sigma_{\bar{X}} = 0.022315$$

Schritt 4 — z-Wert und p-Wert:

$$z = (0.436 - 0.4735) / 0.022315 = -1.65$$

$$\text{Excel: } =\text{NORMVERT}(0,436;0,4735;0,022315;\text{WAHR}) = 4.6 \%$$

Schritt 5 — Entscheidung:

H₀: Der Roulettetisch zeigt mit Wahrscheinlichkeit **18/38** rot. **H₁:** Der Roulettetisch zeigt mit Wahrscheinlichkeit **unter 18/38** rot. **Die Wahrscheinlichkeit ist beim einseitigen Z-Test knapp unterhalb der 5 %-Schwelle. Wir verwerfen die Nullhypothese!**

TEIL 6 — STATISTISCHE TESTS: SYSTEMATIK

19. ☆☆☆ Die drei Hypothesenarten


Beim Z-Test haben wir die Stichprobe gegen eine THEORETISCH BEKANNTE Verteilung getestet. Wir können ihn nur anwenden, weil wir wissen, wie sich der Würfel in der Theorie verhalten sollte. ⚠️ **In der empirischen Forschung und in Data Science haben wir dieses Wissen oft nicht. Uns stehen nur Informationen über unsere Stichprobe zur Verfügung!** Statt die Stichprobe gegen eine aus der Theorie abgeleitete Verteilung zu prüfen, stellen wir **Hypothesen über die Grundgesamtheit** auf:

Hypothesenart	Frage	Beispiel
① Verteilungshypothesen	Folgt ein Merkmal in der Grundgesamtheit einer bestimmten Verteilung?	„Ist das Merkmal normalverteilt oder sieht die Stichprobe nur zufälligerweise normalverteilt aus?“ (Körner pro Maiskolben)
② Parameterhypotesen	Hat die Verteilung eines Merkmals in der Grundgesamtheit bestimmte Parameter (Erwartungswert, Varianz, ...)?	„Mittelwert der Stichprobe ist 600 — können wir das auf die Gesamtheit übertragen?“
② b) Parametertests (2 Stichproben)	Wurden zwei Stichproben aus einer bzgl. eines Merkmals gleichen Grundgesamtheit gezogen?	„Wirkt sich der neue Dünger FSAB+C wirklich auf den Ertrag aus oder ist das Resultat Zufall?“
③ Abhängigkeitshypothesen	Sind zwei Merkmale in der Grundgesamtheit voneinander abhängig?	„Zusammenhang oder Zufall?“ (Punkte in Matheklausur vs. VWL-Klausur)

20. ★★ Der Testauswahl-Entscheidungsbaum

Es gibt dutzende verschiedene statistische Tests! Um die richtige Auswahl zu treffen, müssen wir eine ganze Reihe von Kriterien beachten:

- **Wie viele Stichproben haben wir?** Eine, zwei, mehrere?
- **Wie groß ist unsere Stichprobe?**
- **Auf was wollen wir diese untersuchen?**
- **Ist unsere abhängige Variable numerisch oder kategorial?**
- **Ist unsere abhängige Variable normalverteilt?**
- **Ist unsere unabhängige Variable numerisch oder kategorial?**
- **Haben wir mehrere unabhängige Variablen?**



★ Wichtige Verzweigungen im Detail

- **Größe der Stichprobe** — **Mindestens 30**: Histogramme/Q-Q-Plots genügen (ZGS greift) · **Unter 30**: **Shapiro-Wilk-Test** durchführen
- **Normalitätsprüfung** — Sieht normal aus / Test insignifikant ⇒ **parametrischer Test** · Sieht nicht normal aus / Test signifikant ⇒ **nicht-parametrische Alternative**
- **Nicht-parametrische Alternativen**: Eine Stichprobe → **Einstichproben-Wilcoxon** · Zwei → **Zweistichproben-Wilcoxon** (verbunden: **Verbundener Wilcoxon**) · Viele → **Kruskal-Wallis-Test**
- **Varianzgleichheit für ANOVA**: **Levene-Test** — insignifikant ⇒ **einfaktorielle ANOVA**, signifikant ⇒ **Welch-ANOVA**; bei zwei unabhängigen Variablen ⇒ **zweifaktorielle ANOVA**
- **Verteilungstest allgemein**: **Kolmogorov-Smirnov**
- ★ Bei bekannter Varianz der Grundgesamtheit und (großer) Stichprobengröße kann statt dem t-Test auch ein Z-TEST angewendet werden.

TEIL 7 — t-TEST

21. ★★ Grundgedanke

Die Rechenarbeit hinter statistischen Tests ist aufwendig, wird uns jedoch von Statistiksoftware abgenommen. **UNSERE Aufgabe** ist es, den richtigen Test zu finden und die Ergebnisse richtig zu interpretieren!

Das Kursbeispiel

*Ein Studiengangsleiter schaut sich die Leistung von **WI**- und **Data-Science-*Studierenden in verschiedenen Vorlesungen (**Marketing, Analysis**) an.

	WI	DS		Mkt	Ana
Anzahl	42	34	Anzahl	38	38
Mittelwert	66.0	64.8	Mittelwert	74.1	56.9
Standardabw.	17.7	21.6	Standardabw.	13.9	20.5
Standardfehler	2.73	3.71	Standardfehler	2.26	3.32
Unterschied	+1.2 Punkte		Unterschied	+17.2 Punkte	

22. ★★ Zweistichproben-t-Test

Der Zweistichproben-t-Test untersucht, ob wir aus den Mittelwerten zweier Stichproben auf unterschiedliche Erwartungswerte der wahren Verteilungen schließen können.

Generisches Hypothesenpaar: H_0 — Es gibt **keinen** Unterschied im Erwartungswert der beiden Gruppen. H_1 — Es gibt **einen** Unterschied im Erwartungswert der beiden Gruppen.

22.1 ★★ Gepaarte vs. ungepaarte Stichproben (Klausurfalle!)

	UNGEPAART (nicht verbunden)	GEPAART (verbunden)
Kriterium	Zwischen den Stichproben besteht kein Zusammenhang	Zwischen den Stichproben besteht ein Zusammenhang
Test	Würden wir die beiden Stichproben nebeneinanderlegen, gäbe es keinen Zusammenhang zwischen den jeweils ersten, zweiten, dritten usw. Messungen	Es gäbe einen Zusammenhang zwischen den jeweils ersten, zweiten, dritten usw. Messungen
Kursbeispiel	WI vs. Data Science — „Der erste WI-Student und der erste DSKI-Student sind unterschiedliche Personen! “	Marketing vs. Analysis — „Es handelt sich um Prüfungsleistungen derselben Person! “

22.2 ★★ Ergebnisse und Interpretation

Fall A: Vergleich der Studiengänge (ungepaart)

$$p = 0.8091$$

Interpretation: „Wäre die Nullhypothese wahr, dann erhalten wir bei der gegebenen Stichprobengröße und der gegebenen Varianz mit **Wahrscheinlichkeit 80.91 %** einen Leistungsunterschied von **mindestens 1.2 Punkten**.“ **Selbst ohne Unterschiede im Leistungsniveau ist es sehr wahrscheinlich, einen kleinen Unterschied zu messen! ⇒ Nullhypothese beibehalten.**

Fall B: Vergleich der Vorlesungen (gepaart)

$$p = 0.000000002335 \quad (= 0.0000002335 \%)$$

Interpretation: „Wäre die Nullhypothese wahr, dann erhalten wir mit Wahrscheinlichkeit 0.0000002335 % einen Leistungsunterschied von mindestens 17.2 Punkten.“ **Wir können es nicht ausschließen, aber dass dieser Unterschied durch zufällige Schwankungen zustande kommt, ist extrem unwahrscheinlich. ⇒ Nullhypothese verwerfen.**

23. ★★ Konfidenzintervalle

Zusätzlich zum p-Wert erhalten wir ein **Konfidenzintervall** auf einem bestimmten **Konfidenzniveau** (Standard: 95 %).

Vergleich der Studiengänge — Konfidenzintervall [−8.08 , 10.32]:

„Der Test ist sich zu 95 % sicher, dass der wahre Unterschied in diesem Bereich liegen muss.“

Je größer das geforderte Konfidenzniveau, umso breiter das Intervall:

Niveau	Intervall
90.0 %	[−6.57 , 8.81]
95.0 %	[−8.08 , 10.32]
99.0 %	[−11.1 , 13.35]
99.9 %	[−14.7 , 17.01]

★★ Der Zusammenhang p-Wert ↔ Konfidenzintervall (KLAUSURREGEL!)

Der p-Wert ist eins minus das höchste Konfidenzniveau, in dem die 0 gerade noch nicht berührt wird. Wenn das 95 %-Konfidenzintervall die 0 NICHT enthält, dann ist der p-Wert auf jeden Fall kleiner als 5 %.

- **Studiengänge:** Intervall enthält 0 $\Rightarrow H_0$ beibehalten
- **Vorlesungen:** Intervall [12.75 , 21.67] enthält 0 nicht $\Rightarrow H_0$ verwerfen

24. ★★ Einstichproben-t-Test

Der Einstichproben-t-Test überprüft, ob der Mittelwert eines Merkmals einem ZIELWERT entspricht. Dazu vergleicht er den Mittelwert einer Stichprobe mit einem **exogen vorgegebenen** Zielwert.

Generisches Hypothesenpaar: H_0 — Der wahre Mittelwert **entspricht** dem Zielwert. H_1 — Der wahre Mittelwert **weicht ab** vom Zielwert.

★★ Musterbeispiel Brauerei „Oberschwäble Kopfweh“

Die Brauerei kontrolliert die Qualität ihres Biers stichprobenartig im Labor. Einer der gemessenen Parameter ist der **pH-Wert**. **Zielwert: pH 4.0**. Es werden **25 Chargen** gemessen. Über alle Chargen gemittelt beträgt der pH-Wert **4.095**.

H_0 : Der pH-Wert des gebrauten Bieres entspricht dem **Sollwert von 4.0**. **H_1 :** Der pH-Wert des gebrauten Bieres liegt **über oder unter** dem Sollwert von 4.0. (zweiseitig!)

Ergebnis	Wert
T-Wert	2.16
P-Wert	0.040618
Konfidenzintervall (95 %)	[4.00440018 , 4.18543659]

Interpretation: „Wäre die Nullhypothese wahr, erhalten wir gegeben der Stichprobengröße und der Varianz mit Wahrscheinlichkeit von **4.06 %** eine Abweichung von mindestens 0.095 Skalenpunkten.“ **Der p-Wert ist unter 5 % $\Rightarrow$ Nullhypothese verwerfen! Das 95 %-Konfidenzintervall [4.004 , 4.185] enthält den Zielwert 4.000 NICHT $\Rightarrow$ dieselbe Entscheidung. Konsequenz:** „Falls ja, könnten wir unseren Brauprozess in Richtung mehr Säure anpassen!“

25. ★★ Blick hinter die Kulissen — die t-Statistik

$$t = \frac{\bar{x} - \mu_0}{\sigma_{\bar{X}}} \quad \text{mit} \quad \sigma_{\bar{X}} = \frac{\sigma_X}{\sqrt{n}}$$

Der t-Wert **drückt die Abweichung zum Zielwert in STANDARDFEHLERN aus**. Um daraus den p-Wert zu berechnen, wird der t-Wert in die **Verteilungsfunktion der Studentischen t-Verteilung mit n-1 Freiheitsgraden** eingesetzt:

$$p = 2 \cdot (1 - F(t)) \quad (\text{zweiseitig})$$

25.1 ★★ Warum t-Verteilung und nicht Normalverteilung?

Die Studentische t-Verteilung sieht in Schaubildern täuschend ähnlich wie die Normalverteilung aus, ist aber nicht identisch. ★ Anders als beim Z-Test kennen wir die Varianz der wahren Verteilung NICHT. Als Schätzwert nehmen wir die Varianz der Stichprobe. Dieses Vorgehen ist mit Unsicherheiten behaftet — und die Studentische t-Verteilung berücksichtigt das.

25.2 ★ Freiheitsgrade

Je größer die Stichprobe, umso kleiner die Unsicherheit. Daher müssen wir die t-Verteilung mit der Anzahl an Freiheitsgraden parametrieren. ★ **Für eine hohe Zahl an Freiheitsgraden nähert sich die Studentische t-Verteilung der Normalverteilung an!**

Test	Freiheitsgrade
Einstichproben-t-Test	Stichprobengröße minus 1
Zweistichproben-t-Test	Welch-Approximation

TEIL 8 — ANOVA

26. ★★ ANOVA (Analysis of Variance)

⚠ Eine Sache, die der t-Test NICHT kann, ist mehr als zwei Stichproben miteinander zu vergleichen! Mit einer ANOVA („Analysis of Variance“) können wir genau das machen.

Generisches Hypothesenpaar: H_0 — Es gibt **keinen** Unterschied im Erwartungswert der Stichproben. H_1 — Es existiert **mindestens eine Paarung** von Stichproben mit **unterschiedlichen** Erwartungswerten.

✎☆☆ Musterbeispiel: Vier KIs zur Literaturprüfung

Ein Informatiker testet vier KIs, welche die Literaturangaben von Abschlussarbeiten auf Korrektheit untersuchen sollen. Jede der KIs wird mit **100 Bachelorarbeiten** gefüttert. Gemessen wird die **Accuracy**, d.h. der Anteil der richtig eingestuften Angaben.

$$\text{Accuracy} = \frac{N - \text{FP} - \text{FN}}{N}$$

Bot A	Bot B	Bot C	Bot D
59.4 %	58.7 %	43.2 %	70.6 %

H₀: Es gibt keinen Unterschied in der Accuracy der Bots. **H₁:** Es existiert mindestens eine Paarung von Bots unterschiedlicher Accuracy. **Ergebnis:** p-Wert in der Größenordnung von $10^{-14} \Rightarrow$ **Nullhypothese verwerfen!**

27. ☆☆☆ Post-Hoc-Tests

⚠ **Die Alternativhypothese der ANOVA ist nicht gerade präzise** — sie sagt nur, dass **irgendein** Paar sich unterscheidet. **Um die Daten genauer zu untersuchen, ergänzen wir die ANOVA um sogenannte POST-HOC-TESTS.**

Infrage kommende Post-Hoc-Tests:

- **Tukey HSD** ☆ (am häufigsten eingesetzt — setzt allerdings **homoskedastische Stichproben** voraus)
- **Games-Howell**
- **Paarweise t-Tests mit Bonferroni- / Holm-Korrektur**

Ergebnismatrix (paarweise t-Tests mit Holm-Korrektur):

PWT(HOLM)	A	B	C	D
A	—	0.828	< 0.001	0.002
B	0.828	—	< 0.001	0.001
C	< 0.001	< 0.001	—	< 0.001
D	0.002	0.001	< 0.001	—

Lesart: A und B unterscheiden sich **nicht** signifikant ($p = 0.828$). C ist signifikant schlechter als alle, D signifikant besser als alle.

TEIL 9 — TEST AUF NORMALITÄT

28. ★★ Parametrische Tests und ihre Voraussetzungen

Die t-Tests und die ANOVA sind **PARAMETRISCHE** Tests. Parametrische Tests nehmen an, dass ein Merkmal in der Grundgesamtheit einer bestimmten Verteilung folgt. Der parametrische Test sucht dann die zu den Daten am besten passenden Parameter.

★★ Voraussetzungen für den t-Test

1. Die Daten der Stichprobe sind **METRISCH SKALIERT**.
2. Der **MITTELWERT** der Stichprobe ist **NORMALVERTEILT**.

★★ Nicht-parametrische Alternativen zum t-Test

Alternative	Anwendungsfall
Wilcoxon-Rangsummen-Test	2 ungepaarte Stichproben
Wilcoxon-Vorzeichen-Rang-Test	2 gepaarte Stichproben
Mann-Whitney-U-Test	2 unabhängige Stichproben
Sign-Test	Vergleich Median gegen Zielwert

29. ★★ Wann muss man überhaupt prüfen?

★ Bei größeren Stichproben (ab $n = 30$) können wir die Voraussetzung des normalverteilten Mittelwertes **DANK DES ZGS** als **AUTOMATISCH ERFÜLLT** annehmen. Bei kleineren Stichproben müssen wir genauer hinschauen.

30. ★★ Grafische Methoden

30.1 Histogramm

Naheliegende Idee: Wir betrachten ein Histogramm der Stichprobe und prüfen, ob es normalverteilt aussieht. ⚠ **Problem:** Die Beurteilung hängt stark von der Anzahl der Unterteilungen (Bins) ab — mit 5, 9 oder 16 Unterteilungen sieht dieselbe Stichprobe unterschiedlich aus.

30.2 ★★ Q-Q-Plot (die bessere Methode)

Beim Q-Q-Plot tragen wir die QUANTILE DER STICHPROBE gegen die einer STANDARDNORMALVERTEILUNG auf.

- Die Quantile der Stichprobe entsprechen den aufsteigend sortierten Werten.
- Die Quantile der Normalverteilung werden mit folgender Formel berechnet:

$$Q_i = \Phi^{-1}(p_i) \quad \text{mit} \quad p_i = \frac{i - 0.5}{n}$$

Bei Normalverteilung liegen die Punkte auf einer Geraden.

31. ★★ Statistische Normalitätstests

Test	Prüft auf
Shapiro-Wilk-Test (SW)	Nur Normalverteilung
Kolmogorov-Smirnov-Test (KS)	Mehrere Verteilungen
Anderson-Darling-Test (AD)	Mehrere Verteilungen

⚠️ ★★ DIE ENTSCHEIDENDE UMKEHRUNG (Klausurfalle!)

H₀: Das Merkmal in der Grundgesamtheit **folgt** einer bestimmten Verteilung. **H₁:** Es liegt eine **signifikante Abweichung** von der Verteilung vor. **Die Tests versuchen, eine ABWEICHUNG zu erkennen!** ★ Folglich haben wir unsere Normalverteilung, wenn der p-Wert ÜBER 5 % liegt und wir die Nullhypothese HALTEN können!

32. ★★ Sensitivität und Spezifität — Performance der Tests

Sensitivität = Die Wahrscheinlichkeit, dass der Test eine **abweichend verteilte** Stichprobe auch **als solche erkennt** und **keine false negatives** hervorbringt. **Spezifität** = Die Wahrscheinlichkeit, dass der Test eine **nicht abweichend verteilte** Stichprobe auch als solche erkennt und **keine false positives** hervorbringt.

Simulationsergebnisse (Standardnormalverteilung `rnorm` vs. Gleichverteilung `runif` über `[-1,1]`):

n	SW-Test	KS-Test	AD-Test
15	Sens. 12.7 % / Spez. 95.3 %	Sens. 4.3 % / Spez. 94.9 %	Sens. 2.8 % / Spez. 95.0 %
30	Sens. 37.7 % / Spez. 95.0 %	Sens. 7.2 % / Spez. 95.0 %	Sens. 17.4 % / Spez. 94.8 %
50	Sens. 74.6 % / Spez. 95.1 %	Sens. 23.8 % / Spez. 95.2 %	Sens. 81.6 % / Spez. 95.2 %
100	Sens. 99.6 % / Spez. 94.7 %	Sens. 100.0 % / Spez. 95.2 %	Sens. 100.0 % / Spez. 94.6 %

★★ Die zentrale Erkenntnis

Gerade bei kleinen Stichproben ist die Performance nicht überragend — sehr viele Abweichungen werden nicht erkannt. Warum ist die Spezifität eigentlich **IMMER** bei 95 %? ★ Die 95 % entsprechen der kritischen Schwelle für den p-Wert und damit die Wahrscheinlichkeit eines **FEHLERS ERSTER ART**. ★ Erhöhen wir die kritische Schwelle, opfern wir Spezifität für Sensitivität.

Weiterentwicklungen:

- **KS-Test mit Lilliefors-Korrektur** — bessere Sensitivität bei kleinen Stichproben
- **Filliben's Test** — automatisiert das Auswerten der Q-Q-Plots

33. ★★ Wie schlimm ist eine Verletzung der Normalitätsannahme?

Tatsächlich bedeuten kleinere Abweichungen **NICHT**, dass der Test sofort nutzlos wird. Problematisch sind vor allem folgende Abweichungen:

1. **Hohe Wahrscheinlichkeit für Ausreißer (Fat Tails)**
2. **Starke Asymmetrie, d.h. eine ausgeprägte Schiefe**
3. **Bimodale Verteilungen**

TEIL 10 — DIE CHI-QUADRAT-TESTFAMILIE

34. ★★ χ^2 -Unabhängigkeitstest

Mit der Chi-Quadrat-Testfamilie lernen wir Tests für **KATEGORIALE** Daten bzw. **HÄUFIGKEITSDATEN** kennen. Am häufigsten wird uns der **Unabhängigkeitstest** begegnen. **Generisches Hypothesenpaar:** H_0 : Zwei kategoriale Merkmale weisen **keinen** Zusammenhang auf. H_1 : Zwei kategoriale Merkmale weisen **einen** Zusammenhang auf.

Einführungsbeispiel (Kontingenztafel Raucher/Geschlecht):

	Männer	Frauen	Σ
Nichtraucher	106 (53 %)	122 (61 %)	228
Aufgehört	40 (20 %)	36 (18 %)	76
Raucher	54 (27 %)	42 (21 %)	96
Σ	200	200	400

✍️★★★ Musterbeispiel A/B-Test Werbemailing „0815 Werbemailing“

Wir messen die Performance von zwei Varianten eines Werbemaillings: die bisherige **Variante A** und die neu entwickelte **Variante B**.

	A	B
Stichprobe	615	613
Geöffnet	57	71
Ignoriert	558	542
Quote	9.27 %	11.58 %

*„Deskriptiv sieht es gut aus: die neu entwickelte Variante hat eine höhere Öffnungsrate. **Der Chef und der PA-Betreuer sind aber skeptisch: Du hast doch nur einen Glückstreffer gelandet!**“*

Hypothesenpaar:

H₀: Die Häufigkeit geöffneter Werbemails ist bei beiden Varianten **identisch**. **H₁:** Die Häufigkeit geöffneter Werbemails **unterscheidet sich** zwischen den beiden Varianten.

☆☆ So funktioniert der Test

Der Test vergleicht die **BEOBACHTETE** Kontingenztabelle mit einer **Kontingenztabelle, die wir ERWARTEN** würden, wenn die Nullhypothese zutreffen würde. Gesamtöffnungsrate: $128/1228 = 10.4\%$ $\Rightarrow$ diese erwarten wir bei beiden Varianten.

BEOBACHTUNG	Variante A	Variante B	Σ	ERWARTUNG unter H ₀	Variante A	Variante B	Σ
Geöffnet	57 (9.3 %)	71 (11.6 %)	128 (10.4 %)	Geöffnet	$615 \cdot 0.104 = 64$	$613 \cdot 0.104 = 64$	128
Ignoriert	558	542	1100	Ignoriert	$615 - 64 = 551$	$613 - 64 = 549$	1100
Σ	615	613	1228	Σ	615	613	1228

R-Code und Ergebnis:

```
m <- matrix(c(57,558,71,542), nrow=2, ncol=2,
             dimnames=list(c("opened","ignored"), c("A","B")))
rateA <- m[1,1]/(m[1,1]+m[2,1])
rateB <- m[1,2]/(m[1,2]+m[2,2])
result <- chisq.test(m)

# Pearson's Chi-squared test with Yates' continuity correction
# X-squared = 1.5216, df = 1, p-value = 0.2174
```

Interpretation: „Die Wahrscheinlichkeit eines Häufigkeitsunterschiedes von mindestens 2.3 Prozentpunkten ist selbst unter Gültigkeit der Nullhypothese mit **21.74 %** plausibel.“ $\Rightarrow$ **Wir behalten H₀ bei.**

35. ★★ χ^2 -Anpassungstest (Goodness of Fit)

★ Der Chi-Quadrat-Anpassungstest hat eine ANDERE Fragestellung als der Unabhängigkeitstest: Wir wollen wissen, ob die Verteilung EINES kategorialen Merkmals einer ERWARTETEN Verteilung entspricht.

H_0 : Die beobachtete Verteilung **passt zu** der erwarteten Verteilung. H_1 : Die beobachtete Verteilung **weicht ab** von der erwarteten Verteilung.

✎ ★★ Musterbeispiel Umfrage unter Studierenden

Antworten von **20 aus Data Science** (Grundgesamtheit 200), **25 aus MKE** (300), **10 aus Agrarwirtschaft** (40).
Ist dieses Sample **repräsentativ** oder sind Studiengänge über-/unterrepräsentiert?

```
sample <- c(20,25,10)
base    <- c(200,300,40)
chisq.test(sample, p=base, rescale.p = TRUE)

# Chi-squared test for given probabilities
# X-squared = 9.6364, df = 2, p-value = 0.008081
```

Interpretation: „Wäre die Nullhypothese gültig, würden wir mit Wahrscheinlichkeit **0.808 %** eine mindestens so große Abweichung feststellen. Das ist unwahrscheinlich und deutlich unter der 5 %-Hürde.“
⇒ **Nullhypothese verwerfen**. (Agrarwirtschaft ist massiv überrepräsentiert: 25 % Rücklauf vs. 10 % und 8.3 %.)

TEIL 11 — FEHLER VON STATISTISCHEN TESTS

36. ★★ Die vier Fehlerarten

Fehler	Definition	Alias
Fehler erster Art	Wir lehnen die Nullhypothese ab , obwohl sie eigentlich richtig wäre. ★ Die Wahrscheinlichkeit für diesen Fehler können wir am SIGNIFIKANZNIVEAU ablesen!	Falsch Positiv
Fehler zweiter Art	Wir lehnen die Nullhypothese NICHT ab , obwohl sie eigentlich falsch wäre.	Falsch Negativ
Datenfehler	Wir verwenden Messdaten, die selbst fehlerbehaftet sind.	—
Modellfehler	Wir verwenden einen ungeeigneten Test bzw. treffen Annahmen über Verteilungen und Merkmale, die nicht zutreffen .	—

TEIL 12 — REGRESSIONSANALYSE (OLS)

37. ★★ Systematik der Regression

Bei der Regressionsanalyse suchen wir nach Zusammenhängen zwischen **ABHÄNGIGEN** und **UNABHÄNGIGEN Variablen**. *Beispiel Eisstand: **Unabhängige Variablen** Temperatur, Uhrzeit, Preis → erklären → **Abhängige Variable** Umsatz*

	EINE unabhängige Variable	MEHRERE unabhängige Variablen
EINE abhängige Variable	Univariate EINFACHE Regression	Univariate MULTIPLE Regression
MEHRERE abhängige Variablen	Multivariate EINFACHE Regression	Multivariate MULTIPLE Regression

★ **Merksatz:** „einfach/multipel“ bezieht sich auf die **UNABHÄNGIGEN**, „univariat/multivariat“ auf die **ABHÄNGIGEN Variablen**.

Funktionsformen: Lineare Regression · Quadratische Regression · Logarithmische Regression · Polynomiale Regression

Welches Modell wir wählen, hängt von den Daten und der Theorie hinter den Daten ab.

38. ★★ Das OLS-Grundmodell

Kursbeispiel: Klausurpunkte und Lernstunden

$$y = \beta_0 + \beta_1 \cdot x_1 + \varepsilon$$

y : Punkte in Klausur
 β_0 : Punkte ohne Lernen
 $\beta_1 \cdot x_1$: Punkte pro Lernstunde × Lernstunden
 ε : Alle anderen Einflüsse (Störterm)

★ **Standardinterpretation:** „Ohne Lernen werden im Schnitt β_0 Punkte erreicht. Eine Stunde mehr Lernen ist **im Durchschnitt mit β_1 mehr Punkten ASSOZIIERT.**“

39. ★★ Die OLS-Zielfunktion

Der Algorithmus bewertet seine Modelle durch ein Maß, das die Abweichung des Modells von der Realität misst. Diese Abweichungen werden als **RESIDUEN** bezeichnet. ★ Die **OLS-Regression (Ordinary Least Squares)** bewertet Modelle über die **SUMME DER QUADRIERTEN RESIDUEN**. Sie sucht Schätzer, bei denen die Summe der quadrierten Residuen **MINIMAL** wird.

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Der „Hut“ (β) unterscheidet die Koeffizienten von den dafür gefundenen **SCHÄTZERN**.

Ergebnis im Kursbeispiel:


$$\beta_{\hat{0}} = 38.1, \quad \beta_{\hat{1}} = 4.5 \quad \Rightarrow \quad \hat{y} = 38.1 + 4.5 \cdot x_1$$

„Ohne Lernen werden im Schnitt 38.1 Punkte erreicht. Eine Stunde mehr Lernen ist im Durchschnitt mit 4.534 mehr Punkten assoziiert.“

40. ⚠️★★ Korrelation ≠ Kausalität

Warum ist der Satz so unnötig kompliziert formuliert („assoziert“ statt „bewirkt“)? ★ Das Ergebnis ist **NICHT ZWINGEND KAUSAL**! Hinter dem gefundenen Zusammenhang kann eine **DRITTE Variable** stecken, die wir nicht berücksichtigen und die daher zum Störterm ϵ gehört. Im Beispiel könnte das z.B. **Geschlecht, Gewissenhaftigkeit, Willenskraft oder Intelligenz** sein. **Haben wir diese Werte, können wir sie als KONTROLLVARIABLEN in die Regression mit aufnehmen.**

💡 Das Standard-Gegenbeispiel



41. ★★ Das R-Output vollständig lesen

```

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  38.100     12.861   2.962   0.0110 *
Lernstunden   4.534       1.583   2.864   0.0133 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 17.94 on 13 degrees of freedom
Multiple R-squared:  0.3869, Adjusted R-squared:  0.3398
F-statistic: 8.204 on 1 and 13 DF, p-value: 0.01329

> confint(result, level=0.95)
              2.5 %      97.5 %
(Intercept) 10.315732 65.885123
Lernstunden  1.114246  7.953363

```

Spalte/Zeile	Bedeutung
Estimate	Der Schätzer $\hat{\beta}$
Std. Error	★ Standardfehler: „Wie sicher ist sich die Regression mit dem angezeigten Schätzwert? Je größer der Standardfehler, umso weniger sicher ist sich die Regression! “
t value / Pr(> t)	t-Wert und p-Wert, aus Schätzer und Standardfehler automatisch berechnet
Signif. codes	*** p<0.001 · ** p<0.01 · * p<0.05 · . p<0.1
Adjusted R-squared	★ Anteil der erklärten Varianz (siehe unten)
confint	★ Konfidenzintervall des Schätzers

41.1 ★★ Das Hypothesenpaar hinter JEDEM Schätzer

H₀: Der wahre Wert des Koeffizienten ist **0**. Es gibt daher **keinen** Zusammenhang zwischen der entsprechenden unabhängigen und der abhängigen Variable. **H₁:** Der wahre Wert des Koeffizienten ist **nicht 0**. Es gibt **einen** Zusammenhang.

Konkret im Beispiel:

H₀ für β_1 : Der wahre Wert von β_1 ist null und Lernen hat **keinen** Effekt auf die erreichte Klausurpunktzahl. **H₁ für β_1 :** Der wahre Wert ist nicht null und Lernen hat **einen** Effekt.

41.2 ★★ p-Wert-Interpretation (Standardformulierung!)

★ „Gegeben die Nullhypothese ist wahr und das β_1 ist eigentlich 0 — wie hoch ist dann die Wahrscheinlichkeit, dass wir trotzdem einen mindestens so starken Zusammenhang in den Daten sehen?“
 * „Der p-Wert für β_1 beträgt **1.3 %**. Wenn die Nullhypothese wahr wäre, dann würden wir mit einer Wahrscheinlichkeit von 1.3 % eine Stichprobe ziehen, bei der ein Zusammenhang von mindestens 4.534 Pkt./h besteht.“*

41.3 ★★ Konfidenzintervall des Schätzers

„Die Regression ist sich zu 95 % sicher, dass der Effekt einer Lernstunde zwischen 1.1 und 7.9 Punkten liegt.“ (entspricht $\pm 1.96 \sigma$)

41.4 ★★ R^2 und Adjusted R^2

Welcher Anteil der Varianz in der abhängigen Variable wird durch unsere unabhängigen Variablen erklärt? Die Antwort gibt der R^2 -Wert! „33.98 % der Varianz in den Leistungen werden durch unterschiedliche Länge des Lernens erklärt. 66.02 % hängen von anderen Faktoren ab (Tagesform, Begabung, Lerntechnik usw.)“

42. ★★ Residuenanalyse

Neben den Schätzern sind auch die **RESIDUEN** relevant, d.h. die Abweichungen zwischen Modellschätzung und wahren Werten der abhängigen Variable. Wir untersuchen die Residuen üblicherweise auf:

1. Normalverteilung
2. Homoskedastizität

★ **HOMOSKEDASTIZITÄT** liegt vor, wenn die Residuen von der Höhe des geschätzten Merkmals **UNABHÄNGIG** sind. (Gegenteil: **Heteroskedastizität** — die Streuung der Residuen wächst/schrumpft mit der Schätzung; typisches Trichtermuster im Residuenplot.)

43. 📝★★★ Großes Fallbeispiel: Strommarkt

43.1 Der Ausgangspunkt

Aus der Mikroökonomik kennen wir **Nachfragefunktionen**: sie ordnen jedem Preis eine nachgefragte Menge zu, wobei **höhere Preise typischerweise zu weniger Nachfrage** führen. (Melonen-Beispiel: $q(p) = 20 - 2p$) ⚠️ „Die Parameter dieser Nachfragefunktionen und die Ergebnisse waren nicht selten alles andere als realistisch!“

Datenquelle: SMARD-Datenbank — öffentlich zugängliche Datenbank mit Daten zu Stromerzeugung, Stromverbrauch und Strompreisen. **Viertelstündliche Daten aus 2024** ($n = 35.136$).

43.2 Modell 1 — Nachfrage ~ Preis

$$q = \beta_0 + \beta_1 \cdot p + \varepsilon$$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.934e+01	8.420e-02	586.02	<2e-16 ***
Preis	4.545e-02	8.903e-04	51.05	<2e-16 ***

Multiple R-squared: 0.06905, Adjusted R-squared: 0.06903
 confint: Preis [0.04370479, 0.0471948]

Schätzer: $\beta_0 = 49.34$, $\beta_1 = 0.045 \Rightarrow q(p) = 49.34 + 0.045p$ **H₀:** Der wahre Wert von β_1 ist null. Die Stromnachfrage hängt nicht mit dem Strompreis zusammen. **H₁:** Der wahre Wert von β_1 ist nicht null. **Der p-Wert ist fast 0 und damit unter 0.05 $\Rightarrow$ Nullhypothese verwerfen.**

43.3 ⚠️☆☆ Das Problem

*„Irgendwas an unseren Ergebnissen ist seltsam: Ein um 1 € höherer Großhandelspreis pro MWh geht im Durchschnitt mit einer um **45 MW HÖHEREN** Nachfrage einher. **Die Stromkunden wollen 45 MW mehr Leistung, wenn der Strom an der Börse 1 € teurer wird?**“*

★ **Auflösung:** Die OLS-Regression macht ausschließlich Aussagen über **KORRELATIONEN!** Trotz minimalem p-Wert beweisen wir weder, ob es eine Kausalität gibt, noch in welche Richtung diese geht. Der gesunde Menschenverstand legt nahe: Der Börsenpreis wird 1 € teurer, wenn die Konsumenten 45 MW mehr Leistung nachfragen. $\Rightarrow$ Die Wirkungsrichtung ist umgekehrt!

43.4 Modell 2 — Preis ~ Nachfrage (Preis-Absatz-Funktion)

$$p = \beta_0 + \beta_1 \cdot q + \varepsilon$$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.87667	1.59791	-1.174	0.24
Netzlaster	1.51937	0.02976	51.050	<2e-16 ***

Multiple R-squared: 0.06905, Adjusted R-squared: 0.06903

Die Interpretation ist nun einfacher, aber wir haben ein weiteres Problem: das Modell erklärt nur einen geringen Teil der Preisschwankungen! Nur 6.90 % der Preisschwankungen werden durch Nachfrageschwankungen erklärt.

43.5 ★ Modell 3 — Erweiterung um EE-Einspeisung

$$p = \beta_0 + \beta_1 \cdot q + \beta_2 \cdot EE + \varepsilon$$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.76256	1.03394	3.639	0.000274 ***
Netzlaster	3.11734	0.02057	151.583	< 2e-16 ***
GesamtEE	-3.10775	0.01406	-220.982	< 2e-16 ***

Multiple R-squared: 0.6105, Adjusted R-squared: 0.6105

Logik: „Wenn günstiger erneuerbarer Strom verfügbar ist, müssen weniger teure Kraftwerke laufen und der Strom wird nach dem **MERIT-ORDER-PRINZIP** günstiger.“ **Das Modell wird deutlich besser: R² steigt von 6.9 % auf 61.05 %!** Interpretation:

- „Eine Nachfrageerhöhung um 1 GW geht im Durchschnitt mit einer Erhöhung des Börsenpreises um **3.12 €** einher.“
- „Ein Plus von 1 GW EE-Leistung geht im Durchschnitt mit einer Senkung des Börsenpreises um **3.11 €** einher.“

TEIL 13 — HERAUSFORDERUNGEN DER REGRESSIONSANALYSE

44. ★ Möglichkeiten und Baustellen

✓ Regressionsmodelle sind sehr mächtig ...	✗ ... aber es gibt eine Reihe an Baustellen!
Transformationen und Interaktionen von unabhängigen Variablen sind möglich	Durch MULTIKOLLINEARITÄT kann der Einfluss hoch korrelierter unabhängiger Variablen nur schwer untersucht werden
Kategoriale unabhängige Variablen können durch Dummy-Variablen eingebracht werden	Durch ENDOGENITÄTSPROBLEME können Schätzer systematisch verzerrt werden
Kategoriale abhängige Variablen können durch Logit- oder Probit-Regression untersucht werden	Die manuelle Wahl von unabhängigen Variablen kann zu OVERFITTING führen

45. ★★ Bias und zufälliger Schätzfehler

Wir können nicht nur die Residuen $y - \hat{y}$, sondern auch die **Abweichungen der einzelnen Schätzer** $\hat{\beta} - \beta$ betrachten. **Dieser Schätzfehler kann als Zufallsvariable mit einer bestimmten Verteilung betrachtet werden.**

Kennzahl	Definition	Eigenschaft
BIAS	Der Erwartungswert von $\hat{\beta} - \beta$	Bias = 0 $\Rightarrow$ Schätzer ist ERWARTUNGSTREU. Ansonsten VERZERRT.
Zufälliger Schätzfehler	Die Standardabweichung von $\hat{\beta} - \beta$	★ Wird mit größerer Stichprobengröße kleiner.

⚠️ ★ Im Gegensatz zum zufälligen Schätzfehler wird der **BIAS** auch **NICHT** mit größerer Stichprobe automatisch kleiner!

46. ★★ Multikollinearität

📝 Das Fallbeispiel

Ein Studiengangsleiter möchte ein Vorhersagemodell für die ersten Klausuren. Er lässt einen Anfängerkurs je einen **Kurztest zu Mathe (MS)** und **Coding (CS)** schreiben.

$$\text{Leistung} = \beta_0 + \beta_1 \cdot \text{MS} + \beta_2 \cdot \text{CS} + \varepsilon$$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	12.1140	5.9043	2.052	0.0429 *
math_skill	0.9522	0.3668	2.596	0.0109 *
code_skill	-0.1222	0.4226	-0.289	0.7730

Multiple R-squared: 0.6801, Adjusted R-squared: 0.6735
F-statistic: 103.1 on 2 and 97 DF, p-value: < 2.2e-16

*„Voller Stolz stellt er das geschätzte Modell seinen Kollegen vor. **Es ist ziemlich gut darin, die Daten zu erklären! Leider ergeben die Koeffizienten überhaupt keinen Sinn: Ein um 1 Punkt besseres Ergebnis im Codingtest ist mit 0.12 WENIGER Klausurpunkten assoziiert.**“*

★★ Die Diagnose

Jedes Mal, wenn wir die Simulation wiederholen, erhalten wir komplett andere Koeffizienten. Wir haben einen sehr hohen ZUFÄLLIGEN Schätzfehler. ★ Der Schätzer ist allerdings trotzdem ERWARTUNGSTREU. Im Mittel finden wir die richtigen Koeffizienten. Ursache ist **MULTIKOLLINEARITÄT**: Wir haben eine starke Korrelation zwischen mindestens einer Paarung von unabhängigen Variablen.

46.1 ★★ Multikollinearität feststellen — drei Methoden

#	Methode	Vorgehen	Kritischer Wert
①	Korrelationskoeffizient	Am naheliegendsten: Korrelation zwischen den beiden unabhängigen Variablen. Bei vielen Variablen: Korrelationsmatrix ausgeben.	—
②	Variance Inflation Factor (VIF)	Wir gehen die unabhängigen Variablen durch und regressieren jede gegen alle anderen unabhängigen Variablen . Dann setzen wir den korrigierten R²-Wert in die Formel ein.	★ Ab VIF = 10 problematisch (Kutner/Nachtsheim/Neter 2004)
③	Konditionszahl κ der Korrelationsmatrix	Bei Modellen mit mindestens drei unabhängigen Variablen	★ Ab κ = 30 problematisch (Belsley, Kuh & Welsch 1980)

$$\text{VIF} = \frac{1}{1 - R^2}$$

$$\kappa = \max(\lambda) - \min(\lambda) \quad \text{mit} \quad \det(M - \lambda I) = 0 \quad \text{und} \quad M = \text{Korrelationsmatrix}$$

46.2 ★★ Multikollinearität behandeln

Nach der Diagnose kommt die Behandlung:

1. **Problematische Variablen ENTFERNEN.**
2. **Problematische Variablen ZUSAMMENFASSEN.**
3. **Problematische Variablen WEITER ZERLEGEN.**
4. **Alternatives Schätzverfahren (z.B. RIDGE-REGRESSION).**

47. ★★ Endogenitätsprobleme

Das Fallbeispiel

Die DHBW plant eine groß angelegte Studie zum Zusammenhang von **Bildungsniveau und Einkommen**. Ein Fragebogen misst das Bildungsniveau sehr detailliert. Am Ende soll eine OLS-Regression zeigen, wie viel €/Jahr mehr ein Punkt auf dieser Bildungsskala bringt.

$$\text{Gehalt} = \beta_0 + \beta_1 \cdot \text{Bildung} + \varepsilon$$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	17392.26	2089.50	8.324	8.27e-16 ***
education	575.57	20.54	28.015	< 2e-16 ***

Multiple R-squared: 0.6118, Adjusted R-squared: 0.611

*„**Die Ergebnisse sind traumhaft**. Der Koeffizient für die Bildung ist so signifikant, dass der p-Wert nicht mehr als double darstellbar ist, und es geht um **575 € pro Skalenpunkt**. Rektorat und HoKo wollen das Ergebnis veröffentlichen — **doch die Data Science ist skeptisch. Das sieht zu gut aus ...**“ **Werbeslogan: „Studieren macht reich! Noch heute immatrikulieren!“**

★★ Die Diagnose

Wir erkennen einen starken BIAS. Der Schätzer ist NICHT erwartungstreu, sondern zeigt uns viel zu hohe Werte an. Im Gegensatz zum zufälligen Schätzfehler wird der Bias auch nicht mit größerer Stichprobe automatisch kleiner. Wir haben ein massives Problem.

47.1 ★★ Definition Endogenität

Endogenitätsprobleme entstehen, wenn eine UNABHÄNGIGE Variable vom STÖRTERM statistisch ABHÄNGIG ist.

$$p(x_{i,j} = x \mid \varepsilon_j) \neq p(x_{i,j} = x)$$

Meistens geschrieben als: $\text{cor}(x_i, \varepsilon) \neq 0$

★ Ein Endogenitätsproblem VERZERRT den Schätzer und führt dazu, dass er nicht mehr erwartungstreu ist.

Im Beispiel: Das Endogenitätsproblem entsteht durch den Einfluss der Variable „**Ability**“ (**Können der Person**) auf die Bildung. Der Störterm ε enthält alle Einflüsse auf das Gehalt, die wir nicht in der Regression berücksichtigen: **Können der Person, Glück/Pech der Person**.

47.2 ★★ Problematische Variablen finden

In der Praxis kennen wir den Störterm nicht. Wir müssen überlegen, **welche Variablen gleichzeitig mit der abhängigen Variable UND mit unseren unabhängigen Variablen korrelieren könnten.**

🔍 „WIR SUCHEN DRINGEND! PROBLEMATISCHE VARIABLEN“

- **KORRELIERT MIT ABHÄNGIGER VARIABLE** — Die Problemvariable muss mit dem **Gehalt** einer Person korreliert sein
- **KORRELIERT MIT UNABHÄNGIGER VARIABLE** — Die Problemvariable muss mit der **Bildung** einer Person korreliert sein

47.3 ★★ Lösung 1 — Kontrollvariable aufnehmen (Omitted-Variable-Problem)

Im einfachsten Fall stehen uns Daten zu dieser Variable zur Verfügung. Dann nehmen wir sie in die Regression mit auf und **ENTFERNEN SIE DADURCH AUS DEM STÖRTERM.**

$$\text{Gehalt} = \beta_0 + \beta_1 \cdot \text{Bildung} + \beta_2 \cdot \text{Können} + \varepsilon$$

47.4 ★★ Lösung 2 — Instrumentalvariablenschätzung (IV)

Wenn wir die Daten nicht haben, hilft uns ggf. eine besondere Schätzmethode: die **INSTRUMENTALVARIABLENSCHÄTZUNG.**

★★ Die zwei Anforderungen an ein Instrument

Anforderung	Bedeutung	Im Beispiel
RELEVANT	Es muss mit der unabhängigen Variable korreliert sein, die das Endogenitätsproblem verursacht	Das Instrument muss mit der Bildung unserer Probanden korrelieren
EXOGEN	Es darf NICHT mit dem Störterm korreliert sein	Insbesondere nicht mit der Fähigkeit einer Person!

★★ Die zweistufige OLS-Regression (2SLS)

$$\begin{aligned} \text{STUFE 1: Bildung} &= \beta_0 + \beta_1 \cdot \text{Zugänglichkeit} + \varepsilon \\ \text{STUFE 2: Gehalt} &= \beta_0 + \beta_1 \cdot \text{Bildung} + \varepsilon \end{aligned}$$

Stufe 1: Wir machen die unabhängige Variable, die das Endogenitätsproblem verursacht, **zur abhängigen Variable einer separaten Regression.** Als unabhängige Variable wählen wir **unser Instrument.** **Stufe 2:** Wir führen die ursprünglich geplante OLS-Regression durch und **ersetzen die Werte der problematischen unabhängigen Variable durch die GEFITTETEN WERTE aus der ersten Stufe.**

★★ Der große Vorteil

Ein weiterer Vorteil der IV-Schätzung ist, dass wir die Ergebnisse nun auch **KAUSAL** bewerten dürfen: „Mehr Bildung **FÜHRT ZU** einem höheren Gehalt!“ ⚠ Die kausale Interpretation gilt allerdings **NUR** für die instrumentierte Variable und auch nur dann, wenn die Instrumente wirklich relevant und exogen sind.

48. ★★ Overfitting

Die vielen Möglichkeiten der Regressionsanalyse bergen die Gefahr des Overfittings — und das sowohl durch den Algorithmus als auch **DURCH UNS** als Data Scientists!

- Bei **ML-Algorithmen** tunen wir Parameter, bis wir gute **OOS-Werte** (Out-of-Sample) für **Accuracy, Recall, Precision** und Co. haben.
- Bei der **Regression** ändern wir Wahl und Transformation von unabhängigen Variablen, **bis die „richtigen“ Variablen signifikant werden.**

Lösung: ★ Wir überlassen die Wahl der unabhängigen Variablen dem **ALGORITHMUS** oder einem **REGELWERK**, auf das wir uns **VOR** der Datenanalyse festlegen.

48.1 ★★ Die Grundidee der Regularisierung

Bisher sucht der Algorithmus nach Schätzern, die den **MSE** (Summe der quadrierten Residuen) minimieren.

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Diese Zielfunktion ergänzen wir um eine **STRAFE**, die Overfitting verhindern soll. Die Strafe soll von der **GRÖSSE** der Schätzer und einem Parameter λ abhängen. Mit λ regeln wir die Strenge der Strafe: je größer λ , umso stärker wird der Algorithmus für Overfitting bestraft.

⚠ Warum funktioniert diese naheliegende Straffunktion in der Praxis **NICHT**?

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{k=1}^m \beta_k^2$$

Weil sich **positive und negative Schätzer gegenseitig aufheben** — der Algorithmus kann die Strafe beliebig klein machen, ohne die Schätzer zu verkleinern.

48.2 ★★ Ridge vs. Lasso vs. Elastic Net

RIDGE-REGRESSION (quadrierte Schätzer $\Rightarrow$ euklidische Norm L2):

$$\min \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{k=1}^m \beta_k^2$$

LASSO-REGRESSION (Betrag der Schätzer $\Rightarrow$ „Taxifahrernorm“ L1):

$$\min \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{k=1}^m |\beta_k|$$

ELASTIC-NET-REGRESSION (Kombination):

$$\min \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda_1 \sum_{k=1}^m \beta_k^2 + \lambda_2 \sum_{k=1}^m |\beta_k|$$

★★ Die entscheidende Konsequenz

Der vermeintlich kleine mathematische Unterschied hat eine wesentliche Konsequenz:

- **RIDGE:** unabhängige Variablen werden **selten komplett aus dem Modell entfernt**. Bei Schätzern kleiner 1 verkleinert die Quadrierung die Strafe.
- **LASSO:** dieser Effekt fehlt, und außerdem ist die Betragsfunktion bei 0 nicht differenzierbar. ★ Hier werden unabhängige Variablen ggf. auch AUSSORTIERT.

	Ridge eignet sich, wenn ...	Lasso eignet sich, wenn ...
Ziel	wir alle unabhängigen Variablen berücksichtigt haben möchten, aber Overfitting verhindern oder Multikollinearität behandeln wollen	wir herausfinden wollen, welche unabhängigen Variablen wirklich relevant sind

48.3 ★ Woher kommt λ ?

Wir können es fest vorgeben oder die Wahl dem Algorithmus überlassen. Damit dies nicht zu weiterem Overfitting führt, wird das optimale Lambda mit **k-fold-Crossvalidation** bestimmt.

48.4 ⚠️★★ Der Bias-Variance-Tradeoff

Alle diese drei Varianten haben einen Nachteil: DIE SCHÄTZER SIND NICHT MEHR ERWARTUNGSTREU! ★ Wir nehmen einen höheren BIAS in Kauf, um Overfitting und damit hohe VARIANZ und Instabilität zu senken. Diesen Bias-Variance-Tradeoff gibt es nicht nur in der Regressionsanalyse — ihr kennt ihn aus dem Machine Learning!

TEIL 14 — MAXIMUM-LIKELIHOOD-SCHÄTZUNG

49. ★★ Grundidee

Bei der ML-Schätzung kommen wir zurück zum Grundproblem der statistischen Tests: Wir kennen Eigenschaften unserer Stichprobe, aber nicht die der Grundgesamtheit. ★ Bei der ML-Schätzung wollen wir von der Stichprobe auf die VERTEILUNG der Grundgesamtheit schließen.

Annahme (i.i.d.): Die Stichprobe $x_1, \dots, x_n$ wurde aus der **gleichen Verteilung** gezogen und weist **keine Autokorrelation** auf, d.h. x_i und x_j sind **stochastisch unabhängig für alle $i \neq j$** .

Die Verteilung der Grundgesamtheit GEBEN WIR VOR. Wir nehmen an, dass sie einer bestimmten Verteilung mit den **Parametern $\theta_1, \dots, \theta_n$** folgt. Jetzt suchen wir nach Werten für diese Parameter, **für die die Wahrscheinlichkeit, unsere Stichprobe zu erhalten, MAXIMAL wird:**

$$\max p(x_1, \dots, x_n \mid \theta_1, \dots, \theta_n)$$

50. ★★ Likelihood und Log-Likelihood

Da die Beobachtungen i.i.d. angenommen werden, gilt:

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i)$$

⚠ Die Wahrscheinlichkeit, einen bestimmten Wert EXAKT zu treffen, ist bei kontinuierlichen Verteilungen unendlich klein! (Denn $P(a \leq X \leq b) = \int_a^b \varphi(x) dx$.) Für die Bewertung wird daher die LIKELIHOOD-FUNKTION L eingeführt:

$$L(\theta) = \prod_{i=1}^n \varphi_{\theta}(x_i)$$

Die LOG-LIKELIHOOD-Funktion ist der Logarithmus dieser Funktion. Aus dem Produkt wird eine Summe:

$$\ell(\theta) = \sum_{i=1}^n \ln \varphi_{\theta}(x_i)$$

💡 **Erinnerung:** $\ln(a \cdot b) = \ln(a) + \ln(b) \Rightarrow \ln(\prod x_i) = \sum \ln(x_i)$

51. ★★ Optimierung

Die ML-Schätzer für die Parameter θ erhalten wir durch MINIMIEREN DER NEGATIVEN Log-Likelihoodfunktion:

$$\min -\ell(\theta)$$

Warum das Minuszeichen? ★ Durch das Minus wird die Log-Likelihoodfunktion zu einer LOSS-FUNKTION, ähnlich wie der (M)SE bei der OLS-Regression.

Vorgehen aus der mehrdimensionalen Analysis:

- **Notwendig:** Alle partiellen Ableitungen 0 setzen.
- **Hinreichend:** Hessematrix auf Definitheit untersuchen.

52. ✎★★★ Vollständige Herleitung: ML-Schätzer der Normalverteilung

Schritt 1 — Likelihood-Funktion:

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{1}{2}((x_i - \mu)/\sigma)^2}$$

Schritt 2 — Log-Likelihood:

$$\begin{aligned} \ell(\mu, \sigma^2) &= \sum_{i=1}^n \ln \left[\frac{1}{\sqrt{2\pi\sigma^2}} \right] + \sum_{i=1}^n \ln e^{-\frac{1}{2}((x_i - \mu)/\sigma)^2} \\ &= n \cdot \ln(1) - n \cdot \ln\sqrt{2\pi\sigma^2} - \sum_{i=1}^n \frac{1}{2}((x_i - \mu)/\sigma)^2 \quad (\ln(1) = 0) \\ &= -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2} \end{aligned}$$

Schritt 3 — Partielle Ableitung nach μ :

$$\frac{\partial \ell}{\partial \mu} = \sum_{i=1}^n \frac{x_i - \mu}{\sigma^2} = 0 \quad \Leftrightarrow \quad \sum_{i=1}^n x_i = \sum_{i=1}^n \mu = n\mu \quad \Rightarrow \quad \hat{\mu} = 1/n \sum_{i=1}^n x_i$$

★ Der ML-Schätzer für μ ist das ARITHMETISCHE MITTEL.

Schritt 4 — Partielle Ableitung nach σ^2 :

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^4} = 0 \quad \Leftrightarrow \quad 1/\sigma^2 \cdot \sum_{i=1}^n (x_i - \mu)^2 = n \quad \Rightarrow \quad \sigma^2 = 1/n \sum_{i=1}^n (x_i - \mu)^2$$

★ Der ML-Schätzer für σ^2 ist die (nicht bias-korrigierte) empirische Varianz mit Divisor n .

53. ★★ ML-Ergebnisse interpretieren

R-Beispiel (Binomialverteilung fitten):

```
library(fitdistrplus)
k <- c(1,2,1,0,4,1,3,2,2,5,2,1,2,3,2,2,1,2,4,4,2)
summary(fitdist(k,"binom",fix.arg=list(size=5)))

# Fitting of the distribution 'binom' by maximum likelihood
# Parameters:      prob = 0.4381 (std. err. = 0.0484)
# Fixed parameters: size = 5
# Loglikelihood: -33.76968  AIC: 69.53937  BIC: 70.58389
```



Kennzahl	Bedeutung
Standardfehler	Gibt an, wie sicher wir uns gegeben der Daten mit unserem Schätzer sein können. Je größer der Standardfehler, umso mehr ist der Schätzer mit Unsicherheit behaftet.
Loglikelihood	Der Wert, den $\ell(\theta)$ am gefundenen Maximum annimmt. ★ Je näher dieser Wert an der 0 ist, umso besser ist das Modell. ⚠ Es gibt allerdings KEINEN Maßstab i.S.v. „alles über -100 ist gut“. Der Wert eignet sich eher zum MODELLVERGLEICH als zur direkten Begutachtung eines einzelnen Modells.
AIC (Akaike Information Criterion)	Berücksichtigt die Parameterzahl k : $AIC = -2\ell + 2k$
BIC (Bayesian Information Criterion)	Berücksichtigt auch die Stichprobengröße n : $BIC = -2\ell + k \cdot \ln(n)$

TEIL 15 — DIE ÜBUNGSKLAUSUR MIT VOLLSTÄNDIGER MUSTERLÖSUNG

Aufgabe 1 — Zufallsvariablen, Verteilungen & Z-Test (13 Punkte)

Sie spielen Plinko in einem Onlinecasino. Pro Spiel werden 12.50 € eingesetzt. Die Zufallsvariable X_i steht für die Auszahlung im i -ten Spiel.

p	Auszahlung
3/8	5 €
3/8	10 €
1/8	15 €
1/8	20 €

a) Verteilungs- und Wahrscheinlichkeitsfunktion skizzieren (2 + 2 Punkte)Wahrscheinlichkeitsfunktion $f(x)$ Verteilungsfunktion $F(x)$ 

Sprunghöhen: $3/8$ bei 5 · $3/8$ bei 10 · $1/8$ bei 15 · $1/8$ bei 20 → Treppe 0.375 / 0.75 / 0.875 / 1.00

b) Erwartungswert und Varianz (2 + 2 Punkte)

$$E(X_i) = 5 \cdot (3/8) + 10 \cdot (3/8) + 15 \cdot (1/8) + 20 \cdot (1/8) = 10$$

$$\text{Var}(X_i) = (-5)^2 \cdot (3/8) + (0)^2 \cdot (3/8) + (5)^2 \cdot (1/8) + (10)^2 \cdot (1/8) = 25$$

⚠ Wichtig: Einsatz 12.50 €, Erwartungswert der Auszahlung nur 10 € ⇒ **erwarteter Verlust 2.50 € pro Spiel.**

c) Zufallsvariable für die Gesamtauszahlung von 80 Spielen (2 Punkte)

$$X = \sum_{i=1}^{80} X_i \sim N(n \cdot E(X_i), n \cdot \text{Var}(X_i)) = N(800, 2000)$$

Alternativ mit der Dichtefunktion: $\varphi(x) = 1/\sqrt{2\pi\sigma^2} \cdot e^{(-\frac{1}{2}((x-\mu)/\sigma)^2)}$ mit $\mu = 800$ und $\sigma = \sqrt{2000}$

d) Einseitiger Z-Test bei einer Gesamtauszahlung von 600 € (1 + 2 Punkte)

Hinweis aus der Musterlösung: Es gibt mehrere Möglichkeiten, das Hypothesenpaar zu formulieren. Ein korrektes Paar gibt 1 Punkt.

Variante 1 (pro Spiel): H_0 : Die durchschnittliche Auszahlung beträgt **10** pro Spiel. H_1 : Die durchschnittliche Auszahlung beträgt **weniger als 10** pro Spiel.

Variante 2 (gesamt): H_0 : Die durchschnittliche Auszahlung bei 80 Spielen beträgt **800**. H_1 : Die durchschnittliche Auszahlung bei 80 Spielen liegt **unter 800**.

Auch bei der Berechnung des z-Wertes gibt es zwei legitime Vorgehensweisen (2 Punkte):

$$\text{Über Gesamtauszahlung: } z = \frac{\bar{x} - \mu}{\sigma} = \frac{600 - 800}{\sqrt{2000}} = -4.472$$

$$\text{Über Durchschnitt: } z = \frac{\bar{x} - \mu}{\sigma} = \frac{7.5 - 10}{\sqrt{(25/80)}} = -4.472$$

Ergebnis: -4.472 Standardabweichungen ⇒ weit unter der 5 %-Schwelle ⇒ Wir sollten an der Auszahlungstabelle zweifeln!

Aufgabe 2 — Statistische Modellierung mit Verteilungen (7 Punkte)

Immer wieder kursieren Gerüchte, die Kaffeemaschine in der Mensa sei unzuverlässig und gebe die falsche Kaffee-Art aus. Ein Data-Science-Kurs beobachtet die Kaffeemaschine für 5 Stunden und stellt fest, dass von 425 Kaffeetrinkern 17 einen falschen Kaffee bekamen.

a) Binomialverteilung parametrieren (1 Punkt)

$$p = 17/425 = 0.04$$

$$f(k) = \binom{n}{k} 0.04^k \cdot 0.96^{n-k}$$



Hinweis der Musterlösung: Erfolgs- und Misserfolgswahrscheinlichkeit könnten je nach Interpretation vertauscht werden.

b) Mindestens zwei von 30 Studierenden bekommen falschen Kaffee (1.5 + 1.5 Punkte)

$$p(k \geq 2) = \sum_{k=2}^{30} f(k) = 1 - \sum_{k=0}^1 f(k) = 1 - f(0) - f(1)$$

R:

```
1 - pbinom(1, 30, 0.04)
```

Python:

```
1 - stats.binom.cdf(k=1, n=30, p=0.04)
```

c) Kaffee-Hotline (Poisson + Exponential) (3 Punkte)

$$\lambda = 17/5 = 3.4 \text{ Anrufe pro Stunde}$$

[1 Punkt]

Maximal ein Anruf pro Stunde:

$$p = f(0) + f(1) = \frac{e^{(-3.4)} \cdot 3.4^0}{0!} + \frac{e^{(-3.4)} \cdot 3.4^1}{1!} = 0.1468 = 14.68 \%$$

[1 Punkt]

Erwartungswert Pausenlänge (Exponentialverteilung):

$$E(X) = 1/\lambda = 1/3.4 = 0.294 \text{ Stunden } (\approx 17.6 \text{ Minuten})$$

[1 Punkt]

Aufgabe 3 — Statistische Tests (12 Punkte)

Ein Data-Science-Professor erhebt einen Datensatz mit demografischen Angaben, **Nutzungszeiten von Social-Media-Plattformen** (per App erfasst) und einer **Lebenszufriedenheit auf einer Likert-Skala von 1-7**.

```
8  t.test(data$instagram, data$tiktok)
   # t = 1.35252, df = 39.4824, p-value = 0.1847
   # 95 percent confidence interval: -8.33065 25.33065

9  count <- as.matrix(table(data$gender, data$course))
10 chisq.test(count)
   # p-value = 0.0353

12 ks.test(data$happiness, "pnorm")
   # D = 0.97725, p-value = 0.00021
```

a) Welche Tests, welche Hypothesenpaare, was sagt der p-Wert? (6 Punkte)

Zeile 8 — zweiseitiger ZWEISTICHPROBEN-t-TEST (0.5 P)

H₀ Es gibt **keinen** Unterschied in der durchschnittlichen Nutzungszeit von Insta und TikTok. **H₁** Es gibt **einen** Unterschied in der durchschnittlichen Nutzungszeit von Insta und TikTok. (1 P) „Unter Gültigkeit der Nullhypothese beobachten wir mit Wahrscheinlichkeit **18.47 %** einen mindestens so starken Unterschied in den Mittelwerten der beiden Stichproben.“ (0.5 P)

Zeile 10 — CHI-QUADRAT-UNABHÄNGIGKEITSTEST (0.5 P)

H₀ Die beiden Merkmale „gender“ und „course“ sind **unabhängig**. **H₁** Die beiden Merkmale „gender“ und „course“ sind **abhängig**. (1 P) „Unter Gültigkeit der Nullhypothese beobachten wir mit Wahrscheinlichkeit **3.53 %** eine mindestens so starke Abhängigkeit zwischen den beiden Merkmalen wie in der Stichprobe.“ (0.5 P)

Zeile 12 — KOLMOGOROW-SMIRNOW-TEST (0.5 P)

H₀ Das Merkmal „happiness“ ist **normalverteilt**. **H₁** Das Merkmal „happiness“ ist **nicht normalverteilt**. (1 P) „Unter Gültigkeit der Nullhypothese beobachten wir mit Wahrscheinlichkeit **0.021 %** eine mindestens so starke Abweichung zur Normalverteilung.“ (0.5 P)

b) Zwei Gründe, warum der t-Test in Zeile 8 fragwürdig ist (2 Punkte)

★ 1. Die Daten des Merkmals „happiness“ haben **KEIN METRISCHES SKALENNIVEAU** (Likert-Skala = ordinal). ★ 2. Der Mittelwert ist gemäß dem Ergebnis des Kolmogorow-Smirnow-Tests auch **NICHT NORMALVERTEILT**. (Alternativer Test: **Wilcoxon-Rangsummen-Test** / Mann-Whitney-U-Test)

c) Drei statt zwei Plattformen vergleichen (2 Punkte)

Mit einer ANOVA (0.5 P). Um herauszufinden, zwischen welchen Paarungen signifikante Unterschiede vorliegen, benötigen wir POST-HOC-TESTS (0.5 P). H_0 Es gibt **keinen** Unterschied in der durchschnittlichen Nutzungszeit der Plattformen. H_1 Es gibt **mindestens eine Paarung** an Plattformen, zwischen denen es einen Unterschied in den durchschnittlichen Nutzungszeiten gibt. (1 P)

d) Mehr als zwei Geschlechter und Studiengänge? (2 Punkte)

★ **NEIN.** Der Chi-Quadrat-Unabhängigkeitstest setzt NICHT voraus, dass die Merkmale nur zwei mögliche Ausprägungen haben. Dasselbe gilt für die Implementierung des Tests in R oder Python.

Aufgabe 4 — Regressionsanalyse (13 Punkte)

Ein Studiengangsleiter möchte herausfinden, wie sich die Leistungen im Studium auf das spätere Gehalt auswirken. Sein Datensatz enthält neben dem Gehalt und soziodemografischen Merkmalen insbesondere **die Punktzahl in JEDER Prüfungsleistung** des Studiengangs.

	coef	std err	t	P> t	
(Intercept)	50000.0	4500.0	11.11	< 0.001	
gender_female	-2200.0	4400.0	-0.50	0.618	
state_abroad	5000.0	7500.0	0.67	0.504	
industry_aerospace	5000.0	2500.0	2.00	0.048	*
industry_engineering	-2000.0	2000.0	-1.00	0.308	
industry_consulting	5000.0	5000.0	1.00	0.308	
math_1	-5.0	3.0	-1.67	0.092	.
math_2	5.0	1.5	3.33	0.006	**
statistics	10.0	4.0	2.50	0.024	*
logic	-0.1	-5.0	0.02	0.937	
Adjusted R-squared: 0.315					

a) Interpretation von „statistics“, „state_abroad“ und Adj. R² (6 Punkte)

statistics (2 P): „Das Modell assoziiert einen zusätzlichen Punkt in der Statistiklausur mit 10 € mehr Gehalt. Dieser Zusammenhang ist statistisch signifikant. Die Wahrscheinlichkeit, dass er nur scheinbar durch zufällige Schwankungen in der Stichprobe auftaucht, ist klein.“

state_abroad (2 P): „Das Modell assoziiert das Arbeiten im Ausland mit 5000 € mehr Gehalt. Dieser Zusammenhang ist NICHT statistisch signifikant und könnte sehr wohl zufällig in der Stichprobe auftauchen.“

Adjusted R² (2 P): „Das Modell kann innerhalb der Stichprobe 31.5 % der Varianz im Gehalt erklären. Die übrigen 68.5 % sind der Störterm, d.h. durch andere Einflüsse bedingt.“

b) Problem der vielen Prüfungsleistungen (2 Punkte)

★ „Das Problem ist die **MULTIKOLLINEARITÄT**, d.h. die hohe Korrelation zwischen den vielen Prüfungsleistungen. Die Konsequenz sind **HÖHERE SCHÄTZFEHLER** und damit ggf. Schätzer mit **WIDERSINNIGER** Interpretation. In dem Beispiel gibt es Vorlesungen, bei denen **SCHLECHTERE** Leistungen mit **HÖHEREM** Gehalt assoziiert sind.“ ($math_1 = -5.0$, $logic = -0.1$)

c) Warum ist „nur die BA-Note als Variable“ keine gute Idee? (2 Punkte)

★ „Bei nur einer unabhängigen Variable gibt es logischerweise keine Korrelationen. Der Erklärungsgehalt des Modells wird aber drastisch schlechter werden. Insbesondere werden auch **SINNvolle KONTROLLVARIABLEN** (unterschiedliche Gehaltsniveaus in unterschiedlichen Ländern und Branchen, Gender-Pay-Gap) entfernt. Deren Einfluss wird im besten Fall **ÜBERSEHEN** und im schlimmsten Fall mit dem Einfluss der Bachelorarbeitsnote **KONFUNDIERT**.“

d) Vorschlag Lasso-Regression (3 Punkte)

★ „Die Lasso-Regression bewertet das Modell nicht nur nach dem MSE, sondern berücksichtigt auch die Werte der Schätzer. Bei der Lasso-Regression ist dieser Strafterm so gestaltet, dass weniger aussagekräftige unabhängige Variablen einen Schätzer von 0 erhalten und somit **AUSSORTIERT** werden. Das löst die Multikollinearität und die höheren Schätzfehler, **BRINGT JEDOCH GLEICHZEITIG EINEN BIAS INS SPIEL**.“

Aufgabe 5 — Gemischtes (5 Punkte, Richtig/Falsch)

Jede richtige Antwort bringt einen Punkt. Falsche oder ungültige Antworten geben keine Punkte, führen aber nicht zu einem Punktabzug.

#	Aussage	Antwort	Begründung
1	Verteilungsfunktionen sind monoton wachsend in $\mathbb{R}$.	✓ RICHTIG	Eigenschaft der Verteilungsfunktion: $F(x)$ ist monoton steigend, $\lim F = 0$ bzw. 1
2	Das Integral von minus bis plus unendlich über eine Verteilungsfunktion muss genau 1 ergeben.	✗ FALSCH	⚠ Das gilt für die DICHTEFUNKTION , nicht für die Verteilungsfunktion. Die Verteilungsfunktion konvergiert gegen 1.
3	Der t-Test ist parametrisch .	✓ RICHTIG	t-Tests und ANOVA sind parametrische Tests (Normalverteilungsannahme)
4	Endogenitätsprobleme verursachen keinen Bias, aber mehr Varianz.	✗ FALSCH	⚠ Genau umgekehrt: Endogenität verursacht BIAS. Höhere Varianz kommt von Multikollinearität .
5	In der Grenzwertbetrachtung $\lambda \rightarrow \infty$ konvergiert die Poissonverteilung gegen die Binomialverteilung .	✗ FALSCH	⚠ Umgekehrt: Die BINOMIAL verteilung konvergiert für $n \rightarrow \infty$ (mit $p = \lambda/n$) gegen die POISSON verteilung.

TEIL 16 — CODE UND DATENSÄTZE

(Übungsaufgaben mit Lösungen)

Ordnerstruktur Code und Datensätze.zip

Ordner	Inhalt
Verteilungen	Darts (+SOL), PA-Hotline (+SOL, PA-Hotline.xlsx), Verteilungen.Rmd/.ipynb
Z-Test	Z-Test (+SOL), Würfel.xlsx
T-Test	Notentabelle (+.xlsx), BierQualität (+.xlsx)
ANOVA	KI-Accuracy (+.xlsx)
Normalität	—
Chi-Quadrat-Test	—
Regression-OLS	Strommarkt (+.xlsx), Lernen (+.xlsx)
Regression-Herausforderungen	Multikolarität.R, LassoRidge.Rmd, Medienumfrage.xlsx
Mensa Aufgaben	Datensatz für alle drei Mensa-Übungen

⭐ Übung „Darts“ (Binomialverteilung)

Ein Dartprofi trainiert die T20. Er wirft nacheinander 3 Pfeile und dokumentiert, wie viele davon die T20 treffen. Nutzen Sie die Binomialverteilung, um folgende Wahrscheinlichkeiten zu berechnen:

a) Ein Treffer der T20 bei einem einzelnen Wurf b) In einer Aufnahme mindestens zwei Mal T20 zu treffen c) Ein „180“, bei dem alle drei Pfeile T20 treffen d) Eine Serie von 9 perfekten Darts

✓ Musterlösung (R):

```
hits <- c(1,2,1,1,2,3,0,3,2,0,3,2,1,2,3,3,2,1,0,3,2,1,1,2)

library(fitdistrplus)
fit <- fitdist(hits, "binom", fix.arg = list(size=3))
summary(fit)
p <- fit$estimate

p                # a) 56.9 % einzelne Trefferwahrscheinlichkeit
1 - pbinom(1, 3, p) # b) 60.3 % Chance mindestens zwei T20 zu treffen
dbinom(3, 3, p)   # c) 18.5 % Chance auf einen 180er
dbinom(9, 9, p)   # d) 0.63 % Chance auf 9 perfekte Darts
```

⭐ **Kernidee:** Die Trefferwahrscheinlichkeit p wird per **MAXIMUM-LIKELIHOOD** aus der Stichprobe geschätzt (`fitdist`), dann in die Binomialverteilung eingesetzt.

Übung „PA-Hotline“ (Poisson + Exponential + Gleichverteilung)

Ein Lehrzentrum möchte eine Hotline für Probleme bei Projektarbeiten einrichten. Der wissenschaftliche Leiter ist naiv und denkt sich, dass ohnehin kaum jemand anrufen wird. Bei einem Probelauf bekommt er dann aber jede Menge Anrufe.

Wie hoch ist die Wahrscheinlichkeit, dass ... a) ... in einer Stunde **kein einziger** Anruf kommt? b) ... in einer Stunde **mindestens 5** Anrufe kommen? c) ... zwischen zwei eingehenden Anrufen **max. 5 Minuten** liegen? d) ... zwischen zwei eingehenden Anrufen **mind. 30 Minuten** liegen? **Zusätzlich:** Erwartungswert der Pausenlänge zwischen zwei Gesprächen, sowie die **Wahrscheinlichkeit, während eines laufenden Gesprächs das KLOPFZEICHEN zu erhalten** (Annahme: Gesprächslänge ist gleichverteilt).

Musterlösung (R):

```
library(lubridate); library(dplyr); library(readxl); library(fitdistrplus)

data <- read_excel("PA-Hotline.xlsx", col_types = c("text", "numeric"))
data$Time <- as.POSIXlt(data$Time, format = "%Y-%m-%d %H:%M")
data$Hour <- hour(data$Time)
calls <- data %>% group_by(Hour) %>% summarise(calls = length(Hour))

# --- Anrufanzahl: Poisson ---
fit <- fitdist(calls$calls, "pois")
lambda <- fit$estimate # λ = 2.5 Anrufe/Stunde

dpois(0, lambda) # a) Wahrscheinlichkeit kein einziger Anruf
1 - ppois(4, lambda) # b) Wahrscheinlichkeit mindestens 5 Anrufe

# --- Pausen: Exponentialverteilung ---
pexp(5/60, rate = lambda) # c) Wahrscheinlichkeit maximal 5 Minuten Abstand
1 - pexp(30/60, rate = lambda) # d) Wahrscheinlichkeit mind. 30 Minuten Abstand

# --- Anruflänge: Gleichverteilung ---
fit_len <- fitdist(data$Length, "unif")
min <- fit_len$estimate[1]; max <- fit_len$estimate[2]
```

Erwartete Pausenlänge (Folienlösung):

Da der Erwartungswert linear ist, gilt für die erwartete Länge der Pause:

$$60/2.5 - 15 = 9 \text{ Minuten}$$

($60/\lambda$ = mittlerer Abstand zwischen Anrufbeginnen; minus 15 Minuten mittlere Gesprächslänge)

Klopfzeichen-Aufgabe (Gesetz der totalen Wahrscheinlichkeit):

$$\begin{aligned}
 p(X < Y) &= \int_{-\infty}^{\infty} p(X < y) \cdot \varphi(y) \, dy = \int_{-\infty}^{\infty} F(y) \cdot \varphi(y) \, dy \\
 \text{Gesprächslänge } Y \text{ gleichverteilt: } \varphi(y) &= \begin{cases} 3 & \text{für } y \in [1/12, 5/12] \\ 0 & \text{sonst} \end{cases} \\
 &= \int_{1/12}^{5/12} (1 - e^{-2.5y}) \cdot 3 \, dy \\
 &= 3 \cdot \left[y \right]_{1/12}^{5/12} + 3 \cdot \left[0.4 e^{-2.5y} \right]_{1/12}^{5/12} = 44.9 \%
 \end{aligned}$$

★ **Interpretation: Mit 44.9 % Wahrscheinlichkeit kommt während eines laufenden Gesprächs ein weiterer Anruf herein.**

Übung „Mensa-Datensatz“ (drei Teilaufgaben)

Datensatz-Spalten: `gender`, `status`, `preference` (none/vegetarian/vegan), `allergy` (yes/no), `food_tasty`, `food_healthy`, `food_cheap`, `food_spicy`, `food_saturation`, `food_looks`, `food_variety`, `food_score`

Übung 1 (t-Test):

1. **Gibt es Geschlechterunterschiede bei der Bewertung des Ambiente?** → *Zweistichproben-t-Test, ungepaart*
2. **Bewerten Allergiker das Essen im Schnitt gleich gut wie Nicht-Allergiker?** → *Zweistichproben-t-Test, ungepaart*
3. **Werden Ambiente und Essen im Schnitt unterschiedlich gut bewertet?** → *Zweistichproben-t-Test, GEPAART (dieselbe Person bewertet beides!)*

Übung 2 (Chi-Quadrat):

- **Unterschiede in den Essenspräferenzen nach Geschlecht** → Kontingenztafel + **Chi-Quadrat-Unabhängigkeitstest**
- **Entspricht die Verteilung der Essenspräferenzen dem Bundesdurchschnitt von 10 % vegetarisch und 2.5 % vegan?** → **Chi-Quadrat-ANPASSUNGSTEST**

Übung 3 (OLS-Regression):

- **Abhängige Variable:** `food_score`
- **Unabhängige Variablen:** Geschlecht, Status, Essenspräferenz, Allergikerstatus, Bewertung von Ambiente und Service



SELBSTTEST — Fragen zum Abfragen

▼ Teil 1–3: Zufallsvariablen, Momente, Verteilungen

1. **Definiere „Zufallsvariable“.** Was ist der Definitionsbereich, was der Wertebereich?
2. Warum braucht man bei der Münze eine Abbildungsvorschrift, beim Würfel nicht?
3. Ordne zu: Würfel · Münze · Roulette · Zufallsgenerator (0,1) — diskret oder kontinuierlich?
4. **Nenne die drei Kolmogorov-Axiome.**
5. **Fülle die 2×2-Tabelle:** diskret/kontinuierlich × „Wkt. $ZV \leq x$ “ / „Wkt. $ZV = x$ “.
6. **Nenne die drei Eigenschaften der Verteilungsfunktion.**
7. Wie sieht $F(x)$ beim Würfel aus? Was ist die Abrundungsfunktion?
8. **Was gibt die Dichtefunktion an — und was gibt sie ausdrücklich NICHT an?**
9. **Nenne beide Richtungen des Zusammenhangs $F(x) \leftrightarrow \phi(x)$.**
10. Warum ist die Höhe der Dichtefunktion bei einer Gleichverteilung über $[0,2]$ genau 0.5?
11. **Erwartungswertformeln für diskret und kontinuierlich.**
12. Berechne den Erwartungswert des Würfels und des Zufallsgenerators $[0,1]$.
13. **Wie lautet die Linearitätsregel des Erwartungswerts? Rechne $E(3X+Y)$ für D6 und D20.**
14. **Varianzformeln für diskret und kontinuierlich. Wie kommt man auf die Standardabweichung?**
15. Berechne $\text{Var}(X)$ für den Würfel (2.91) und für den Zufallsgenerator $[0,1]$ (0.08333).
16. **Wann ist die Varianz linear additiv? Wie lautet die allgemeine Formel mit Kovarianz?**
17. **Glücksrad ($4 \times 0\text{€}$, $3 \times 1\text{€}$, $2 \times 2\text{€}$, $1 \times 5\text{€}$): $E(X)$, $\text{Var}(X)$, σ .**
18. **Roulette (10 € auf Schwarz, 47.36 %/52.64 %): $E(X)$, $\text{Var}(X)$, σ .**
19. **Nenne die 4 Momente und ihre zentralen Gegenstücke.**
20. **Schiefe-Formel. Was bedeuten $\gamma = 0$, $\gamma > 0$, $\gamma < 0$?**
21. **Exzess-Formel. Wozu dient die „-3“? Was bedeuten $\gamma > 0$ und $\gamma < 0$?**
22. **Erstelle die Übersichtstabelle: 5 Verteilungen mit Funktion, μ und σ^2 .**
23. **Gleichverteilung: μ und σ^2 herleiten.**
24. **Was beschreibt die Binomialverteilung? Formel, μ , σ^2 .**
25. **Fakultät und Binomialkoeffizient definieren. $C(5,3)$ berechnen.**
26. **Elfmeter: 4 Treffer aus 5 bei $p = 0.75$. Rechne komplett. Woher kommt der Faktor 5?**
27. Skizziere die Herleitung von $\mu = np$.
28. **Was beschreibt die Poisson-Verteilung? Formel, μ , σ^2 . Wie lautet die rekursive Eigenschaft?**
29. **Erkläre den Zusammenhang Binomial $\rightarrow$ Poisson. Wie lautet die Grenzwertbetrachtung?**
30. **Was beschreibt die Exponentialverteilung? Dichte, Verteilungsfunktion, μ , σ^2 .**
31. **Was bedeutet Gedächtnislosigkeit? Formel + zwei Beispielsätze + Beweis.**
32. **Dichtefunktion der Normalverteilung. Warum heißt sie „normal“?**

▼ **Teil 4-5: Zentraler Grenzwertsatz und Z-Test**

33. **Zwei Würfel: Sind Summe und Verteilung noch gleichverteilt? Erkläre.**
34. **Formuliere den ZGS. Nenne die Voraussetzungen an $X_1 \dots X_n$.**
35. **Nenne die zwei ZGS-Formeln (Summe und Mittelwert) mit μ und σ^2 .**
36. **Wie lautet die Faustregel für „großes n"? Und die Ausnahme?**
37. **Nenne die Sigma-Regeln ($1\sigma/2\sigma/3\sigma$) und die vier umgekehrten Werte (90/95/99/99.9 %).**
38. **Was ist der Unterschied zwischen deskriptiver und induktiver Statistik?**
39. **Führe den Würfel-Z-Test ($n=40$, $\bar{x}=3.2$) in allen fünf Schritten durch.**
40. **Formuliere die Standard-Interpretation des p-Werts wörtlich.**
41. **Einseitig vs. zweiseitig: Wie ändern sich Hypothesen, z-Wert und p-Wert im Würfelbeispiel?**
42. **Prüfmaschine ($n=10.000$, Augensumme 33.290): Rechne z. Was folgt daraus über den Einfluss von n?**
43. **Roulette (218/500 rot): Rechne den kompletten Anteilstest durch, inkl. $\text{Var}(X)$ der Bernoulli-Variablen.**

▼ **Teil 6-8: Statistische Tests, t-Test, ANOVA**

44. **Warum kann man den Z-Test in der Praxis oft nicht anwenden?**
45. **Nenne die drei Hypothesenarten mit je einem Beispiel.**
46. **Nenne die sieben Kriterien für die Testauswahl.**
47. **Zeichne den Entscheidungsbaum ab „Die abhängige Variable y ist ...".**
48. **Welcher Test bei: kategoriale y, zwei Ausprägungen? Kategoriale y, viele Ausprägungen?**
49. **Welcher Test bei: numerische y, Mittelwerte über 3+ Gruppen vergleichen?**
50. **Welcher Test bei: y metrisch skaliert, paarweiser Zusammenhang? Und wenn nicht metrisch?**
51. **Ab welcher Stichprobengröße reichen Histogramm/Q-Q-Plot statt Shapiro-Wilk?**
52. **Welche Tests kommen bei erwarteten Häufigkeiten unter 5 zum Einsatz?**
53. **Wann Levene-Test, wann einfaktorielle/Welch-/zweifaktorielle ANOVA?**
54. **Was untersucht der Zweistichproben-t-Test? Generisches Hypothesenpaar.**
55. **Gepaart vs. ungepaart: Kriterium + je ein Kursbeispiel.**
56. **Interpretiere $p = 0.8091$ (Studiengänge) und $p = 0.000000002335$ (Vorlesungen) wörtlich.**
57. **Was ist ein Konfidenzintervall? Was passiert bei höherem Konfidenzniveau?**
58. **Formuliere den Zusammenhang p-Wert $\leftrightarrow$ Konfidenzintervall exakt.**
59. **Was prüft der Einstichproben-t-Test? Generisches Hypothesenpaar.**
60. **Brauerei-Beispiel: Zielwert, Ist-Wert, t-Wert, p-Wert, KI — und die Entscheidung.**
61. **t-Statistik-Formel. Wie berechnet sich $\sigma_{\bar{X}}$? Wie kommt man vom t-Wert zum p-Wert?**
62. **Warum t-Verteilung statt Normalverteilung?**
63. **Was sind Freiheitsgrade? Wie viele beim Ein-, wie beim Zweistichproben-t-Test?**
64. **Was kann der t-Test nicht, was die ANOVA kann? Generisches Hypothesenpaar der ANOVA.**
65. **KI-Beispiel: Accuracy-Formel, vier Werte, p-Wert, Entscheidung.**
66. **Warum brauchen wir Post-Hoc-Tests? Nenne drei. Welcher ist am häufigsten und was setzt er voraus?**

▼ Teil 9–11: Normalität, Chi-Quadrat, Fehler

67. Was sind parametrische Tests? Nenne die zwei Voraussetzungen des t-Tests.
68. Nenne die vier nicht-parametrischen Alternativen mit Anwendungsfall.
69. Ab welcher Stichprobengröße ist die Normalitätsannahme automatisch erfüllt — und warum?
70. Was ist das Problem am Histogramm als Normalitätsprüfung?
71. Erkläre den Q-Q-Plot. Wie berechnet man die Quantile der NV?
72. Nenne die drei Normalitätstests und was sie jeweils prüfen können.
73. ⚠ Wie lauten H_0 und H_1 bei Normalitätstests? Wann haben wir Normalverteilung — bei $p < 5\%$ oder $p > 5\%$?
74. Definiere Sensitivität und Spezifität.
75. Warum ist die Spezifität in der Simulation immer bei 95 %? Was passiert, wenn man die Schwelle erhöht?
76. Welcher Test hat bei $n=15$ die beste Sensitivität? Welcher bei $n=50$?
77. Welche drei Abweichungen von der Normalverteilung sind für den t-Test wirklich problematisch?
78. Was prüft der χ^2 -Unabhängigkeitstest? Generisches Hypothesenpaar.
79. Werbemail-Beispiel: Erstelle beobachtete UND erwartete Kontingenztafel. Wie kommt man auf die 64?
80. $p = 0.2174$ — interpretiere und entscheide.
81. Was prüft der χ^2 -Anpassungstest? Wie unterscheidet er sich vom Unabhängigkeitstest?
82. Studiengang-Umfrage (20/200, 25/300, 10/40): $p = 0.00808$ — interpretiere und entscheide.
83. Nenne die vier Fehlerarten statistischer Tests. Wo liest man die Wahrscheinlichkeit für den Fehler 1. Art ab?

▼ Teil 12-14: Regression, Herausforderungen, ML-Schätzung

84. **Erstelle die 2×2-Tabelle einfach/multipel × univariat/multivariat.**
85. Nenne vier nicht-lineare Regressionsformen. Wovon hängt die Modellwahl ab?
86. **Schreibe das OLS-Grundmodell mit allen Komponenten auf und interpretiere β_0 und β_1 wörtlich.**
87. **Was sind Residuen? Wie lautet die OLS-Zielfunktion?**
88. ⚠ **Warum sagt man „assoziiert“ statt „bewirkt“? Erkläre am Eisverkäufe-Beispiel.**
89. **Erkläre jede Zeile des R-Outputs: Estimate, Std. Error, t value, $\text{Pr}(> |t|)$, Signif. codes, Adj. R^2 , confint.**
90. **Wie lautet das Hypothesenpaar hinter JEDEM Regressionsschätzer?**
91. **Formuliere die p-Wert-Interpretation für einen Regressionskoeffizienten wörtlich.**
92. **Was sagt R^2 aus? Interpretiere 0.3398 im Lernstunden-Beispiel.**
93. **Worauf untersucht man die Residuen? Definiere Homoskedastizität.**
94. **Strommarkt Modell 1: Was ist das seltsame Ergebnis? Wie löst man es auf?**
95. **Strommarkt Modell 3: Welche Variable kommt hinzu, welche Logik steckt dahinter, wie ändert sich R^2 ?**
96. **Nenne drei Möglichkeiten und drei Baustellen der Regression.**
97. **Definiere Bias und zufälligen Schätzfehler. Welcher wird mit größerer Stichprobe kleiner?**
98. **Multikollinearität: Fallbeispiel, Symptom, Ursache. Ist der Schätzer erwartungstreu?**
99. **Nenne die drei Methoden zur Feststellung von Multikollinearität mit kritischen Werten.**
100. **VIF-Formel. Wie berechnet man den R^2 dafür? Konditionszahl-Formel.**
101. **Nenne die vier Behandlungsmöglichkeiten für Multikollinearität.**
102. **Endogenität: Fallbeispiel, Symptom, formale Definition (beide Schreibweisen).**
103. **Wodurch entstand das Problem im Bildung-Gehalt-Beispiel?**
104. **Nach welchen zwei Eigenschaften sucht man bei einer „problematischen Variable“?**
105. **Lösung 1: Was ist ein Omitted-Variable-Problem und wie löst man es?**
106. **Was sind die zwei Anforderungen an ein Instrument? Beschreibe beide Stufen der IV-Schätzung.**
107. ⭐ **Welchen zusätzlichen Vorteil bringt IV — und mit welcher Einschränkung?**
108. **Wie entsteht Overfitting durch den Algorithmus und wie durch den Data Scientist?**
109. **Warum funktioniert die naive Straffunktion $\lambda \sum \beta_k$ nicht?**
110. **Schreibe die Zielfunktionen von Ridge, Lasso und Elastic Net auf. Welche Norm ist jeweils gemeint?**
111. ⭐ **Warum sortiert Lasso Variablen aus und Ridge nicht? Wann verwendet man welche?**
112. **Woher kommt λ ? Was verhindert Overfitting bei der λ -Wahl?**
113. **Was ist der Nachteil aller drei Regularisierungen? Erkläre den Bias-Variance-Tradeoff.**
114. **Was ist die Grundidee der ML-Schätzung? Welche Annahme (i.i.d.) steckt dahinter?**
115. **Warum braucht man die Likelihood-Funktion statt der Wahrscheinlichkeit?**
116. **Likelihood und Log-Likelihood aufschreiben. Warum der Logarithmus?**
117. **Warum minimiert man die NEGATIVE Log-Likelihood?**
118. **Was ist notwendig, was hinreichend für das Optimum?**
119. **Leite die ML-Schätzer für μ und σ^2 der Normalverteilung her.**
120. **Interpretiere Standardfehler, Loglikelihood, AIC und BIC. Formeln für AIC und BIC.**

▼ **Teil 15-16: Übungsklausur und Code-Aufgaben**

121. **Plinko A1:** Skizziere $f(x)$ und $F(x)$. Berechne $E(X) = 10$ und $\text{Var}(X) = 25$.
122. **Plinko A1c:** Definiere die Zufallsvariable für 80 Spiele und gib ihre Verteilung an.
123. **Plinko A1d:** Formuliere beide zulässigen Hypothesenpaare und rechne z auf beiden Wegen (-4.472).
124. **Kaffeemaschine A2a:** Wie parametriert man die Binomialverteilung aus 17/425?
125. **Kaffeemaschine A2b:** Formel + R-Code + Python-Code für $p(k \geq 2)$ bei $n=30$.
126. **Kaffeemaschine A2c:** λ , $p(\text{max. 1 Anruf}) = 0.1468$ und $E(\text{Pausenlänge}) = 0.294 \text{ h}$ — rechne nach.
127. **A3a:** Nenne alle drei Tests, alle drei Hypothesenpaare und alle drei p -Wert-Interpretationen.
128. **A3b:** Nenne beide Gründe gegen den t -Test bei Likert-Daten.
129. **A3c:** Welcher Test für drei Plattformen? Warum Post-Hoc?
130. **A3d:** Braucht der Chi-Quadrat-Test genau zwei Ausprägungen? Begründe.
131. **A4a:** Interpretiere „statistics“ (10 €, $p=0.024$), „state_abroad“ (5000 €, $p=0.504$) und $\text{Adj. } R^2 = 0.315$.
132. **A4b:** Welches Problem, welche Konsequenz, wo sieht man es im Output?
133. **A4c:** Warum löst „nur BA-Note“ das Problem, ist aber trotzdem schlecht? (Stichwort: Konfundierung)
134. **A4d:** Wie löst Lasso das Problem und welchen Nachteil handelt man sich ein?
135. **A5:** Alle fünf Richtig/Falsch-Aussagen mit Begründung.
136. **Darts:** Wie schätzt man p ? Nenne alle vier R-Befehle und ihre Ergebnisse.
137. **PA-Hotline:** Welche Verteilung für Anruferanzahl, welche für Pausen, welche für Gesprächslänge?
138. **PA-Hotline:** Wie kommt man auf die erwartete Pausenlänge von 9 Minuten?
139. **PA-Hotline:** Erkläre die Klopzeichen-Rechnung (Gesetz der totalen Wahrscheinlichkeit, 44.9 %).
140. **Mensa:** Welcher t -Test-Typ für die drei Teilfragen? Warum ist Frage 3 gepaart?
141. **Mensa:** Welcher Chi-Quadrat-Test für „Präferenz nach Geschlecht“, welcher für „vs. Bundesdurchschnitt“?

➤ KLAUSUR-SPICKZETTEL (Formelübersicht)

VERTEILUNGEN

Verteilungsfkt.	$F(x) = P(X \leq x)$	monoton steigend, $\rightarrow 0 / \rightarrow 1$
Wahrscheinl.fkt.	$f(x) = P(X = x)$	$\sum f(x) = 1$
Dichtefkt.	$P(a \leq X \leq b) = \int_a^b \varphi(x) dx$	$\int_{-\infty}^{\infty} \varphi(x) dx = 1$
Zusammenhang	$F(x) = \int_{-\infty}^x \varphi(t) dt$	$\varphi(x) = F'(x)$

MOMENTE

$E(X) = \sum x \cdot f(x)$	bzw. $\int x \cdot \varphi(x) dx$	$E(aX+bY) = aE(X)+bE(Y)$
$Var(X) = \sum [x-E(X)]^2 f(x)$	bzw. $\int [x-E(X)]^2 \varphi(x) dx$	
$Var(aX+bY) = a^2 Var(X) + b^2 Var(Y) + 2ab \cdot Cov(X,Y)$		
Schiefe $\gamma = \mu_3/\sigma^3$	Exzess $\gamma = \mu_4/\sigma^4 - 3$	

VERTEILUNGEN

	$f(x) / \varphi(x)$	μ	σ^2
Gleichverteilung $[a,b]$	$1/(b-a)$	$(a+b)/2$	$(b-a)^2/12$
Binomial(n,p)	$C(n,k) p^k (1-p)^{n-k}$	np	$np(1-p)$
Poisson(λ)	$e^{(-\lambda)} \lambda^k / k!$	λ	λ
Exponential(λ)	$\lambda e^{(-\lambda x)} \quad F = 1 - e^{(-\lambda x)}$	$1/\lambda$	$1/\lambda^2$
Normal(μ, σ^2)	$1/\sqrt{2\pi\sigma^2} e^{(-\frac{1}{2}((x-\mu)/\sigma)^2)}$	μ	σ^2

ZGS $\sum x_i \sim N(n\mu, n\sigma^2) \quad \bar{x} \sim N(\mu, \sigma^2/n) \quad n \geq 30 \text{ (bzw. } 100)$

SIGMA $1\sigma \rightarrow 68.2\% \quad 2\sigma \rightarrow 95.4\% \quad 3\sigma \rightarrow 99.6\%$
 $90\% \rightarrow 1.64\sigma \quad 95\% \rightarrow 1.96\sigma \quad 99\% \rightarrow 2.32\sigma \quad 99.9\% \rightarrow 3.09\sigma$

TESTS

z-Wert	$z = (\bar{x} - \mu) / \sigma_{\bar{X}}$	$\sigma_{\bar{X}} = \sigma / \sqrt{n}$	(σ der GG bekannt)
t-Wert	$t = (\bar{x} - \mu_0) / \sigma_{\bar{X}}$	$df = n-1$	(σ geschätzt)
$p < 5\% \Rightarrow H_0 \text{ verwerfen} \quad \text{! Normalitätstests: } p > 5\% \Rightarrow \text{NV!}$			
KI enthält 0 nicht $\Leftrightarrow p < 5\%$			

REGRESSION

$y = \beta_0 + \beta_1 x_1 + \varepsilon$	$\min \sum (y_i - \hat{y}_i)^2$	
VIF = $1/(1-R^2)$	krit. 10	$\kappa = \max(\lambda) - \min(\lambda)$ krit. 30
Endogenität: $\text{cor}(x_i, \varepsilon) \neq 0 \Rightarrow \text{BIAS}$		
Ridge: $+ \lambda \sum \beta_k^2$ (L2)	Lasso: $+ \lambda \sum \beta_k $ (L1, sortiert aus)	

MAXIMUM LIKELIHOOD

$L(\theta) = \prod \varphi_{\theta}(x_i)$	$\ell(\theta) = \sum \ln \varphi_{\theta}(x_i)$	$\min -\ell(\theta)$
AIC = $-2\ell + 2k$	BIC = $-2\ell + k \cdot \ln(n)$	
ML-Schätzer NV: $\hat{\mu} = (1/n) \sum x_i \quad \hat{\sigma}^2 = (1/n) \sum (x_i - \hat{\mu})^2$		